

Джеймс Г.
Уиттон Д.
Хастис Т.
Тибширани Р.

Введение в статистическое обучение с примерами на языке R

Введение в статистическое обучение с примерами на языке R

Джеймс Г.

Уиттон Д.

Хастис Т.

Тибширани Р.

An Introduction to Statistical Learning with Applications in R

Gareth James

Daniela Witten

Trevor Hastie

Robert Tibshirani



Введение в статистическое обучение с примерами на языке R

Джеймс Г.

Уиттон Д.

Хасты Т.

Тибширани Р.



Москва, 2016

УДК 519.25/.6:004.434R

ББК 22.17с5

Д40

Джеймс Г., Уиттон Д., Хасты Т., Тибширани Р.

Д40 Введение в статистическое обучение с примерами на языке R. Пер. с англ. С. Э. Мастицкого – М.: ДМК Пресс, 2016. – 450 с.: ил.

ISBN 978-5-97060-293-5

Книга представляет собой доступно изложенное введение в статистическое обучение – незаменимый набор инструментов, позволяющих извлечь полезную информацию из больших и сложных наборов данных, которые начали возникать в последние 20 лет в таких областях, как биология, экономика, маркетинг, физика и др. В этой книге описаны одни из наиболее важных методов моделирования и прогнозирования, а также примеры их практического применения. Рассмотренные темы включают линейную регрессию, классификацию, создание повторных выборок, регуляризацию, деревья решений, машины опорных векторов, кластеризацию и др. Описание этих методов сопровождается многочисленными иллюстрациями и практическими примерами. Поскольку цель этого учебника заключается в продвижении методов статистического обучения среди практикующих академических исследователей и промышленных аналитиков, каждая глава включает примеры практической реализации соответствующих методов с помощью R – чрезвычайно популярной среды статистических вычислений с открытым кодом.

Издание рассчитано на неспециалистов, которые хотели бы применять современные методы статистического обучения для анализа своих данных. Предполагается, что читатели ранее прослушали лишь курс по линейной регрессии и не обладают знаниями матричной алгебры.

УДК 519.25/.6:004.434R

ББК 22.17с5

Translation from the English language edition:

An Introduction to Statistical Learning

by Gareth James, Daniela Witten, Trevor Hastie and Robert Tibshirani

Copyright © Springer Science+Business Media New York 2013

Springer New York is a part of Springer Science+Business Media.

All Rights Reserved.

This work is subject to copyright. All rights are reserved by the Publisher, whether the whole or part of the material is concerned, specifically the rights of translation, reprinting, reuse of illustrations, recitation, broadcasting, reproduction on microfilms or in any other physical way, and transmission or information storage and retrieval, electronic adaptation, computer software, or by similar or dissimilar methodology now known or hereafter developed. Exempted from this legal reservation are brief excerpts in connection with reviews or scholarly analysis or material supplied specifically for the purpose of being entered and executed on a computer system, for exclusive use by the purchaser of the work.

Все права защищены. Любая часть этой книги не может быть воспроизведена в какой бы то ни было форме и какими бы то ни было средствами без письменного разрешения владельцев авторских прав.

Материал, изложенный в данной книге, многократно проверен. Но поскольку вероятность технических ошибок все равно существует, издательство не может гарантировать абсолютную точность и правильность приводимых сведений. В связи с этим издательство не несет ответственности за возможные ошибки, связанные с использованием книги.

ISBN 978-1-4614-7137-0 (англ.)

ISBN 978-5-97060-293-5 (рус.)

Copyright © Springer Science+Business Media New York, 2013

© Издание, оформление, перевод, ДМК Пресс, 2016

Оглавление

От переводчика	10
Предисловие	11
1 Введение	13
2 Статистическое обучение	27
2.1 Что такое статистическое обучение?	27
2.1.1 Зачем оценивать f ?	29
2.1.2 Как мы оцениваем f ?	33
2.1.3 Компромисс между точностью предсказаний и интерпретируемостью модели	36
2.1.4 Обучение с учителем и без учителя	38
2.1.5 Различия между проблемами регрессии и классификации	40
2.2 Описание точности модели	41
2.2.1 Измерение качества модели	41
2.2.2 Компромисс между смещением и дисперсией	46
2.2.3 Задачи классификации	49
2.3 Лабораторная работа: введение в R	56
2.3.1 Основные команды	56
2.3.2 Графики	59
2.3.3 Индексирование данных	60
2.3.4 Загрузка данных	61
2.3.5 Дополнительные графические и количественные сводки	63
2.4 Упражнения	65
3 Линейная регрессия	71
3.1 Простая линейная регрессия	72
3.1.1 Оценивание коэффициентов	73
3.1.2 Точность оценок коэффициентов	75
3.1.3 Оценивание точности модели	80
3.2 Множественная линейная регрессия	83
3.2.1 Оценивание регрессионных коэффициентов	84
3.2.2 Некоторые важные вопросы	87
3.3 Другие аспекты регрессионной модели	95
3.3.1 Качественные предикторы	95
3.3.2 Потенциальные проблемы	105
3.4 Маркетинговый план	116

3.5	Сравнение линейной регрессии с методом K ближайших соседей	118
3.6	Лабораторная работа: линейная регрессия	123
3.6.1	Библиотеки	123
3.6.2	Простая линейная регрессия	124
3.6.3	Множественная линейная регрессия	127
3.6.4	Эффекты взаимодействия	129
3.6.5	Нелинейные преобразования предикторов	130
3.6.6	Качественные предикторы	132
3.6.7	Написание функций	134
3.7	Упражнения	135
4	Классификация	143
4.1	Общее представление о классификации	143
4.2	Почему не линейная регрессия?	144
4.3	Логистическая регрессия	146
4.3.1	Логистическая модель	147
4.3.2	Оценивание регрессионных коэффициентов	149
4.3.3	Предсказания	150
4.3.4	Множественная логистическая модель	151
4.3.5	Логистическая регрессия для зависимых переменных с числом классов > 2	154
4.4	Дискриминантный анализ	154
4.4.1	Использование теоремы Байеса для классификации	155
4.4.2	Линейный дискриминантный анализ для $p = 1$	155
4.4.3	Линейный дискриминантный анализ для $p > 1$	158
4.4.4	Квадратичный дискриминантный анализ	166
4.5	Сравнение методов классификации	168
4.6	Лабораторная работа: логистическая регрессия, LDA, QDA и KNN	172
4.6.1	Данные по цене акций	172
4.6.2	Логистическая регрессия	173
4.6.3	Линейный дискриминантный анализ	178
4.6.4	Квадратичный дискриминантный анализ	180
4.6.5	Метод K ближайших соседей	181
4.6.6	Применение к данным по жилым прицепам	182
4.7	Упражнения	186
5	Методы создания повторных выборок	192
5.1	Перекрестная проверка	193
5.1.1	Метод проверочной выборки	193
5.1.2	Перекрестная проверка по отдельным наблюдениям	196
5.1.3	k -кратная перекрестная проверка	198
5.1.4	Компромисс между смещением и дисперсией в контексте k -кратной перекрестной проверки	201
5.1.5	Перекрестная проверка при решении задач классификации	202
5.2	Бутстреп	205
5.3	Лабораторная работа: перекрестная проверка и бутстреп	209
5.3.1	Метод проверочной выборки	209

5.3.2	Перекрестная проверка по отдельным наблюдениям .	210
5.3.3	k -кратная перекрестная проверка	212
5.3.4	Бутстреп	212
5.4	Упражнения	215
6	Отбор и регуляризация линейных моделей	221
6.1	Отбор подмножества переменных	223
6.1.1	Отбор оптимального подмножества	223
6.1.2	Пошаговый отбор	225
6.1.3	Выбор оптимальной модели	228
6.2	Методы сжатия	234
6.2.1	Гребневая регрессия	234
6.2.2	Лассо	238
6.2.3	Выбор гиперпараметра	248
6.3	Методы снижения размерности	249
6.3.1	Регрессия на главные компоненты	251
6.3.2	Метод частных наименьших квадратов	257
6.4	Особенности работы с данными большой размерности	259
6.4.1	Данные большой размерности	259
6.4.2	Что не так с большими размерностями?	260
6.4.3	Регрессия для данных большой размерности	262
6.4.4	Интерпретация результатов в задачах большой размерности	264
6.5	Лабораторная работа 1: методы отбора подмножеств переменных	265
6.5.1	Отбор оптимального подмножества	265
6.5.2	Отбор путем пошагового включения и исключения переменных	268
6.5.3	Нахождение оптимальной модели при помощи методов проверочной выборки и перекрестной проверки	269
6.6	Лабораторная работа 2: гребневая регрессия и лассо	272
6.6.1	Гребневая регрессия	273
6.6.2	Лассо	276
6.7	Лабораторная работа 3: регрессия при помощи методов PCR и PLS	278
6.7.1	Регрессия на главные компоненты	278
6.7.2	Регрессия по методу частных наименьших квадратов	280
6.8	Упражнения	281
7	Выходя за пределы линейности	288
7.1	Полиномиальная регрессия	289
7.2	Ступенчатые функции	291
7.3	Базисные функции	293
7.4	Регрессионные сплайны	294
7.4.1	Кусочно-полиномиальная регрессия	294
7.4.2	Ограничения и сплайны	295
7.4.3	Представление сплайнов с помощью базисных функций	296

7.4.4	Выбор числа и расположения узлов	298
7.4.5	Сравнение с полиномиальной регрессией	299
7.5	Сглаживающие сплайны	300
7.5.1	Общее представление о сглаживающих сплайнах	300
7.5.2	Нахождение параметра сглаживания λ	302
7.6	Локальная регрессия	304
7.7	Обобщенные аддитивные модели	307
7.7.1	GAM для регрессионных задач	307
7.7.2	GAM для задач классификации	311
7.8	Лабораторная работа: нелинейные модели	312
7.8.1	Полиномиальная регрессия и ступенчатые функции	313
7.8.2	Сплайны	318
7.8.3	GAM	319
7.9	Упражнения	322
8	Методы, основанные на деревьях решений	328
8.1	Деревья решений: основные понятия	328
8.1.1	Регрессионные деревья	329
8.1.2	Деревья классификации	337
8.1.3	Сравнение деревьев с линейными моделями	339
8.1.4	Преимущества и недостатки деревьев решений	341
8.2	Бэггинг, случайные леса, бустинг	342
8.2.1	Бэггинг	342
8.2.2	Случайные леса	347
8.2.3	Бустинг	349
8.3	Лабораторная работа: деревья решений	351
8.3.1	Построение деревьев классификации	351
8.3.2	Построение регрессионных деревьев	355
8.3.3	Бэггинг и случайные леса	356
8.3.4	Бустинг	358
8.4	Упражнения	359
9	Машины опорных векторов	364
9.1	Классификатор с максимальным зазором	364
9.1.1	Что такое гиперплоскость?	365
9.1.2	Классификация с использованием гиперплоскости	365
9.1.3	Классификатор с максимальным зазором	368
9.1.4	Построение классификатора с максимальным зазором	370
9.1.5	Случай, когда разделяющая гиперплоскость не существует	370
9.2	Классификаторы на опорных векторах	371
9.2.1	Общие представления о классификаторах на опорных векторах	371
9.2.2	Более подробное описание классификатора на опорных векторах	374
9.3	Машины опорных векторов	377
9.3.1	Классификация с использованием нелинейных решающих границ	377
9.3.2	Машина опорных векторов	378

9.3.3	Применение к данным по нарушению сердечной функции	382
9.4	Машины опорных векторов для случаев с несколькими классами	383
9.4.1	Классификация типа «один против одного»	384
9.4.2	Классификация типа «один против всех»	384
9.5	Связь с логистической регрессией	384
9.6	Лабораторная работа: машины опорных векторов	387
9.6.1	Классификатор на опорных векторах	387
9.6.2	Машина опорных векторов	391
9.6.3	ROC-кривые	393
9.6.4	SVM с несколькими классами	395
9.6.5	Применение к данным по экспрессии генов	395
9.7	Упражнения	397
10	Обучение без учителя	402
10.1	Трудность обучения без учителя	402
10.2	Анализ главных компонент	403
10.2.1	Что представляют собой главные компоненты?	404
10.2.2	Альтернативная интерпретация главных компонент .	408
10.2.3	Дополнительный материал по PCA	409
10.2.4	Другие приложения PCA	414
10.3	Методы кластеризации	414
10.3.1	Кластеризация по методу K средних	415
10.3.2	Иерархическая кластеризация	418
10.3.3	Практические аспекты применения кластеризации . .	429
10.4	Лабораторная работа 1: анализ главных компонент	432
10.5	Лабораторная работа 2: кластерный анализ	434
10.5.1	Кластеризация по методу K средних	434
10.5.2	Иерархическая кластеризация	436
10.6	Лабораторная работа 3: анализ данных NCI60	438
10.6.1	Применение PCA к данным NCI60	439
10.6.2	Кластеризация наблюдений из набора данных NCI60	441
10.7	Упражнения	444

От переводчика

В последние несколько лет наблюдается небывалый рост объема, скорости получения и сложности данных в самых разных областях жизнедеятельности человека. Неудивительно, что и спрос на специалистов, способных извлечь полезную информацию из этих потоков данных, сегодня высок, как никогда раньше. Важную роль в подготовке таких специалистов играет учебная литература по современным методам статистического анализа. Написать хороший учебник — это титанический труд, однако авторы книги, которую Вы сейчас держите в руках, справились с этой задачей блестяще. Простота изложения материала, многочисленные практические примеры и хорошо продуманные лабораторные работы и упражнения сделали книгу «An Introduction to Statistical Learning with Applications in R» чрезвычайно популярной в академических кругах и среди аналитиков коммерческих организаций во всем мире. Для меня было честью выполнить перевод этой работы, и я рад, что теперь она стала доступной и для русскоязычных читателей.

Я сделал все, что было в моих силах, чтобы максимально точно передать текст оригинала, однако возможность повстречать неточности в использованной терминологии и банальные опечатки, к сожалению, полностью не исключена. О любых замечаниях сообщайте, пожалуйста, по адресу rtutorialsbook@gmail.com — это позволит внести соответствующие правки при публикации последующих изданий.

Я благодарен Дмитрию Мовчану и всей команде «ДМК Пресс» за помощь с подготовкой и изданием этой книги, а также Артему Груздеву, Дмитрию Дерябину и Александру Вишератину за оказанные ими консультации и внимательное прочтение рукописи. Наконец, я хотел бы поблагодарить свою жену Светлану за ее бесконечное терпение и понимание в отношении всех моих начинаний, одним из которых стала работа над этим переводом.

Сергей Мاستицкий

Лондон, март 2015 г.

Предисловие

К статистическому обучению относят набор инструментов, предназначенных для моделирования и понимания сложно организованных данных. Это недавно разработанная область статистики, которая развивалась параллельно с достижениями в компьютерных науках и особенно машинном обучении. Данная область охватывает многие методы, включая лассо и разреженную регрессию, классификационные и регрессионные деревья, бустинг и метод опорных векторов.

Одновременно со взрывообразным ростом круга задач, связанных с «большими данными», статистическое обучение стало очень популярным во многих научных областях, а также в маркетинге, финансах и других бизнес-дисциплинах. Люди с навыками статистического обучения очень востребованны.

Одна из первых книг в этой области — «*Основы статистического обучения*» (ОСО)¹ — была опубликована в 2001 г., а в 2009 г. вышло ее второе издание. ОСО стала очень популярной книгой среди не только статистиков, но и специалистов из смежных областей. Одна из причин такой популярности заключается в относительно легкодоступном стиле изложения. Однако ОСО предназначена для людей с основательной математической подготовкой. Новая книга «*Введение в статистическое обучение*» возникла в связи с ощутимой необходимостью в более широком и не таком техническом изложении материала. В этой новой книге мы освещаем многие из тех же тем, которые присутствуют в ОСО, но уделяем основное внимание практическому применению соответствующих методов, а не их математическим деталям. Мы разработали лабораторные работы, иллюстрирующие реализацию каждого метода с использованием статистического пакета R. Эти лабораторные работы позволяют читателю получить ценный практический опыт.

Эта книга подойдет для студентов и магистрантов, углубленно изучающих статистику или родственные дисциплины, а также для представителей других наук, которые желают применять инструменты статистического обучения для анализа своих данных. Ее можно использовать в качестве учебника для курса, длящегося один или два семестра.

Мы благодарим за ценные комментарии следующих читателей черновых вариантов этой книги: Паллави Басу, Александру Чулдечову, Патрику Данахера, Уилла Фитиана, Луэллу Фу, Сэма Гросса, Макса Гразьера Г'Селла, Кортни Паулсон, Ксингао Кьяо, Элизу Шенг, Ноа Симон, Кена Минга Тана и Ксина Лу Тана.

¹ Hastie T., Tibshirani R., Friedman J. (2001) The Elements of Statistical Learning. Springer, 745 p.

«Делать предсказания трудно, особенно в отношении будущего».

Йоги Бerra

Джеймс Гарет (Лос-Анджелес, США)

Даниела Уиттен (Сиэтл, США)

Тревор Хасты (Пало Альто, США)

Роберт Тибширани (Пало Альто, США)

Глава 1

Введение

Обзор задач статистического обучения

Под *статистическим обучением* понимают огромный набор инструментов, предназначенных для *понимания данных*. Эти инструменты можно разделить на две группы: *обучение с учителем* и *обучение без учителя*. В общих чертах статистическое обучение подразумевает построение статистической модели для предсказания, или оценивания, некоторой *выходной переменной* на основе одной или нескольких *входных переменных*. Подобные проблемы встречаются в настолько разнящихся областях, как бизнес, медицина, астрофизика и государственное управление. При обучении без учителя имеются входные переменные, но нет предсказываемой переменной; тем не менее мы можем выявить закономерности и структуру в таких данных. В качестве иллюстрации некоторых практических приложений статистического обучения ниже мы кратко обсудим три реальных набора данных, рассматриваемых в этой книге.

Данные по заработной плате

В этом примере мы исследуем связь нескольких факторов с уровнем заработной платы у группы мужчин из центрально-атлантического региона США (в этой книге мы будем ссылаться на соответствующие данные как «набор данных Wage»). В частности, мы хотим выяснить зависимость между заработной платой работника (переменная *wage*) и его возрастом (*age*), уровнем образования (*education*), а также календарным годом (*year*). Посмотрите, например, на график, представленный слева на рис. 1.1, где показана связь между заработной платой и возрастом работников из этого набора данных. Имеется свидетельство в пользу того, что *wage* увеличивается по мере возрастания *age*, а затем снова снижается примерно после 60 лет. Синяя линия, которая соответствует оценке среднего уровня *wage* для заданного значения *age*, позволяет увидеть этот тренд более четко.

Зная возраст работника, мы можем *предсказать* его заработную плату по этой кривой. Однако на рис. 1.1 также хорошо виден значительный разброс относительно этого среднего значения, из чего следует, что сама по себе переменная *age* вряд ли позволит с большой точностью предсказать *wage* для конкретного человека.




РИСУНОК 1.1. Таблица Wage с данными по заработной плате мужчин из центрально-атлантического региона США. Слева: wage как функция от age. В среднем wage увеличивается одновременно с age до возраста около 60 лет, после чего начинает снижаться. В центре: wage как функция от year. В период с 2003 по 2009 г. имеет место медленный, но устойчивый рост wage в среднем на 10 000\$ в год. Справа: диаграмма размахов wage как функции от education, где 1 соответствует самому низкому уровню образования (неоконченная средняя школа), а 5 – самому высокому уровню (ученая степень). В среднем wage возрастает с уровнем образования

У нас имеется также информация по уровню образования каждого работника и его заработной плате wage за каждый год year. Графики, представленные в центре и справа на рис. 1.1, показывают wage в зависимости от year и education и свидетельствуют о том, что каждый из этих факторов связан с wage. С 2003 по 2009 г. значения зарплаты с каждым годом линейно возрастают примерно на 10 000\$, хотя этот рост очень слабый, по сравнению с разбросом в данных. Зарплаты также выше у людей с более высоким уровнем образования: работники с наименьшим уровнем образования (1) в целом зарабатывают гораздо меньше, чем работники с самым высоким уровнем (5). Очевидно, что наиболее точное предсказание wage для конкретного человека будет получено при объединении информации по его возрасту age, уровню образования education и году year. В главе 3 мы обсудим линейную регрессию, которую можно применить для предсказания wage по этим данным. В идеале мы должны предсказывать wage с учетом нелинейного характера связи этой переменной с age. В главе 7 мы рассмотрим класс методов, предназначенных для решения данной проблемы.

Данные по рынку акций

В случае с набором данных Wage предсказывается непрерывное, или количественное, выходное значение. Часто такую ситуацию называют проблемой восстановления регрессии. Однако в некоторых случаях мы можем столкнуться с необходимостью предсказать нечисловое значение, т. е. категориальную, или качественную, выходную переменную. Так, в главе 4 мы рассмотрим набор данных по рынку акций, который описывает днев-

ные изменения индекса Standard & Poor's 500 (S&P) в течение 5-летнего периода (с 2001 по 2005 г.). Мы будем ссылаться на него как на «набор данных Smarket». Задача заключается в предсказании *возрастания* или *снижения* индекса на основе его удельного изменения за последние 5 дней. Здесь проблема статистического обучения не подразумевает предсказания числового значения. Вместо этого предсказывается рост (Up) или снижение (Down) рынка акций для того или иного дня. Это известно как проблема *классификации*. Модель, способная с высокой точностью предсказывать направление движения рынка, была бы очень полезной!




РИСУНОК 1.2. Слева: диаграмма размахов, отражающая процентное изменение индекса S&P по сравнению со вчерашним значением для дней, когда происходили рост или снижение рынка (по данным Smarket). В центре и справа: то же, но показаны процентные изменения по сравнению с двумя и тремя предыдущими днями соответственно

На рис. 1.2 слева представлена диаграмма размахов, отражающая процентные изменения индекса акций по сравнению с предыдущим днем: для 648 дней, когда в следующие за ними дни рынок вырос, и для 602 дней, когда рынок ушел вниз. Эти две диаграммы почти идентичны, что указывает на невозможность простой стратегии по использованию вчерашнего состояния индекса S&P для предсказания его сегодняшнего положения. Остальные графики, на которых приведены диаграммы размахов для процентных изменений в сравнении с двумя и тремя предыдущими днями, также указывают на отсутствие выраженной связи между прошлым и текущим состояниями индекса. Безусловно, отсутствие связи здесь ожидаемо, иначе при наличии тесных корреляций между следующими друг за другом днями мы могли бы использовать простую торговую стратегию для получения прибыли. Тем не менее в главе 4 мы подробно исследуем эти данные при помощи нескольких методов статистического обучения. Интересно, что есть некоторые указания на наличие слабых закономерностей в этих данных, предполагающие возможность правильного предсказания направления движения рынка примерно в 60% случаев (по крайней мере, для этого 5-летнего периода; рис. 1.3).




РИСУНОК 1.3. Мы подогнали квадратичную дискриминантную модель для части данных Smarket, соответствующей периоду с 2001 по 2004 г., и предсказали вероятность снижения рынка акций для данных за 2005 г. В среднем предсказанная вероятность снижения рынка выше для дней, когда снижение в действительности имело место. На основе этих результатов мы можем правильно предсказать направление движения рынка в 60% случаев

Данные по экспрессии генов

Два предыдущих примера иллюстрируют данные, в которых есть как входные, так и выходные переменные. Однако еще один важный класс проблем охватывает ситуации, в которых мы наблюдаем только входные переменные, без соответствующей зависимой переменной. Например, выполняя маркетинговые исследования, мы могли бы располагать демографической информацией для ряда уже имеющих или потенциальных клиентов. У нас может возникнуть желание понять, какие клиенты похожи друг на друга, для чего мы объединили бы отдельных людей в группы в соответствии с их наблюдаемыми характеристиками. Такая ситуация известна как проблема *кластеризации*. В отличие от предыдущих примеров, здесь мы не пытаемся предсказать какую-либо выходную переменную.

Мы посвящаем главу 10 обсуждению методов статистического обучения, предназначенных для решения проблем, в которых нет естественной выходной переменной. Мы рассматриваем набор данных NCI60, состоящий из 6830 значений уровня экспрессии генов в 64 линиях раковых клеток. Вместо предсказания какой-то конкретной выходной переменной нам интересно выяснить наличие групп, или кластеров, среди этих клеточных линий на основе измерений генной экспрессии. Решить этот вопрос нелегко, отчасти из-за наличия тысяч значений уровня экспрессии для каждой линии, которое затрудняет визуализацию данных.

График, показанный на рис. 1.4 слева, решает эту проблему путем представления каждой из 64 клеточных линий при помощи всего лишь двух чисел — Z_1 и Z_2 . Это первые две *главные компоненты* данных, которые сводят 6830 значений уровня экспрессии по каждой линии до двух чисел, или *измерений*. Несмотря на вероятность потери некоторой части информации в результате такого снижения размерности, теперь появля-

ется возможность визуально исследовать данные на наличие кластеров. Выбор числа кластеров часто бывает трудной проблемой. Однако график, приведенный на рис. 1.4 слева, указывает на наличие не менее четырех групп клеточных линий, которые мы пометили разными цветами. Теперь мы можем подробнее изучить клеточные линии из каждого кластера на предмет их сходства по типу рака и тем самым лучше понять взаимосвязь между уровнями генной экспрессии и раком.




РИСУНОК 1.4. Слева: представление данных по уровню экспрессии генов NCI60 в двумерном пространстве, образованном переменными Z_1 и Z_2 . Каждая точка соответствует одной из 64 клеточных линий. Клеточные линии образуют примерно четыре группы, которые мы представили разными цветами. Справа: то же, что и слева, за тем исключением, что мы выделили каждый из 14 типов рака при помощи символов разной формы и цвета. Клеточные линии, соответствующие одному типу рака, стремятся располагаться в этом двумерном пространстве рядом

Оказывается, что в случае с этим конкретным набором данных клеточные линии соответствуют 14 различным типам рака. (Эта информация, однако, не была использована при создании диаграммы на рис. 1.4 слева.) Справа на рис. 1.4 показаны те же данные, однако 14 типов рака отмечены символами разной формы и цвета. Хорошо видно, что клеточные линии с одинаковым типом рака стремятся располагаться близко друг к другу в этом двумерном представлении. Кроме того, несмотря на то что информация по раку не была использована для создания первого графика, полученная кластеризация в значительной мере соответствует действительным типам рака, наблюдаемым на втором графике. Это в определенной мере является независимым подтверждением верности нашего кластерного анализа.

Краткая история развития статистического обучения

Несмотря на то что термин «статистическое обучение» достаточно новый, многие из основополагающих концепций этой дисциплины были раз-

работаны очень давно. В начале XIX века Лежандр и Гаусс опубликовали статьи по *методу наименьших квадратов*. Этот подход был впервые успешно применен для решения проблем астрономии. Линейная регрессия используется для предсказания значений количественных переменных, таких, например, как заработная плата. Для предсказания значений качественных переменных (например, выживет пациент или нет, пойдет рынок акций вверх или вниз) Фишер в 1936 г. предложил *линейный дискриминантный анализ*. В 1940–х г. разные авторы предложили альтернативный подход — *логистическую регрессию*. В начале 1970–х г. Нельдер и Веддербурн ввели термин «*обобщенные линейные модели*» для целого класса методов статистического обучения, которые включают как линейную, так и логистическую регрессию в качестве частных случаев.

К концу 1970–х г. стали доступными многие другие методы обучения на основе данных. Однако почти всегда это были линейные методы, поскольку с вычислительной точки зрения подгонка *нелинейных* зависимостей в то время была неосуществимой. К началу 1980–х гг. вычислительные технологии, наконец, были усовершенствованы до уровня, который больше не ограничивал работу с нелинейными методами. В середине 1980–х г. Брейман, Фридман, Ольшен и Стоун ввели *деревья регрессии и классификации* и стали одними из первых, кто детально продемонстрировал большой потенциал для практической реализации этого метода, включая перекрестную проверку для выбора модели. В 1986 г. Хасты и Тибширани ввели термин «*обобщенные аддитивные модели*» для класса нелинейных дополнений обобщенных линейных моделей, а также разработали соответствующее программное обеспечение.

С тех пор благодаря появлению *машинного обучения* и других дисциплин, статистическое обучение развилось в новую ветвь статистики, уделяющую основное внимание обучению с учителем и без учителя, а также прогнозированию. В последние годы прогресс в статистическом обучении был связан с ростом доступности мощного и относительно удобного программного обеспечения, каковым является популярная и бесплатная система R. Потенциально это может привести к дальнейшей трансформации дисциплины из набора методов, используемых и разрабатываемых статистиками и специалистами в области компьютерных наук, в неотъемлемый набор инструментов для гораздо более широкого сообщества.

Об этой книге

Книга «Основы статистического обучения» (ОСО), написанная Хасты, Тибширани и Фридманом, была впервые опубликована в 2001 г. С тех пор она превратилась в важную справочную работу по фундаментальным основам статистического обучения. Ее успех обусловлен широким и детальным рассмотрением многих тем статистического обучения, а также тем фактом, что (в сравнении со многими специализированными учебниками по статистике) она доступна для широкой аудитории. Однако больше всего успех ОСО связан с тематикой этой книги. На момент публикации интерес к области статистического обучения начинал свой взрывообразный рост. ОСО стала одной из первых доступных и всеобъемлющих вводных работ по этой теме.

С момента публикации ОСО статистическое обучение продолжило свой расцвет. Развитие этой дисциплины приняло две формы. Наиболее заметный рост был связан с разработкой новых и усовершенствованных подходов статистического обучения, предназначенных для получения ответов на широкий круг вопросов в ряде научных областей. Однако статистическое обучение расширило также и свою аудиторию. В 1990-х г. рост доступности вычислительных ресурсов вызвал волну интереса к этой области со стороны неспециалистов по статистике, которым не терпелось начать использовать современные статистические инструменты для анализа своих данных. К сожалению, высокотехническая природа этих методов означала, что сообщество их пользователей оставалось ограниченным преимущественно экспертами по статистике, компьютерным и смежным областям, имеющими необходимую подготовку (и время) для освоения и реализации соответствующих методов.

В последние годы новое и усовершенствованное программное обеспечение значительно облегчило практическое применение многих методов статистического обучения. В то же время во многих областях, таких как бизнес, здравоохранение, генетика, социальные науки и т.д., произошло осознание того, что статистическое обучение является мощным инструментом для решения важных практических задач. Как следствие оно перестало быть чем-то, что представляет преимущественно академический интерес, и превратилось в популярную дисциплину с огромной потенциальной аудиторией. Несомненно, этот тренд продолжится по мере роста доступности огромных объемов данных и программного обеспечения, предназначенного для их анализа.

Цель книги *«Введение в статистическое обучение»* (ВСО) состоит в том, чтобы содействовать превращению статистического обучения из академической в популярную практическую дисциплину. ВСО не предназначена для замены ОСО, которая является гораздо более обстоятельной работой как по числу рассматриваемых в ней методов, так и по глубине их описания. Мы рассматриваем ОСО в качестве справочника для профессионалов (имеющих ученые степени по статистике, машинному обучению или сходным направлениям), которым необходимо понимать технические детали, лежащие в основе подходов статистического обучения. Однако сообщество пользователей методов машинного обучения расширилось и включает людей с более широким кругом интересов и с разным образованием. Поэтому мы убеждены, что сейчас появилось место для менее технической и более доступной версии ОСО.

В ходе преподавания этих тем на протяжении многих лет мы обнаружили, что они представляют интерес для магистрантов и аспирантов из настолько далеких друг от друга дисциплин, как бизнес-администрирование, биология и компьютерные науки, а также для ориентированных на количественные дисциплины студентов старших курсов. Для этой разнородной аудитории важно иметь возможность понимать модели, их предпосылки, а также сильные и слабые стороны различных методов. Однако многие технические детали методов статистического обучения, такие как алгоритмы оптимизации и теоретические свойства методов, для этой аудитории не представляют большого интереса. Мы убеждены, что таким студентам не нужно иметь глубокого понимания этих аспектов, для того чтобы начать осознанно применять различные методы и сделать

вклад в соответствующие научные дисциплины с помощью инструментария статистического обучения.

Книга ВСО основана на следующих четырех предпосылках.

1. *Многие методы статистического обучения применимы и полезны для широкого круга академических и практических дисциплин, выходящих далеко за рамки статистической науки.* Мы убеждены, что многие современные процедуры статистического обучения должны стать (и станут) настолько же широко доступными и используемыми, как классические методы наподобие линейной регрессии. В связи с этим вместо попытки охватить все возможные подходы (а это невыполнимая задача) мы сконцентрировались на представлении методов, которые считаем наиболее широко применимыми.
2. *Статистическое обучение не следует рассматривать как набор «черных ящиков».* Не существует метода, который одинаково хорошо сработает во всех возможных ситуациях. Без понимания всех «винтиков» внутри «ящика» и без взаимодействия с этими «винтиками» невозможно выбрать наилучший «ящик». Поэтому мы предприняли попытку тщательно описать модель, идею, допущения и компромиссы, лежащие в основе каждого рассматриваемого нами метода.
3. *Несмотря на важность понимания функции, выполняемой каждым «винтиком», нет необходимости уметь конструировать саму машину, находящуюся внутри «ящика».* Поэтому мы минимизировали обсуждение технических деталей, имеющих отношение к процедурам подгонки моделей и теоретическим свойствам методов. Мы предполагаем, что читатель чувствует себя комфортно с простейшими математическими концепциями, но мы не ожидаем от него ученой степени в области математических наук. Например, мы почти полностью исключили использование матричной алгебры, и всю книгу можно понять без знания матриц и векторов.
4. *Мы предполагаем, что читатель интересуется применением методов статистического обучения для решения практических проблем.* Чтобы удовлетворить этот интерес и мотивировать к применению обсуждаемых методов, после каждой главы мы приводим раздел с лабораторными работами. В каждой лабораторной работе мы знакомим читателя с реалистичным практическим применением методов, рассмотренных в соответствующей главе. Когда мы преподавали этот материал в наших курсах, мы отводили на лабораторные работы примерно треть всего времени и нашли их чрезвычайно полезными. Многие студенты, которые поначалу испытывали затруднения при работе с командным интерфейсом R, усвоили необходимые навыки в течение семестра. Мы использовали R потому, что эта система является бесплатной и достаточно мощной для реализации всех рассмотренных в книге методов. Кроме того, она имеет расширения, которые можно загрузить для реализации буквально тысяч дополнительных методов. Но важнее всего то, что R предпочитают академические статистики, и новые методы часто становятся доступными в R на несколько лет раньше того, как они появляются в платных

программах. Тем не менее лабораторные работы в ВСО автономны, и их можно пропускать, если читатель желает использовать другое программное обеспечение или не намерен применять обсуждаемые методы к реальным проблемам.

Кому следует прочесть эту книгу?

Эта книга предназначена для всех, кто интересуется применением современных статистических методов для моделирования и прогнозирования на основе данных. Эта группа читателей включает ученых, инженеров, финансовых аналитиков, а также людей с меньшей технической и математической подготовкой, которые имеют образование в таких областях, как социальные науки или бизнес. Мы ожидаем, что читатель прослушал как минимум один вводный курс по статистике. Знание линейной регрессии также полезно, но не обязательно, поскольку в главе 3 мы даем обзор ключевых концепций, лежащих в основе этого метода. Уровень математики в этой книге умеренный, и детальное знание матричных операций не требуется. Книга содержит введение в язык статистического программирования R. Предыдущий опыт программирования на другом языке, вроде MATLAB или Python, полезен, но не обязателен.

Мы успешно преподавали материал на этом уровне магистрантам и аспирантам, изучающим бизнес, компьютерные науки, биологию, науки о Земле, психологию и многие другие направления естественных и гуманитарных наук. Эта книга также могла бы оказаться подходящей для студентов последних курсов, которые уже прослушали курс по линейной регрессии. В контексте математически более строгого курса, где основным учебником является ОСО, ВСО можно было бы использовать в качестве дополнительного источника для преподавания вычислительных аспектов различных методов.

Обозначения и простая матричная алгебра

Выбор системы обозначений для учебника — это всегда сложная задача. В большинстве случаев мы применяем те же условные обозначения, что и в ОСО.

Мы будем использовать n для обозначения числа отдельных значений, или наблюдений, в нашей выборке. При помощи p мы будем обозначать число имеющихся переменных, на основе которых можно делать предсказания. Например, набор данных Wage состоит из 12 переменных для 3000 людей, так что у нас есть $n = 3000$ наблюдений и $p = 12$ переменных, таких как `year`, `age`, `wage` и др. Заметьте, что на протяжении всей этой книги для обозначения имен переменных мы используем цветной шрифт: Имя Переменной.

В некоторых примерах p может быть довольно большим, порядка нескольких тысяч или даже миллионов; подобная ситуация достаточно часто возникает, например, при анализе современных биологических данных или данных по интернет-рекламе.

Обычно при помощи x_{ij} мы будем обозначать i -е значение j -й переменной, где $i = 1, 2, \dots, n$, а $j = 1, 2, \dots, p$. На протяжении этой книги

i будет использоваться для индексирования выборок или отдельных наблюдений (от 1 до n), а j — для индексирования переменных (от 1 до p). С помощью $\mathbf{X}$ мы обозначаем матрицу размером $n \times p$, чей (i, j) -й элемент — это x_{ij} . Другими словами,

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}.$$

Читателям, не знакомым с матрицами, полезно будет мысленно представлять $\mathbf{X}$ в виде таблицы чисел с n строками и p столбцами.

В ряде случаев нам будут интересны строки матрицы $\mathbf{X}$, которые мы записываем как $x_1, x_2, \dots, x_n$. Здесь x_i представляет собой вектор длиной p , содержащий значения p переменных для i -го наблюдения. Другими словами,

$$x_i = \begin{pmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{ip} \end{pmatrix}. \quad (1.1)$$

(По определению, векторы представлены в виде столбцов.) Например, для набора данных Wage x_i — это вектор длиной 12, состоящий из значений `year`, `age`, `wage` и других переменных для i -го человека. В других случаях вместо строк нам будут интересны столбцы матрицы $\mathbf{X}$, которые мы записываем как $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_p$. Каждый из этих столбцов является вектором длиной n , т. е.

$$\mathbf{x}_j = \begin{pmatrix} x_{1j} \\ x_{2j} \\ \vdots \\ x_{nj} \end{pmatrix}.$$

Например, в случае с данными Wage $\mathbf{x}_1$ содержит $n = 3000$ значений `year`.

Используя эту нотацию, матрицу $\mathbf{X}$ можно записать как

$$\mathbf{X} = (\mathbf{x}_1 \quad \mathbf{x}_2 \quad \cdots \quad \mathbf{x}_p),$$

или

$$\mathbf{X} = \begin{pmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_n^T \end{pmatrix}.$$

Символ T обозначает *транспозицию* матрицы или вектора. Так, например,

$$\mathbf{X}^T = \begin{pmatrix} x_{11} & x_{21} & \cdots & x_{n1} \\ x_{12} & x_{22} & \cdots & x_{n2} \\ \vdots & \vdots & & \vdots \\ x_{1n} & x_{2n} & \cdots & x_{np} \end{pmatrix},$$

тогда как

$$x_i^T = (x_{i1} \quad x_{i2} \quad \cdots \quad x_{ip}).$$

Мы используем y_i для обозначения i -го наблюдения переменной, которую мы хотим предсказать (например, *wage*). Следовательно, в векторной форме мы записываем набор всех n наблюдений как

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}.$$

Тогда наши наблюдаемые данные состоят из пар $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, где каждый элемент x_i — это вектор длиной p . Если $p = 1$, то x_i является просто скаляром.

В этой книге вектор длиной n всегда будет обозначаться при помощи *прописной буквы, выделенной жирным шрифтом*, т. е.

$$\mathbf{a} = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix}.$$

Однако векторы, чья длина отличается от n (например, векторы признаков длиной p , как в (1.1)), будут обозначаться при помощи прописных букв, выполненных обычным шрифтом (например, a). Скаляры также будут обозначаться при помощи таких *прописных букв*, т. е. a . В редких случаях, когда использование прописных букв с обычным шрифтом может привести к двусмысленности, мы будем пояснять, что имеется в виду. Матрицы будут обозначаться с использованием *заглавных букв, выполненных жирным шрифтом* (например, $\mathbf{A}$). Случайные переменные будут обозначаться *заглавными буквами, выполненными обычным шрифтом* (например, A), вне зависимости от их размерности.

Иногда у нас будет возникать необходимость указать размерность конкретного объекта. Чтобы показать, что объект является вектором, мы будем использовать нотацию $a \in \mathbb{R}$. Чтобы показать, что это вектор длиной k , мы будем использовать обозначение $a \in \mathbb{R}^k$ (или $a \in \mathbb{R}^n$, если он имеет длину n). Объекты, которые являются матрицами размером $r \times s$, мы будем обозначать как $\mathbf{A} \in \mathbb{R}^{r \times s}$.

Мы избегали использования матричной алгебры везде, где это было возможно. Однако в нескольких случаях полностью избегать ее становилось слишком обременительно. В этих редких случаях важно понимать концепцию умножения двух матриц. Предположим, что $\mathbf{A} \in \mathbb{R}^{r \times d}$,

а $\mathbf{B} \in \mathbb{R}^{d \times s}$. Результат умножения $\mathbf{A}$ на $\mathbf{B}$ обозначается как $\mathbf{AB}$. Элемент (i, j) матрицы $\mathbf{AB}$ вычисляется путем умножения каждой i -й строки $\mathbf{A}$ на соответствующий элемент j -го столбца $\mathbf{B}$. Иначе говоря, $(\mathbf{AB})_{ij} = \sum_{k=1}^d a_{ik}b_{kj}$. В качестве примера представьте, что

$$\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \quad \text{и} \quad \mathbf{B} = \begin{pmatrix} 5 & 6 \\ 7 & 8 \end{pmatrix}.$$

Тогда

$$\mathbf{AB} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \begin{pmatrix} 5 & 6 \\ 7 & 8 \end{pmatrix} = \begin{pmatrix} 1 \times 5 + 2 \times 7 & 1 \times 6 + 2 \times 8 \\ 3 \times 5 + 4 \times 7 & 3 \times 6 + 4 \times 8 \end{pmatrix} = \begin{pmatrix} 19 & 22 \\ 43 & 50 \end{pmatrix}.$$

Заметьте, что результатом этой операции является матрица размером $r \times s$. $\mathbf{AB}$ можно вычислить только, если число столбцов в $\mathbf{A}$ равно числу строк в $\mathbf{B}$.

Структура этой книги

Глава 2 вводит основные термины и концепции, лежащие в основе статистического обучения. Эта глава описывает также классификатор на основе *K ближайших соседей* — очень простой метод, который удивительно хорошо работает для многих проблем. Главы 3 и 4 охватывают классические линейные методы регрессии и классификации. В частности, глава 3 дает обзор *линейной регрессии* — фундаментальной отправной точки всех регрессионных методов. В главе 4 мы обсуждаем два наиболее важных классических метода классификации — *логистическую регрессию* и *линейный дискриминантный анализ*.

Центральной проблемой всех случаев использования статистического обучения является выбор наилучшего метода для решения конкретной задачи. Поэтому в главе 5 мы знакомим читателя с *перекрестной проверкой* и *бутстрепом*, которые можно использовать для оценивания точности нескольких методов и выбора самого подходящего из них.

Многие недавние исследования в области статистического обучения были посвящены нелинейным методам. Однако линейные методы часто имеют преимущества по сравнению со своими нелинейными конкурентами в смысле интерпретируемости, а иногда и точности предсказаний. Поэтому в главе 6 мы рассматриваем целый ряд линейных методов, как классических, так и более современных, которые предлагают потенциальные улучшения по сравнению со стандартной линейной регрессией. Речь идет о *пошаговом отборе*, *гребневой регрессии*, *регрессии на главные компоненты*, методе *частных наименьших квадратов* и *лассо-регрессии*.

Остальные главы посвящены миру нелинейного статистического обучения. Сначала в главе 7 мы вводим несколько нелинейных методов, которые хорошо работают для проблем с одной входной переменной. Затем мы показываем, как эти методы можно использовать для построения нелинейных *аддитивных* моделей с несколькими входными переменными. В главе 8 мы исследуем методы, основанные на *решающих деревьях*, включая *бэггинг*, *бустинг* и *случайные леса*. Метод *опорных векторов*

— совокупность подходов для решения задач как линейной, так и нелинейной классификации — обсуждается в главе 9. Наконец, в главе 10 мы рассматриваем ситуацию, когда у нас имеются входные переменные, но нет выходной переменной. В частности, мы описываем *анализ главных компонент*, кластеризацию с помощью *метода K средних*, а также *иерархическую кластеризацию*.

В конце каждой главы мы приводим одну или несколько лабораторных работ с использованием R, в которых подробно разбираем примеры практического применения рассмотренных в этой главе методов. Эти лабораторные работы демонстрируют сильные и слабые стороны разных подходов, а также предоставляют полезный справочный материал по синтаксису, необходимому для реализации разных методов. Возможно, читатель предпочтет работать над этими лабораторными в своем собственном темпе, но это могут быть также и групповые сессии, являющиеся частью классной работы. В каждой лабораторной работе мы представляем результаты, которые получили на момент написания книги. Однако постоянно выходят новые версии R, и со временем используемые в лабораторных работах пакеты будут обновлены. Поэтому возможно, что в будущем представленные в соответствующих разделах результаты больше не будут в точности соответствовать результатам, полученным читателем. По мере необходимости мы будем обновлять лабораторные работы на сайте книги.

Мы используем значок  для обозначения разделов и упражнений повышенной сложности. Эти разделы могут быть легко пропущены читателями, которые не желают так глубоко погружаться в соответствующий материал или не имеют необходимой математической подготовки.

Данные, использованные в лабораторных работах и упражнениях

В этом учебнике мы иллюстрируем методы статистического обучения на практических примерах из маркетинга, финансов, биологии и других областей. Пакет ISLR, доступный на сайте книги, содержит несколько наборов данных, которые необходимы для выполнения соответствующих лабораторных работ и упражнений. Один из таких наборов данных входит в состав библиотеки MASS, а еще один является частью базового дистрибутива R. Таблица 1.1 содержит сводную информацию по данным, необходимым для выполнения лабораторных работ и упражнений. Несколько таких наборов данных, используемых в главе 2, доступно также в виде текстовых файлов на сайте книги.

Веб-сайт книги

Веб-сайт этой книги находится по адресу www.StatLearning.com. Он содержит целый ряд ресурсов, включая связанный с книгой R-пакет и некоторые дополнительные наборы данных.

ТАБЛИЦА 1.1. *Список наборов данных, необходимых для выполнения лабораторных работ и упражнений в этом учебнике. Все данные доступны в пакете ISLR, за исключением Boston и USArrests (они входят в состав базового дистрибутива R)*

Название	Описание
Auto	Расход топлива, мощность двигателя и другая информация по автомобилям
Boston	Стоимость жилья и другая информация по пригородам Бостона
Caravan	Информация по людям, которым была предложена страховка для их жилых прицепов
Carseats	Информация по продажам автомобильных сидений в 400 магазинах
College	Демографические характеристики, стоимость обучения и другие данные по колледжам США
Default	Данные по должникам компании, выпускающей кредитные карты
Hitters	Данные по заработной плате бейсбольных игроков
Khan	Измерения генной экспрессии для четырех типов рака
NCI60	Измерения генной экспрессии для 64 раковых клеточных линий
OJ	Информация по продажам апельсинового сока марок Citrus Hill и Minute Made
Portfolio	Исторические значения финансовых активов, используемые для распределения инвестиционных средств
Smarket	Дневные удельные изменения доходности индекса S&P за 5-летний период
USArrests	Криминальная статистика в расчете на 100 000 жителей в 50 штатах США
Wage	Данные исследования доходов мужчин в центрально-атлантическом регионе США
Weekly	1098 значений недельной доходности рынка акций за 21 год

Благодарности

Несколько графиков в этой книге было заимствовано из ОСО: рис. 6.7, 8.3 и 10.12. Все остальные графики в книге новые.

Глава 2

Статистическое обучение

2.1 Что такое статистическое обучение?

Рассмотрим простой пример, который поможет нам приступить к изучению статистического обучения. Представьте себе, что мы являемся консультантами-статистиками, нанятыми некоторым клиентом для разработки рекомендаций по повышению продаж определенного продукта. Набор данных Advertising включает сведения по продажам (sales) этого продукта в 200 различных регионах, а также по величине регионального бюджета на рекламу продукта в средствах массовой информации (СМИ) трех видов: телевидение (TV), радио (radio) и газеты (newspaper). Эти данные представлены на рис. 2.1. Наш клиент не имеет прямой возможности увеличить продажи. С другой стороны, он может контролировать затраты на рекламу в каждом из трех типов СМИ. Следовательно, если мы обнаружим связь между затратами на рекламу и продажами, то сможем дать рекомендации нашему клиенту по корректированию бюджета на рекламу, что опосредованно приведет к увеличению продаж. Другими словами, наша цель состоит в разработке модели, которую можно будет использовать для верных предсказаний продаж на основе данных по бюджету для трех типов СМИ.

При таком сценарии уровни бюджета на рекламу в разных СМИ являются *входными переменными*, тогда как sales — это *выходной переменной*. Входные переменные обычно обозначаются при помощи символа X с нижним индексом, позволяющим различать отдельные переменные. Так, X_1 может обозначать бюджет TV, X_2 — бюджет radio, а X_3 — бюджет newspaper. Входные переменные известны под разными названиями — *предикторы*, *независимые переменные*, *признаки*, или иногда просто *переменные*. Выходную переменную — в данном случае sales — часто называют *откликом*, или *зависимой переменной*, и обычно обозначают при помощи символа Y . В этой книге мы будем использовать указанные термины попеременно.

входная и
выходная
перемен-
ные

независи-
мая и
зависимая
перемен-
ные

предиктор
признак
отклик

В качестве более общего случая представьте, что мы наблюдаем некоторый количественный отклик Y и p отдельных предикторов $X_1, X_2, \dots, X_p$. Мы делаем предположение о том, что существует определенная связь между Y и $X = (X_1, X_2, \dots, X_p)$, которую в очень общей форме можно записать как




РИСУНОК 2.1. Набор данных Advertising. На рисунке показан объем продаж (sales, тыс. единиц) в зависимости от величины бюджета на рекламу (тыс. долларов) на телевидении (TV), радио (radio) и в газетах (newspaper) в 200 регионах.

$$Y = f(X) + \epsilon. \quad (2.1)$$

ошибка

Здесь f — это некоторая фиксированная, но не известная функция от $X_1, \dots, X_p$, а ϵ — *ошибка*, которая не зависит от X и имеет нулевое среднее значение. В таком представлении f выражает *систематическую* информацию о Y , содержащуюся в X .

В качестве другого примера рассмотрим данные для 30 человек из таблицы Income, отражающие зависимость дохода (income) от количества лет, затраченных этими людьми на образование (years of education; см. рис. 2.2 слева). Этот график предполагает, что мы могли бы предсказать доход на основе длительности обучения. Однако функция, связывающая входную переменную с выходной переменной, в общем случае неизвестна. В такой ситуации мы должны оценить f на основе имеющихся наблюдений. Поскольку таблица Income содержит имитированные данные, то f известна и показана на рис. 2.2 справа в виде кривой голубого цвета. Вертикальные отрезки соответствуют ошибкам ϵ . Заметьте, что некоторые из 30 наблюдений лежат выше голубой линии, а некоторые — ниже, но в целом среднее значение ошибок примерно равно нулю.

В общем случае функция f может включать более одной входной переменной. На рис. 2.3 мы изображаем income как функцию от длительности обучения и стажа (seniority). Здесь f представляет собой двумерную плоскость, которую мы должны оценить на основе имеющихся данных.

В сущности, под статистическим обучением понимают совокупность методов для оценивания f . В этой главе мы рассматриваем некоторые из ключевых теоретических концепций, применяемых при нахождении f , а также инструменты для определения качества полученных оценок.




РИСУНОК 2.2. Набор данных Income. Слева: красные точки соответствуют значениям переменных `income` (доход, десятки тыс. долларов) и `years` (длительность обучения, лет) у 30 человек. Справа: голубая кривая соответствует истинной функции связи между `income` и `years`, которая обычно неизвестна (в этом случае она известна, поскольку данные были имитированы). Черные вертикальные линии показывают ошибки соответствующих наблюдений. Заметьте, что некоторые ошибки положительны (когда наблюдение лежит выше голубой кривой), а некоторые — отрицательны (когда наблюдение находится ниже кривой). В целом среднее значение ошибок примерно равно нулю

2.1.1 Зачем оценивать f ?

Существуют две основные причины, по которым мы хотели бы оценить f : *предсказание* и *статистический вывод*. Обсудим каждую из этих причин по порядку.

Предсказание

Во многих ситуациях набор входных переменных X легко доступен, однако получить выходную переменную Y не так просто. Благодаря тому, что ошибки имеют нулевое среднее значение, при таком сценарии мы можем предсказать Y с помощью

$$\hat{Y} = \hat{f}(X), \quad (2.2)$$

где $\hat{f}$ представляет собой нашу оценку f , а $\hat{Y}$ — предсказанное значение Y . В подобной ситуации $\hat{f}$ часто рассматривают как *черный ящик*, в том смысле, что если $\hat{f}$ обеспечивает верные предсказания Y , то точная форма этой функции для нас не важна.

В качестве примера предположим, что $X_1, \dots, X_p$ являются характеристиками образца крови пациента, которые легко измерить в лаборатории, а Y — это переменная, отражающая риск того, что пациент проявит резко негативную реакцию на определенный лекарственный препарат. Естественным будет желание предсказать Y по X , поскольку таким образом




РИСУНОК 2.3. График показывает income как функцию от years и seniority (переменные из набора данных Income). Голубая плоскость отражает истинную зависимость income от years и seniority, которая известна, поскольку эти данные были имитированы. Красные точки показывают наблюдаемые значения для 30 человек

мы сможем избежать назначения данного препарата пациентам с высоким риском негативной реакции, т.е. пациентам с высокими значениями оценок Y .

Точность $\hat{Y}$ в качестве предсказанного значения Y зависит от двух величин, которые мы будем называть *устраняемой ошибкой* и *неустраняемой ошибкой*. Обычно $\hat{f}$ не будет идеальной оценкой f , и эта неточность приведет к возникновению некоторой ошибки. Такая ошибка является *устраняемой*, поскольку потенциально мы можем улучшить точность $\hat{f}$, используя более подходящий статистический метод для оценивания f . Но даже если бы имелась возможность достичь настолько идеальной оценки $\hat{f}$, что $\hat{Y} = f(X)$, наше предсказанное значение все равно содержало бы в себе некоторую ошибку! Подобная ошибка известна как *неустраняемая*, поскольку как бы хорошо мы ни оценили f , мы не сможем снизить ошибку, привнесенную за счет ϵ .

Почему же неустраняемая ошибка превышает нулевое значение? Величина ϵ может включать неучтенные переменные, которые полезны для предсказания Y , но поскольку мы их не измеряем, то $\hat{f}$ не может использовать их для предсказания. Например, риск негативной реакции может варьировать у того или иного пациента в определенный день в зависимости условий производства самого лекарственного препарата или от общего состояния здоровья пациента в тот день.

Представьте себе некоторую конкретную оценку $\hat{f}$ и набор предикторов X , которые дают предсказание $\hat{Y} = \hat{f}(X)$. Допустите на мгновение, что и $\hat{f}$, и X являются фиксированными величинами. Тогда можно легко показать, что

устрани-
мая и
неустрани-
мая
ошибки

$$E(Y - \hat{Y})^2 = E[f(X) + \epsilon - \hat{f}(X)]^2 = \underbrace{[f(X) - \hat{f}(X)]^2}_{\text{устраняемая}} + \underbrace{\text{Var}(\epsilon)}_{\text{неустраняемая}}, \quad (2.3)$$

где $E(Y - \hat{Y})^2$ представляет собой среднее, или *ожидаемое*, значение квадрата разности между предсказанным и истинным значением Y , а $\text{Var}(\epsilon)$ — *дисперсию*, связанную с ошибкой ϵ .

ожидаемое
значение
дисперсия

В этой книге сделан упор на методы, предназначенные для оценивания f с целью минимизации устранимой ошибки. Важно помнить, что неустраняемая ошибка всегда будет обеспечивать верхнюю границу точности нашего предсказания Y . На практике эта граница почти всегда неизвестна.

Статистический вывод

Часто мы заинтересованы в понимании того, как изменение $X_1, \dots, X_p$ влияет на Y . В такой ситуации мы хотим оценить f , но наша цель не обязательно заключается в получении предсказаний для Y . Вместо этого мы хотим понять взаимоотношение между X и Y или, более конкретно, понять функциональную связь между Y и $X_1, \dots, X_p$. В этом случае $\hat{f}$ нельзя рассматривать в качестве черного ящика, поскольку нам нужно знать ее точную форму. При таком сценарии мы можем быть заинтересованы в ответе на следующие вопросы:

- *Какие предикторы связаны с откликом?* Часто только небольшая часть имеющихся в распоряжении предикторов тесно связана с Y . В зависимости от стоящей задачи нахождение ограниченного числа *важных* предикторов в большом наборе возможных переменных может оказаться чрезвычайно полезным.
- *Какова связь между откликом и каждым предиктором?* Некоторые предикторы могут иметь положительную связь с Y в том смысле, что увеличение предиктора вызывает возрастание значений Y . Другие предикторы могут оказывать противоположный эффект. В зависимости от сложности f связь между откликом и некоторым предиктором может зависеть также от значений других предикторов.
- *Можно ли связь между Y и каждым предиктором адекватно обобщить в виде линейного уравнения, или эта связь является более сложной?* Исторически сложилось так, что большинство методов для оценивания f подразумевали линейную форму. В некоторых ситуациях такое допущение является обоснованным или даже желательным. Однако часто истинная связь является более сложной и линейная модель не способна обеспечить адекватное представление зависимости между входными и выходными переменными.

В этой книге мы увидим несколько примеров, относящихся к ситуациям, когда требуется выполнение предсказаний, получение статистических выводов или комбинация обеих этих задач.

Например, представьте себе фирму, которая заинтересована в проведении персонализированной маркетинговой кампании. Цель заключается в использовании имеющихся в распоряжении фирмы демографических данных для нахождения людей, которые положительно ответят на высланное по почте предложение. В этом случае демографические переменные служат в качестве предикторов, а отклик на маркетинговую кампанию (положительный или отрицательный) является выходной переменной. Фирма не ставит задачей сформировать глубокое понимание взаимоотношений между каждым отдельным предиктором и откликом — вместо этого ей просто нужна точная модель для предсказания отклика на основе предикторов. Это пример построения модели для получения предсказаний.

С другой стороны, рассмотрим данные из таблицы Advertising, изображенные на рис. 2.1. Интерес могут представлять ответы на следующие вопросы:

- *Какие СМИ способствуют продажам?*
- *Какие СМИ вызывают наибольший всплеск продаж?*
- *Насколько тесно рост продаж связан с тем или иным увеличением затрат на телерекламу?*

Такая ситуация подпадает под парадигму статистических выводов. Другой пример включает моделирование бренда продукта, который клиент мог бы купить, исходя из таких переменных, как цена, местоположение магазина, уровни скидок, цена у конкурентов и т. д. В этой ситуации нас больше всего могло бы интересовать то, как каждая отдельная переменная влияет на вероятность покупки. Например, *какое влияние на продажи оказывает изменение цены?* Это пример моделирования с целью сделать статистический вывод.

Наконец, иногда моделирование выполняют для получения как предсказаний, так и статистических выводов. Например, в случае с недвижимым имуществом мы могли бы попытаться увязать значения стоимости домов с такими входными переменными, как уровень преступности, район, расстояние от реки, качество воздуха, доход соседей, размер домов и т. д. В этом случае нам может быть интересно то, как отдельные входные переменные влияют на цены: например, *насколько дороже будет дом с видом на реку?* Это проблема по получению статистического вывода. С другой стороны, нас могло бы интересовать просто предсказание стоимости дома на основе его характеристик: *недо- или переоценен этот дом?* Это проблема предсказания.

В зависимости от того, какова наша главная цель — предсказание, статистический вывод, или комбинация этих двух проблем, — для оценивания f подходящими могут оказаться разные методы. Например, *линейные модели* позволяют делать относительно простые и интерпретируемые статистические выводы, но в сравнении с другими подходами они могут давать менее точные предсказания. С другой стороны, некоторые из высоконелинейных подходов, обсуждаемых нами в последних главах этой книги, потенциально могут обеспечить очень точные предсказания для Y , но за счет менее интерпретируемой модели, по которой статистические выводы сделать сложнее.

2.1.2 Как мы оцениваем f ?

В этой книге мы рассматриваем многие линейные и нелинейные подходы для оценивания f . Тем не менее часто эти методы имеют определенные общие характеристики. Мы приводим обзор этих общих черт в данном разделе. Во всех случаях предполагается, что у нас имеется набор из n отдельных наблюдений. Например, на рис. 2.2 у нас есть $n = 30$ наблюдений. Эти наблюдения называются *обучающими данными*¹, поскольку мы используем их для тренировки, или обучения, нашего метода тому, как оценить f . Пусть x_{ij} символизирует значение j -го предиктора, или входной переменной, у наблюдения i , где $i = 1, 2, \dots, n$, а $j = 1, 2, \dots, p$. Аналогичным образом пусть y_i обозначает отклик у i -го наблюдения. Обучающие данные тогда состоят из пар $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, где $x_i = (x_{i1}, x_{i2}, \dots, x_{ip})^T$.

обучающие данные

Наша цель заключается в применении некоторого метода статистического обучения к входным данным для нахождения неизвестной функции f . Другими словами, мы хотим найти такую функцию $\hat{f}$, что $Y \approx \hat{f}(X)$ для любого наблюдения (X, Y) . В общих чертах большинство методов статистического обучения для решения этой задачи можно разделить на *параметрические* и *непараметрические*.

параметрические и непараметрические методы

Параметрические методы

Параметрические методы подразумевают основанную на модели процедуру из двух шагов.

1. Во-первых, мы делаем некоторое предположение о функциональной форме f . Например, одно из простых предположений заключается в том, что f является линейной функцией от X :

$$f(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p. \quad (2.4)$$

Это *линейная модель*, которая будет детально обсуждаться в главе 3. Как только мы допустили, что f имеет линейную форму, проблема оценивания f значительно упрощается. Вместо нахождения совершенно произвольной p -мерной функции $f(X)$ нам нужно будет оценить лишь $p + 1$ коэффициентов $\beta_0, \beta_1, \dots, \beta_p$.

2. После выбора модели нам потребуется процедура, которая использует обучающие данные для *подгонки*, или *обучения*, модели. В случае линейной модели (2.4) нам необходимо оценить параметры $\beta_0, \beta_1, \dots, \beta_p$. Другими словами, мы хотим найти такие значения этих параметров, при которых

подгонка обучение

$$Y \approx \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p.$$

Наиболее распространенный метод для подгонки модели (2.4) известен как *метод наименьших квадратов*, и мы обсудим его в главе 3. Однако метод наименьших квадратов является лишь одним из многих возможных способов. В главе 6 мы рассмотрим другие подходы для нахождения параметров уравнения (2.4).

метод наименьших квадратов

¹ Синонимами этого термина являются «обучающая выборка» и «обучающее множество», которые также будут использоваться в дальнейшем. — Прим. пер.




РИСУНОК 2.4. Линейная модель, подогнанная по методу наименьших квадратов к данным Income (см. рис. 2.3). Выборочные значения представлены точками красного цвета, а желтая плоскость показывает подогнанную к данным модель

Описанный выше подход, основанный на модели, называется *параметрическим*; он сводит проблему оценивания f к проблеме оценивания некоторого набора параметров. Допущение о параметрической форме f упрощает проблему нахождения этой функции, поскольку, как правило, оценить набор параметров $\beta_0, \beta_1, \dots, \beta_p$ линейной модели (2.4) гораздо проще, чем подогнать совершенно произвольную функцию f . Потенциальный недостаток параметрического подхода заключается в том, что выбираемая нами модель обычно не будет совпадать с истинной неизвестной формой f . Если выбранная модель слишком отличается от истинной, то наша оценка f будет плохой. Мы можем попытаться решить эту проблему, выбрав *гибкие* модели, которые способны описать многие из возможных функциональных форм f . В целом, однако, подгонка более гибкой модели требует оценивания большего числа параметров. Такие более сложные модели могут приводить к явлению, известному как *переобучение*, которое, в сущности, означает то, что эти модели начинают слишком близко аппроксимировать ошибками, или *шум*, в данных. Эти проблемы обсуждаются на протяжении всей книги.

Рисунок 2.4 демонстрирует пример применения параметрического метода к данным Income (см. рис. 2.3). Мы подогнали линейную модель вида

$$\text{income} \approx \beta_0 + \beta_1 \times \text{education} + \beta_2 \times \text{seniority}.$$

Поскольку мы допустили наличие линейной связи между откликом и этими двумя предикторами, то вся проблема по подгонке модели сводится к оцениванию β_0, β_1 и β_2 , которое мы выполняем с использованием линейной регрессии по методу наименьших квадратов. Сравнивая рис. 2.3 и 2.4, мы можем увидеть, что представленная на рис. 2.4 линейная модель не вполне верна: истинная функция f имеет некоторый изгиб, который

не отражен в этой линейной модели. Тем не менее линейная модель, похоже, хорошо справляется с задачей по описанию положительной зависимости между `education` и `income`, а также несколько менее выраженной положительной зависимости между `seniority` и `income`. Возможно, что при таком небольшом числе наблюдений это лучшее, что мы можем сделать.




РИСУНОК 2.5. Гладкий сплайн типа «тонкая пластина», подогнанный к данным `Income` (см. рис. 2.3), показан желтым цветом; выборочные наблюдения представлены точками красного цвета. Сплайны обсуждаются в главе 7

Непараметрические методы

Непараметрические методы не делают явных предположений в отношении функциональной формы f . Вместо этого они выполняют поиск такой оценки f , которая приближается к данным максимально близко, не будучи при этом слишком грубой или слишком извилистой. Такие подходы могут иметь существенное преимущество по сравнению с параметрическими методами: избегая предположения о конкретной функциональной форме f , они способны точно описать более широкий ряд возможных форм f . Любой параметрический подход несет с собой возможность того, что используемая для оценивания f функциональная форма значительно отличается от истинной функции, вследствие чего итоговая модель будет плохо описывать данные. В то же время непараметрические методы полностью уходят от этой опасности, поскольку, по сути, не делается никакого предположения о форме f . Однако непараметрические методы страдают существенным недостатком: поскольку они не сводят проблему оценивания f к ограниченному набору параметров, то для получения точной оценки f требуется очень большое число наблюдений (намного больше, чем обычно необходимо для какого-либо параметрического метода).

Пример применения непараметрического метода для описания данных `Income` показан на рис. 2.5. Для оценивания f использован сплайн типа

сплайн
типа
«тонкая
пластина»

«тонкая пластина». Этот метод не предписывает f какую-либо предварительно заданную модель. Вместо этого он пытается получить такую оценку f , которая максимально близко находилась бы к наблюдаемым данным, при условии что эта аппроксимация является *гладкой*. В рассматриваемом случае непараметрический метод дал удивительно точную оценку истинной функции f , показанной на рис. 2.3. Для подгонки сплайна типа «тонкая пластина» аналитик должен выбрать степень сглаживания. Рисунок 2.6 изображает результат подгонки такого же сплайна с меньшим уровнем сглаживания, который позволяет получить более неровную плоскость. Полученная функция в точности соответствует данным! Однако сплайн, показанный на рис. 2.6, намного более изменчив в сравнении с истинной функцией f из рис. 2.3. Это — пример переобучения, о котором мы говорили ранее. Такая ситуация нежелательна, поскольку полученная модель не будет давать точных предсказаний по новым наблюдениям, не входившим в состав исходного набора данных. Мы обсуждаем методы подбора *корректной* степени сглаживания в главе 5. Сплайны обсуждаются в главе 7.




РИСУНОК 2.6. Грубый сплайн типа «тонкая пластина», подогнанный к данным Income (рис. 2.3). Эта модель не делает ошибок на обучающих данных

Как мы выяснили, параметрические и непараметрические методы имеют свои преимущества и недостатки. На протяжении этой книги мы рассматриваем оба подхода.

2.1.3 Компромисс между точностью предсказаний и интерпретируемостью модели

Некоторые из методов, рассматриваемых нами в этой книге, являются менее гибкими, или более ограниченными, в том смысле, что они способны породить лишь относительно небольшой набор функциональных форм

для оценивания f . Например, линейная регрессия является относительно негибким подходом, поскольку она может порождать только линейные функции вроде линий на рис. 2.1 или плоскости на рис. 2.4. Другие методы, такие как сплайны типа «тонкая пластина», приведенные на рис. 2.5 и 2.6, являются намного более гибкими, так как они могут порождать гораздо более широкий спектр возможных форм для оценивания f .



РИСУНОК 2.7. Один из способов представить компромисс между гибкостью и интерпретируемостью разных методов статистического обучения. В целом при возрастании гибкости метода его интерпретируемость снижается

Резонно мог бы возникнуть следующий вопрос: зачем нам вообще выбирать более ограниченный метод вместо очень гибкого метода? Имеется несколько причин предпочесть более ограниченную модель. Если мы преимущественно заинтересованы в статистических выводах, то ограниченные модели являются гораздо более интерпретируемыми. Например, когда целью является статистический вывод, линейная модель может быть хорошим выбором, поскольку довольно легко будет понять взаимоотношения между Y и $X_1, X_2, \dots, X_p$. В то же время очень гибкие методы, такие как сплайны, обсуждаемые в главе 7 и показанные на рис. 2.5 и 2.6, а также методы бустинга, обсуждаемые в главе 8, могут приводить к настолько сложным оценкам f , что будет трудно понять, как любой отдельно взятый предиктор связан с откликом.

Рисунок 2.7 иллюстрирует компромисс между гибкостью и интерпретируемостью некоторых методов, рассматриваемых нами в этой книге. Обсуждаемая в главе 3 линейная регрессия по методу наименьших квадратов является относительно негибкой, но при этом вполне интерпретируемой. Метод *лассо*, обсуждаемый в главе 6, основан на линейной модели (2.4), но использует альтернативную процедуру для оценивания коэффициентов $\beta_1, \beta_2, \dots, \beta_p$. Эта новая процедура накладывает более жесткие ограничения при нахождении оценок коэффициентов и приравнивает некоторые из них в точности к нулю. Следовательно, в этом смысле лассо является менее гибким подходом, чем линейная регрессия. Кроме того, этот ме-

обобщен-
ные
аддитив-
ные
модели

бэггинг
бустинг
метод
опорных
векторов

тод легче поддается интерпретации по сравнению с линейной регрессией, поскольку в конечной модели переменная-отклик будет зависеть только от небольшого подмножества предикторов, а именно тех, чьи оценки коэффициентов оказались отличными от нуля. В то же время *обобщенные аддитивные модели* (GAM)², обсуждаемые в главе 7, расширяют (2.4), позволяя моделировать определенные нелинейные зависимости. Как следствие GAM являются более гибкими, чем линейная регрессия. Они также несколько менее интерпретируемы, чем линейная регрессия, поскольку связь между каждым предиктором и откликом в них моделируется с использованием кривой. Наконец, полностью нелинейные методы, такие как *бэггинг*, *бустинг* и *метод опорных векторов* с нелинейными ядрами, обсуждаемые в главах 8 и 9, являются чрезвычайно гибкими подходами, которые трудно интерпретировать.

Мы выяснили, что в случаях, когда целью анализа является статистический вывод, есть явные преимущества в использовании простых и относительно негибких методов статистического обучения. Однако в некоторых ситуациях мы заинтересованы только в предсказании, а интерпретируемость предсказательной модели нам просто неинтересна. Например, если мы пытаемся разработать алгоритм для предсказания цены акций, то единственным нашим требованием к алгоритму будет точность прогноза — интерпретируемость значения не имеет. В такой ситуации мы могли бы ожидать, что лучше всего будет использовать наиболее гибкую из имеющихся моделей. Удивительно, но это не всегда так! Часто мы будем получать более точные предсказания с помощью менее гибкого метода. Это явление, которое на первый взгляд может показаться нелогичным, объясняется склонностью более гибких методов к переобучению. Мы видели пример переобучения на рис. 2.6. Подробнее мы будем обсуждать эту важную концепцию в разделе 2.2 и в других частях книги.

2.1.4 Обучение с учителем и без учителя

с учителем
и без
учителя

Большинство проблем статистического обучения попадает в одну из двух категорий: *обучение с учителем* и *без учителя*. Все рассмотренные до сих пор примеры из этой главы относятся к категории обучения с учителем. Для каждого измеренного значения предиктора x_i , где $i = 1, \dots, n$, имеется соответствующее значение отклика y_i . Мы желаем построить модель, которая описывает связь между откликом и предикторами с целью точного предсказания отклика для будущих наблюдений (прогнозирование) или для лучшего понимания взаимоотношений между откликом и предикторами (статистические выводы). Многие классические методы статистического обучения, такие как линейная регрессия и *логистическая регрессия* (глава 4), а также более современные подходы, вроде GAM, бустинга и метода опорных векторов, относятся к категории обучения с учителем. Таким проблемам посвящена большая часть этой книги.

логисти-
ческая
регрессия

Обучение без учителя, в свою очередь, описывает несколько более сложную ситуацию, в которой для каждого наблюдения $i = 1, \dots, n$ мы имеем вектор измерений x_i , но без соответствующего отклика y_i . Подогнать линейную регрессионную модель невозможно, поскольку подлежащая предсказанию зависимая переменная отсутствует. При таком сценарии

² Аббревиатура от «generalized additive models». — Прим. пер.

рии мы в некотором смысле работаем вслепую: подобную ситуацию называют обучением *без учителя*, поскольку у нас нет зависимой переменной, которая «руководила» бы нашим анализом. Какой статистический анализ все же возможен? Мы можем попытаться понять взаимоотношения между переменными или между наблюдениями. Один из статистических инструментов, который мы можем использовать в такой ситуации, — это *кластерный анализ*, или кластеризация. Цель кластерного анализа заключается в установлении того, разделяются ли наблюдения $x_1, \dots, x_n$ на относительно четко выраженные группы. Например, в исследовании по сегментированию рынка мы могли бы учесть различные характеристики (переменные) для потенциальных клиентов, такие как почтовый индекс, семейный доход и покупательские привычки. Мы могли бы ожидать, что клиенты образуют разные группы, такие как «тратящие много» и «тратящие мало». Если бы информация по стоимости покупок была доступна для каждого клиента, тогда было бы возможным обучение с учителем. Однако такая информация отсутствует, т. е. мы не знаем покупательную способность потенциальных клиентов. При таком сценарии мы можем попытаться выполнить кластерный анализ на основе измеренных переменных с целью определить обособленные группы клиентов. Обнаружение подобных групп может представлять интерес в связи с тем, что они могут различаться в отношении некоторой интересной характеристики, такой как типичные траты на покупки.

кластер-
ный
анализ




РИСУНОК 2.8. Кластеризация данных, содержащих три группы. Каждая группа показана с использованием разных цветных символов. Слева: три группы хорошо разделены. В такой ситуации кластерный анализ успешно их обнаружит. Справа: группы в определенной степени перекрываются. Здесь задача кластеризации является более сложной

На рис. 2.8 представлен простой пример проблемы кластеризации. Мы изобразили 150 наблюдений со значениями двух переменных — X_1 и X_2 . Каждое наблюдение соответствует одной из трех отдельных групп. В целях демонстрации члены каждой группы обозначены нами в виде разноцветных символов. Однако на практике групповые принадлежности неиз-

вестны, и задача заключается именно в определении группы, к которой относится каждое наблюдение. На рис. 2.8 слева эта задача довольно проста, поскольку группы хорошо разделены. В то же время рисунок справа иллюстрирует более трудную задачу, в которой имеется некоторое перекрытие между группами. Нельзя ожидать, что в этом случае метод кластеризации правильно отнесет все перекрывающиеся точки к их соответствующим группам (голубой, зеленой или оранжевой).

В примерах, показанных на рис. 2.8, есть только две переменные, и поэтому для обнаружения кластеров можно просто визуально изучить диаграммы рассеяния. Однако на практике мы часто сталкиваемся с данными, которые содержат намного больше, чем две переменные. В таких случаях представить наблюдения на графике непросто. Например, если в нашем наборе данных есть p переменных, то можно будет построить $p(p - 1)/2$ отдельных диаграмм рассеяния, и их визуальное инспектирование для обнаружения кластеров будет просто невыполнимо. По этой причине важную роль играют методы автоматической кластеризации. Мы обсуждаем кластеризацию и другие методы обучения без учителя в главе 10.

Многие проблемы естественным образом распадаются на категории обучения с учителем и без учителя. Однако иногда вопрос о том, к какой из этих двух категорий следует отнести конкретный анализ, менее ясен. Предположим, например, что у нас есть набор из n наблюдений. Для m наблюдений, где $m < n$, у нас имеются измерения как для предикторов, так и для отклика. Для остальных $n - m$ наблюдений у нас есть измерения предикторов, но нет отклика. Подобный сценарий может возникать, когда измерение предикторов является относительно дешевым, но сбор информации по соответствующим откликам сопряжен с гораздо большими затратами. Мы называем такую ситуацию проблемой *обучения смешанного типа*. В этом случае желательно применить такой метод статистического обучения, который включает как те m наблюдений, для которых измерения отклика доступны, так и те $n - m$ наблюдений, для которых такие измерения отсутствуют. Хотя это очень интересная тема, она лежит за рамками данной книги.

2.1.5 Различия между проблемами регрессии и классификации

Переменные можно охарактеризовать либо как *количественные*, либо как *качественные* (последние известны также как «*категориальные*»). Количественные переменные принимают числовые значения. В качестве примеров можно привести возраст, рост и доход человека, стоимость дома и цену акций. В свою очередь, качественные переменные принимают значения, соответствующие одному из K различных *классов*, или категорий. Примеры качественных переменных: пол человека (мужской или женский), бренд купленного продукта (A, B или C), переход в категорию неплательщиков по долгам (да или нет), а также диагноз ракового заболевания (острая миелоидная лейкемия, острая лимфобластическая лейкемия или отсутствие лейкемии). Обычно проблемы, связанные с количественным откликом, называют проблемами *регрессии*, тогда как проблемы, связанные с качественным откликом, часто называют проблемами *классификации*.

обучение
смешанно-
го типа

типы пере-
менных

класс

регрессия
и класси-
фикация

Однако это различие не всегда бывает таким четким. Регрессия по методу наименьших квадратов (глава 3) используется для количественного отклика, тогда как логистическая регрессия обычно применяется для качественного *бинарного* отклика (т. е. пеменной с двумя классами). Поэтому логистическая регрессия часто используется как метод классификации. Но поскольку этот метод оценивает вероятности классов, о нем можно думать также и как о методе регрессии. Некоторые статистические методы, такие как метод K ближайших соседей (главы 2 и 4) и бустинг (глава 8), могут применяться как для количественных, так и для качественных откликов.

Обычно мы выбираем метод на основе того, является ли отклик количественным или качественным; например, мы могли бы использовать линейную регрессию для количественного отклика и логистическую регрессию — для качественного. В то же время тип предикторов (т. е. являются ли они количественными или качественными) обычно считается менее важным. Большинство обсуждаемых в этой книге методов статистического обучения может применяться вне зависимости от типа предикторов, при условии что перед выполнением анализа все качественные предикторы должным образом *закодированы*.

2.2 Описание точности модели

Одна из ключевых целей этой книги заключается в том, чтобы представить читателю широкий круг методов статистического обучения, выходящих далеко за рамки стандартного подхода линейной регрессии. Зачем описывать столько разных методов статистического обучения вместо одного, *самого лучшего* метода? В статистике *бесплатный сыр бывает только в мышеловке*: ни один из методов не доминирует над другими для всех возможных наборов данных. На некотором конкретном наборе данных тот или иной метод может оказаться оптимальным, тогда как другие методы могут сработать лучше на похожих или отличающихся данных. Поэтому выбор метода, который дает наилучшие результаты для имеющегося набора данных, представляет собой важную задачу. Выбор такого метода может оказаться одним из самых трудных аспектов применения статистического обучения на практике.

В этом разделе мы обсуждаем некоторые из наиболее важных концепций, возникающих при выборе процедуры статистического обучения для того или иного набора данных. По мере дальнейшего изложения мы будем объяснять, как представленные здесь концепции можно применять на практике.

2.2.1 Измерение качества модели

Чтобы оценить эффективность некоторого метода статистического обучения в отношении имеющегося набора данных, нам необходим способ для измерения того, насколько хорошо полученные при помощи этого метода предсказания совпадают с наблюдаемыми данными. Другими словами, нам нужно количественно выразить степень того, насколько предсказанное значение отклика близко к истинному значению отклика у соответ-

средне-
квадра-
тичная
ошибка

ствующего наблюдения. В регрессионном анализе наиболее часто используемой для этого мерой является *среднеквадратичная ошибка* (MSE)³, вычисляемая как

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{f}(x_i))^2, \quad (2.5)$$

где $\hat{f}(x_i)$ — это предсказанное значение, которое $\hat{f}$ дает для i -го наблюдения. MSE будет низкой, если предсказанные значения отклика очень близки к истинным значениям, и высокой, если для некоторых наблюдений предсказанные и истинные значения существенно разнятся.

MSE в (2.5) вычисляется на основе обучающих данных, которые были использованы для подгонки модели, и поэтому точнее будет называть ее *ошибкой на обучающей выборке*⁴. Однако обычно нас не очень заботит то, как хорошо метод работает на обучающих данных. Вместо этого мы *заинтересованы в точности предсказаний, которые мы получаем, когда применяем наш метод к не использованным ранее контрольным данным*. Почему это нас заботит? Представьте, что мы заинтересованы в разработке алгоритма предсказания цены акций на основе их доходности в прошлом. Мы можем обучить некоторый метод, используя значения доходности акций за последние 6 месяцев. Однако нам не очень интересно, насколько хорошо наш метод предсказывает значения цены акций для прошлой недели. Вместо этого нас интересует то, как хорошо он будет предсказывать цену на завтра или для следующего месяца. В том же ключе представьте, что у нас есть измерения клинических показателей (например, вес, давление крови, рост, возраст, семейная история болезни) для нескольких пациентов, а также информация о том, болен ли каждый пациент диабетом. Мы можем использовать этих пациентов, чтобы обучить статистический метод для предсказания риска диабета на основе клинических измерений. В действительности мы хотим, чтобы этот метод верно предсказывал риск диабета для *будущих пациентов* на основе их клинических измерений. Нам не очень интересно, насколько точно метод предсказывает риск диабета для пациентов, использованных для обучения модели, поскольку мы уже знаем, кто из этих пациентов болен.

Чтобы выразить это математически, представьте, что мы подгоняем нашу статистическую модель к обучающим наблюдениям $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ и получаем оценку $\hat{f}$. Далее мы можем вычислить $\hat{f}(x_1), \hat{f}(x_2), \dots, \hat{f}(x_n)$. Если полученные значения примерно равны $y_1, y_2, \dots, y_n$, то MSE на обучающей выборке, рассчитанная по (2.5), окажется низкой. Однако нам совсем нет дела то того, что $\hat{f}(x_i) \approx y_i$; вместо этого мы хотим знать, является ли величина $\hat{f}(x_0)$ примерно равной y_0 , где (x_0, y_0) — *неизвестное ранее проверочное наблюдение, которое не использовалось при обучении статистической модели*. Мы хотим выбрать такой метод, который дает минимальную *ошибку на контрольной выборке*⁵, а не минимальную ошибку на обучающей выборке. Другими словами,

³ Аббревиатура от «mean squared error». — Прим. пер.

⁴ Синонимами являются также термины «ошибка на обучающих данных», «ошибка на обучающем множестве» и «ошибка обучения». — Прим. пер.

⁵ Синонимами являются также термины «ошибка на проверочной выборке», «ошибка на тестовой выборке» и «ошибка на проверочном множестве». — Прим. пер.

ошибка на
обучаю-
щей
выборке

контроль-
ная
выборка

ошибка на
контроль-
ной
выборке

располагая большим количеством наблюдений, мы могли бы вычислить

$$\text{Ave}(y_0 - \hat{f}(x_0))^2, \quad (2.6)$$

то есть среднеквадратичную ошибку предсказаний для этих проверочных наблюдений (x_0, y_0) . Мы хотели бы выбрать такую модель, для которой это среднее значение — среднеквадратичная ошибка на контрольной выборке — является как можно меньшим.

Каким же образом нам выбрать метод, минимизирующий MSE на контрольной выборке? В некоторых случаях у нас в распоряжении может оказаться набор контрольных данных, т. е. мы можем иметь доступ к набору наблюдений, которые не были использованы для обучения статистической модели. Тогда мы можем просто вычислить величину из (2.6) по этим проверочным наблюдениям и выбрать метод статистического обучения с наименьшей контрольной MSE. Но как быть, если проверочные наблюдения недоступны? В этом случае теоретически можно было бы выбрать метод статистического обучения, который минимизирует MSE на обучающей выборке. Это могло бы показаться разумным подходом, поскольку MSE на обучающей и контрольной выборках выглядят тесно связанными между собой. К сожалению, у этой стратегии есть фундаментальная проблема: нет гарантии, что метод с минимальной MSE на обучающих данных также будет иметь минимальную MSE на контрольных данных. Грубо говоря, проблема заключается в том, что многие статистические методы специально оценивают коэффициенты с целью минимизации MSE на обучающей выборке. Ошибка обучения у этих методов может быть довольно низкой, но MSE на контрольных данных часто гораздо выше.

Рисунок 2.9 иллюстрирует этот феномен на простом примере. Слева на этом рисунке приведены наблюдения, которые были сгенерированы нами на основе (2.1), а истинная функция f показана кривой черного цвета. Оранжевая, голубая и зеленая кривые иллюстрируют три возможные оценки f , полученные при помощи методов с возрастающим уровнем гибкости. Оранжевая линия представляет собой линейную регрессионную модель, которая относительно негибка. Голубая и зеленая кривые были получены при помощи обсуждаемых в главе 7 *сглаживающих сплайнов* с разными уровнями гладкости. Хорошо видно, что по мере увеличения гибкости кривые все ближе подступают к наблюдениям. Зеленая кривая является наиболее гибкой и описывает данные очень хорошо; однако мы видим, что она слабо напоминает истинную функцию f (показана черным) в силу своей извилистости. Изменяя уровень гибкости сглаживающего сплайна, мы можем подогнать к этим данным много разных моделей.

сглажива-
ющий
сплайн

Перейдем теперь к графику, приведенному на рис. 2.9 справа. Серая линия показывает среднее значение MSE на обучающей выборке в зависимости от уровня гибкости, или, более формально, от *числа степеней свободы*, для нескольких сглаживающих сплайнов. Число степеней свободы представляет собой величину, которая обобщает гибкость кривой; более подробно это понятие обсуждается в главе 7. Оранжевые, голубые и зеленые квадраты показывают ошибки обучения, связанные с соответствующими кривыми на рисунке слева. Более ограниченная и, следовательно, более гладкая кривая имеет меньше степеней свободы, чем извилистая кривая (заметьте, что на рис. 2.9 линейная регрессия имеет две степени свободы и является наиболее ограниченной). MSE на обучающей выборке

число
степеней
свободы




РИСУНОК 2.9. Слева: данные, имитированные на основе f , показаны полыми точками черного цвета. Представлены три способа подгонки f : линейная регрессия (оранжевая линия) и две модели гладких сплайнов (голубая и зеленая линии). Справа: среднеквадратичная ошибка на обучающих (серая линия) и контрольных данных (красная линия), а также минимально возможное значение ошибки для контрольных данных (пунктирная линия). Квадратные символы соответствуют ошибкам на обучающих и контрольных выборках, которые были получены для трех моделей, изображенных на графике слева

монотонно снижается по мере возрастания гибкости. В этом примере истинная функция f нелинейна, в связи с чем линейная модель (оранжевый цвет) недостаточно гибка для получения удовлетворительной оценки f . Из всех трех методов зеленая кривая имеет наименьшую MSE на обучающих данных, поскольку она соответствует наиболее гибкой из трех моделей, представленных на графике слева.

В этом примере истинная функция f нам известна, и поэтому мы также можем вычислить MSE для очень большой контрольной совокупности в зависимости от гибкости модели. (Конечно, как правило, f неизвестна, и такие вычисления будут невозможны.) MSE на контрольной выборке показана на рис. 2.9 справа в виде красной кривой. Как и в случае с MSE на обучающих данных, MSE на контрольной выборке сначала снижается по мере увеличения гибкости. Однако в какой-то момент MSE на контрольной выборке снова начинает возрастать. Как следствие оранжевая и зеленая кривые имеют самые высокие ошибки на контрольных данных. Голубая кривая имеет минимальную MSE на контрольной выборке, что не должно удивлять, поскольку визуально эта модель выглядит как наилучшая оценка f (см. рис. 2.9 слева). Горизонтальная прерывистая линия показывает $\text{Var}(\epsilon)$ — неустранимую ошибку из (2.3), которая соответствует наименьшей достижимой MSE на контрольных данных для всех возможных методов. Следовательно, сглаживающий сплайн, показанный в виде голубой линии, близок к оптимуму.

Как видно на рис. 2.9 (справа), по мере возрастания гибкости метода статистического обучения происходит монотонное снижение MSE на обучающих данных и *U-образное* изменение MSE на контрольных данных. Это является фундаментальным свойством статистического обучения, которое остается справедливым для любого имеющегося набора данных и для любого применяемого статистического метода. По мере увеличения гибкости модели MSE на обучающей выборке будет снижаться, но MSE на контрольной выборке не обязательно будет вести себя тем же образом. Ситуацию, когда некоторый метод обеспечивает небольшую MSE на обучающих данных и высокую MSE на проверочных данных, называют *переобучением* модели. Это происходит потому, что наша процедура статистического обучения слишком усердно пытается найти закономерности в обучающих данных и в результате может обнаружить некоторые закономерности, которые просто случайны и никак не связаны с истинными свойствами неизвестной функции f . При переобучении модели MSE на контрольной выборке будет большой потому, что предполагаемые закономерности, найденные нашим методом в обучающих данных, в проверочных данных просто не существуют. Заметьте, что вне зависимости от того, случилось ли переобучение, мы почти всегда ожидаем, что MSE на обучающих данных будет ниже, чем MSE на контрольных данных, поскольку большинство методов статистического обучения так или иначе пытаются минимизировать ошибку обучения. К переобучению относят также частный случай, когда менее гибкая модель обеспечивает меньшую MSE на контрольных данных.




РИСУНОК 2.10. То же, что на рис. 2.9, но с истинной функцией f , которая намного ближе к линейной. В этой ситуации линейная регрессия очень хорошо описывает данные

На рис. 2.10 приведен пример, в котором истинная функция f приблизительно линейна. Как и раньше, мы наблюдаем монотонное снижение MSE на обучающих данных по мере возрастания гибкости модели, а кривая MSE на контрольных данных имеет *U-образную* форму. Одна-

ко в связи с тем, что истинная зависимость близка к линейной, MSE на контрольных данных лишь незначительно снижается перед последующим возрастанием, и поэтому оранжевая линия, подогнанная по методу наименьших квадратов, подходит для описания данных гораздо лучше, чем очень гибкая зеленая кривая. Наконец, рис. 2.11 иллюстрирует пример, в котором функция f в значительной мере нелинейна. Кривые MSE для обучающих и контрольных выборок по-прежнему демонстрируют те же общие закономерности, но теперь имеет место быстрое снижение обеих этих кривых, перед тем как MSE на контрольных данных начинает медленно возрастать.

На практике вычислить MSE по обучающим данным относительно легко, однако оценить MSE на контрольных данных гораздо труднее, поскольку они обычно отсутствуют. Как показывают предыдущие три примера, уровень гибкости, соответствующий модели с наименьшей контрольной MSE, может значительно варьировать в зависимости от свойств данных. В этой книге мы обсуждаем целый ряд подходов, которые можно использовать на практике получения оценки этого минимального значения. Одним из важных методов, предназначенных для оценивания MSE на контрольных данных, является *перекрестная проверка*⁶ (глава 5).




РИСУНОК 2.11. То же, что на рис. 2.9, но с истинной функцией f , существенно отличной от линейной. В этой ситуации линейная регрессия описывает данные очень плохо

2.2.2 Компромисс между смещением и дисперсией

Оказывается, что U-образная форма кривых, описывающих MSE на контрольных данных (рис. 2.9–2.11), является результатом двух конкурирующих свойств методов статистического обучения. Хотя математическое доказательство выходит за рамки этой книги, можно показать, что для

⁶ Используются также термины «кросс-проверка», «кросс-валидация» и «скользящий контроль». — Прим. пер.

некоторого контрольного значения x_0 ожидаемую MSE всегда можно разложить на сумму трех фундаментальных величин: дисперсии $\hat{f}(x_0)$, квадрата смещения $\hat{f}(x_0)$ и дисперсии остатков ϵ . Другими словами⁷:

дисперсия
смещение

$$E \left(y_0 - \hat{f}(x_0) \right)^2 = \text{Var}(\hat{f}(x_0)) + [\text{Bias}(\hat{f}(x_0))]^2 + \text{Var}(\epsilon). \quad (2.7)$$

Здесь $E \left(y_0 - \hat{f}(x_0) \right)^2$ обозначает математическое ожидание ошибки на контрольной выборке и представляет собой среднее значение MSE, которое мы получили бы при многократном повторном оценивании f на основе большого числа обучающих выборок и вычислении ошибки для каждого контрольного значения x_0 . Общую ожидаемую MSE на контрольной выборке можно вычислить путем усреднения $E \left(y_0 - \hat{f}(x_0) \right)^2$ для всех возможных проверочных значений x_0 .

математи-
ческое
ожидание
ошибки

Уравнение (2.7) говорит нам о том, что для минимизации ожидаемой ошибки на проверочных данных мы должны выбрать такой метод статистического обучения, который одновременно обеспечивает низкую дисперсию и низкое смещение. Заметьте, что дисперсия по определению является положительной величиной, равно как и квадрат смещения. В итоге мы видим, что математическое ожидание MSE на контрольной выборке никогда не может быть ниже неустранимой ошибки $\text{Var}(\epsilon)$ из уравнения (2.3).

Что мы понимаем под дисперсией и смещением метода статистического обучения? Дисперсия означает величину, на которую $\hat{f}$ изменилась бы при оценивании этой функции с использованием другой обучающей выборки. Поскольку для подгонки модели используются обучающие данные, то разные обучающие выборки будут приводить к разным $\hat{f}$. В идеале оценки $\hat{f}$, полученные на разных выборках, должны варьировать незначительно. Однако если некоторый метод обладает высокой дисперсией, то небольшие изменения в обучающих данных могут привести к большим изменениям в $\hat{f}$. В целом более гибкие статистические методы имеют более высокую дисперсию. Рассмотрим зеленую и оранжевую кривые на рис. 2.9. Гибкая зеленая кривая очень близко следует за отдельными наблюдениями. Она обладает высокой дисперсией, поскольку изменение любого наблюдения может вызвать значительное изменение оценки $\hat{f}$. В то же время подогнанная по методу наименьших квадратов оранжевая кривая является относительно негибкой и имеет низкую дисперсию, поскольку сдвиг любого наблюдения приведет, скорее всего, лишь к небольшому сдвигу положения этой кривой.

В свою очередь, смещение означает ошибку, вводимую за счет аппроксимирования проблемы из реального мира, которая может оказаться чрезвычайно сложной, при помощи гораздо более простого метода. Например, линейная регрессия предполагает, что между Y и $X_1, X_2, \dots, X_p$ имеется линейная зависимость. Маловероятно, что какая-либо проблема из реального мира действительно описывается такой простой зависимостью, в связи с чем применение линейной регрессии несомненно приведет к определенному смещению оценки f . На рис. 2.11 истинная функция f явно нелинейна, и поэтому не важно, как много наблюдений у нас есть

⁷ В соответствии с англоязычными терминами Var и Bias в приведенной формуле обозначают дисперсию и смещение соответственно. — Прим. пер.

в распоряжении — верную оценку при помощи линейной регрессии получить здесь будет невозможно. Другими словами, линейная регрессия в этом примере вызывает большое смещение. Однако на рис. 2.10 истинная функция f очень близка к линейной, и поэтому при наличии достаточного объема данных линейная регрессия сможет дать верную оценку. В целом более гибкие методы вызывают меньшее смещение.

Как правило, при использовании более гибких методов дисперсия будет возрастать, а смещение — снижаться. Относительная скорость изменения этих двух величин определяет направление изменения MSE на контрольной выборке. По мере увеличения гибкости некоторого класса методов снижение смещения вначале обычно происходит быстрее, чем рост дисперсии. В результате этого математическое ожидание MSE на контрольной выборке снижается. Однако в определенный момент возрастающая гибкость перестает оказывать влияние на смещение, но при этом вызывает рост дисперсии. Когда это происходит, MSE на контрольной выборке возрастает. Заметьте, что мы уже наблюдали такое начальное снижение ошибки на контрольных данных и последующее ее возрастание (см. графики, представленные справа на рис. 2.9–2.11).




РИСУНОК 2.12. Квадрат смещения (голубая кривая), дисперсия (оранжевая кривая), $\text{Var}(\epsilon)$ (пунктирная линия) и MSE на контрольной выборке (красная кривая) для трех наборов данных, показанных на рис. 2.9–2.11. Вертикальная пунктирная линия показывает уровень гибкости, соответствующий наименьшей MSE

Три графика на рис. 2.12 иллюстрируют свойства уравнения (2.7) на примере данных, показанных на рис. 2.9–2.11. В каждом случае сплошная синяя линия показывает квадрат смещения для разных уровней гибкости, а оранжевая кривая соответствует дисперсии. Горизонтальная прерывистая линия отражает $\text{Var}(\epsilon)$ — неустранимую ошибку. Наконец, красная кривая, соответствующая MSE на контрольной выборке, является суммой этих трех величин. Во всех трех случаях по мере увеличения гибкости метода дисперсия возрастает, а смещение снижается. Однако уровень гибкости, соответствующий оптимальной MSE на контрольной выборке, значительно различается между этими тремя наборами данных, поскольку

квадрат смещения и дисперсия в каждом случае изменяются с разными скоростями. На рис. 2.12 слева уровень смещения поначалу быстро падает, вызывая резкое начальное снижение математического ожидания MSE на контрольной выборке. С другой стороны, на центральной графике рис. 2.12 истинная функция f близка к линейной, в связи с чем имеет место лишь небольшое снижение уровня смещения по мере увеличения гибкости, а MSE на контрольной выборке незначительно снижается перед началом быстрого роста по мере увеличения дисперсии. Наконец, на рисунке 2.12 справа с увеличением гибкости наблюдается значительное падение уровня смещения, поскольку истинная функция f существенно нелинейна. Имеется также очень небольшое возрастание дисперсии по мере роста гибкости. В результате MSE на контрольной выборке значительно падает, перед тем, как снова начать медленно возрастать по мере увеличения гибкости.

Связь между смещением, дисперсией и MSE на контрольной выборке, описанная в уравнении 2.7 и показанная на рис. 2.12, известна как *компромисс между смещением и дисперсией*⁸. Хороший результат, достигаемый методом статистического обучения на контрольных данных, требует как низкой дисперсии, так и низкого квадрата смещения. Это называют компромиссом, поскольку можно легко получить метод с чрезвычайно низким смещением, но высокой дисперсией (например, нарисовав кривую, которая проходит через каждую точку обучающей выборки), или метод с очень низкой дисперсией, но высоким смещением (путем подгонки горизонтальной линии к данным). Трудность заключается в нахождении метода, у которого малы как дисперсия, так и квадрат смещения. Данный компромисс является одной из наиболее важных тем этой книги.

компро-
мисс

В практической ситуации, когда функция f неизвестна, выполнить непосредственный расчет MSE на контрольных данных, уровня смещения и дисперсии для некоторого метода статистического обучения обычно невозможно. Тем не менее следует всегда помнить о компромиссе между смещением и дисперсией. В этой книге мы рассматриваем методы, которые являются чрезвычайно гибкими и поэтому могут фактически полностью устранить смещение. Однако это не гарантирует того, что они будут работать лучше более простого метода, такого как линейная регрессия. В качестве экстремального примера предположим, что истинная функция f является линейной. В этой ситуации линейная регрессия будет обладать нулевым смещением, в связи с чем более сложному методу будет сложно конкурировать. Однако если истинная функция f в значительной мере нелинейна и у нас есть много обучающих наблюдений, тогда, возможно, нам стоит воспользоваться более гибким методом, как показано на рис. 2.11. В главе 5 мы обсуждаем перекрестную проверку, которая представляет собой способ оценки контрольной MSE с использованием обучающих данных.

2.2.3 Задачи классификации

До сих пор при обсуждении качества моделей мы фокусировались на задачах регрессии. Однако многие из встретившихся нам концепций, таких как компромисс между смещением и дисперсией, переносятся на задачи классификации лишь с небольшими модификациями, обусловленны-

⁸ В оригинале используется термин «bias-variance trade-off». — Прим. пер.

частота
ошибок

ми тем, что y_i больше не являются количественными значениями. Предположим, что мы пытаемся оценить f на основе обучающих наблюдений $\{(x_1, y_1), \dots, (x_n, y_n)\}$, где $y_1, \dots, y_n$ теперь представляют собой значения качественной переменной. Наиболее распространенный способ количественного описания точности нашей оценки $\hat{f}$ заключается в расчете *частоты ошибок* на обучающей выборке, т.е. доли ошибок, допущенных при применении нашей оцененной функции $\hat{f}$ к обучающим наблюдениям:

$$\frac{1}{n} \sum_{i=1}^n I(y_i \neq \hat{y}_i). \quad (2.8)$$

индикаторная
переменная

Здесь $\hat{y}_i$ представляет собой метку класса, предсказанную для i -го наблюдения при помощи $\hat{f}$. $I(y_i \neq \hat{y}_i)$ — это *индикаторная переменная*⁹, равная 1 при $y_i \neq \hat{y}_i$ и 0 при $y_i = \hat{y}_i$. Если $I(y_i \neq \hat{y}_i) = 0$, то i -е наблюдение было предсказано нашим методом классификации правильно; иначе оно классифицировано неверно. Следовательно, уравнение (2.8) позволяет вычислить долю неправильно классифицированных случаев.

ошибка
обучения

Величину из уравнения 2.8 называют *частотой ошибок на обучающей выборке*, поскольку она рассчитывается на основе данных, используемых для обучения нашего классификатора. Как и в задачах регрессии, нам более всего интересны частоты ошибок, получаемые в результате применения нашего классификатора к контрольным наблюдениям, которые не использовались в ходе обучения модели. *Частота ошибок на контрольной выборке*, связанная с набором проверочных наблюдений вида (x_0, y_0) , вычисляется как¹⁰

ошибка на
контрольной
выборке

$$\text{Ave}(I(y_0 \neq \hat{y}_0)), \quad (2.9)$$

где $\hat{y}_0$ представляет собой метку класса, полученную в результате применения классификатора к проверочному наблюдению с вектором предикторов x_0 . *Хорошим* является тот классификатор, у которого ошибка (2.9) минимальна.

Байесовский классификатор

Можно показать (хотя математическое доказательство выходит за рамки данной книги), что средняя частота ошибок на контрольных данных, приведенная в (2.9), минимизируется очень простым классификатором, который *присваивает каждому наблюдению наиболее вероятный класс с учетом соответствующих значений предикторов*. Другими словами, нам следует отнести проверочное наблюдение с вектором предикторов x_0 к такому классу j , для которого вероятность

$$\Pr(Y = j | X = x_0) \quad (2.10)$$

условная
вероятность

максимальна. Заметьте, что (2.10) представляет собой *условную вероятность*¹¹, т.е. вероятность того, что $Y = j$ при наблюдаемом векторе предикторов x_0 . Этот очень простой классификатор называют *байесовским*

⁹ В оригинале используется термин «indicator variable». В русскоязычных источниках применяется также термин «фиктивная переменная». — Прим. пер.

¹⁰ Ave означает усреднение (от «average»). — Прим. пер.

¹¹ В оригинале используется термин «conditional probability». — Прим. пер.

классификатором. В проблеме с двумя классами, где имеется только два возможных значения отклика, например *класс 1* или *класс 2*, байесовский классификатор предсказывает класс 1, если $\Pr(Y = 1|X = x_0) > 0.5$, и класс 2 в остальных случаях.

байесов-
ский
классифи-
катор

На рис. 2.13 приведен пример с использованием имитированного набора данных в двумерном пространстве, образованном предикторами X_1 и X_2 . Оранжевые и синие кружки соответствуют обучающим наблюдениям, которые принадлежат к двум разным классам. Для каждого значения X_1 и X_2 имеется своя вероятность того, что отклик относится к «оранжевому» или «синему классу». Поскольку это имитированные данные, то мы знаем, как они были получены, и мы можем вычислить условные вероятности для каждой пары значений X_1 и X_2 . Закрашенная оранжевым цветом область отражает множество точек, для которых $\Pr(Y = \text{оранжевый}|X)$ превышает 50%, тогда как область, закрашенная синим цветом, показывает множество точек, для которых эта вероятность ниже 50%. Фиолетовая пунктирная линия соответствует точкам, для которых вероятность в точности равна 50%. Эта линия называется *байесовской решающей границей*¹². Предсказание байесовского классификатора определяется байесовской решающей границей: наблюдение, попадающее в оранжевую область, будет отнесено к «оранжевому классу», а наблюдение, попадающее в синюю область, — к «синему классу».

байесов-
ская
решающая
граница




РИСУНОК 2.13. Набор имитированных данных, состоящий из 100 наблюдений в каждой группе (обозначены синим и оранжевым цветами). Фиолетовая пунктирная линия соответствует байесовской решающей границе. Фоновая сетка оранжевого цвета обозначает область, в которой наблюдение из контрольной выборки будет отнесено к «оранжевому» классу, а сетка синего цвета соответствует области, в которой контрольное наблюдение будет отнесено к «синему» классу

¹² В оригинале используется термин «Bayes decision boundary». — Прим. пер.

Байесовский классификатор обеспечивает наименьшую возможную частоту ошибок на контрольной выборке, называемую *байесовской частотой ошибок*. Поскольку байесовский классификатор всегда выберет класс, для которого величина (2.10) максимальна, частота ошибок при $X = x_0$ составит $1 - \max_j \Pr(Y = j|X = x_0)$. В целом общая байесовская частота ошибок вычисляется как

$$1 - E \left(\max_j \Pr(Y = j|X) \right), \quad (2.11)$$

где математическое ожидание есть средняя вероятность, рассчитанная по всем возможным значениям X . Для наших имитированных данных байесовская частота ошибок составляет 0.1304. Это больше 0, поскольку классы в генеральной совокупности перекрываются и $\Pr(Y = j|X = x_0) < 1$ для некоторых значений x_0 . Байесовская частота ошибок аналогична обсуждавшейся ранее неустранимой ошибке.

Метод K ближайших соседей

Теоретически для предсказания качественного отклика всегда желательно было бы использовать байесовский классификатор. Однако для реальных данных мы не знаем условного распределения Y при заданном X , и поэтому вычисление байесовского классификатора невозможно. Следовательно, байесовский классификатор служит в качестве недостижимого золотого стандарта, с которым сравниваются другие методы. Многие методы пытаются оценить условное распределение Y при заданном X и затем относят то или иное наблюдение к классу с наибольшей *оцененной* вероятностью. Одним из них является *метод K ближайших соседей* (KNN)¹³. Для некоторого положительного целого числа K и контрольного наблюдения x_0 классификатор KNN сначала определяет K наблюдений из обучающей выборки (обозначаются как $\mathcal{N}_0$), которые находятся максимально близко к x_0 . Затем он оценивает условную вероятность для класса j как долю примеров в $\mathcal{N}_0$, у которых значение отклика равно j :

$$\Pr(Y = j|X = x_0) = \frac{1}{K} \sum_{i \in \mathcal{N}_0} I(y_i = j). \quad (2.12)$$

Наконец, KNN применяет теорему Байеса и относит проверочное наблюдение x_0 к классу с наибольшей вероятностью.

На рис. 2.14 приведен пример, поясняющий метод KNN. На графике слева мы изобразили небольшой обучающий набор данных, состоящий из шести голубых и шести оранжевых точек. Наша цель — сделать предсказание для точки, обозначенной черным крестиком. Предположим, что мы выбрали $K = 3$. Тогда KNN сначала определит три наблюдения, расположенных к крестику ближе всего. Эта близлежащая область обозначена кругом. Она содержит две синие точки и одну оранжевую, что приводит к вероятности $2/3$ для «синего класса» и $1/3$ для «оранжевого класса». Следовательно, KNN предскажет, что черный крестик принадлежит к «синему классу». На рис. 2.14 справа мы применили метод KNN с $K = 3$

¹³ Аббревиатура от «K-nearest neighbors». — Прим. пер.

для всех возможных значений X_1 и X_2 и изобразили соответствующую решающую границу.

Несмотря на то что это очень простой подход, KNN часто может приводить к созданию классификаторов, которые удивительно близки к оптимальному байесовскому классификатору. На рис. 2.15 показана решающая граница метода KNN с $K = 10$, примененного к большому по размеру набору имитированных данных из рис. 2.13. Обратите внимание: даже несмотря на то, что истинная решающая граница классификатору KNN неизвестна, его решающая граница очень похожа на границу байесовского классификатора. Частота ошибок на контрольной выборке при использовании KNN составляет 0.1363, что близко к байесовской частоте ошибок — 0.1304.




РИСУНОК 2.14. Метод KNN с $K = 3$ проиллюстрирован на простом примере с шестью «синими» и шестью «оранжевыми» наблюдениями. Слева: подлежащее классификации наблюдение из контрольной выборки показано черным крестиком. Определены три ближайшие к этому наблюдению точки, в результате чего оно отнесено к наиболее часто встречающемуся среди соседей классу — в данном случае к «синему классу». Справа: решающая граница KNN из этого примера показана линией черного цвета. Синяя сетка соответствует области, в которой наблюдение из контрольной выборки будет отнесено к «синему классу», а сетка оранжевого цвета — области, в которой наблюдение из контрольной выборки будет отнесено к «оранжевому классу»

Выбор K имеет огромный эффект на итоговый классификатор KNN. На рис. 2.16 приведены две модели KNN, подогнанные к имитированным данным из рис. 2.13 с использованием $K = 1$ и $K = 100$. При $K = 1$ решающая граница чрезмерно гибка и обнаруживает закономерности в данных, которые не согласуются с байесовской решающей границей. Это соответствует классификатору с низким смещением и очень высокой дисперсией. По мере увеличения K метод становится менее гибким и формирует решающую границу, похожую на прямую линию. Это соответствует классификатору с низкой дисперсией и высоким смещением. Для этих




РИСУНОК 2.15. Черная линия показывает решающую границу KNN для данных из рис. 2.13, найденную с использованием $K = 10$. Байесовская решающая граница представлена в виде фиолетовой пунктирной линии. Эти две решающие границы очень похожи

имитированных данных ни $K = 1$, ни $K = 100$ не дают хороших предсказаний: частоты ошибок на контрольных данных составляют 0.1695 и 0.1925 соответственно.

Как и в случае с регрессией, сильной связи между ошибкой на обучающих данных и ошибкой на контрольных данных нет. При $K = 1$ ошибка обучения KNN равна 0, однако ошибка на контрольных данных может быть довольно высокой. Как правило, при использовании более гибких методов частота ошибки на обучающей выборке будет снижаться, но частота ошибок на контрольной выборке не обязательно будет вести себя тем же образом. На рис. 2.17 мы изобразили ошибки KNN на обучающих и проверочных данных в зависимости от $1/K$. При увеличении $1/K$ этот метод становится более гибким. Подобно регрессионным моделям, при увеличении гибкости частота ошибок на обучающих данных равномерно снижается. Однако ошибка на контрольных данных проявляет характерную U -образную форму, поначалу снижаясь (с минимумом примерно на отметке $K = 10$), а затем снова возрастая, когда метод становится чрезмерно гибким и приводит к переобучению.

При решении задач как регрессии, так и классификации выбор правильного уровня гибкости является критическим для успеха любого метода статистического обучения. Компромисс между смещением и дисперсией и вытекающая из него U -образная форма кривой ошибки на контрольных данных могут сделать этот выбор тяжелой задачей. В главе 5 мы вернемся к данной теме и обсудим различные подходы для оценивания частот ошибок на контрольных выборках, а тем самым и нахождения оптимального уровня гибкости для того или иного метода статистического обучения.




РИСУНОК 2.16. Сравнение решающих границ KNN (черные сплошные линии), полученных по данным из рис. 2.13 с использованием $K = 1$ и $K = 100$. При $K = 1$ решающая граница получается чрезмерно гибкой, тогда как при $K = 100$ она недостаточно гибка. Байесовская решающая граница показана в виде фиолетовой пунктирной линии




РИСУНОК 2.17. Ошибки KNN-классификатора на обучающей (синяя кривая, 200 наблюдений) и контрольной выборках (оранжевая линия, 5000 наблюдений) для данных из рис. 2.13, показанные в зависимости от возрастающей гибкости ($1/K$) или, что эквивалентно, в зависимости от снижающегося числа соседей K . Черная пунктирная линия показывает байесовскую частоту ошибок. Извилистость кривых обусловлена малым размером обучающей выборки

2.3 Лабораторная работа: введение в R

В этой лабораторной работе мы представим некоторые простые команды R. Лучший способ изучения нового языка заключается в экспериментировании с его командами. R можно загрузить с сайта

<http://cran.r-project.org/>

2.3.1 Основные команды

функция Для выполнения тех или иных операций R использует *функции*. Для запуска функции с именем *funcname* мы набираем `funcname(input1, input2)`, где входные параметры, или *аргументы*, `input1` и `input2` сообщают R, как именно следует исполнить эту функцию. Например, для создания вектора с несколькими числами мы используем функцию *конкатенации* `c()`¹⁴. Следующая команда говорит R объединить числа 1, 3, 2 и 5 и сохранить их в виде вектора с именем `x`. Когда мы наберем `x`, то в ответ получим этот вектор.

```
> x <- c(1, 3, 2, 5)
> x
[1] 1 3 2 5
```

Обратите внимание на то, что `>` не является частью команды — R выводит этот знак просто, чтобы показать свою готовность к выполнению следующей команды. Мы можем сохранять объекты не только с помощью `<-`, но также и `=`:

```
> x = c(1, 6, 2)
> x
[1] 1 6 2
> y = c(1, 4, 3)
```

Множественное нажатие клавиши со стрелкой *вверх* приведет к показу предыдущих команд, которые можно отредактировать. Это полезно, поскольку необходимость повторения похожих команд возникает часто. Кроме того, ввод команды `?funcname` всегда откроет новое окно со справочным файлом, содержащим дополнительную информацию по функции `funcname`.

Мы можем попросить R выполнить сложение двух чисел. В этом случае программа сначала добавит первое число из `x` к первому числу из `y` и т. д. Однако `x` и `y` должны быть одинаковой длины. Мы можем проверить их длину при помощи функции `length()`.

```
> length(x)
[1] 3
> length(y)
[1] 3
> x + y
[1] 2 10 5
```

¹⁴ «Concatenate» значит «соединять», «объединять». — Прим. пер.

Функция `ls()` позволяет просмотреть список всех объектов, таких как данные и функции, которые мы сохранили до этого момента. Функцию `rm()` можно использовать для удаления любого нежелательного объекта.

```
> ls()
[1] "x" "y"
> rm(x, y)
> ls()
character (0)
```

Имеется также возможность удалить все объекты за один раз:

```
> rm(list = ls())
```

Функцию `matrix()` можно использовать для создания матрицы с числами. Перед применением функции `matrix()` мы можем узнать о ней больше:

```
> ?matrix
```

Справочный файл сообщает, что функция `matrix()` принимает несколько входных параметров, но пока мы сосредоточимся на первых трех: данные (элементы матрицы), количество строк и количество столбцов. Сначала создадим простую матрицу.

```
> x = matrix(data = c(1, 2, 3, 4), nrow = 2, ncol = 2)
> x
      [,1] [,2]
[1,]    1    3
[2,]    2    4
```

Обратите внимание, что мы могли бы с тем же успехом не набирать `data =`, `nrow =` и `ncol =` в приведенной выше команде `matrix()`, а просто ввести

```
x = matrix(c(1, 2, 3, 4), 2, 2)
```

и это имело бы тот же эффект. Однако иногда бывает полезно указать имена аргументов, т. к. иначе R будет предполагать, что аргументы функции подаются на нее в том же порядке, который приведен в справочном файле этой функции. Как показано в данном примере, по умолчанию R создает матрицы путем последовательного заполнения столбцов. В качестве альтернативы можно использовать опцию `byrow = TRUE` для заполнения матрицы по строкам.

```
> matrix(c(1, 2, 3, 4), 2, 2, byrow = TRUE)
      [,1] [,2]
[1,]    1    2
[2,]    3    4
```

Заметьте, что в приведенной выше команде мы не присвоили матрице никакого имени вроде `x`. В этом случае матрица выводится на экран, но не сохраняется для будущих вычислений. Функция `sqrt()` возвращает квадратный корень каждого элемента вектора или матрицы. Команда `x^2` возводит каждый элемент `x` в квадрат; возможно использование любой степени, включая дроби и отрицательные степени.

```
> sqrt(x)
      [,1] [,2]
[1,] 1.00 1.73
[2,] 1.41 2.00
> x^2
      [,1] [,2]
[1,]    1    9
[2,]    4   16
```

rnorm() Функция `rnorm()` генерирует вектор случайных нормально распределенных значений, при этом аргумент `n` задает размер выборки. Каждый раз при вызове этой функций мы будем получать другой результат. Здесь мы создаем два коррелирующих набора чисел — `x` и `y` — и применяем **cor()** функцию `cor()` для расчета корреляции между ними.

```
> x = rnorm(50)
> y = x + rnorm(50, mean = 50, sd = .1)
> cor(x, y)
[1] 0.995
```

По умолчанию `rnorm()` создает случайные переменные, представляющие стандартное нормальное распределение со средним значением 0 и стандартным отклонением 1. Однако, как показано выше, среднее значение и стандартное отклонение можно изменить при помощи аргументов `mean` и `sd`. Иногда мы хотим, чтобы наш код в точности воспроизводил один тот же набор случайных чисел; для этого мы можем использовать **set.seed()** функцию `set.seed()`. Функция `set.seed()` принимает в качестве аргумента произвольное целое число.

```
> set.seed(1303)
> rnorm(50)
[1] -1.1440 1.3421 2.1854 0.5364 0.0632 0.5022 -0.0004
. . .
```

Мы используем `set.seed()` во всех лабораторных работах каждый раз, когда выполняем вычисления, содержащие случайные величины. Как правило, это должно помочь пользователю воспроизвести наши результаты. Однако следует отметить, что с появлением новых версий R могут возникнуть небольшие несоответствия между книгой и тем, что выдает R.

mean() Функции `mean()` и `var()` можно использовать для вычисления среднего значения и дисперсии некоторого набора чисел. Применение `sqrt()` к результату работы `var()` даст стандартное отклонение. Или можно просто **mean()** применить функцию `sd()`.

```
> set.seed(3)
> y = rnorm(100)
> mean(y)
[1] 0.0110
> var(y)
[1] 0.7329
> sqrt(var(y))
[1] 0.8561
> sd(y)
[1] 0.8561
```

2.3.2 Графики

Использование функции `plot()` является основным способом визуализации данных в R. Например, `plot(x, y)` создаст график зависимости значений `y` от значений `x`. Имеется большое количество дополнительных опций, которые можно подать на функцию `plot()`. Например, использование аргумента `xlab` приведет к появлению заголовка оси `X`. Для получения дополнительной информации о функции `plot()` введите команду `?plot`.

```
> x = rnorm(100)
> y = rnorm(100)
> plot(x, y)
> plot(x, y, xlab = "this is the x-axis",
      ylab = "this is the y-axis", main = "Plot of X vs Y")
```

Часто у нас будет возникать желание сохранить построенный в R график. Используемая для этого команда будет зависеть от типа файла, который мы хотим создать. Например, для создания PDF-файла мы используем функцию `pdf()`, а для создания JPEG-файла — функцию `jpeg()`.

`pdf()`
`jpeg()`

```
> pdf("Figure.pdf ")
> plot(x, y, col = "green")
> dev.off()
null device
1
```

Функция `dev.off()` сообщает R, что мы завершили создание графика. В качестве альтернативы мы можем просто скопировать содержимое графического окна и вставить его в файл нужного типа, вроде документа Word.

Функцию `seq()` можно использовать для создания последовательности чисел. Например, `seq(a, b)` создает вектор из целых чисел от `a` до `b`. Есть много опций: например, `seq(0, 1, length = 10)` создаст последовательность из 10 чисел, которые равномерно размещены на промежутке от 0 до 1. Команда `3:11` является сокращенным вариантом `seq(3, 11)` для целых чисел.

`seq()`

```
> x = seq(1, 10)
> x
[1] 1 2 3 4 5 6 7 8 9 10
> x = 1:10
> x
[1] 1 2 3 4 5 6 7 8 9 10
> x = seq(-pi, pi, length = 50)
```

Теперь мы построим несколько более сложные графики. Функция `contour()` создает *контурную диаграмму* для изображения трехмерных данных, которая напоминает топографическую карту. Эта функция принимает три аргумента:

`contour()`
контурная
диаграмма

1. Вектор значений `x` (первое измерение),
2. Вектор значения `y` (второе измерение),

3. Матрица, чьи элементы соответствуют значениям z (третье измерение) для каждой пары координат (x, y) .

Как и в случае с функцией `plot()`, есть много входных параметров, которые можно использовать для тонкой настройки функции `contour()`. Чтобы узнать о них подробнее, просмотрите справочный файл, набрав `?contour`.

```
> y = x
> f = outer(x, y, function(x, y) cos(y)/(1 + x^2))
> contour(x, y, f)
> contour(x, y, f, nlevels = 45, add = T)
> fa = (f - t(f))/2
> contour(x, y, fa, nlevels = 15)
```

`image()` Функция `image()` работает так же, как и `contour()`, за исключением того, что она создает цветную диаграмму, где цвет зависит от значения z . Такая диаграмма известна как *тепловая карта* и иногда используется для изображения температуры в прогнозах погоды. В качестве альтернативы для создания трехмерных графиков можно использовать `persp()`. Аргументы `theta` и `phi` контролируют углы обзора графика.

```
> image(x, y, fa)
> persp(x, y, fa)
> persp(x, y, fa, theta = 30)
> persp(x, y, fa, theta = 30, phi = 20)
> persp(x, y, fa, theta = 30, phi = 70)
> persp(x, y, fa, theta = 30, phi = 40)
```

2.3.3 Индексирование данных

Часто мы хотим изучить только некоторую часть данных. Предположим, что наши данные хранятся в матрице A .

```
> A = matrix(1:16, 4, 4)
> A
      [,1] [,2] [,3] [,4]
[1,]    1    5    9   13
[2,]    2    6   10   14
[3,]    3    7   11   15
[4,]    4    8   12   16
```

Тогда выполнение команды

```
> A[2, 3]
[1] 10
```

приведет к выбору элемента, соответствующего второй строке и третьему столбцу. Первое число после открывающей скобки `[` всегда соответствует строке, а второе — столбцу. Мы можем также выбрать несколько строк и столбцов одновременно, указав векторы в качестве индексов.

```
> A[c(1, 3), c(2, 4)]
      [,1] [,2]
[1,]    5   13
[3,]    7   15
```

```
[1,]    5    13
[2,]    7    15
> A[1:3, 2:4]
      [,1] [,2] [,3]
[1,]    5    9    13
[2,]    6   10   14
[3,]    7   11   15
> A[1:2,]
      [,1] [,2] [,3] [,4]
[1,]    1    5    9   13
[2,]    2    6   10   14
> A[, 1:2]
      [,1] [,2]
[1,]    1    5
[2,]    2    6
[3,]    3    7
[4,]    4    8
```

В последних двух примерах отсутствует индекс либо для столбцов, либо для строк. Это означает, что следует включать все столбцы или все строки соответственно. R рассматривает одну строку или столбец матрицы как вектор.

```
> A[1,]
[1] 1 5 9 13
```

Использование знака минус – в индексе говорит R, что нужно оставить все строки или столбцы, за исключением указанных в этом индексе.

```
> A[-c(1, 3), ]
      [,1] [,2] [,3] [,4]
[1,]    2    6   10   14
[2,]    4    8   12   16
> A[-c(1, 3), -c(1, 3, 4)]
[1] 6 8
```

Функция `dim()` выводит размерность матрицы, т. е. число содержащихся в ней строк, за которым следует число столбцов. `dim()`

```
> dim(A)
[1] 4 4
```

2.3.4 Загрузка данных

Для большинства анализов первым шагом является импортирование набора данных в R. Функция `read.table()` — один из основных инструментов для этого. Справочный файл содержит детали, касающиеся использования этой функции. Для экспортирования данных мы можем использовать функцию `write.table()`.

`read.table()`

`write.table()`

Перед попыткой загрузить некоторый набор данных мы должны убедиться в том, что R знает правильную директорию, где нужно его искать. Например, в системе Windows можно было бы выбрать директорию при помощи опции `Change dir...` из раздела `File` главного меню. Однако

таблица
данных

детали того, как это сделать, зависят от используемой операционной системы (Windows, Mac, Unix), и поэтому дополнительную информацию мы здесь не приводим. Мы начинаем с загрузки набора данных `Auto`. Эти данные являются частью пакета `ISLR` (мы обсуждаем пакеты в главе 3), но для демонстрации функции `read.table()` мы загружаем их из текстового файла. Следующая команда загрузит файл `Auto.data` в R и сохранит его в виде объекта `Auto` в формате, который называется «таблица данных»¹⁵. (Этот текстовый файл можно найти на сайте книги.) После загрузки данных можно применить функцию `fix()` для просмотра этих данных в окне, напоминающем электронную таблицу. Однако перед вводом любых следующих команд эта таблица должна быть закрыта.

```
> Auto = read.table("Auto.data")
> fix(Auto)
```

Заметьте, что `Auto.data` — это просто текстовый файл, который вы могли бы открыть также на своем компьютере при помощи стандартного текстового редактора. Часто перед загрузкой того или иного набора данных в R хорошей идеей будет просмотреть его с использованием текстового редактора или других программ, таких как Excel.

Этот конкретный набор данных не был загружен корректно, поскольку система R предположила, что имена переменных являются частью данных и поэтому включила их в первую строку. Эти данные содержат также несколько пропущенных значений, отмеченных вопросительным знаком ?. Пропущенные значения — частое явление в реальных данных. Использование опции `header = T` (`header = TRUE`) при вызове функции `read.table()` сообщает R о том, что первая строка файла содержит имена переменных, а использование опции `na.strings` говорит R о том, что каждый раз при обнаружении определенного сочетания символов (например, вопросительного знака) это сочетание следует рассматривать в качестве пропущенного элемента матрицы.

```
> Auto = read.table("Auto.data", header = T, na.strings = "?")
> fix(Auto)
```

Excel — это программа для хранения данных в одном из распространенных форматов. Легким способом загрузки таких данных в R является сохранение их в виде CSV-файла (от «comma separated values», т.е. «значения, разделенные запятыми») и использование функции `read.table()` для загрузки.

```
> Auto = read.csv("Auto.csv", header = T, na.strings = "?")
> fix(Auto)
> dim(Auto)
[1] 397 9
> Auto [1:4, ]
```

`dim()` Функция `dim()` сообщает нам, что данные содержат 397 наблюдений, или строк, и девять переменных, или столбцов. Есть разные способы работы с пропущенными значениями. В данном случае пропущенные значения содержатся только в пяти строках, и поэтому мы используем функцию `na.omit()` `na.omit()`, чтобы просто удалить эти строки.

¹⁵ В оригинале используется термин «data frame». — Прим. пер.

```
> Auto = na.omit(Auto)
> dim(Auto)
[1] 392 9
```

После корректной загрузки данных мы можем применить функцию `names()` для просмотра имен переменных.

```
> names(Auto)
[1] "mpg"      "cylinders"  "displacement"  "horsepower"
[5] "weight"   "acceleration" "year"          "origin"
[9] "name"
```

2.3.5 Дополнительные графические и количественные сводки

Мы можем воспользоваться функцией `plot()` для создания *диаграмм рассеяния* количественных переменных. Однако простой ввод имен переменных приведет к сообщению об ошибке, поскольку R не знает, что эти переменные нужно искать в таблице `Auto`.

```
> plot(cylinders, mpg)
Error in plot(cylinders, mpg) : object 'cylinders' not found
```

Для обращения к переменной мы должны указать название набора данных и имя этой переменной, объединенные знаком `$`. В качестве альтернативы мы можем использовать функцию `attach()`, чтобы сообщить R о том, что переменные в этом наборе данных нужно сделать доступными по их имени.

```
> plot(Auto$cylinders, Auto$mpg )
> attach(Auto)
> plot(cylinders, mpg)
```

Переменная `cylinders`¹⁶ хранится в виде количественного вектора, и поэтому она была распознана R как количественная переменная. Но поскольку имеется лишь небольшое число возможных значений `cylinders`, эту переменную, возможно, следует рассматривать как качественную. Функция `as.factor()` конвертирует количественные переменные в качественные.

```
> cylinders = as.factor(cylinders)
```

Если отображенная на оси *X* переменная является качественной, то функция `plot()` автоматически построит *диаграмму размахов*. Как обычно, для настройки графика можно указать целый ряд опций.

```
> plot(cylinders, mpg)
> plot(cylinders, mpg, col = "red")
> plot(cylinders, mpg, col = "red", varwidth = T)
> plot(cylinders, mpg, col = "red", varwidth = T, horizontal=T)
> plot(cylinders, mpg, col = "red", varwidth = T,
      xlab = "cylinders", ylab = "MPG")
```

¹⁶ Речь идет о количестве цилиндров в двигателе автомобиля. — Прим. пер.

`hist()` Для построения *гистограммы* можно использовать функцию `hist()`.
 гистограм- Заметьте, что `col = 2` имеет тот же эффект, что и `col = "red"`.
 ма

```
> hist(mpg)
> hist(mpg, col = 2)
> hist(mpg, col = 2, breaks = 15)
```

матрица Функция `pairs()` создает *матрицу диаграмм рассеяния*, т.е. диаграмму
 диаграмм рассеяния для каждой пары переменных из того или иного набора данных.
 рассеяния Мы можем также построить диаграммы рассеяния только для определен-
 ного подмножества переменных.

```
> pairs(Auto)
> pairs(~ mpg + displacement + horsepower + weight +
  acceleration, Auto)
```

Сочетание функций `plot()` и `identify()` обеспечивает полезный интерактивный метод определения значений конкретной переменной на графике. Мы подаем на `identify()` три аргумента: переменные для отображения на осях X и Y и переменную, чьи значения мы хотели бы указать рядом с каждой точкой. Тогда щелчок мышью по некоторой точке на графике заставит R вывести соответствующее значение интересующей нас переменной. Щелчок правой кнопкой мыши по графику остановит работу функции `identify()` (Ctrl + щелчок на компьютерах Mac). Выведенные функцией `identify()` числа соответствуют порядковым номерам строк в таблице данных.

```
> plot(horsepower, mpg)
> identify(horsepower, mpg, name)
```

`summary()` Функция `summary()` рассчитывает количественные сводки по каждой переменной в конкретном наборе данных.

```
> summary(Auto)
```

mpg	cylinders	displacement
Min. : 9.00	Min. :3.000	Min. : 68.0
1st Qu. :17.00	1st Qu. :4.000	1st Qu. :105.0
Median :22.75	Median :4.000	Median :151.0
Mean :23.45	Mean :5.472	Mean :194.4
3rd Qu. :29.00	3rd Qu. :8.000	3rd Qu. :275.8
Max. :46.60	Max. :8.000	Max. :455.0

horsepower	weight	acceleration
Min. : 46.0	Min. :1613	Min. : 8.00
1st Qu. : 75.0	1st Qu. :2225	1st Qu. :13.78
Median : 93.5	Median :2804	Median :15.50
Mean :104.5	Mean :2978	Mean :15.54
3rd Qu. :126.0	3rd Qu. :3615	3rd Qu. :17.02
Max. :230.0	Max. :5140	Max. :24.80

year	origin	name
Min. :70.00	Min. :1.000	amc matador : 5
1st Qu. :73.00	1st Qu. :1.000	ford pinto : 5
Median :76.00	Median :1.000	toyota corolla : 5

Mean	:75.98	Mean	:1.577	amc gremlin	: 4
3rd Qu.	:79.00	3rd Qu.	:2.000	amc hornet	: 4
Max.	:82.00	Max.	:3.000	chevrolet chevette	: 4
				(Other)	:365

Для качественных переменных, таких как name, R перечислит число наблюдений, попадающих в каждую категорию. Мы можем также получить сводку только по одной переменной.

```
> summary(mpg)
  Min.  1st Qu.  Median    Mean 3rd Qu.  Max.
  9.00   17.00   22.75   23.45  29.00  46.60
```

Закончив использование R, мы вводим `q()` для завершения работы, или `q()` для выхода из программы. При выходе из R у нас есть возможность сохранить текущую *рабочую среду*, чтобы в следующий раз сделать доступными все объекты, которые мы создали во время этой сессии работы с R. Перед выходом из R мы можем захотеть сохранить историю всех команд, выполненных во время последней сессии; это можно сделать при помощи функции `savehistory()`. В следующий раз при запуске R мы можем загрузить эту историю команд при помощи функции `loadhistory()`.

рабочая среда
`savehistory()`
`loadhistory()`

2.4 Упражнения

Теоретические

- Для каждого из пунктов (a)–(d) укажите, будем ли мы обычно ожидать от гибкого статистического метода лучшего или худшего качества предсказаний, по сравнению с негибким методом. Обоснуйте свой ответ.
 - Размер выборки n очень большой, а количество предикторов p невелико.
 - Количество предикторов p очень большое, а число наблюдений n невелико.
 - Связь между предикторами и откликом в значительной мере нелинейна.
 - Дисперсия остатков, т. е. $\sigma^2 = \text{Var}(\epsilon)$, чрезвычайно велика.
- Объясните, является ли каждый из описанных ниже сценариев задачей на классификацию или регрессию, и укажите, заинтересованы ли мы больше в статистическом выводе или в предсказании. Наконец, приведите n и p .
 - Мы собираем данные по 500 наиболее успешным компаниям США. Для каждой компании мы учитываем доход, число работников, отрасль и заработную плату исполнительного директора. Мы заинтересованы в понимании факторов, которые влияют на зарплату исполнительного директора.

- (b) Мы собираемся запустить новый продукт и хотим знать, будет он *успешным* или *неуспешным*. Мы собираем данные по 20 похожим продуктам, запущенным ранее. Для каждого продукта мы учитываем его успех или провал, продажную цену, величину маркетингового бюджета, цену у конкурента и десять других переменных.
 - (c) Мы заинтересованы в предсказании процентного изменения курса доллара США в зависимости от недельных изменений цены акций на мировых рынках. В связи с этим мы собираем недельные данные для всего 2012 года. Для каждой недели мы учитываем процентное изменение курса доллара, а также процентные изменения цены акций на рынках США, Великобритании и Германии.
3. Теперь мы снова вернемся к разложению ошибки предсказаний на дисперсию и смещение.
- (a) Приведите набросок графика, где одновременно изображено поведение типичных кривых квадрата смещения, дисперсии, ошибки на обучающих данных, ошибки на контрольных данных и байесовской, или неустранимой, ошибки по мере увеличения гибкости методов статистического обучения. Ось X должна отражать уровень гибкости метода, а ось Y — значения для каждой кривой. Должно быть пять кривых. Убедитесь, что вы пометили каждую кривую.
 - (b) Объясните, почему каждая из пяти кривых имеет ту форму, которую вы изобразили, выполняя (a).
4. Теперь поразмышляем над некоторыми случаями практического применения методов статистического обучения.
- (a) Опишите три прикладные задачи, где полезной могла бы оказаться *классификация*. Опишите отклик и предикторы. Что является целью каждой задачи — статистический вывод или предсказание? Объясните свой ответ.
 - (b) Опишите три прикладные задачи, где полезной могла бы оказаться *регрессия*. Опишите отклик и предикторы. Что является целью каждой задачи — статистический вывод или предсказание? Объясните свой ответ.
 - (c) Опишите три прикладные задачи, где полезным мог бы оказаться *кластерный анализ*.
5. В чем заключаются преимущества и недостатки очень гибких методов регрессии и классификации (по сравнению с менее гибкими методами)? В каких условиях можно было бы предпочесть более гибкий метод менее гибкому? Когда предпочтительным мог бы оказаться менее гибкий метод?
6. Опишите различия между параметрическим и непараметрическим подходами к статистическому обучению. Каковы преимущества параметрического подхода к регрессии и классификации (по сравнению с непараметрическим подходом)? Каковы недостатки?

7. В приведенной ниже таблице представлено обучающее множество, состоящее из шести наблюдений, трех предикторов и одной качественной переменной.

Наблюдение	X_1	X_2	X_3	Y
1	0	3	0	Красный
2	2	0	0	Красный
3	0	1	3	Красный
4	0	1	2	Зеленый
5	-1	0	1	Зеленый
6	1	1	1	Красный

Предположим, мы хотим использовать этот набор данных, чтобы предсказать Y по $X_1 = X_2 = X_3 = 0$ при помощи метода K ближайших соседей.

- Вычислите евклидово расстояние между каждым наблюдением и контрольной точкой $X_1 = X_2 = X_3 = 0$.
- Каково наше предсказание при $K = 1$? Почему?
- Каково наше предсказание при $K = 3$? Почему?
- Если байесовская решающая граница в этой проблеме является высоконелинейной, будет ли *оптимальное* значение K высоким или низким? Почему?

Практические

8. Это упражнение касается набора данных College, который можно найти в файле `College.csv`. Он содержит несколько переменных для 777 университетов и колледжей США. К этим переменным относятся:

- **Private**: индикатор того, является ли заведение публичным или частным;
- **Apps**: количество полученных заявлений на поступление;
- **Accept**: количество принятых абитуриентов;
- **Enroll**: количество новых зарегистрированных студентов;
- **Top10perc**: количество новых студентов, входивших в список 10% лучших учеников своего класса в средней школе;
- **Top25perc**: количество новых студентов, входивших в список 25% лучших учеников своего класса в средней школе;
- **F.Undegrad**: количество студентов, занимающихся полный рабочий день;
- **P.Undegrad**: количество студентов, занимающихся неполный рабочий день;
- **Outstate**: плата за обучение для студентов из других штатов;

- Room.Board: плата за проживание и питание;
- Books: стоимость учебников;
- Personal: примерные затраты на личные нужды;
- PhD: процент преподавателей с ученой степенью;
- Terminal: процент преподавателей с самой высокой ученой степенью в соответствующей области науки;
- S.F.Ratio: соотношение между численностью студентов и преподавателей;
- perc.alumni: процент бывших выпускников, делающих денежные пожертвования;
- Expend: затраты заведения на обучение одного студента;
- Grad.Rate: процент студентов, завершающих полный цикл обучения.

Перед загрузкой данных в R их можно просмотреть в программе Excel или в текстовом редакторе.

- (a) Примените функцию `read.csv()` для загрузки данных в R. Присвойте загруженным данным имя `college`. Убедитесь, что вы задали правильную директорию, в которой хранятся эти данные.
- (b) Просмотрите данные при помощи функции `fix()`. Вы должны заметить, что первый столбец просто содержит названия университетов. Мы не очень хотим, чтобы этот столбец рассматривался R как данные. Однако эти названия могут оказаться полезными позднее. Попробуйте следующие команды:

```
> rownames(college) = college[, 1]  
> fix(college)
```

Вы должны увидеть, что теперь появился столбец `row.names` с названиями всех исследованных университетов. Это означает, что система R присвоила каждой строке имя, соответствующее тому или иному университету. R не будет пытаться выполнять вычисления над именами строк. Однако нам все еще нужно удалить первый столбец, в котором хранятся названия университетов. Попробуйте

```
> college = college[, -1]  
> fix(college)
```

Теперь вы должны видеть, что первым столбцом в данных является `Private`. Заметьте, что перед столбцом `Private` появился еще один столбец с заголовком `row.names`. Однако этот столбец не является частью данных — это имена, присвоенные R каждой строке.

- (c) i. Примените функцию `summary()` для вывода количественной сводки по имеющимся в таблице переменным.

- ii. Примените функцию `pairs()` для построения матрицы диаграмм рассеяния по первым десяти столбцам, или переменным. Помните, что вы можете обратиться к первым десяти столбцам матрицы `A`, используя `A[, 1:10]`.
- iii. Создайте новую качественную переменную `Elite`, разбив на классы переменную `Top10perc`. Мы собираемся разделить университеты на две группы в зависимости от того, превышает ли 50% доля студентов, входивших в список 10% лучших учеников своих классов в средней школе.

```
> Elite = rep("No", nrow(college))
> Elite[college$Top10perc > 50] = "Yes"
> Elite = as.factor(Elite)
> college = data.frame(college, Elite)
```

Примените функцию `summary()` для нахождения числа элитных университетов. Теперь примените функцию `plot()` для создания диаграммы размахов по переменным `Outstate` и `Elite`.

- iv. Воспользуйтесь функцией `hist()` и для нескольких количественных переменных постройте гистограммы с разным числом классов. Полезной для вас может оказаться команда `par(mfrow = c(2, 2))`: она разделит окно графического устройства на четыре области, что сделает возможным построение четырех графиков одновременно. Изменение аргументов этой функции приведет к разделению экрана иным образом.
 - v. Продолжите изучение данных и приведите небольшое обобщение ваших находок.
9. Это упражнение касается набора данных `Auto`, рассмотренных в лабораторной работе. Убедитесь, что пропущенные значения в этой таблице были удалены.
- (a) Какие предикторы являются количественными, а какие — качественными?
 - (b) Каков *размах* значений каждого предиктора? Вы можете ответить на этот вопрос при помощи функции `range()`.
 - (c) Каковы среднее значение и стандартное отклонение каждого количественного предиктора?
 - (d) Теперь удалите 10-е и 85-е наблюдения. Чему равны размах, среднее значение и стандартное отклонение каждого предиктора в оставшемся наборе данных?
 - (e) Используя полный набор данных, исследуйте предикторы графически при помощи диаграмм рассеяния или других инструментов на ваш выбор. Создайте несколько графиков, характеризующих взаимоотношения между предикторами. Прокомментируйте свои находки.
 - (f) Предположим, что мы хотим предсказать расход топлива (`mpg`) на основе других переменных. Указывают ли ваши графики

`range()`

на то, что какие-то переменные могли бы оказаться полезными для предсказания `mpg`? Обоснуйте свой ответ.

10. Это упражнение касается набора данных Boston.

пакет

(a) Данные Boston являются частью пакета MASS.

```
> library(MASS)
```

Теперь данные содержатся в объекте Boston.

```
> Boston
```

Почитайте об этом наборе данных:

```
> ?Boston
```

Сколько строк в этом наборе данных? Сколько столбцов? Что представляют собой эти строки и столбцы?

- (b) Сделайте несколько парных диаграмм рассеяния для предикторов (столбцов) из этого набора данных. Опишите свои находки.
- (c) Связаны ли какие-то из предикторов с уровнем преступности в расчете на душу населения (переменная `crim`)? Если да, то объясните эту связь.
- (d) Похоже ли, что некоторые из пригородов Бостона имеют особенно высокие уровни преступности? Налоговые ставки (`tax`)? Отношение численности учащихся к численности учителей (`ptratio`)? Прокомментируйте размах значений каждого предиктора.
- (e) Через сколько пригородов из этого набора данных протекает река Чарльз (`chas`)?
- (f) Чему равна медиана отношения численности учащихся к численности учителей в пригородах из этого набора данных?
- (g) Какой из пригородов Бостона имеет самое низкое медианное значение числа домов, занятых их владельцами (`medv`)? Чему равны значения других предикторов у этого пригорода и насколько они отличаются от значений соответствующих предикторов в целом? Прокомментируйте свои находки.
- (h) У какого количества пригородов из этого набора данных среднее число комнат в доме (`rm`) больше семи? Больше восьми? Опишите пригороды, где число комнат в доме в среднем выше восьми.

Глава 3

Линейная регрессия

Эта глава посвящена *линейной регрессии* — очень простому методу обучения с учителем. В частности, линейная регрессия является полезным инструментом для предсказания количественного отклика. Линейная регрессия применялась на протяжении длительного времени, и о ней написано бесчисленное количество учебников. Хотя она может показаться несколько скучной в сравнении с некоторыми другими, более современными методами статистического обучения, описанными в последующих главах этой книги, линейная регрессия по-прежнему является полезным и широко применяемым методом. В связи с этим невозможно переоценить важность хорошего понимания линейной регрессии для последующего освоения других, более сложных методов обучения. В этой главе мы даем обзор некоторых ключевых идей, лежащих в основе линейной регрессионной модели, а также метода наименьших квадратов, который чаще всего используется для подгонки этой модели.

Вспомните данные Advertising из главы 2. На рис. 2.1 показан объем продаж некоторого продукта (*sales*, тыс. единиц) в зависимости от размера бюджета для рекламы на телевидении (*TV*), радио (*radio*) и в газетах (*newspaper*). Представьте, что нас в качестве консультантов-статистиков попросили воспользоваться этими данными и предложить такой маркетинговый план на следующий год, который приведет к высоким продажам продукта. Какая информация была бы полезной для разработки подобной рекомендации? Вот некоторые важные вопросы, на которые нам, возможно, следует обратить внимание:

1. *Существует ли зависимость между размером рекламного бюджета и объемом продаж?* Наша первая цель должна заключаться в установлении того, указывают ли данные на наличие связи между затратами на рекламу и продажами. Если оснований для такого заключения мало, то можно утверждать, что деньги на рекламу тратить не стоит.
2. *Насколько сильна связь между размером рекламного бюджета и продажами?* Допустив наличие связи между рекламой и объемом продаж, мы хотели бы выяснить силу этой связи. Другими словами, можем ли мы с высокой точностью предсказать объем продаж, исходя из заданного размера рекламного бюджета? Это был бы случай тесной связи. А может быть, прогноз продаж на основе затрат

на рекламу лишь немногим лучше случайного угадывания? Это был бы случай слабой связи.

3. *Какое средство массовой информации способствует продажам?* Способствуют ли продажам все три информационных канала — телевидение, радио и газеты, или только один или два канала? Для ответа на этот вопрос мы должны найти способ выделить эффекты отдельных СМИ при одновременной затрате денег на все три из них.
4. *Насколько точно мы можем оценить влияние каждого СМИ на продажи?* Насколько увеличатся продажи в расчете на каждый доллар, затраченный на рекламу в конкретном СМИ? Насколько точно мы можем предсказать этот прирост?
5. *Насколько точно мы можем спрогнозировать будущие продажи?* Каков наш прогноз объема продаж и насколько он точен для того или иного уровня затрат на рекламу на телевидении, радио и в газетах?
6. *Является ли связь линейной?* Если имеет место примерно прямолинейная зависимость между затратами на рекламу в разных СМИ и объемом продаж, то линейная регрессия будет подходящим методом. Если же это не так, то у нас все еще есть возможность преобразовать предикторы или отклик таким образом, чтобы сделать линейную регрессию применимой.
7. *Существует ли синергия между рекламой в разных СМИ?* Возможно, что затраты в размере 50 000\$ на телерекламу и 50 000\$ на радио-рекламу приводят к большим продажам, нежели затраты в размере 100 000\$ на рекламу только на телевидении или только на радио. В маркетинге этот эффект известен как *синергия*, тогда в статистике его называют эффектом *взаимодействия*.

синергия
взаимо-
действие

Оказывается, что линейную регрессию можно использовать для получения ответов на каждый из этих вопросов. Сначала мы обсудим все эти вопросы в общем контексте, а затем вернемся к ним в разделе 3.4 в контексте этой конкретной задачи.

3.1 Простая линейная регрессия

Простая линейная регрессия полностью соответствует своему названию: это очень простой подход для предсказания количественного отклика Y на основе единственной независимой переменной X . Он подразумевает, что между X и Y существует примерно линейная зависимость. Математически мы можем записать линейную регрессию как

простая
линейная
регрессия

$$Y \approx \beta_0 + \beta_1 X. \quad (3.1)$$

Знак $\approx$ означает «*примерно моделируется как*». Иногда мы будем говорить о (3.1) как о *регрессии Y на X* (или *Y по X*). Например, X может представлять собой затраты на телерекламу (TV), а Y — объем продаж

(sales). Тогда мы можем построить регрессию sales по TV, подогнав модель

$$\text{sales} \approx \beta_0 + \beta_1 \text{TV}.$$

В уравнении 3.1 β_0 и β_1 — это константы, известные как *свободный член* и *угол наклона* линейной модели. В более общем виде β_0 и β_1 называют *коэффициентами*, или *параметрами*, модели. Применив наши обучающие данные для нахождения оценок коэффициентов β_0 и β_1 , мы можем предсказать будущие объемы продаж на основе того или иного размера затрат на телерекламу путем вычисления

свободный член

угол наклона

коэффициент параметр

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x, \quad (3.2)$$

где $\hat{y}$ — это значение Y , предсказанное по $X = x$. Здесь мы используем символ $\hat{}$ («крышечка») для обозначения оцененного значения неизвестного параметра, или коэффициента, или для обозначения предсказанной величины отклика.

3.1.1 Оценивание коэффициентов

На практике β_0 и β_1 неизвестны. Поэтому перед тем, как мы сможем применить (3.1) для получения предсказаний, мы должны воспользоваться данными для нахождения оценок коэффициентов. Пусть

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

представляют собой n пар наблюдений, каждая из которых состоит из значения X и значения Y . В примере с данными Advertising у нас есть размер бюджета на телерекламу и объем продаж продукта в $n = 200$ различных регионах. (Напомним, что эти данные представлены на рис. 2.1.) Наша цель заключается в получении оценок коэффициентов β_0 и β_1 таким образом, чтобы линейная модель (3.1) хорошо описывала данные, т. е. чтобы $y_i \approx \hat{\beta}_0 + \hat{\beta}_1 x_i$ для $i = 1, \dots, n$. Другими словами, мы хотим найти такие свободный член $\hat{\beta}_0$ и угловой коэффициент $\hat{\beta}_1$, чтобы итоговая линия располагалась максимально близко к $n = 200$ наблюдениям. Существует большое количество способов выразить *близость*. Однако наиболее обычный подход сводится к минимизации критерия *наименьших квадратов*, и мы применяем этот подход в данной главе. Альтернативные методы будут рассмотрены в главе 6.

критерий наименьших квадратов

Пусть $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ представляет собой значение Y , предсказанное на основе i -го значения X . Тогда $e_i = y_i - \hat{y}_i$ — это i -й *остаток*, т. е. разница между i -м наблюденным значением отклика и i -м значением отклика, предсказанным нашей линейной моделью. Мы определяем *сумму квадратов остатков* (RSS)¹ как

остаток

сумма квадратов остатков

$$\text{RSS} = e_1^2 + e_2^2 + \dots + e_n^2,$$

или в эквивалентной форме как

¹ Аббревиатура от «residual sum of squares». — Прим. пер.

$$\text{RSS} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \dots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2. \quad (3.3)$$

Метод наименьших квадратов находит такие $\hat{\beta}_0$ и $\hat{\beta}_1$, которые минимизируют RSS. Применяв некоторые вычисления, можно показать, что эти оптимальные оценки представляют собой

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}, \quad (3.4)$$

где $\bar{y} \equiv \frac{1}{n} \sum_{i=1}^n y_i$ и $\bar{x} \equiv \frac{1}{n} \sum_{i=1}^n x_i$ — выборочные средние. Другими словами, (3.4) дает определение оценок коэффициентов простой линейной регрессии по методу наименьших квадратов.




РИСУНОК 3.1. Для данных Advertising показана регрессия объема продаж (sales) по затратам на телерекламу (TV), подогнанная по методу наименьших квадратов. Модель найдена путем минимизации суммы квадратов остатков. Каждый серый отрезок соответствует остатку, и модель подгоняется на основе компромисса, заключающегося в усреднении квадратов этих остатков. В данном случае линейная модель в целом передает суть зависимости, хотя в левой части графика она несколько неадекватна

Рисунок 3.1 демонстрирует простую линейную регрессию, подогнанную по данным Advertising, где $\hat{\beta}_0 = 7.03$, а $\hat{\beta}_1 = 0.0475$. Иными словами, согласно этой аппроксимации, потраченные на телерекламу дополнительные 1000\$ приводят к продаже примерно 47.5 дополнительной единицы продукта. На рис. 3.2 мы рассчитали RSS для нескольких значений β_0 и β_1 по данным Advertising, используя sales в качестве отклика и TV в качестве предиктора. На каждой диаграмме красная точка представляет собой пару оценок (β_0, β_1) , полученных по методу наименьших квадратов в соответствии с (3.4). Хорошо видно, что эти значения минимизируют RSS.




РИСУНОК 3.2. Контурная и трехмерная диаграммы RSS для данных Advertising с использованием sales в качестве отклика и TV в качестве предиктора. Красные точки соответствуют оценкам $\hat{\beta}_1$ и $\hat{\beta}_2$, полученным по методу наименьших квадратов согласно (3.4)

3.1.2 Точность оценок коэффициентов

Согласно (2.1), мы предполагаем, что истинная зависимость между X и Y принимает форму $Y = f(X) + \epsilon$ для некоторой неизвестной функции f , где ϵ — случайные ошибки с нулевым средним. Если f аппроксимируется линейной функцией, то мы можем записать эту зависимость как

$$Y = \beta_0 + \beta_1 X + \epsilon. \tag{3.5}$$

Здесь β_0 представляет собой свободный член уравнения, т.е. ожидаемое значение Y при $X = 0$, а β_1 — угловой коэффициент, т.е. среднее приращение Y , связанное с увеличением X на одну единицу. Остатки отражают все, что мы упускаем из вида: возможно, истинная зависимость не является линейной, могут существовать другие переменные, вызывающие вариацию Y , а также могут иметь место ошибки измерения. Обычно мы предполагаем, что остатки независимы от X .

Модель, представленная в (3.5), определяет регрессионную линию генеральной совокупности, которая является наилучшей линейной аппроксимацией истинной зависимости между X и Y ². Оценки регрессионных коэффициентов, полученные по методу наименьших квадратов согласно (3.4), характеризуют линию наименьших квадратов из (3.2). В качестве простого гипотетического примера на рис. 3.3 слева показаны две такие линии. Мы создали 100 случайных значений X и 100 соответствующих значений Y на основе модели

истинная
регрес-
сионная
линия

линия
наимень-
ших
квадратов

$$Y = 2 + 3X + \epsilon, \tag{3.6}$$

² Предположение о линейной форме зависимости часто является полезной рабочей моделью. Однако, несмотря на то, о чем говорят многие учебники, мы убеждены, что истинная зависимость является линейной только в редких случаях.




РИСУНОК 3.3. Набор имитированных данных. Слева: красная линия соответствует истинной зависимости $f(X) = 2 + 3X$, которая известна как регрессионная линия генеральной совокупности. Синяя линия представляет собой линию наименьших квадратов — она является оценкой $f(X)$, полученной по методу наименьших квадратов на основе выборочных данных, показанных в виде полых черных точек. Справа: регрессионная линия генеральной совокупности по-прежнему показана красным цветом, а линия наименьших квадратов — темно-синим. Светло-синим цветом показаны десять линий наименьших квадратов, вычисленные на основе отдельных случайных выборок. Каждая линия наименьших квадратов отличается от других таких линий, но в среднем они довольно похожи на регрессионные линии генеральной совокупности

где значения ϵ были извлечены из нормального распределения с нулевым средним. Красная линия на рис. 3.3 слева изображает истинную зависимость $f(X) = 2 + 3X$, тогда как голубая линия получена на основе данных по методу наименьших квадратов. Истинная зависимость для реальных данных обычно неизвестна, однако всегда можно вычислить линию наименьших квадратов, используя оценки коэффициентов, приведенные в (3.4). Иными словами, при решении практических задач у нас имеется доступ к набору наблюдений, по которым мы можем вычислить линию наименьших квадратов, однако регрессионная линия для генеральной совокупности остается ненаблюдаемой. На рис. 3.3 справа мы создали десять различных наборов данных на основе модели (3.6) и изобраили соответствующие десять линий наименьших квадратов. Заметьте, что разные наборы данных, сгенерированные на основе одной той же истинной модели, дают несколько различающиеся линии наименьших квадратов, тогда как ненаблюдаемая регрессионная линия генеральной совокупности остается неизменной.

На первый взгляд, разница между регрессионной линией генеральной совокупности и линией наименьших квадратов может показаться несущественной и сбивающей с толку. У нас есть только одна выборка, и поэтому что значат эти две разные линии, описывающие зависимость между

предиктором и откликом? По существу, концепция этих двух линий является естественным продолжением стандартного статистического подхода по использованию информации о выборке для оценивания характеристик большой совокупности. Представьте, например, что мы заинтересованы в нахождении генерального среднего значения μ некоторой случайной переменной Y . К сожалению, μ неизвестно, но все же у нас есть доступ к n наблюдениям Y , которые мы можем записать как $y_1, \dots, y_n$ и которые мы можем использовать для нахождения оценки μ . Разумной оценкой является $\hat{\mu} = \hat{y}$, где $\hat{y} = \frac{1}{n} \sum_{i=1}^n y_i$ — выборочное среднее. Выборочное среднее и среднее генеральной совокупности различаются, но в целом выборочное среднее обеспечит хорошую оценку генерального среднего. Точно таким же образом неизвестные коэффициенты β_0 и β_1 в линейной регрессии определяют регрессионную линию генеральной совокупности. Мы пытаемся оценить эти неизвестные коэффициенты при помощи $\hat{\beta}_0$ и $\hat{\beta}_1$, представленных в (3.4). Эти оценки коэффициентов определяют линию наименьших квадратов.

Аналогия между линейной регрессией и оцениванием среднего значения случайной переменной является уместной благодаря концепции *смещение* *несмещенной*. Если мы используем $\hat{\mu}$ для оценивания μ , то эта оценка является *несмещенной*, в том смысле, что в среднем мы ожидаем равенство между $\hat{\mu}$ и μ . Что именно здесь имеется в виду? Речь здесь идет о том, что на основе некоторого конкретного набора наблюдений $y_1, \dots, y_m$ $\hat{\mu}$ может дать завышенную оценку μ , а на основе другого набора наблюдений $\hat{\mu}$ может дать заниженную оценку μ . Однако мы могли бы усреднить очень большое число оценок μ , полученных на очень большом количестве выборок, и тогда это среднее значение было бы *в точности* равно μ . Следовательно, несмещенная оценка не проявляет систематических отклонений от истинного значения соответствующего параметра. Свойство несмещенности справедливо также для оценок коэффициентов, получаемых по методу наименьших квадратов в соответствии с (3.4): если мы оцениваем β_0 и β_1 на основе какого-то конкретного набора данных, то наши оценки не будут в точности равны β_0 и β_1 . Однако мы могли бы усреднить оценки, полученные на очень большом количестве наборов данных, и тогда средние значения этих оценок попали бы точно «в яблочко»! Фактически на рис. 3.3 справа мы можем увидеть, что результат усреднения нескольких линий наименьших квадратов, каждая из которых была оценена на отдельном наборе данных, довольно близок к истинной линии регрессии.

Мы продолжаем обсуждение аналогии с оценкой генерального среднего значения случайной переменной Y . Естественным будет следующий вопрос: насколько точным является выборочное среднее $\hat{\mu}$ в качестве оценки μ ? Мы выяснили, что среднее из $\hat{\mu}$, рассчитанных по большому количеству выборок, будет близко к μ , однако какая-то одна конкретная оценка $\hat{\mu}$ может существенно недооценивать или переоценивать μ . Насколько большим будет отклонение этой единственной оценки $\hat{\mu}$? Как правило, мы отвечаем на этот вопрос путем вычисления *стандартной ошибки* $\hat{\mu}$, которая обозначается как $SE(\hat{\mu})$. У нас есть хорошо известная формула

$$\text{Var}(\hat{\mu}) = SE(\hat{\mu})^2 = \frac{\sigma^2}{n}, \quad (3.7)$$

где σ — это стандартное отклонение каждой из реализаций y_i перемен-

стандартная
ошибка

ной Y^3 . Грубо говоря, стандартная ошибка показывает нам, насколько в среднем данная оценка $\hat{\mu}$ отличается от истинного значения μ . Уравнение 3.7 говорит нам также, что при увеличении n это отклонение снижается, т. е. чем больше у нас есть наблюдений, тем меньше будет стандартная ошибка $\hat{\mu}$. Точно так же нам может быть интересно, насколько $\hat{\beta}_0$ и $\hat{\beta}_1$ близки к истинным значениям β_0 и β_1 . Для вычисления стандартных ошибок $\hat{\beta}_0$ и $\hat{\beta}_1$ мы применяем следующие формулы:

$$SE(\hat{\beta}_0)^2 = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right], \quad SE(\hat{\beta}_1)^2 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad (3.8)$$

где $\sigma^2 = \text{Var}(\epsilon)$. Для того чтобы эти формулы были применимы, мы должны допустить, что остатки ϵ_i всех наблюдений являются некоррелированными и обладают общей дисперсией σ^2 . На рис. 3.1 это со всей очевидностью не так, однако формулы все же обеспечивают хорошую аппроксимацию. Заметьте, что $SE(\hat{\beta}_1)$ в формуле становится меньше при увеличении размаха x_i ; интуитивно это объясняется тем, что в таком случае у нас есть больше информации для оценивания угла наклона. Мы видим также, что $SE(\hat{\beta}_0)$ была бы равна $SE(\hat{\mu})$ при $\bar{x} = 0$ (в этом случае $\hat{\beta}_0$ был бы равен $\bar{y}$). Как правило, дисперсия σ^2 не известна, но может быть оценена по данным. Эта оценка σ называется *стандартной ошибкой остатков* и вычисляется по формуле $RSE = \sqrt{RSS/(n-2)}$ ⁴. Строго говоря, для того чтобы показать, что при нахождении σ^2 по данным была получена выборочная оценка, нам следует писать $\widehat{SE}(\hat{\beta}_1)$, однако для простоты обозначений мы отбросим эту дополнительную «крышечку».

Стандартные ошибки можно использовать для вычисления *доверительных интервалов*. Под 95%-ным доверительным интервалом понимают такой диапазон значений, который с вероятностью 95% будет содержать истинное неизвестное значение параметра. Этот диапазон задается в виде нижнего и верхнего доверительных пределов, вычисляемых по выборочным данным. В случае с линейной регрессией 95%-ный доверительный интервал для $\hat{\beta}_1$ принимает следующую приблизительную форму⁵:

$$\hat{\beta}_1 \pm 2 \cdot SE(\hat{\beta}_1). \quad (3.9)$$

Другими словами, имеет место примерно 95%-ная вероятность того, что интервал

$$\left[\hat{\beta}_1 - 2 \cdot SE(\hat{\beta}_1), \hat{\beta}_1 + 2 \cdot SE(\hat{\beta}_1) \right] \quad (3.10)$$

³ Эта формула работает при условии, что n наблюдений не коррелируют друг с другом.

⁴ Аббревиатура от «residual standard error». — Прим. пер.

⁵ Приблизительность этого решения обусловлена несколькими причинами. Уравнение 3.10 основано на допущении о том, что остатки имеют гауссово распределение. Кроме того, множитель 2 перед $SE(\hat{\beta}_1)$ будет несколько варьировать в зависимости от числа наблюдений n в линейной регрессии. Если быть точнее, то вместо числа 2 уравнение 3.10 должно содержать 97.5%-ный квантиль t -распределения с $n - 2$ степенями свободы. Детали, касающиеся вычисления 95%-ного доверительного интервала в R, будут приведены позднее в этой главе.

стандартная
ошибка
остатков

доверительный
интервал

будет содержать истинное значение β_1 . Аналогично доверительный интервал для β_0 будет принимать следующую приблизительную форму:

$$\hat{\beta}_0 \pm 2 \cdot \text{SE}(\hat{\beta}_0). \quad (3.11)$$

В случае с данными по рекламе 95%-ный доверительный интервал для β_0 составляет [6.130, 7.935], а 95%-ный доверительный интервал для β_1 составляет [0.042, 0.053]. Следовательно, мы можем заключить, что в отсутствие какой-либо рекламы продажи в среднем будут составлять от 6130 до 7940 единиц. При этом каждый раз при увеличении затрат на телерекламу на 1000\$ рост продаж в среднем составит от 42 до 53 единиц.

Стандартные ошибки можно также использовать для *проверки статистических гипотез* в отношении коэффициентов. Наиболее обычной является проверка *нулевой гипотезы*

проверка гипотезы

нулевая гипотеза

$$H_0 : \text{связи между } X \text{ и } Y \text{ нет} \quad (3.12)$$

против *альтернативной гипотезы*

$$H_a : \text{между } X \text{ и } Y \text{ имеется определенная связь.} \quad (3.13)$$

С математической точки зрения это соответствует проверке гипотезы

$$H_0 : \beta_1 = 0$$

против

$$H_0 : \beta_1 \neq 0,$$

поскольку если $\beta_1 = 0$, то модель (3.5) сводится к $Y = \beta_0 + \epsilon$ и связи между X и Y нет. Для проверки нулевой гипотезы нам необходимо выяснить, является ли $\hat{\beta}_1$ — наша оценка β_1 — достаточно удаленной от нуля для того, чтобы быть уверенным в ее ненулевом значении. Какое расстояние является достаточным? Это, конечно, зависит от точности $\hat{\beta}_1$, т. е. от $\text{SE}(\hat{\beta}_1)$. Если $\text{SE}(\hat{\beta}_1)$ мала, то даже относительно небольшие $\hat{\beta}_1$ могут обеспечить веское основание в пользу того, что $\beta_1 \neq 0$, а следовательно, и того, что между X и Y имеется определенная связь. В то же время при большой $\text{SE}(\hat{\beta}_1)$ для отклонения нулевой гипотезы абсолютное значение $\hat{\beta}_1$ также должно быть большим. На практике мы вычисляем t -критерий

t -критерий

$$t = \frac{\hat{\beta}_1 - 0}{\text{SE}(\hat{\beta}_1)}, \quad (3.14)$$

который показывает, на сколько стандартных отклонений $\hat{\beta}_1$ отстоит от 0. Если связи между X и Y действительно не существует, то мы ожидаем, что величина (3.14) будет иметь t -распределение с $n - 2$ степенями свободы. t -распределение имеет колоколообразную форму, и при $n > 30$ оно довольно похоже на нормальное распределение. Следовательно, допустив, что $\beta_1 = 0$, можно очень просто вычислить вероятность наблюдения любого значения, равного или превышающего $|t|$. Мы называем эту вероятность p -значением. Мы интерпретируем p -значение примерно следующим образом: в отсутствие какой-либо реальной связи между предиктором и откликом небольшое p -значение указывает на низкую вероятность

p -значение

случайного обнаружения существенной связи между этими предиктором и откликом. Следовательно, если наблюдается низкое p -значение, то мы можем сделать заключение о существовании определенной связи между предиктором и откликом. При достаточно низком p -значении мы *отклоняем нулевую гипотезу*, т.е. объявляем существование связи между X и Y . Распространенные пороговые p -значения для отклонения нулевой гипотезы составляют 1% и 5%. При $n = 30$ эти значения соответствуют t -критерию из (3.14), равному примерно 2 и 2.75.

ТАБЛИЦА 3.1. Коэффициенты регрессионной зависимости количества проданных единиц товара от бюджета на телерекламу, рассчитанные по методу наименьших квадратов на основе данных Advertising. Увеличение затрат на телерекламу на 1000\$ связано с увеличением продаж примерно на 50 единиц (вспомните, что переменная *sales* выражается в тысячах единиц, а переменная *TV* — в тысячах долларов)

	Коэффициент	Ст. ошибка	t	p
Свободный член	7.0325	0.4578	15.36	< 0.0001
TV	0.0475	0.0027	17.67	< 0.0001

В табл. 3.1 приведены детали регрессионной зависимости количества продаж от размера бюджета на телерекламу, рассчитанной по методу наименьших квадратов для данных Advertising. Заметьте, что коэффициенты $\hat{\beta}_0$ и $\hat{\beta}_1$ очень большие, по сравнению с их стандартными ошибками, и поэтому значения t -критерия также высоки; вероятности наблюдения таких значений при верной H_0 фактически равны нулю. Следовательно, мы заключаем, что $\beta_0 \neq 0$ и $\beta_1 \neq 0^6$.

3.1.3 Оценивание точности модели

После отклонения нулевой гипотезы (3.12) в пользу альтернативной гипотезы (3.13) естественным будет желание количественно оценить степень того, *насколько хорошо модель описывает данные*. Качество линейной регрессионной модели обычно оценивается при помощи двух родственных мер: *стандартной ошибки остатков* (RSE) и коэффициента детерминации R^2 .

В табл. 3.2 приведены RSE, статистика R^2 и F -критерий (будет описан в подразделе 3.2.2) для линейной регрессии количества продаж по размеру бюджета на телерекламу.

Стандартная ошибка остатков

Вспомним, что в модели (3.5) каждому наблюдению соответствует остаток ϵ . Из-за наличия этих остатков мы не смогли бы в точности предсказать

⁶ В табл. 3.1 низкое p -значение для свободного члена показывает, что мы можем отклонить нулевую гипотезу о $\beta_0 = 0$, а низкое p -значение для TV показывает, что мы можем отклонить нулевую гипотезу о $\beta_1 = 0$. Отклонение последней нулевой гипотезы позволяет нам сделать заключение о существовании связи между TV и *sales*. Отклонение же первой гипотезы позволяет нам утверждать, что в отсутствие затрат на телерекламу продажи не равны нулю.

Y по X , даже если бы знали истинную регрессионную линию (т.е. если бы β_0 и β_1 были известны). RSE представляет собой оценку стандартного отклонения ϵ . Грубо говоря, это средняя величина отклонения отклика от истинной регрессионной линии. Она рассчитывается по формуле

$$\text{RSE} = \sqrt{\frac{1}{n-2} \text{RSS}} = \sqrt{\frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (3.15)$$

ТАБЛИЦА 3.2. *Дополнительная информация по регрессионной зависимости количества продаж от размера бюджета на телерекламу, рассчитанной по методу наименьших квадратов для данных Advertising*

Мера	Значение
Стандартная ошибка остатков	3.26
R^2	0.612
F -критерий	312.1

Заметьте, что RSS была определена в подразделе 3.1.1 и вычисляется по формуле

$$\text{RSS} = \sum_{i=1}^n (y_i - \hat{y}_i)^2. \quad (3.16)$$

По результатам регрессионного анализа, представленным в табл. 3.2, мы видим, что для данных по рекламе RSE составляет 3.26. Другими словами, фактические продажи в каждом регионе в среднем отклоняются от истинной регрессионной линии примерно на 3260 единиц. Об этом можно думать также в следующем ключе: даже если бы модель была правильной и истинные значения неизвестных коэффициентов β_0 и β_1 были в точности известны, любое предсказание продаж на основе размера бюджета на телерекламу все равно отклонялось бы в среднем на 3260 единиц. Является ли ошибка предсказания в 3260 единиц приемлемой, зависит, конечно, от контекста проблемы. В данных по рекламе среднее значение `sales` по всем регионам составляет примерно 14 000 единиц, и поэтому удельная ошибка составляет $3260/14000 = 23\%$.

RSE считается мерой *несоответствия* модели (3.5) данным. Если предсказания, полученные с использованием модели, очень близки к истинным значениям отклика, т.е. $\hat{y}_i \approx y_i$ для $i = 1, \dots, n$, то величина (3.15) будет небольшой, и мы сможем заключить, что модель описывает данные очень хорошо. С другой стороны, если $\hat{y}_i$ существенно отличается от y_i в одном или нескольких случаях, то RSE может оказаться довольно большой, указывая плохое соответствие модели данным.

Коэффициент детерминации R^2

RSE — это абсолютная мера несоответствия модели (3.5) данным. Но поскольку она выражается в тех же единицах измерения, что и Y , то не

всегда бывает ясно, какая RSE является хорошей. Коэффициент детерминации R^2 представляет собой альтернативную меру соответствия. Этот показатель принимает форму доли — доли объясненной дисперсии, в связи с чем он всегда изменяется от 0 до 1 и не зависит от шкалы измерения Y .

Для вычисления R^2 мы применяем следующую формулу:

$$R^2 = \frac{TSS - RSS}{TSS} = 1 - \frac{RSS}{TSS}, \quad (3.17)$$

общая
сумма
квадратов

где $TSS = \sum (y_i - \bar{y})^2$ — это *общая сумма квадратов*, а определение RSS дано в (3.16). TSS является мерой общей дисперсии отклика Y , и о ней можно думать как о степени изменчивости, присущей отклику до выполнения регрессионного анализа. В то же время RSS выражает степень изменчивости, которая осталась необъясненной после построения регрессионной модели. Следовательно, $TSS - RSS$ выражает количество дисперсии отклика, объясненное («изъятное») после выполнения регрессионного анализа, а R^2 — *долю дисперсии Y , объясненную при помощи X* . Статистика R^2 , близкая к 1, указывает на то, что значительная доля изменчивости отклика была объяснена регрессионной моделью. Число, близкое к 0, указывает на то, что регрессионная модель объяснила лишь незначительную долю изменчивости отклика; это может иметь место либо в силу того, что линейная модель неверна, либо в связи с естественно высокой дисперсией остатков σ^2 , либо по обоим причинам одновременно. В табл. 3.2 $R^2 = 0.61$, и значит, линейная регрессия по TV объясняет немногим меньше двух третей изменчивости sales.

Статистика R^2 из (3.17) имеет преимущество над RSE из (3.15) с точки зрения легкости интерпретации, поскольку, в отличие от RSE, она всегда изменяется от 0 до 1. Однако определение *хорошего значения R^2* может вызвать затруднения и, как правило, зависит от конкретной задачи. Например, в некоторых задачах физики нам может быть известно, что данные были действительно порождены линейной моделью с небольшой дисперсией остатков. В этом случае мы ожидали бы значение R^2 , очень близкое к 1, а существенно меньшее значение R^2 могло бы указывать на серьезную проблему с экспериментом, в котором были получены соответствующие данные. С другой стороны, в типичных задачах биологии, психологии, маркетинга и других областей линейная модель (3.5) в лучшем случае является очень грубой аппроксимацией данных, а остатки часто бывают очень большими в связи с неучтенными факторами. При таком сценарии мы ожидали бы лишь небольшую долю дисперсии отклика, объясненную предиктором, и значение $R^2 = 0.1$ было бы более реалистичным.

корреляция

Статистика R^2 является мерой линейной зависимости между X и Y . Вспомните, что корреляция, определяемая как

$$\text{Cor}(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}, \quad (3.18)$$

также является мерой линейной зависимости между X и Y ⁷. Это подра-

⁷ Отметим, что в действительности правая часть выражения (3.18) представляет собой выборочный коэффициент корреляции; следовательно, более корректным способом записи был бы $\text{Cor}(X, Y)$, однако мы опускаем «крышечку» для простоты обозначений.

зумевают, что для оценки степени соответствия линейной модели данным мы могли бы использовать $r = \text{Cor}(X, Y)$, а не R^2 . Действительно, можно показать, что в случае с простой линейной регрессией $R^2 = r^2$. Другими словами, квадрат коэффициента корреляции и коэффициент детерминации R^2 идентичны. Однако в следующем разделе мы будем обсуждать проблему множественной линейной регрессии, в которой для предсказания отклика мы одновременно используем несколько предикторов. Идея корреляции между предикторами и откликом на такой сценарий автоматически не переносится, поскольку корреляция выражает силу связи только между парой переменных, а не несколькими переменными. Мы увидим, что эту роль выполняет R^2 .

3.2 Множественная линейная регрессия

Простая линейная регрессия является полезным методом для предсказания некоторого отклика на основе единственной независимой переменной. Однако на практике у нас часто есть несколько предикторов. Например, в случае с данными Advertising мы изучили связь между количеством продаж и телерекламой. У нас имеются данные также по затратам на рекламу на радио и в газетах, и мы можем быть заинтересованы в установлении связи между количеством продаж и рекламой в каком-либо из этих двух типов СМИ. Как нам расширить наш анализ данных по рекламе, чтобы учесть эти два дополнительных предиктора?

Один из способов заключается в расчете трех отдельных простых регрессионных моделей, каждая из которых в качестве предиктора использует затраты на рекламу в соответствующем СМИ. Например, мы можем подогнать простую линейную регрессию для предсказания продаж на основе затрат на радиорекламу. Результаты представлены в табл. 3.3 (верхняя часть). Мы видим, что увеличение затрат на радиорекламу на 1000\$ связано с увеличением продаж примерно на 203 единицы. Нижняя часть табл. 3.3 содержит коэффициенты простой линейной регрессии количества продаж по размеру бюджета на рекламу в газетах. Увеличение затрат на рекламу в газетах на 1000\$ связано с увеличением продаж примерно на 55 единиц.

Однако метод подгонки простой линейной регрессионной модели отдельно для каждого предиктора не является в полной мере удовлетворительным. Прежде всего не ясно, как сделать единый прогноз продаж при заданных размерах бюджета на рекламу в каждом из трех типов СМИ, поскольку каждому из этих размеров соответствует отдельное регрессионное уравнение. Во-вторых, каждое из трех регрессионных уравнений игнорирует два других вида СМИ при расчете оценок регрессионных коэффициентов. Вскоре мы увидим, что если затраты на рекламу в разных СМИ в тех 200 регионах, которые составляют наш набор данных, коррелируют друг с другом, то это может привести к очень обманчивым оценкам эффектов отдельных СМИ на продажи.

Вместо подгонки отдельной регрессионной модели для каждого предиктора более подходящим методом является расширение простой линейной регрессионной модели (3.5) таким образом, чтобы непосредственно учесть наличие нескольких предикторов. Для этого мы можем присвоить

ТАБЛИЦА 3.3. *Дополнительные простые линейные регрессионные модели для данных Advertising. Вверху: коэффициенты простой линейной регрессии количества продаж по размеру бюджета на радиорекламу. Внизу: то же, но для рекламы в газетах. Увеличение затрат на радиорекламу на 1000\$ связано с увеличением продаж в среднем примерно на 203 единицы, тогда как аналогичное увеличение затрат на рекламу в газетах связано с увеличением продаж в среднем примерно на 55 единиц (заметьте, что переменная sales выражается в тысячах единиц, а переменные radio и newspaper — в тысячах долларов)*

Простая линейная регрессия sales по radio				
	Коэффициент	Ст. ошибка	<i>t</i>	<i>p</i>
Свободный член	9.312	0.563	16.54	< 0.0001
radio	0.203	0.020	9.92	< 0.0001

Простая линейная регрессия sales по newspaper				
	Коэффициент	Ст. ошибка	<i>t</i>	<i>p</i>
Свободный член	12.351	0.621	19.88	< 0.0001
newspaper	0.055	0.017	3.30	< 0.0001

каждому предиктору свой угловой коэффициент в рамках одной модели. Допустим, что в общем виде у нас имеется *p* отдельных предикторов. Тогда множественная регрессионная модель принимает форму

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \epsilon, \tag{3.19}$$

где *X_j* — это *j*-й предиктор, а *β_j* выражает силу связи между соответствующей переменной и откликом. Мы интерпретируем *β_j* как *среднее* изменение *Y*, вызванное увеличением *X_j* на одну единицу при *удержании всех остальных предикторов на фиксированном уровне*. Для примера с рекламой уравнение (3.19) превращается в

$$\text{sales} = \beta_0 + \beta_1 \times \text{TV} + \beta_2 \times \text{radio} + \beta_3 \times \text{newspaper} + \epsilon. \tag{3.20}$$

3.2.1 Оценивание регрессионных коэффициентов

Подобно тому, как это было в случае с простой линейной регрессией, регрессионные коэффициенты *β₀, β₁, ..., β_p* в (3.19) неизвестны и подлежат оцениванию. Имея оценки *β̂₀, β̂₁, ..., β̂_p*, мы можем сделать предсказания при помощи формулы

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \cdots + \hat{\beta}_p x_p. \tag{3.21}$$

Параметры оцениваются с использованием того же метода наименьших квадратов, который мы видели в контексте простой линейной регрессии. Мы выбираем *β₀, β₁, ..., β_p* с целью минимизации суммы квадратов остатков

$$\text{RSS} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_p x_{ip})^2. \quad (3.22)$$

Значения $\beta_0, \beta_1, \dots, \beta_p$, которые минимизируют (3.22), представляют собой оценки коэффициентов множественной регрессии по методу наименьших квадратов. В отличие от оценок простой линейной регрессии (3.4), оценки коэффициентов множественной регрессии имеют довольно сложные формы, которые проще всего представить с использованием матричной алгебры. По этой причине мы их здесь не приводим. Для вычисления этих оценок можно использовать любой статистический пакет, и позже в этой главе мы покажем, как это сделать в R. Рисунок 3.4 иллюстрирует пример подгонки модели наименьших квадратов к гипотетическим данным с $p = 2$ предикторами.




РИСУНОК 3.4. В трехмерном пространстве, представленном двумя предикторами и одной независимой переменной, линия наименьших квадратов становится плоскостью. Эта плоскость выбирается путем минимизации суммы возведенных в квадрат вертикальных расстояний от каждого наблюдения (показаны красными точками) до плоскости

В табл. 3.4 приведены оценки коэффициентов множественной регрессионной модели для данных Advertising, в которой затраты на рекламу на телевидении, радио и в газетах используются для предсказания количества продаж. Мы интерпретируем эти результаты следующим образом: при некотором фиксированном бюджете на рекламу на телевидении

и в газетах трата дополнительных 1000\$ на радиорекламу приводит к увеличению продаж примерно на 189 единиц. Сравнивая эти коэффициенты с таковыми в табл. 3.1 и 3.3, мы можем заметить, что оценки коэффициентов множественной регрессии для TV и radio довольно похожи на оценки коэффициентов простой линейной регрессии. Однако, несмотря на то что оценка регрессионного коэффициента для newspaper в табл. 3.3 значительно отличалась от нуля, оценка коэффициента newspaper в модели множественной регрессии оказалась близка к нулю, а соответствующее r -значение, примерно равное 0.86, перестало быть значимым. Данный пример показывает, что коэффициенты простой и множественной регрессий могут быть довольно разными. Эта разница обусловлена тем фактом, что в простой регрессии угловой коэффициент отражает средний эффект увеличения затрат на рекламу в газетах на 1000\$ без учета эффектов других предикторов (TV и radio). В случае же со множественной регрессией коэффициент newspaper соответствует среднему эффекту увеличения затрат на рекламу в газетах на 1000\$ при фиксированных уровнях TV и radio.

ТАБЛИЦА 3.4. Коэффициенты множественной регрессии количества продаж по размеру затрат на рекламу на телевидении, радио и в газетах, рассчитанные по методу наименьших квадратов на основе данных Advertising

	Коэффициент	Ст. ошибка	t	p
Свободный член	2.939	0.3119	9.42	< 0.0001
TV	0.046	0.0014	32.81	< 0.0001
radio	0.189	0.0086	21.89	< 0.0001
newspaper	-0.001	0.0059	-0.18	< 0.8599

Имеет ли смысл тот факт, что множественная регрессия указывает на отсутствие связи между sales и newspaper, тогда как простая линейная регрессия предполагает обратное? Оказывается, что имеет. Обратите внимание на корреляционную матрицу для трех предикторов и независимой переменной, представленную в табл. 3.5. Заметьте, что корреляция между radio и newspaper составляет 0.35. Это указывает на наличие повышенных затрат на рекламу в газетах в тех регионах, где много тратится на радиорекламу. Теперь представьте, что множественная регрессия является корректной и реклама в газетах не имеет прямого влияния на продажи, тогда как реклама на радио ведет к их росту. Тогда в регионах, где мы тратим больше на радиорекламу, наши продажи в целом будут выше, и, согласно нашей корреляционной матрице, в тех же регионах в целом мы также будем тратить больше на рекламу в газетах. Следовательно, в простой линейной регрессии, которая описывает связь только между sales и newspaper, мы будем наблюдать более высокие значения sales при высоких значениях newspaper, даже если реклама в газетах в действительности не оказывает влияния на продажи. Таким образом, продажи, связанные с рекламой в газетах, являются суррогатом продаж, вызванных рекламой на радио, — переменная newspaper как бы получает «кредит» за счет влияния radio на sales.

Этот несколько неожиданный результат часто встречается во многих ситуациях из реальной жизни. Представьте себе следующий абсурдный

ТАБЛИЦА 3.5. *Корреляционная матрица для переменных TV, radio, newspaper и sales из набора данных Advertising*

	TV	radio	newspaper	sales
TV	1.0000	0.0548	0.0567	0.7822
radio		1.0000	0.3541	0.5762
newspaper			1.0000	0.2283
sales				1.0000

пример, иллюстрирующий суть этого явления. Регрессия числа нападения акул на купающихся по количеству продаж мороженого на основе данных, собранных в течение некоторого времени для определенного пляжа, показала бы наличие положительной связи, подобной той, что наблюдается между sales и newspaper. Конечно, никто (пока) не заявил, что для снижения числа нападений акул нужно запретить продавать мороженое на пляжах. В действительности более высокие температуры заставляют большее количество людей посещать пляж, что в итоге приводит к более высоким продажам мороженого и более частым нападениям акул. Множественная регрессия числа атак по количеству продаж мороженого и температуре ожидаемо показывает, что с поправкой на температуру уровень продаж мороженого перестает быть значимым предиктором.

3.2.2 Некоторые важные вопросы

При выполнении множественной линейной регрессии мы обычно заинтересованы в ответе на несколько важных вопросов.

1. *Является ли хотя бы один из предикторов $X_1, X_2, \dots, X_p$ полезным для предсказания отклика?*
2. *Все ли предикторы помогают объяснить Y , или полезным является только некоторое подмножество предикторов?*
3. *Насколько хорошо модель описывает данные?*
4. *Имея некоторый набор значений предикторов, как нам предсказать отклик, и насколько точным будет наше предсказание?*

Теперь мы рассмотрим каждый из этих вопросов по порядку.

Вопрос 1: Имеется ли связь между откликом и предикторами?

Вспомните, что в случае с простой линейной регрессией для установления существования связи между откликом и предиктором мы можем просто проверить равенство β_1 нулю. В случае множественной регрессии с p предикторами нам необходимо выяснить, равны ли нулю все регрессионные коэффициенты, т.е. $\beta_1 = \beta_2 = \dots = \beta_p = 0$. Как и в простой линейной регрессии, для ответа на этот вопрос мы выполняем проверку статистической гипотезы. Мы проверяем нулевую гипотезу

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$$

против

H_a : как минимум один β_j не равен нулю.

F -критерий Проверка этой гипотезы выполняется путем вычисления F -критерия

$$F = \frac{(\text{TSS} - \text{RSS})/p}{\text{RSS}/(n - p - 1)}, \quad (3.23)$$

где, как и в простой линейной регрессии, $\text{TSS} = \sum (y_i - \bar{y})^2$, а $\text{RSS} = \sum (y_i - \hat{y})^2$. Если предположения в отношении линейной модели справедливы, то можно показать, что

$$E\{\text{RSS}/(n - p - 1)\} = \sigma^2,$$

а также (при справедливой H_0), что

$$E\{(\text{TSS} - \text{RSS})/p\} = \sigma^2.$$

Следовательно, в отсутствие связи между откликом и предикторами можно было бы ожидать, что F -критерий примет значение, близкое к 1. С другой стороны, если верна H_a , то $E\{(\text{TSS} - \text{RSS})/p\} > \sigma^2$, и мы ожидаем $F > 1$.

ТАБЛИЦА 3.6. *Дополнительная информация по регрессии количества продаж от затрат на рекламу на телевидении, радио и в газетах, рассчитанной по методу наименьших квадратов для данных Advertising. Другая информация об этой модели была приведена в табл. 3.4*

Мера	Значение
Стандартная ошибка остатков	1.69
R^2	0.897
F -критерий	570

F -критерий для множественной линейной регрессии, описывающей зависимость sales от radio, TV и newspaper, приведен в табл. 3.6. В этом примере F -критерий составляет 570. Поскольку это значение намного больше 1, оно является убедительным свидетельством против нулевой гипотезы H_0 . Другими словами, большой F -критерий указывает на то, что как минимум одно средство рекламы должно быть связано с продажами. Но что, если бы F -критерий был ближе к 1? Насколько большим должно быть значение F , чтобы мы смогли отклонить H_0 и сделать заключение о существовании зависимости? Оказывается, что ответ зависит от значений n и p . При большом n значение F -критерия, ненамного превышающее 1, уже могло бы служить достаточным свидетельством против H_0 . В то же время при небольшом n для отклонения H_0 требуется более высокий F -критерий. Если H_0 верна и остатки ϵ_i имеют нормальное распределение, то

F -критерий подчиняется F -распределению⁸. Имея некоторые значения n и p , можно воспользоваться любым статистическим пакетом для вычисления по этому распределению p -значения, связанного с соответствующим F -критерием. На основе этого p -значения мы можем определить, нужно ли отклонять H_0 . Для данных по рекламе p -значение F -критерия в сущности равно нулю (табл. 3.6), и поэтому у нас есть очень убедительное свидетельство в пользу того, что как минимум одно СМИ связано с увеличением продаж.

В (3.23) мы проверяем H_0 о том, что нулю равны все коэффициенты. Иногда мы хотим проверить равенство нулю лишь некоторого подмножества, образованного q коэффициентами. Это соответствует нулевой гипотезе

$$H_0 = \beta_{p-q+1} = \beta_{p-q+2} = \dots = \beta_p = 0,$$

где для удобства мы поместили подлежащие исключению переменные в конце списка. В этом случае мы подгоняем вторую модель, которая использует все переменные, *за исключением* этих последних q переменных. Пусть сумма квадратов остатков для такой модели обозначается как RSS_0 . Тогда подходящим F -критерием будет

$$F = \frac{(RSS_0 - RSS)/q}{RSS/(n - p - 1)}. \quad (3.24)$$

Заметьте, что в табл. 3.4 для каждого предиктора были приведены отдельные t -критерий и p -значение. Они предоставляют информацию о том, связан ли каждый предиктор с откликом в присутствии других предикторов. Оказывается, что каждый из этих t -критериев эквивалентен⁹ F -критерию, который рассчитывается после удаления соответствующей переменной из модели, т.е. $q = 1$ в (3.24). Таким образом, каждый t -критерий характеризует *частный эффект* от добавления соответствующей переменной в модель. Например, как мы обсуждали ранее, эти p -значения говорят о том, что TV и radio связаны с sales, а также о том, что в присутствии двух других предикторов указаний на связь между newspaper и sales нет.

Имея эти отдельные p -значения для каждой переменной, зачем нам вообще смотреть на общий F -критерий? В конце концов, вполне вероятно, что если какое-либо из p -значений является очень низким, то *как минимум один из предикторов связан с откликом*. Однако это ложная логика, особенно при наличии большого числа предикторов p .

Представьте себе пример, в котором $p = 100$ и $H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$ верна, т.е. ни одна из переменных в действительности не связана с откликом. В этой ситуации примерно у 5% переменных p -значения (вроде тех, которые представлены в табл. 3.4) будут ниже 0.05 просто в силу случая. Другими словами, мы ожидаем увидеть примерно пять *низких* p -значений даже в отсутствие какой-либо истинной связи между предикторами и откликом. На самом деле мы почти гарантированно обнаружим

⁸ Даже если остатки имеют распределение, отличное от нормального, при наличии большого числа наблюдений F -критерий приближенно будет подчиняться F -распределению.

⁹ Квадрат каждого t -критерия представляет собой соответствующий F -критерий.

как минимум одно p -значение ниже 0.05, возникшее по чистой случайности. Следовательно, если мы будем применять отдельные t -критерии и связанные с ними p -значения для принятия решения о наличии взаимосвязи между переменными и откликом, то столкнемся с очень большой вероятностью сделать неправильное заключение. Однако F -критерий не страдает от этой проблемы, поскольку он делает поправку на количество предикторов. Следовательно, при верной H_0 есть лишь 5%-ная вероятность того, что F -критерий будет сопровождаться p -значением, меньшим 0.05, вне зависимости от количества предикторов или объема наблюдений.

Использование F -критерия для проверки наличия какой-либо связи между предикторами и откликом работает при относительно небольшом p , и конечно небольшом, по сравнению с n . Однако иногда у нас есть большое количество переменных. При $p > n$ число подлежащих оцениванию коэффициентов β_j превышает число имеющихся для этого наблюдений. В этом случае мы даже не сможем подогнать линейную регрессионную модель по методу наименьших квадратов, и поэтому невозможно будет использовать ни F -критерий, ни большинство других концепций, с которыми мы столкнулись в данной главе. При большом p можно применять некоторые подходы, обсуждаемые в следующем подразделе, например *пошаговый отбор с включением переменных*. Этот многомерный сценарий обсуждается более подробно в главе 6.

Вопрос 2: Отбор важных переменных

Как обсуждалось в предыдущем подразделе, первым шагом множественного регрессионного анализа является вычисление F -критерия и изучение соответствующего p -значения. Если на основе этого p -значения мы делаем вывод о том, что как минимум один из предикторов связан с откликом, то естественным будет желание выяснить, *какие именно* предикторы «виноваты» в этом. Мы могли бы исследовать отдельные p -значения вроде тех, которые представлены в табл. 3.4, но, как было отмечено ранее, при большом p велика вероятность, что мы сделаем неверные заключения.

Наличие связи между всеми предикторами и откликом возможно, однако чаще встречаются ситуации, когда отклик связан только с некоторым подмножеством предикторов. Задачу по нахождению предикторов, связанных с откликом, с целью последующей подгонки единой модели, включающей только такие предикторы, называют *отбором информативных переменных*. Проблема отбора информативных переменных детально исследуется в главе 6, и поэтому здесь мы приведем только краткое описание некоторых классических подходов.

В идеале мы хотели бы выполнить отбор переменных путем перебора большого количества различных моделей, каждая из которых включает свой набор предикторов. Например, при $p = 2$ мы можем рассмотреть четыре модели: (1) модель без переменных, (2) модель, содержащую лишь X_1 , (3) модель, содержащую только X_2 , и (4) модель, содержащую X_1 и X_2 . Далее мы можем выбрать *оптимальную* из всех рассмотренных моделей. Как мы определяем, какая из моделей является оптимальной? Для суждения о качестве модели можно использовать разные критерии. Они включают C_p Мэллоу, информационный критерий Акаике (AIC), байесовский информационный критерий (BIC), а также скорректированный

отбор
информа-
тивных
перемен-
ных

C_p
Мэллоу

AIC
BIC

коэффициент детерминации R^2 . Эти критерии детально обсуждаются в главе 6. Кроме того, мы можем определить оптимальную модель путем визуализации результатов моделирования (например, остатков) для обнаружения соответствующих закономерностей.

скорректи-
рованный
 R^2

К сожалению, существует 2^p моделей, содержащих подмножества p переменных. Это означает, что даже для умеренных p перебор всех возможных подмножеств предикторов невыполним. Например, мы видели, что при $p = 2$ рассмотрению подлежат $2^2 = 4$ модели. Однако при $p = 30$ нам придется рассмотреть $2^{30} = 1\,073\,741\,824$ моделей! Это непрактично. Следовательно, за исключением случаев с очень небольшим p , мы не можем рассмотреть все 2^p моделей, и вместо этого нам нужен какой-то автоматизированный и эффективный способ для выбора меньшего набора подлежащих рассмотрению моделей. Для решения этой задачи существует три классических метода:

- *Отбор с включением.* Мы начинаем с нулевой модели — модели, которая включает свободный член, но не содержит предикторов. Далее мы подгоняем p простых линейных регрессий и добавляем к нулевой модели ту переменную, которая приводит к наименьшей RSS. Затем мы добавляем ту переменную, которая приводит к наименьшей RSS для новой модели с двумя переменными. Этот процесс продолжается до удовлетворения некоторого правила остановки.
- *Отбор с исключением.* Мы начинаем с модели, включающей все переменные, и исключаем из нее переменную с наибольшим p -значением, т. е. наименее значимую переменную. Далее подгоняется новая модель с $(p - 1)$ переменными, и из нее удаляется переменная с наибольшим p -значением. Этот процесс продолжается до удовлетворения некоторого правила остановки. Например, мы можем остановиться, когда p -значения у всех переменных оказываются ниже определенного порога.
- *Комбинированный отбор.* Этот метод является сочетанием отбора с включением и отбора с исключением. Мы начинаем с нулевой модели и, как при отборе с включением, добавляем переменную, обеспечивающую наилучшее качество. Далее мы продолжаем добавлять переменные одну за другой. Конечно, как мы уже видели в примере с данными Advertising, по мере добавления новых предикторов в модель некоторые p -значения могут становиться большими. Следовательно, если в какой-то момент p -значение какой-то из переменных в модели начинает превышать некоторый порог, мы удаляем эту переменную из модели. Мы продолжаем выполнять эти шаги вперед и назад до тех пор, пока p -значения у всех переменных в модели не оказываются достаточно низкими, а p -значения у исключенных переменных — высокими при добавлении в модель.

Отбор с исключением неприменим при $p > n$, тогда как отбор с включением применим в любых ситуациях. Отбор с включением является жадным методом и может на ранних этапах добавить переменные, которые позднее становятся излишними. Комбинированный отбор может это исправить.

Вопрос 3: Качество модели

Двумя наиболее распространенными количественными мерами качества модели являются RSE и R^2 (доля объясненной дисперсии). Эти показатели вычисляются и интерпретируются тем же образом, как и для простой линейной регрессии.

Вспомните, что в простой линейной регрессии коэффициент детерминации R^2 равен квадрату корреляции между откликом и независимой переменной. Оказывается, что в случае множественной линейной регрессии он равен $\text{Cor}(Y, \hat{Y})^2$, т. е. квадрату корреляции между откликом и его модельным значением; по сути, одним из свойств подогнанной линейной модели является то, что из всех возможных моделей она максимизирует эту корреляцию.

Значение R^2 , близкое к 1, указывает на то, что модель объясняет значительную часть дисперсии независимой переменной. Например, в табл. 3.6 мы видели, что для данных Advertising модель, предсказывающая продажи на основе всех трех типов рекламы, имела $R^2 = 0.8972$. С другой стороны, у модели, которая использует для предсказания sales только TV и radio, R^2 составляет 0.89719. Другими словами, имеет место *небольшое* увеличение R^2 при добавлении newspaper в модель, которая уже содержит TV и radio, хотя раньше в табл. 3.4 мы видели, что р-значение для newspaper было незначимым. Оказывается, что R^2 всегда будет возрастать при добавлении в модель дополнительных переменных, даже если эти переменные очень слабо связаны с откликом. Это обусловлено тем фактом, что добавление новой переменной в формулу наименьших квадратов обязано приводить к более точному описанию обучающих данных (хотя это не обязательно так для контрольной выборки). Поэтому статистика R^2 , также вычисленная по обучающим данным, обязана возрастать. То обстоятельство, что добавление газетной рекламы в модель, включающую рекламу на телевидении и радио, вызывает лишь незначительное увеличение R^2 , является дополнительным свидетельством в пользу того, что newspaper можно исключить из модели. В сущности, newspaper не вызывает реального улучшения качества модели, подогнанной по обучающей выборке, и включение этой переменной может привести к плохим результатам на независимых контрольных выборках в силу переобучения.

В то же время модель, содержащая в качестве предиктора только TV, имела $R^2 = 0.61$ (табл. 3.2). Добавление переменной radio в эту модель приводит к существенному улучшению R^2 . Это предполагает, что модель, которая предсказывает продажи на основе рекламы на телевидении и радио, гораздо лучше модели, использующей только телевизионную рекламу. Мы могли бы также охарактеризовать это улучшение количественно, исследовав р-значение коэффициента для radio в модели, которая содержит в качестве предикторов только TV и radio.

RSE у модели, содержащей в качестве предикторов только TV и radio, составляет 1.681, а у модели, которая включает также newspaper, RSE = 1.686 (табл. 3.6). В то же время модель, включающая только TV, имеет RSE = 3.26 (табл. 3.2). Это подтверждает наше предыдущее заключение о том, что модель, использующая для предсказания продаж затраты на рекламу на телевидении и радио, является гораздо более точной (на обучающей выборке), чем та, которая использует только затраты на телере-

кламу. Более того, при условии, что в качестве предикторов используются затраты на рекламу на телевидении и радио, нет смысла в добавлении в качестве предиктора также затрат на рекламу в газетах. Внимательный читатель может задаться вопросом о том, как при добавлении в модель переменной *newspaper* RSE может увеличиться, учитывая, что RSS обязана снижаться? В общем виде RSE вычисляется по формуле

$$\text{RSE} = \sqrt{\frac{1}{n - p - 1} \text{RSS}}, \quad (3.25)$$

которая упрощается до (3.15) в случае простой линейной регрессии. Таким образом, модели с большим количеством переменных могут иметь более высокую RSE, если снижение RSS мало, по сравнению с увеличением p .

Помимо анализа рассмотренных только что RSE и R^2 , полезной может оказаться также визуализация данных. Графические сводки могут выявить проблемы с моделью, незаметные по количественным показателям. Например, на рис. 3.5 представлен трехмерный график зависимости *sales* от TV и radio. Мы видим, что некоторые наблюдения лежат выше, а некоторые — ниже плоскости наименьших квадратов. Похоже, в частности, что линейная модель переоценивает *sales* в случаях, когда большая часть рекламного бюджета была потрачена только на телевидение или только на радио. При этом она недооценивает *sales* в случаях, когда бюджет был разделен между этими двумя СМИ. Такую выраженную нелинейную зависимость невозможно смоделировать с высокой точностью при помощи линейной регрессии. Данная зависимость предполагает наличие *синергии*, или эффекта *взаимодействия* между разными типами рекламы, когда определенное сочетание СМИ приводит к большему росту продаж, нежели использование любого из них по отдельности. В подразделе 3.3.2 мы обсудим расширение линейной модели, позволяющее учесть подобные синергичные эффекты путем добавления новых переменных, описывающих взаимодействия.

Вопрос 4: Предсказания

Подогнав множественную регрессионную модель, можно легко применить (3.21) для предсказания значения отклика Y по набору значений предикторов $X_1, X_2, \dots, X_p$. Однако имеют место три вида неопределенности в отношении такого предсказания:

1. Коэффициенты $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$ являются оценками $\beta_0, \beta_1, \dots, \beta_p$. Иными словами, *плоскость наименьших квадратов*

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \dots + \hat{\beta}_p X_p$$

является лишь оценкой *истинной регрессионной плоскости*

$$f(X) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p.$$

Неточность в оценках коэффициентов есть проявление *устранимой ошибки* (глава 2). Мы можем вычислить доверительный интервал с целью определения того, насколько близка оценка $\hat{Y}$ к $f(X)$.




РИСУНОК 3.5. Линейная зависимость sales от TV и radio, подогнанная по данным Advertising. По характеру расположения остатков видна четко выраженная нелинейная зависимость. Положительные остатки (располагаются над плоскостью) преимущественно выстраиваются вдоль линии, проходящей под углом 45° , где затраты на теле- и радиорекламу распределены равномерно. При неравномерном распределении бюджетов отрицательные остатки (большинство из них не видны) в основном отклоняются от этой линии

2. Конечно, на практике предположение о линейной форме модели для $f(X)$ почти всегда является упрощением реальности, в связи с чем имеет место дополнительный источник потенциально устранимой ошибки, который мы называем *смещением модели*. Поэтому, применяя линейную модель, мы фактически оцениваем наилучшую линейную аппроксимацию истинной регрессионной плоскости. Однако здесь мы проигнорируем это несоответствие и будем действовать, как будто линейная модель верна.
3. Даже если бы мы знали $f(X)$, т. е. если бы нам были известны истинные значения $\beta_0, \beta_1, \dots, \beta_p$, зависимую переменную невозможно было бы предсказать с абсолютной точностью из-за наличия в модели (3.21) случайной ошибки ϵ . В главе 2 мы называли это *неустраняемой ошибкой*. Насколько большим будет отклонение Y от $\hat{Y}$? Для ответа на этот вопрос мы применяем *интервалы предсказания*. Интервалы предсказания всегда шире доверительных интервалов, поскольку они включают как (устраняемую) ошибку оценки $f(X)$, так и неопределенность в отношении того, насколько отдельная точка будет отличаться от истинной регрессионной плоскости (неустраняемая ошибка).

Мы применяем *доверительный интервал*, чтобы количественно выразить неопределенность в отношении *среднего* объема продаж в большом числе городов. Например, при затратах в каждом городе 100 000\$ на те-

лерекламу и 20 000\$ на радиорекламу, 95%-ный доверительный интервал составит [10 985, 11 528]. В 95% случаев интервалы данного типа будут содержать истинное значение $f(X)$.¹⁰ С другой стороны, *интервал предсказания* можно использовать для количественного описания неопределенности в отношении объема продаж в конкретном городе. При затрате в некотором городе 100 000\$ на телерекламу и 20 000\$ на радиорекламу, 95%-ный интервал предсказания составит [7930, 14 580]. В 95% случаев интервалы этого типа будут содержать истинное значение Y для данного города. Заметьте, что интервалы обоих типов центрированы относительно значения 11 256, однако интервал предсказания значительно шире доверительного интервала, что отражает повышенную неопределенность в отношении объема продаж в конкретном городе, по сравнению со средним уровнем продаж в большом количестве городов.

интервал
предсказа-
ния

3.3 Другие аспекты регрессионной модели

3.3.1 Качественные предикторы

До сих пор мы полагали, что все переменные в нашей линейной регрессионной модели являются *количественными*. Однако на практике это не всегда так — часто некоторые предикторы являются качественными.

Например, набор данных Credit, изображенный на рис. 3.6, содержит данные по среднему долгу по кредитной карте (balance) для ряда клиентов банка, а также несколько количественных предикторов: age (возраст), cards (количество карт), education (количество лет, потраченных на образование), income (доход, тыс. долларов), limit (кредитный лимит) и rating (кредитный рейтинг). Каждый график на рис. 3.6 представляет собой диаграмму рассеяния для пары переменных, чьи названия указаны в метках соответствующих строк и столбцов. Например, диаграмма, расположенная сразу справа от слова «Баланс», описывает связь между balance и age, тогда как диаграмма справа от слова «Возраст» соответствует связи между age и cards. Помимо этих количественных переменных, у нас есть также четыре качественные переменные: gender (пол), student (является ли клиент студентом), status (состоит ли клиент в браке) и ethnicity (белый, афроамериканец или азиат).

Предикторы, имеющие только два уровня

Представим, что мы хотим выяснить различия по балансу на кредитной карте между мужчинами (Male) и женщинами (Female), игнорируя пока другие переменные. Если качественный предиктор (известный также как «*фактор*») имеет только два *уровня*, или возможных значения, то добавить его в регрессионную модель очень просто. Мы просто создаем *индикаторную*, или *фиктивную*, переменную, которая принимает только два возможных количественных значения. Например, на основе переменной gender (пол) мы можем создать новую переменную вида

фактор

уровень
индикаторная
переменная

¹⁰ Другими словами, если мы получим много наборов данных, аналогичных Advertising, и построим доверительный интервал для среднего значения sales на основе каждого из этих наборов (затрачивая 100 000\$ на TV- и 20 000\$ на радио-рекламу), то 95% полученных доверительных интервалов будут включать истинное значение sales.




РИСУНОК 3.6. Набор данных Credit содержит переменные balance, age, cards, education, income, limit и rating для нескольких потенциальных клиентов банка

$$x_i = \begin{cases} 1, & \text{если } i\text{-й клиент — женщина} \\ 0, & \text{если } i\text{-й клиент — мужчина} \end{cases} \quad (3.26)$$

и использовать эту переменную в качестве предиктора в уравнении регрессии. Это приводит к следующей модели:

$$y_i = \beta_0 + \beta_1 x_1 + \epsilon_i = \begin{cases} \beta_0 + \beta_1 + \epsilon_i, & \text{если } i\text{-й клиент — женщина} \\ \beta_0 + \epsilon_i, & \text{если } i\text{-й клиент — мужчина.} \end{cases} \quad (3.27)$$

Здесь β_0 можно интерпретировать как средний баланс на кредитной карте у мужчин, $\beta_0 + \beta_1$ — как средний баланс на кредитной карте у женщин, а β_1 — как среднюю разницу по балансу на кредитной карте между женщинами и мужчинами.

В табл. 3.7 приведены оценки коэффициентов и другая информация по модели (3.27). Средний долг на кредитной карте у мужчин оценен в 509.80\$, тогда как у женщин он оказался на 19.73\$ выше, т.е. $509.80\$ + 19.73\$ = 529.53\$$. Заметьте, однако, что p -значение у индикаторной переменной очень высокое. Это указывает на отсутствие статистически значимой разницы между мужчинами и женщинами по среднему балансу на кредитной карте.

ТАБЛИЦА 3.7. Коэффициенты регрессии *balance* по *gender*, рассчитанные по методу наименьших квадратов на основе данных *Credit*

	Коэффициент	Ст. ошибка	t	p
Свободный член	509.80	33.13	15.389	< 0.0001
<i>gender</i> [Female]	19.73	46.05	0.429	0.6690

Решение закодировать пол женщин в (3.27) при помощи 1, а мужчин при помощи 0 является произвольным и не влияет на качество итоговой модели, однако оно определяет интерпретацию коэффициентов. Если бы мы закодировали пол мужчин при помощи 1, а пол женщин при помощи 0, то оценки β_0 и β_1 составили бы 529.53\$ и $-19.73\$$ соответственно, что снова привело бы к предсказанному долгу на кредитной карте в $529.53\$ - 19.73\$ = 509.80\$$ у мужчин и 529.53\$ у женщин. В качестве альтернативы кодированию с помощью 0 и 1 мы могли бы создать индикаторную переменную

$$x_i = \begin{cases} 1, & \text{если } i\text{-й клиент — женщина} \\ -1, & \text{если } i\text{-й клиент — мужчина} \end{cases}$$

и использовать эту переменную в регрессионном уравнении. Это приводит к следующей модели:

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i = \begin{cases} \beta_0 + \beta_1 + \epsilon_i, & \text{если } i\text{-й клиент — женщина} \\ \beta_0 - \beta_1 + \epsilon_i, & \text{если } i\text{-й клиент — мужчина.} \end{cases}$$

Теперь β_0 можно интерпретировать как общий средний долг на кредитной карте без учета пола клиентов, а β_1 — как величину, на которую долг у женщин и мужчин выше и ниже этого общего среднего значения соответственно. В данном примере оценка β_0 составляет 519.665\$ — среднее от средних значений у мужчин (509.80\$) и женщин (529.53\$). Оценка β_1 составила бы 9.865\$, т.е. половину от 19.73\$ — средней величины различий между женщинами и мужчинами. Важно подчеркнуть, что итоговые предсказания кредитного баланса для мужчин и женщин будут идентичными вне зависимости от использованной схемы кодирования. Различия появляются только в интерпретации коэффициентов.

Качественные предикторы, имеющие более двух уровней

Когда качественный предиктор имеет более двух уровней, одна индикаторная переменная не может представить все возможные значения. В та-

кой ситуации мы можем создать дополнительные индикаторные переменные. Так, для *ethnicity* (этническая принадлежность) мы создаем две такие переменные. Первой из них могла бы быть

$$x_{i1} = \begin{cases} 1, & \text{если } i\text{-й клиент — азиат} \\ 0, & \text{если } i\text{-й клиент — не азиат,} \end{cases} \quad (3.28)$$

а второй —

$$x_{i2} = \begin{cases} 1, & \text{если } i\text{-й клиент — белый} \\ 0, & \text{если } i\text{-й клиент — не белый.} \end{cases} \quad (3.29)$$

Тогда обе эти переменные можно было бы использовать в уравнении регрессии для получения следующей модели:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \epsilon_i = \begin{cases} \beta_0 + \beta_1 + \epsilon_i, & \text{если } i\text{-й клиент — азиат} \\ \beta_0 + \beta_2 + \epsilon_i, & \text{если } i\text{-й клиент — белый} \\ \beta_0 + \epsilon_i, & \text{если } i\text{-й клиент — афроамериканец.} \end{cases} \quad (3.30)$$

Теперь β_0 можно интерпретировать как средний кредитный баланс у афроамериканцев, β_1 — как разницу по среднему балансу у азиатов и афроамериканцев, а β_2 — как разницу по среднему балансу у белых и афроамериканцев. Число индикаторных переменных всегда будет на единицу меньше числа уровней фактора. Уровень без соответствующей индикаторной переменной — афроамериканцы в данном примере — известен как базовый.

Из табл. 3.8 мы видим, что оцененное среднее значение *balance* для базового уровня (афроамериканцы) составляет 531.00\$. Оцененный долг в группе азиатов на 18.69\$ меньше, чем в группе афроамериканцев, а долг в группе белых на 12.50\$ меньше, чем в группе афроамериканцев. Однако *p*-значения у коэффициентов этих двух индикаторных переменных очень большие, что указывает на отсутствие статистических оснований для вывода о существовании реальной разницы между этническими группами по балансу на кредитной карте. Повторим еще раз, что уровень, выбранный в качестве базового, является произвольным, и предсказания для каждой группы в итоге будут одинаковыми вне зависимости от этого выбора. Однако коэффициенты и их *p*-значения все же зависят от выбранного способа кодирования индикаторных переменных. Вместо того чтобы полагаться на отдельные коэффициенты, мы можем использовать *F*-критерий для проверки гипотезы $H_0 = \beta_1 = \beta_2 = 0$ — данный тест не будет зависеть от способа кодирования. *P*-значение для этого *F*-критерия составляет 0.96, на основании чего мы не можем отклонить нулевую гипотезу об отсутствии связи между *balance* и *ethnicity*.

базовый
уровень

ТАБЛИЦА 3.8. Коэффициенты регрессии *balance* по *ethnicity*, рассчитанные по методу наименьших квадратов на основе данных *Credit*. Эта линейная модель определена в (3.30), т. е. этническая принадлежность закодирована при помощи двух индикаторных переменных, представленных в (3.28) и (3.29)

	Коэффициент	Ст. ошибка	<i>t</i>	<i>p</i>
Свободный член	531.00	46.32	11.464	< 0.0001
<i>ethnicity</i> [Asian]	−18.69	65.02	−0.287	0.7740
<i>ethnicity</i> [Caucasian]	−12.50	56.68	−0.221	0.8260

Использование метода индикаторных переменных не составляет труда при включении в модель как количественных, так и качественных предикторов. Например, для нахождения регрессионной зависимости *balance* от количественной переменной вроде *income* и качественной переменной вроде *student* мы должны просто создать индикаторную переменную для *student*, а затем подогнать множественную регрессионную модель, используя *income* и эту индикаторную переменную в качестве предикторов кредитного баланса.

Помимо рассмотренного здесь метода индикаторных переменных, существует множество других способов кодирования качественных переменных. Все эти способы приводят к созданию эквивалентных моделей, однако коэффициенты и их интерпретация различаются, поскольку эти коэффициенты предназначены для отображения разных контрастов. Эта тема выходит за рамки данной книги, и мы не будем дальше ее рассматривать.

контрасты

Расширения линейной модели

Стандартная линейная регрессионная модель (3.19) позволяет получать интерпретируемые результаты и довольно хорошо работает при решении многих практических проблем. Однако она основана на ряде строгих ограничивающих допущений, которые на практике часто не выполняются. Два наиболее важных допущения утверждают, что зависимость между предикторами и откликом является аддитивной и линейной. Условие аддитивности означает, что влияние предиктора X_j на отклик Y не зависит от значений других предикторов. Условие линейности заключается в том, что изменение отклика Y при изменении X_j на одну единицу одинаково вне зависимости от значения X_j . В этой книге мы рассматриваем несколько сложных методов, которые ослабляют эти допущения. Здесь мы кратко рассмотрим некоторые классические подходы, позволяющие расширить линейную модель.

аддитивность
линейность

Снятие ограничения на аддитивность

В нашем предыдущем анализе данных *Advertising* мы сделали заключение о том, что объем продаж (*sales*) связан с рекламой как на радио (*radio*), так и телевидении (*TV*). Линейные модели, легшие в основу этого вывода, подразумевали, что эффект на *sales* от увеличения затрат на рекламу в одном СМИ не зависит от затрат на другое СМИ. Например,

линейная модель (3.20) утверждает, что среднее изменение sales при увеличении TV на одну единицу всегда равно β_1 , вне зависимости от затрат на радиорекламу.

Однако эта простая модель может быть неверной. Представьте, что на самом деле затраты на радиорекламу увеличивают эффективность телерекламы, в связи с чем угловой коэффициент для TV должен возрастать одновременно с radio. В такой ситуации при фиксированном бюджете в 100 000\$ трата половины денег на радиорекламу, а второй половины на телерекламу может увеличить продажи в большей степени, нежели при направлении всех денег отдельно на теле- или радиорекламу. В маркетинге этот эффект известен как *синергия*, а в статистике его называют эффектом *взаимодействия*. Как видно на рис. 3.5, подобный эффект может иметь место в данных по рекламе. Заметьте, что при низких уровнях TV и radio действительные значения sales ниже тех значений, которые предсказывает модель. Однако при равномерном распределении бюджета на оба типа рекламы модель имеет тенденцию завышать продажи.

Рассмотрим стандартную линейную регрессионную модель с двумя переменными:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon.$$

Согласно этой модели, при увеличении X_1 на одну единицу Y увеличится в среднем на β_1 единиц. Заметьте, что присутствие X_2 не изменяет этого утверждения, т.е. вне зависимости от значения X_2 увеличение X_1 на одну единицу приведет к увеличению Y на β_1 единиц. Один из способов расширения этой модели для учета синергии заключается в добавлении третьего предиктора, который называется *эффектом взаимодействия* и вычисляется как произведение X_1 и X_2 . Это приводит к модели

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + \epsilon. \quad (3.31)$$

Каким образом добавление этой новой переменной ослабляет условие аддитивности? Обратите внимание на то, что (3.31) можно переписать в виде

$$Y = \beta_0 + (\beta_1 + \beta_3 X_2) X_1 + \beta_2 X_2 + \epsilon = \beta_0 + \tilde{\beta}_1 X_1 + \beta_2 X_2 + \epsilon, \quad (3.32)$$

где $\tilde{\beta}_1 = \beta_1 + \beta_3 X_2$. Поскольку $\tilde{\beta}_1$ изменяется одновременно с X_2 , то влияние X_1 на Y больше не будет постоянным: изменение X_2 приведет к изменению эффекта X_1 на Y .

Представьте, например, что мы заинтересованы в изучении производительности некоторой фабрики. Мы хотим предсказать количество единиц продукции (units) на основе числа производственных линий (lines) и общего числа работников (workers). Вполне вероятно, что эффект от увеличения числа производственных линий будет зависеть от числа работников, поскольку если не будет работников для управления линиями, то увеличение числа этих линий не приведет к росту продукции. Это предполагает, что в линейную модель для предсказания units следует включить эффект взаимодействия между lines и workers. Предположим, что при подгонке модели мы получаем

$$\begin{aligned}\text{units} &\approx 1.2 + 3.4 \times \text{lines} + 0.22 \times \text{workers} + 1.4 \times (\text{lines} \times \text{workers}) = \\ &= 1.2 + (3.4 + 1.4 \times \text{workers}) \times \text{lines} + 0.22 \times \text{workers}.\end{aligned}$$

Другим словами, добавление новой линии увеличит количество единиц продукции на $3.4 + 1.4 \times \text{workers}$. Следовательно, чем больше у нас работников, тем сильнее будет эффект переменной *lines*.

Теперь мы вернемся к примеру с данными по рекламе. Линейная модель, которая использует *radio*, *TV* и их взаимодействие для предсказания *sales*, принимает следующую форму:

$$\begin{aligned}\text{sales} &= \beta_0 + \beta_1 \times \text{TV} + \beta_2 \times \text{radio} + \beta_3 \times (\text{radio} \times \text{TV}) + \epsilon = \\ &= \beta_0 + (\beta_1 + \beta_3 \times \text{radio}) \times \text{TV} + \beta_2 \times \text{radio} + \epsilon.\end{aligned}\quad (3.33)$$

Мы можем интерпретировать β_3 как прирост эффективности телерекламы в ответ на увеличение радиорекламы на одну единицу (и наоборот). Коэффициенты, получаемые при подгонке модели (3.33), представлены в табл. 3.9.

ТАБЛИЦА 3.9. Коэффициенты регрессионной зависимости *sales* от *TV*, *radio* и их взаимодействия (см. уравнение 3.33), рассчитанные по методу наименьших квадратов на основе данных Advertising

	Коэффициент	Ст. ошибка	<i>t</i>	<i>p</i>
Свободный член	6.7502	0.248	27.23	< 0.0001
TV	0.0191	0.002	12.70	< 0.0001
radio	0.0289	0.009	3.24	0.0014
TV × radio	0.0011	0.000	20.73	< 0.0001

Результаты, приведенные в табл. 3.9, со всей очевидностью указывают на то, что модель, включающая эффект взаимодействия, превосходит модель, которая содержит только *главные эффекты*. Р-значение для эффекта взаимодействия (*TV* × *radio*) является крайне низким, что говорит о наличии веских оснований в пользу $H_a : \beta_3 \neq 0$. Иными словами, четко видно, что истинная зависимость не является аддитивной. Коэффициент детерминации R^2 для модели (3.33) составляет 96.8%, тогда как для модели, предсказывающей *sales* на основе *TV* и *radio* без эффекта их взаимодействия, он составляет лишь 89.7%. Это означает, что $(96.8 - 89.7)/(100 - 89.7) = 69\%$ дисперсии *sales*, остающейся после подгонки аддитивной модели, были объяснены эффектом взаимодействия. Оценки коэффициентов, приведенные в табл. 3.9, указывают на то, что увеличение затрат на телерекламу на 1000\$ связано с ростом продаж на $(\hat{\beta}_1 + \hat{\beta}_3 \times \text{radio}) \times 1000 = 19 + 1.1 \times \text{radio}$ единиц. В свою очередь увеличение на 1000\$ затрат на радиорекламу будет связано с ростом продаж на $(\hat{\beta}_2 + \hat{\beta}_3 \times \text{TV}) \times 1000 = 29 + 1.1 \times \text{TV}$ единиц.

В этом примере р-значения для *TV*, *radio* и эффекта их взаимодействия являются статистически значимыми (табл. 3.9), и поэтому ясно, что в модель должны быть включены все три переменные. Однако иногда

главный эффект

принцип
иерархии

бывает так, что эффект взаимодействия имеет очень низкое p -значение, а соответствующие главные эффекты (в данном случае TV и radio) — нет. *Принцип иерархии* гласит, что при включении в модель эффекта взаимодействия нам следует также включать главные эффекты, даже если p -значения их коэффициентов незначимы. Другими словами, если взаимодействие между X_1 и X_2 выглядит важным, тогда нам следует включить в модель и X_1 , и X_2 , даже если оценки их коэффициентов имеют высокие p -значения. Обоснование этого принципа состоит в том, что если переменная $X_1 \times X_2$ связана с откликом, то проверка равенства коэффициентов X_1 и X_2 нулю практически не представляет интереса. Кроме того, переменная $X_1 \times X_2$ обычно коррелирует с X_1 и X_2 , и поэтому исключение главных эффектов изменяет смысл взаимодействия.

В предыдущем примере мы рассмотрели взаимодействие между переменными TV и radio, обе из которых являются количественными. Однако концепция взаимодействия одинаково применима также к качественным переменным и к комбинациям количественных и качественных переменных. Более того, взаимодействие между качественной и количественной переменными имеет особенно привлекательную интерпретацию. Обратимся к набору данных Credit из подраздела 3.3.1 и предположим, что мы хотим предсказать balance на основе количественной переменной income и качественной переменной student.

В отсутствие эффекта взаимодействия модель принимает следующую форму:

$$\begin{aligned} \text{balance}_i &\approx \beta_0 + \beta_1 \times \text{income}_i + \\ &\begin{cases} \beta_2, & \text{если } i\text{-й клиент — студент} \\ 0, & \text{если } i\text{-й клиент — не студент} \end{cases} = \\ &\beta_1 \times \text{income}_i + \\ &\begin{cases} \beta_0 + \beta_2, & \text{если } i\text{-й клиент — студент} \\ \beta_0, & \text{если } i\text{-й клиент — не студент.} \end{cases} \end{aligned} \quad (3.34)$$

Заметьте, что это сводится к подгонке двух параллельных линий — одной для студентов, а другой для не студентов. Уравнения линий для студентов и не студентов имеют разные свободные члены — $\beta_0 + \beta_2$ против β_0 , — но одинаковый угол наклона β_1 . Эта ситуация показана на рис. 3.7 слева. Факт параллельного расположения линий означает, что средняя величина изменения balance при увеличении income на одну единицу не зависит от того, является ли тот или иной клиент студентом. Потенциально это вносит в модель серьезное ограничение, поскольку в действительности изменение дохода может оказывать очень разные эффекты на долг по кредитной карте у студента и не студента.

Это ограничение можно упразднить, добавив эффект взаимодействия — переменную, созданную путем умножения income на индикаторную переменную student. Тогда наша модель превратится в следующую:




РИСУНОК 3.7. Коэффициенты регрессионной зависимости *balance* от *income* у студентов и не студентов, подогнанной по методу наименьших квадратов на основе данных *Credit*. Слева: подогнана модель (3.34). Взаимодействия между *income* и *student* нет. Справа: подогнана модель (3.35). Имеет место взаимодействие между *income* и *student*

$$\text{balance}_i \approx \beta_0 + \beta_1 \times \text{income}_i + \begin{cases} \beta_2 + \beta_3 \times \text{income}_i, & \text{если } i\text{-й клиент — студент} \\ 0, & \text{если } i\text{-й клиент — не студент} \end{cases} = \begin{cases} (\beta_0 + \beta_2) + (\beta_1 + \beta_3) \times \text{income}_i, & \text{если } i\text{-й клиент — студент} \\ \beta_0 + \beta_1 \times \text{income}_i, & \text{если } i\text{-й клиент — не студент.} \end{cases} \quad (3.35)$$

Подчеркнем еще раз, что у нас есть две разные регрессионные линии для студентов и не студентов. Однако теперь эти регрессионные линии имеют разные свободные члены ($\beta_0 + \beta_2$ против β_0) и коэффициенты угла наклона ($\beta_1 + \beta_3$ против β_1). Это позволяет учесть возможность того, что изменения в доходе могут по-разному влиять на долг по кредитной карте у студентов и не студентов. График на рис. 3.7 справа показывает зависимости между *income* и *balance* у студентов и не студентов, подогнанные в соответствии с моделью (3.35). Видно, что угол наклона прямой у студентов ниже, чем у не студентов. Это предполагает, что увеличение дохода у студентов связано с меньшим ростом долга по кредитной карте.

Нелинейные зависимости

Как обсуждалось ранее, линейная регрессионная модель (3.19) предполагает линейную связь между откликом и предикторами. Однако в некоторых случаях истинная связь между откликом и предикторами может быть нелинейной. Здесь мы представим очень простой способ непосредственного расширения линейной модели, позволяющий подгонять нелинейные зависимости при помощи *полиномиальной регрессии*. В последующих главах мы представим более сложные подходы для подгонки нелинейных моделей, основанные на более универсальной методологии.

полиноми-
альная
регрессия




РИСУНОК 3.8. Данные из таблицы Auto. Приведены mpg (расход топлива) и horsepower (мощность двигателя) для нескольких автомобилей. Линейная регрессионная модель показана в виде оранжевой линии. Линейная регрессионная модель, включающая horsepower^2 , показана в виде голубой линии. Линейная регрессионная модель, включающая все полиномы horsepower вплоть до 5-й степени, показана в виде зеленой линии

Рассмотрим рис. 3.8, где показана зависимость mpg (расход топлива, миль на галлон) от horsepower (мощность двигателя, лошадиные силы) для нескольких автомобилей из набора данных Auto. Оранжевая линия соответствует линейной регрессионной модели. Имеет место выраженная связь между mpg и horsepower, однако хорошо видно, что эта связь нелинейна: данные указывают на искривленную форму зависимости. Простой подход для включения нелинейных зависимостей в линейную модель состоит в добавлении преобразованных предикторов. Например, характер расположения точек на рис. 3.8 указывает на *квадратичную* форму зависимости, из чего следует, что модель вида

$$\text{mpg} = \beta_0 + \beta_1 \times \text{horsepower} + \beta_2 \times \text{horsepower}^2 + \epsilon \quad (3.36)$$

может дать более приемлемое описание данных. Уравнение 3.36 предполагает предсказание mpg на основе нелинейной функции horsepower. Однако это все еще линейная модель! Другими словами, (3.36) — это просто множественная регрессионная модель, в которой $X_1 = \text{horsepower}$, а $X_2 = \text{horsepower}^2$. Поэтому для нахождения β_0 , β_1 и β_2 и подгонки искривленной линии мы можем воспользоваться стандартным программным обеспечением для линейной регрессии. Результат подгонки квадратичной модели к этим данным представлен в виде голубой линии на рис. 3.8. Похоже, что квадратичное уравнение описывает данные намного лучше уравнения, содержащего только линейный член. Статистика R^2 у квадратичной модели составляет 0.688 против 0.606 у линейной модели, а p -значение квадратичного члена является высоко значимым (табл. 3.10).

ТАБЛИЦА 3.10. Коэффициенты регрессионной зависимости mpg от horsepower и horsepower^2 , рассчитанные по методу наименьших квадратов на основе данных Auto

	Коэффициент	Ст. ошибка	t	p
Свободный член	56.9001	1.8004	31.6	< 0.0001
horsepower	-0.4662	0.0311	-15.0	< 0.0001
horsepower^2	0.0012	0.0001	10.1	< 0.0001

Если включение horsepower^2 привело к такому существенному улучшению модели, то почему бы не добавить также horsepower^3 , horsepower^4 или даже horsepower^5 ? Зеленая кривая на рис. 3.8 представляет собой результат подгонки модели, включающей все полиномы вплоть до 5-й степени. Полученная модель выглядит излишне извилистой, т.е. не ясно, действительно ли включение дополнительных членов привело к более качественному описанию данных.

Описанный нами выше метод расширения линейной модели для учета нелинейных зависимостей известен как *полиномиальная регрессия*, поскольку мы добавляем в регрессионную модель полиномиальные функции предикторов. В главе 7 мы продолжим рассмотрение этого, а также других способов нелинейных расширений линейной модели.

3.3.2 Потенциальные проблемы

При подгонке линейной регрессионной модели к тому или иному набору данных может возникнуть целый ряд проблем. Наиболее распространенные из этих проблем заключаются в следующем.

1. Нелинейность связи между откликом и предикторами.
2. Корреляция остатков.
3. Непостоянная дисперсия остатков.
4. Выбросы.
5. Влиятельные наблюдения.
6. Коллинеарность.

На практике обнаружение и преодоление этих проблем являются в равной степени искусством и наукой. На эту тему написано огромное количество страниц в многочисленных книгах. Поскольку в этой книге линейная регрессионная модель не является основным центром внимания, мы приведем лишь краткое описание некоторых ключевых аспектов.

1. Нелинейность данных

Линейная регрессионная модель предполагает наличие прямолинейной связи между предикторами и откликом. Если истинная зависимость далека от линейной, то фактически все заключения, которые мы делаем на основе подогнанной модели, будут сомнительными. Кроме того, существенно более низкой может оказаться точность предсказаний такой модели.

Графики остатков представляют собой полезный графический инструмент для обнаружения нелинейности. Имея простую линейную регрессионную модель, мы можем изобразить остатки $e_i = y_i - \hat{y}_i$ в зависимости от предиктора x_i . В случае множественной регрессионной модели, которая содержит несколько предикторов, мы вместо этого изображаем зависимость остатков от предсказанных, или модельных, значений $\hat{y}_i$. В идеале график остатков не выявит никакой различимой структуры в расположении точек. Наличие же такой структуры может указывать на определенную проблему с линейной моделью.




РИСУНОК 3.9. Графики зависимости остатков от предсказанных, или модельных, значений для набора данных Auto. На каждом графике красная кривая представляет собой сглаживающую линию, подогнанную к остаткам с целью облегчить выявление характера их расположения. Слева: линейная регрессия mpg по horsepower. Выраженная закономерность в расположении остатков указывает на нелинейность в данных. Справа: линейная регрессия mpg по horsepower и horsepower². Закономерности в расположении остатков почти нет

Слева на рис. 3.9 изображены остатки линейной регрессии mpg по horsepower, подогнанной по данным Auto (см. рис. 3.8). Красная кривая представляет собой сглаживающую линию, подогнанную к остаткам с целью облегчить обнаружение каких-либо закономерностей в их расположении. Остатки демонстрируют выраженную U-образную форму, что является надежным свидетельством нелинейности в данных. Справа на рис. 3.9 показаны остатки, полученные в результате подгонки модели (3.36) с квадратичным членом. Здесь закономерности в расположении остатков почти нет, что указывает на более адекватное описание данных, вызванное добавлением квадратичного члена.

Если график остатков свидетельствует о наличии нелинейной связи в данных, то простым решением проблемы является добавление в модель нелинейных преобразований предикторов, таких как $\log X$, $\sqrt{X}$ и X^2 . В последующих главах этой книги мы будем обсуждать другие, более продвинутое нелинейные методы, позволяющие преодолеть эту проблему.

2. Корреляция остатков

Важное допущение линейной регрессионной модели состоит в том, что остатки $\epsilon_1, \epsilon_2, \dots, \epsilon_n$ являются некоррелированными. Что это означает? Например, если в остатках нет корреляции, то положительное значение ϵ_i практически не несет никакой информации о знаке ϵ_{i+1} . Стандартные ошибки, которые рассчитываются для оценок регрессионных коэффициентов или предсказанных значений отклика, основаны на предположении о некоррелированных остатках. Если же корреляция в остатках присутствует, то оцененные стандартные ошибки обычно будут занижать истинные значения стандартных ошибок. В результате этого доверительные интервалы и интервалы предсказаний будут уже, чем следует. Например, 95%-ный доверительный интервал может включать истинное значение параметра с вероятностью, намного меньшей, чем 0.95. Р-значения параметров модели также будут ниже, чем следует; это могло бы привести к ложному заключению о том, что тот или иной параметр является статистически значимым. Короче говоря, коррелированные остатки могут привести к необоснованному чувству уверенности в нашей модели.

В качестве экстремального примера предположим, что мы случайно продублировали наши данные и это привело к возникновению пар идентичных наблюдений и остатков. Проиригнорировав это, мы вычисляли бы стандартные ошибки, как будто у нас была выборка объемом $2n$, хотя на самом деле у нас есть только n наблюдений. Наши оценки параметров для $2n$ и n наблюдений были бы одинаковыми, но доверительные интервалы оказались бы в $\sqrt{2}$ раз ниже!

Отчего возникает корреляция в остатках? Подобные корреляции обычны при работе с *временными рядами*, которые состоят из наблюдений, полученных через определенные промежутки времени. Часто наблюдения, полученные в соседних временных точках, будут иметь положительно коррелирующие остатки. Для обнаружения этого в некотором наборе данных мы можем изобразить остатки из нашей модели в зависимости от времени. В отсутствие корреляции в остатках на графике не должно быть видно никаких закономерностей. С другой стороны, при наличии положительной корреляции в остатках может наблюдаться *трекинг* — явление, при котором соседние остатки имеют похожие значения. Рисунок 3.10 иллюстрирует эти идеи. На верхнем графике мы видим остатки из линейной регрессии, подогнанной к имитированным данным, в которых остатки не коррелируют. Указаний на наличие временного тренда в этом случае нет. Остатки же, показанные на нижнем графике, происходят из набора данных, в котором корреляция составляет 0.9. Здесь имеет место выраженная закономерность — соседние остатки имеют тенденцию принимать похожие значения. Наконец, график, представленный в центре, иллюстрирует умеренный случай, в котором корреляция остатков составила 0.5. Трекинг все еще заметен, но выражен не так четко.

временной
ряд

трекинг

Разработано большое количество методов, позволяющих корректно учесть корреляцию в остатках при работе с временными рядами. Корреляции в остатках могут встречаться также при работе с данными, которые не являются временными рядами. Например, представьте себе ситуацию, в которой рост людей предсказывается по их весу. Условие некоррелированных остатков могло бы нарушаться в случаях, когда некоторые участ-




РИСУНОК 3.10. Графики остатков для временных рядов, которые были сгенерированы с использованием разных уровней корреляции ρ между соседними временными точками

ники исследования были членами одной семьи, или употребляли одинаковую диету, или были подвержены действию одинаковых факторов среды. В целом предположение о некоррелированных остатках является чрезвычайно важным для линейной регрессии и других статистических методов, и ключом к снижению риска возникновения подобных корреляций является хорошее планирование эксперимента.

3. Непостоянная дисперсия остатков

Другое важное допущение линейной регрессионной модели состоит в том, что ее остатки имеют постоянную дисперсию, т. е. $\text{Var}(\epsilon_i) = \sigma^2$. На этом допущении основано вычисление соответствующих стандартных ошибок и доверительных интервалов, а также проверка статистических гипотез.

К сожалению, очень часто дисперсия остатков оказывается непостоянной. Например, она может возрастать с увеличением значений отклика. Непостоянство, или *гетероскедастичность*, дисперсии можно выявить по наличию воронкообразной формы на графике остатков. На рис. 3.11 слева приведен пример, в котором разброс остатков возрастает по мере увеличения предсказанных значений. При возникновении такой проблемы одним

из возможных решений является преобразование отклика Y с использованием вогнутой функции вроде $\log Y$ или $\sqrt{Y}$. Подобное преобразование сопровождается более сильным «сжатием» более высоких значений остатков, что приводит к снижению гетероскедастичности. Справа на рис. 3.11 показан график остатков после преобразования отклика путем логарифмирования. Теперь остатки демонстрируют постоянную дисперсию, хотя и имеется некоторое указание на слабовыраженную нелинейную зависимость в данных.




РИСУНОК 3.11. *Графики остатков. На каждом графике красная кривая представляет собой сглаживающую линию, подогнанную к остаткам для выявления характера их расположения. Синие линии соответствуют квартилям остатков и подчеркивают закономерность в их расположении. Слева: воронкообразная форма указывает на гетероскедастичность. Справа: отклик был прологарифмирован, и теперь указаний на гетероскедастичность нет*

Иногда у нас есть хорошее представление о дисперсии каждого значения зависимой переменной. Например, i -е значение отклика могло бы представлять собой среднее значение из n_i исходных наблюдений. Если каждое из этих исходных наблюдений не коррелирует с дисперсией σ^2 , то их среднее значение имеет дисперсию $\sigma_i^2 = \sigma^2/n_i$. В этом случае простым решением проблемы является подгонка модели по методу *взвешенных наименьших квадратов*, в котором веса пропорциональны обратным величинам дисперсий ($w_i = n_i$ в данном примере). Большинство программ для расчета линейной регрессии позволяет работать с весами наблюдений.

метод
взвешен-
ных
наимень-
ших
квадратов

4. Выбросы

Выброс — это наблюдение, у которого y_i существенно отличается от значения, предсказанного моделью. Выбросы могут возникать по ряду причин — например, неверный учет наблюдения во время сбора данных.

выброс

Красная точка (наблюдение № 20), показанная слева на рис. 3.12, является примером типичного выброса. Красная сплошная линия — это регрессионная модель, подогнанная по методу наименьших квадратов, а синяя




РИСУНОК 3.12. Слева: линия наименьших квадратов показана красным цветом, а регрессионная линия, подогнанная после удаления выброса, — синим. В центре: график остатков четко показывает наличие выброса. Справа: студентизированный остаток выброса равен 6, тогда как обычно мы ожидаем значения от -3 до 3 .

прерывистая линия — это модель, подогнанная по методу наименьших квадратов после удаления выброса. В данном случае удаление выброса оказывает незначительный эффект на модель: оно почти не изменяет угла наклона и приводит лишь к незначительному снижению коэффициента свободного члена. Для выброса, который не имеет необычного значения предиктора, подобное незначительное влияние на модель типично. Однако даже если выброс не оказывает большого эффекта на модель, он может привести к возникновению других проблем. Так, в данном примере RSE составляет 1.09 при включении выброса в модель и лишь 0.77 после его удаления. Поскольку RSE используется для вычисления всех доверительных интервалов и p -значений, подобное резкое увеличение, вызванное лишь одним наблюдением, может иметь последствия для интерпретации всей модели. Похожим образом включение выброса в модель вызывает снижение R^2 с 0.892 до 0.805.

Для обнаружения выбросов можно воспользоваться графиками остатков. В этом примере выброс виден очень хорошо (см. график остатков, показанный в центре на рис. 3.12). Однако на практике бывает сложно решить, насколько большим должен быть остаток, чтобы считать соответствующее наблюдение выбросом. Для преодоления этой проблемы вместо исходных остатков мы можем изобразить *студентизированные остатки*, рассчитанные путем деления каждого остатка e_i на его оцененное стандартное отклонение. Наблюдения, чьи студентизированные остатки в абсолютном выражении превышают 3, потенциально являются выбросами. Справа на рис. 3.12 студентизированный остаток выброса превышает 6, тогда как студентизированные остатки остальных наблюдений изменяются от -2 до 2 .

Если мы убеждены, что выброс появился из-за ошибки, допущенной в ходе сбора данных или документирования, то простым решением будет исключение этого наблюдения из анализа. Однако следует соблюдать осторожность, поскольку выброс может указывать и на недостаток в самой модели (например, отсутствие в ней важного предиктора).

Наблюдения с высокой разбалансировкой

Как мы только что выяснили, выбросы — это наблюдения, у которых для заданного предиктора x_i наблюдается необычное значение отклика y_i . В то же время наблюдения с *высокой разбалансировкой*¹¹ имеют необычное значение x_i . Например, наблюдение № 41, показанное справа на рис. 3.13, обладает высокой разбалансировкой в том смысле, что значение предиктора у этого наблюдения велико в сравнении с другими наблюдениями. (Обратите внимание, что на рис. 3.13 показаны те же данные, что и на рис. 3.12, но с добавлением одного наблюдения, обладающего высокой разбалансировкой). Красной сплошной линией показана модель, подогнанная по методу наименьших квадратов, а прерывистой синей линией — модель, подогнанная после удаления наблюдения № 41. Сравнивая графики, представленные слева на рис. 3.12 и 3.13, мы видим, что удаление наблюдения с высокой разбалансировкой оказывает гораздо более сильное влияние на линию наименьших квадратов, нежели удаление выброса. И действительно, наблюдения с высокой разбалансировкой обычно оказывают значительное влияние на регрессионную линию. Влияние нескольких наблюдений на линию наименьших квадратов служит причиной беспокойства, поскольку такие наблюдения могут сделать непригодной всю модель. По этой причине обнаружению наблюдений с высокой разбалансировкой следует уделять серьезное внимание.

высокая
разбалан-
сировка




РИСУНОК 3.13. Слева: наблюдение № 41 является наблюдением с высокой разбалансировкой, тогда как № 20 — нет. Красная линия соответствует модели, подогнанной ко всем данным, а синяя линия — модели, подогнанной после удаления наблюдения № 41. В центре: красная точка не является необычной по значению X_1 или значению X_2 , но все же выходит за пределы основного массива данных и поэтому обладает высоким показателем разбалансировки. Справа: Наблюдение № 41 имеет высокий показатель разбалансировки и большой остаток

В случае простой линейной регрессии наблюдения с высокой разбалансировкой обнаружить довольно легко, поскольку мы просто можем найти точки, у которых значение предиктора выходит за пределы нормального интервала значений. В случае же множественной регрессии со многими предикторами возможна ситуация, когда некоторое наблюдение вполне находится в пределах диапазонов значений отдельных предикторов, но является необычным по всем предикторам сразу. Пример набора

¹¹ В оригинале используется термин «high leverage points». — Прим. пер.

данных с двумя предикторами показан в центре на рис. 3.13. У большинства наблюдений значения предикторов находятся в пределах эллипса, ограниченного голубой прерывистой линией, однако красная точка выходит далеко за пределы этого диапазона. Тем не менее это наблюдение не является необычным ни по значению X_1 , ни по значению X_2 в отдельности. Поэтому если мы исследуем только X_1 или только X_2 , нам не удастся обнаружить, что это наблюдение обладает высокой разбалансировкой. Эта проблема более выражена в случае множественной регрессии, поскольку при наличии более двух предикторов не существует простого способа одновременно изобразить все имеющиеся в данных переменные.

Для количественного выражения степени разбалансировки того или иного наблюдения мы вычисляем *показатель разбалансировки*¹². Высокое значение этого показателя говорит о том, что наблюдение обладает высокой разбалансировкой. Для простой регрессии

$$h_i = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_{i'=1}^n (x_{i'} - \bar{x})^2}. \quad (3.37)$$

Из этого уравнения видно, что h_i возрастает по мере увеличения разности между x_i и $\bar{x}$. Существует простое обобщение h_i для случая со многими предикторами, однако соответствующую формулу мы здесь не приводим. Показатель разбалансировки всегда изменяется от $1/n$ до 1, а его среднее значение для всех наблюдений всегда равно $(p+1)/n$. Поэтому если показатель разбалансировки у некоторого значения намного превосходит $(p+1)/n$, то мы можем ожидать, что это наблюдение обладает высокой разбалансировкой.

Справа на рис. 3.13 показан график зависимости студентизированных остатков от h_i для данных, представленных на том же рисунке слева. Наблюдение № 41 четко выделяется за счет очень высокого показателя разбалансировки, а также высокого студентизированного остатка. Другими словами, оно является и выбросом, и наблюдением с высокой разбалансировкой. Это особенно опасная комбинация! Данный график объясняет также, почему наблюдение № 20 имеет относительно слабый эффект на результат подгонки линии наименьших квадратов (см. рис. 3.12) — оно обладает низкой разбалансировкой.

6. Коллинеарность

Под коллинеарностью понимают ситуацию, в которой два или более предиктора тесно связаны друг с другом. Концепция коллинеарности проиллюстрирована на рис. 3.14 на примере набора данных Credit. Слева на этом рисунке видно, что два предиктора *limit* (лимит кредита) и *age* (возраст клиента) практически не связаны друг с другом. В то же время справа этом рисунке предикторы *limit* и *rating* (рейтинг клиента) тесно коррелируют, и мы говорим, что они *коллинеарны*. Наличие коллинеарности может вызвать проблемы в ходе выполнения регрессионного анализа в связи с трудностью выделения эффектов отдельных коллинеарных

¹² В оригинале используется термин «leverage statistic». Речь идет о диагональных элементах h_i т. н. *матрицы проекции на пространство предикторов* H (применяются также названия «матрица влияния» и «матрица воздействия»; англ. «hat matrix», «influence matrix»). — Прим. пер.

предикторов на отклик. Иными словами, поскольку `limit` и `rating` имеют тенденцию к согласованному увеличению или снижению, установление связи каждой из этих переменных с откликом (`balance`) может оказаться затруднительным.




РИСУНОК 3.14. Диаграммы рассеяния для наблюдений из набора данных `Credit`. Слева: график зависимости между возрастом клиента (`age`) и кредитным лимитом (`limit`). Эти две переменные не являются коллинеарными. Справа: график зависимости между рейтингом клиента `rating` и кредитным лимитом (`limit`). Имеет место высокая коллинеарность

Рисунок 3.15 иллюстрирует некоторые из трудностей, которые могут возникнуть из-за коллинеарности. Слева на этом рисунке показана контурная диаграмма RSS (3.22), рассчитанной для разных возможных оценок коэффициентов регрессионной зависимости `balance` от `limit` и `age`. Каждый эллипс соответствует набору коэффициентов для заданного значения RSS, причем эллипсы, расположенные близко к центру, соответствуют наименьшим значениям RSS. Черная точка и прерывистые линии показывают оценки коэффициентов, которые сопровождаются наименьшей RSS, т. е. это оценки, полученные по методу наименьших квадратов. Оси `limit` и `age` были масштабированы таким образом, чтобы изобразить на графике все возможные оценки коэффициентов, которые находятся на расстоянии вплоть до четырех стандартных ошибок по обе стороны от оценок, полученных по методу наименьших квадратов. Таким образом, график изображает все правдоподобные значения коэффициентов. Например, мы видим, что истинное значение коэффициента для `limit` почти наверняка лежит где-то между 0.15 и 0.20.

В то же время на рис. 3.15 справа показана контурная диаграмма RSS для возможных оценок коэффициентов регрессионной зависимости `balance` от `rating` и `limit` — предикторов, которые, как мы знаем, высоко коллинеарны. Теперь эллипсы принимают очень узкую форму: имеет место большой размах значений оценок коэффициентов с одинаковыми значениями RSS. Следовательно, небольшое изменение в данных может заставить пару значений коэффициентов, которые обеспечивают наимень-




РИСУНОК 3.15. Контурные диаграммы для значений RSS как функции от параметров β различных регрессионных моделей, рассчитанных по данным Credit. На каждом графике черная точка соответствует значениям коэффициентов с наименьшей RSS . Слева: контурная диаграмма RSS для регрессионной зависимости баланса на кредитной карте (balance) от возраста клиента (age) и кредитного лимита (limit). Минимальное значение хорошо определено. Справа: контурная диаграмма RSS для регрессионной зависимости balance от rating (рейтинг клиента) и limit. Из-за наличия коллинеарности имеет место большое количество пар $(\beta_{\text{Лимит}}, \beta_{\text{Рейтинг}})$ с одинаковым значением RSS

шую RSS (т.е. оценки, полученные по методу наименьших квадратов), переместиться куда-угодно вдоль эллипса. Это приводит к очень большой неопределенности в отношении оценок коэффициентов. Заметьте, что шкала значений коэффициента для limit теперь изменяется от -0.2 до 0.2 — это восьмикратное увеличение диапазона вероятных значений данного коэффициента, по сравнению с регрессионной моделью, включающей age. Интересно, что хотя по отдельности коэффициенты limit и rating теперь обладают гораздо большей неопределенностью, вместе они почти наверняка будут находится в пределах изображенной узкой области. Например, не стоит ожидать, что истинные значения коэффициентов limit и rating составят -0.1 и 1 соответственно, хотя для каждого коэффициента в отдельности эти значения возможны.

Поскольку коллинеарность снижает точность оценок регрессионных коэффициентов, она вызывает увеличение стандартной ошибки $\hat{\beta}_j$. Вспомните, что t -критерий для каждого предиктора рассчитывается путем деления $\hat{\beta}_j$ на соответствующую стандартную ошибку. Следовательно, коллинеарность приводит к снижению t -критерия. В результате этого в присутствии коллинеарности у нас может не получиться отклонить $H_0 : \beta_j = 0$. Это означает, что из-за коллинеарности *мощность* статистического теста, т.е. вероятность безошибочного обнаружения *ненулевого* коэффициента, снижается.

Табл. 3.11 сравнивает оценки коэффициентов двух отдельных множественных регрессионных моделей. Первая представляет собой регрессию

ТАБЛИЦА 3.11. Приведены результаты для двух регрессионных моделей, построенных по данным Credit. Модель M1 — это регрессия balance по age и limit, а M2 — регрессия balance по rating и limit. Стандартная ошибка $\hat{\beta}_{\text{limit}}$ во второй модели выше в 12 раз из-за коллинеарности

Модель	Параметр	Коэффициент	Ст. ошибка	t	p
M1	Свободный член	-173.411	43.828	-3.957	< 0.0001
	age	-2.292	0.672	-3.407	0.0007
	limit	0.173	0.005	34.496	< 0.0001
M2	Свободный член	-377.537	45.254	-8.343	< 0.0001
	rating	2.202	0.952	2.312	0.0213
	limit	0.025	0.064	0.384	0.7012

balance по age и limit, а вторая — регрессию balance по rating и limit. В первой модели как age, так и limit высокосignификантны и имеют очень низкие p-значения. Во второй модели коллинеарность между limit и rating привела к увеличению стандартной ошибки оценки коэффициента limit в 12 раз, а p-значение увеличилось до 0.701. Другими словами, из-за наличия коллинеарности роль переменной limit была замаскирована. Во избежание подобной ситуации при подгонке модели желательно обнаружить и устранить потенциальные проблемы, связанные с коллинеарностью.

Простой способ обнаружения коллинеарности заключается в изучении корреляционной матрицы предикторов. Высокое (по модулю) значение в такой матрице указывает на наличие пары высоко коррелирующих переменных, а следовательно, и на наличие в данных проблемы коллинеарности. К сожалению, не все связанные с коллинеарностью проблемы можно обнаружить путем инспектирования корреляционной матрицы: коллинеарность может существовать между тремя и более переменными, даже когда не установлено ни одной существенно высокой парной корреляции. Мы называем такую ситуацию *мультиколлинеарностью*. Вместо инспектирования корреляционной матрицы более надежным способом обнаружения мультиколлинеарности является вычисление *фактора инфляции дисперсии* (VIF¹³). VIF представляет собой отношение дисперсии $\hat{\beta}_j$ в полной модели к дисперсии $\hat{\beta}_j$ в модели, содержащей только один этот предиктор j . Наименьшее возможное значение VIF составляет 1 и указывает на полное отсутствие коллинеарности. На практике обычно имеет место небольшая степень коллинеарности между предикторами. В качестве эмпирического правила можно считать, что VIF, превышающий 5 или 10, указывает на излишне высокую степень коллинеарности. VIF для каждой переменной можно вычислить по следующей формуле:

$$\text{VIF}(\hat{\beta}_j) = \frac{1}{1 - R_{X_j|X_{-j}}^2},$$

где $R_{X_j|X_{-j}}^2$ — это R^2 из регрессии X_j по всем остальным предикторам. Если значение $R_{X_j|X_{-j}}^2$ близко к 1, то коллинеарность присутствует и поэтому VIF будет большим.

¹³ Аббревиатура от «variance inflation factor». — Прим. пер.

В случае с данными Credit регрессия balance по age, rating и limit показывает, что эти предикторы имеют VIF, равные 1.01, 160.67 и 160.59 соответственно. Как мы и ожидали, в данных есть значительная коллинеарность!

При столкновении с проблемой коллинеарности можно воспользоваться двумя простыми решениями. Первое заключается в удалении проблематичных переменных из регрессии. Обычно это можно сделать без значительного снижения качества модели, поскольку коллинеарность подразумевает, что заключенная в соответствующей переменной информация об отклике в присутствии других переменных избыточна. Например, если мы построим регрессию balance по age и limit, исключив предиктор rating, то итоговые значения VIF будут близки к минимально возможному значению — 1, а R^2 снизится с 0.754 до 0.75. Поэтому исключение rating из совокупности предикторов успешно решит проблему коллинеарности без снижения качества модели. Второе решение заключается в объединении коллинеарных переменных в один предиктор. Например, мы могли бы взять среднее значение стандартизованных версий limit и rating для создания новой переменной, которая измеряет *кредитоспособность*.

3.4 Маркетинговый план

Теперь мы вкратце вернемся к семи вопросам в отношении данных Advertising, которые мы задали в начале этой главы.

1. *Есть ли зависимость между затратами на рекламу и объемом продаж?*

На этот вопрос можно ответить, построив множественную регрессию sales по TV, radio и newspaper как в (3.20) и проверив гипотезу $H_0 : \beta_{TV} = \beta_{radio} = \beta_{newspaper} = 0$. В подразделе 3.2.2 мы показали, что о необходимости отклонения этой нулевой гипотезы можно судить по F -критерию. В данном случае p -значение для F -критерия очень низкое (табл. 3.6), что является надежным свидетельством существования связи между объемом продаж и рекламой.

2. *Насколько сильна связь между затратами на рекламу и объемом продаж?*

В подразделе 3.1.3 мы обсудили два показателя точности модели. Во-первых, RSE оценивает стандартное отклонение отклика от истинной линии регрессии. Для данных Advertising RSE составляет 1681 единицу, тогда как среднее значение отклика равно 14022, что указывает на удельную ошибку около 22%. Во-вторых, коэффициент детерминации R^2 выражает долю дисперсии отклика, объясненную предикторами. Предикторы объясняют почти 90% дисперсии sales. RSE и статистика R^2 приведены в табл. 3.6.

3. *Какой тип рекламы способствует продажам?*

Для ответа на этот вопрос мы можем проанализировать p -значения, связанные с t -критерием каждого предиктора (см. подраздел 3.1.2). В множественной линейной регрессии из табл. 3.4 p -значения для TV

и radio низки, а р-значение для newspaper — нет. Это говорит о том, что на sales влияет только реклама на телевидении и на радио. В главе 6 мы рассмотрим этот вопрос подробнее.

4. *Каков размер эффекта каждого типа рекламы на продажи?*

В подразделе 3.1.2 мы видели, что при помощи стандартной ошибки $\hat{\beta}_j$ можно сконструировать доверительные интервалы для β_j . В случае с данным Advertising мы имеем следующие доверительные интервалы: (0.043, 0.049) для TV, (0.172, 0.206) для radio и (–0.013, 0.011) для newspaper. Доверительные интервалы для TV и radio узкие и далеки от нуля, что указывает на связь рекламы в этих СМИ с количеством продаж. Однако интервал для newspaper содержит ноль, указывая на то, что эта переменная не является статистически значимой при заданных значениях TV и radio.

В подразделе 3.3.3 мы видели, что коллинеарность может привести к очень большим стандартным ошибкам. Могла ли коллинеарность стать причиной очень широкого доверительного интервала для newspaper? Значения VIF для TV, radio и newspaper составляют 1.005, 1.145 и 1.145 соответственно, что указывает на отсутствие коллинеарности.

Для оценки степени влияния каждого типа рекламы на продажи мы можем отдельно рассчитать три простые линейные регрессии. Результаты приведены в табл. 3.1 и 3.3. Есть свидетельство очень тесной связи между TV и sales, а также между radio и sales. При игнорировании значений TV и radio наблюдается умеренно выраженная связь между newspaper и sales.

5. *Насколько точно мы можем спрогнозировать будущие продажи?*

Отклик можно предсказать при помощи уравнения (3.21). Точность этой оценки зависит от того, хотим ли мы предсказать отдельное значение отклика — $Y = f(X) + \epsilon$, или его среднее значение — $f(X)$ (см. подраздел 3.2.2). В первом случае мы применяем интервал предсказаний, а во втором — доверительный интервал. Интервалы предсказаний всегда будут шире доверительных интервалов, поскольку они учитывают неопределенность, связанную с ϵ — неустранимой ошибкой.

6. *Является ли связь линейной?*

В подразделе 3.3.3 мы видели, что для обнаружения нелинейности можно использовать графики остатков. Если зависимость является линейной, то в расположении остатков не должно наблюдаться никакой закономерности. В случае с данными Advertising на рис. 3.5 мы наблюдаем нелинейную зависимость, хотя эту зависимость можно было бы увидеть также и на графике остатков. В подразделе 3.3.2 мы обсудили добавление преобразованных предикторов в линейную регрессионную модель для учета подобных нелинейных зависимостей.

7. *Существует ли синергия между разными типами рекламы?*

Стандартная линейная регрессионная модель подразумевает аддитивную связь между предикторами и откликом. Аддитивную модель легко интерпретировать, поскольку эффект одного предиктора на отклик не зависит от значений других предикторов. Однако допущение аддитивности может оказаться нереалистичным для некоторых наборов данных. В подразделе 3.3.2 мы показали, как добавить в регрессионную модель эффект взаимодействия для учета неаддитивных зависимостей. Низкое p -значение эффекта взаимодействия указывает на наличие подобных зависимостей. По рис. 3.5 следовало, что данные Advertising могут обладать свойством неаддитивности. Включение в модель эффекта взаимодействия приводит к существенному увеличению R^2 — примерно с 90% до почти 97%.

3.5 Сравнение линейной регрессии с методом K ближайших соседей

Как обсуждалось в главе 2, линейная регрессия представляет собой пример *параметрического* метода, поскольку она предполагает линейную функциональную форму для $f(X)$. Параметрические методы имеют несколько преимуществ. Обычно подгонка таких моделей не составляет труда, т. к. требуется оценить только небольшой набор коэффициентов. В случае линейной регрессии коэффициенты имеют простую интерпретацию, и можно легко выполнить проверку их статистической значимости. Однако параметрические методы все же обладают недостатком: в силу своего устройства они делают строгие предположения относительно формы $f(X)$. Если выбранная функциональная форма далека от истинной, а наша цель заключается в получении точных предсказаний, то параметрический метод сработает плохо. Например, если мы предположим линейную связь между X и Y , а истинная зависимость существенно отличается от линейной, то полученная модель будет плохо соответствовать данным и любые сделанные на ее основе выводы будут ненадежными.

В то же время непараметрические методы не делают однозначного предположения относительно формы $f(X)$ и, следовательно, предоставляют альтернативный и более гибкий подход для выполнения регрессионного анализа. В этой книге мы обсуждаем разные непараметрические подходы. Здесь мы рассмотрим один из наиболее простых и хорошо известных непараметрических методов — *метод K ближайших соседей* (KNN-регрессия¹⁴). KNN-регрессия очень похожа на KNN-классификатор, описанный в главе 2. Для некоторого заданного значения K и прогнозируемого наблюдения x_0 KNN-регрессия сначала находит K обучающих наблюдений (обозначаются как $\mathcal{N}_0$), которые ближе всего расположены к x_0 . Затем она оценивает $f(x_0)$, усредняя значения отклика всех обучающих наблюдений из $\mathcal{N}_0$. Другими словами,

$$\hat{f}(x_0) = \frac{1}{K} \sum_{x_i \in \mathcal{N}_0} y_i.$$

¹⁴ Аббревиатура от « K -nearest neighbors». — Прим. пер.




РИСУНОК 3.16. Графики $\hat{f}(X)$, полученные путем подгонки KNN-регрессии к двумерным данным с 64 наблюдениями (оранжевые точки). Слева: $K = 1$ приводит к грубой ступенчатой функции. Справа: $K = 9$ приводит к гораздо более гладкой функции

На рис. 3.16 показаны две модели KNN, подогнанные к данным с двумя предикторами. Модель с $K = 1$ показана на графике слева, а график справа соответствует модели с $K = 9$. Мы видим, что при $K = 1$ модель KNN идеально интерполирует обучающие наблюдения и, следовательно, принимает вид ступенчатой функции. При $K = 9$ модель KNN все еще является ступенчатой функцией, однако усреднение по девяти наблюдениям приводит к гораздо меньшим областям с одинаковыми прогнозными значениями, а следовательно, и к более гладкой функции. В целом оптимальное значение K будет зависеть от компромисса между смещением и дисперсией, который мы описали в главе 2. Небольшое значение K обеспечивает наиболее гибкую модель, которая будет обладать низким смещением, но высокой дисперсией. Эта дисперсия обусловлена тем фактом, что предсказание в некоторой конкретной области полностью определяется лишь одним наблюдением. В то же время более высокие значения K обеспечивают более гладкую и менее изменчивую модель: прогнозное значение в некоторой области является результатом усреднения нескольких точек, в связи с чем изменение одного наблюдения имеет незначительный эффект. Однако сглаживание может замаскировать некоторые особенности структуры $f(X)$. В главе 5 мы рассмотрим несколько методов для оценивания величины ошибок предсказаний. Эти методы можно использовать для нахождения оптимального значения K для KNN-регрессии.

В каких условиях параметрический метод, такой как обычная линейная регрессия, будет превосходить непараметрический метод, такой как KNN-регрессия? Ответ прост: *параметрический метод превзойдет непараметрический метод, если выбранная параметрическая форма будет близка к истинной форме f* . На рис. 3.17 показан пример данных, сгенерированных на основе одномерной линейной регрессионной модели. Черные сплошные линии соответствуют $f(X)$, тогда как синие линии показывают KNN-модели, подогнанные с использованием $K = 1$ и $K = 9$. В этом

случае предсказания при $K = 1$ слишком изменчивы, тогда как более гладкая модель с $K = 9$ намного ближе к истинной $f(X)$. Однако в связи с тем, что истинная зависимость является линейной, непараметрическому методу сложно конкурировать с линейной регрессией: непараметрический метод сопровождается увеличением дисперсии, которое не компенсируется пониженным смещением. Слева на рис. 3.18 синяя прерывистая линия показывает линейную регрессию, подогнанную к тем же данным. Это почти идеальная модель. Справа на рис. 3.18 видно, что на этих данных линейная регрессия превосходит метод KNN. Зеленая сплошная линия, показанная как функция от $1/K$, описывает изменение среднеквадратичной ошибки (MSE) KNN-регрессии на контрольной выборке. Кривая ошибок KNN-регрессии находится намного выше черной прерывистой линии, которая соответствует MSE на контрольной выборке у линейной регрессии. При высоком значении K метод KNN работает несколько хуже линейной регрессии (в смысле MSE). При небольших K он работает намного хуже.




РИСУНОК 3.17. Графики $\hat{f}(X)$, полученные путем подгонки KNN-регрессии к одномерному набору данных со 100 наблюдениями. Истинная зависимость показана черной сплошной линией. Слева: синяя линия соответствует $K = 1$ и интерполирует (т. е. проходит через) обучающие наблюдения. Справа: синяя линия соответствует $K = 9$ и представляет собой более гладкую модель

На практике истинная зависимость Y от X редко бывает в точности линейной. Рисунок 3.19 сравнивает относительную эффективность линейной регрессии и метода KNN при возрастающей степени нелинейности связи между X и Y . В верхнем ряду графиков истинная зависимость почти линейна. В этом случае мы видим, что MSE на контрольных данных у линейной регрессии лучше, чем у KNN-регрессии с низкими значениями K . Однако при $K \geq 4$ KNN превосходит линейную регрессию. Во втором ряду показано более существенное отклонение от линейности. В этой ситуации метод KNN значительно превосходит линейную регрессию при всех значениях K . Заметьте, что по мере увеличения степени нелинейности MSE на контрольной выборке у непараметрического метода KNN почти не изменяется, тогда как MSE на контрольной выборке у линейной регрессии демонстрирует существенный рост.




РИСУНОК 3.18. Набор данных, показанный на рис. 3.17, исследован более подробно. Слева: синяя линия изображает модель, подогнанную по методу наименьших квадратов. Поскольку $f(X)$ действительно является линейной функцией (показана черной прерывистой линией), линейная регрессия обеспечивает очень хорошую оценку $f(X)$. Справа: горизонтальная прерывистая линия изображает MSE линейной регрессии на контрольной выборке, а зеленая сплошная линия соответствует MSE KNN-регрессии в зависимости от $1/K$ (на логарифмической шкале). Линейная регрессия достигает более низкой ошибки на контрольных данных по сравнению с KNN-регрессией, поскольку $f(X)$ в действительности является линейной функцией. Наилучший результат для KNN-регрессии имеет место при очень большом значении K , которое соответствует небольшому значению $1/K$

Рисунки 3.18 и 3.19 иллюстрируют ситуации, когда метод KNN работает несколько хуже линейной регрессии при линейной истинной зависимости и намного лучше при нелинейных зависимостях. На практике, когда истинная зависимость неизвестна, можно было бы заключить, что метод KNN следует предпочесть линейной регрессии, поскольку он сработает лишь незначительно хуже в случае линейной истинной зависимости, но в то же время может дать намного более высокие результаты при нелинейной истинной зависимости. Однако в действительности даже при выраженной нелинейной истинной зависимости метод KNN может дать менее качественные решения, по сравнению с линейной регрессией. В частности, на рис. 3.18 и 3.19 показаны ситуации с $p = 1$ предиктором. При более высоких размерностях метод KNN часто работает хуже линейной регрессии.

На рис. 3.20 представлена та же ситуация с выраженной нелинейностью, как и во втором ряду на рис. 3.19, однако мы добавили дополнительные шумовые предикторы, которые не связаны с откликом. При $p = 1$ или $p = 2$ метод KNN превосходит линейную регрессию. Однако при $p = 3$ результаты неоднозначны, а при $p \geq 4$ линейная регрессия превосходит KNN. Более того, увеличение размерности вызвало лишь небольшое увеличение MSE на контрольной выборке у линейной регрессии, но более чем десятикратное увеличение MSE у KNN-регрессии. Подобное снижение качества по мере увеличения размерности является обычной проблемой метода KNN и обусловлено тем, что при высоких размерностях, по сути,




РИСУНОК 3.19. Набор данных, показанный на рис. 3.17, исследован более подробно. Слева: синяя линия изображает модель, подогнанную по методу наименьших квадратов. Поскольку $f(X)$ действительно является линейной функцией (показана черной прерывистой линией), то линейная регрессия обеспечивает очень хорошую оценку $f(X)$. Справа: горизонтальная прерывистая линия изображает MSE линейной регрессии на контрольной выборке, а зеленая сплошная линия соответствует MSE KNN-регрессии в зависимости от $1/K$ (на логарифмической шкале). Линейная регрессия обеспечивает более низкую ошибку на контрольных данных, по сравнению с KNN-регрессией, поскольку истинная $f(X)$ является линейной функцией. Наилучший результат для KNN-регрессии имеет место при очень большом значении K , которое соответствует небольшому значению $1/K$

происходит снижение объема выборки. В рассматриваемом наборе данных имеется 100 обучающих наблюдений; при $p = 1$ это дает достаточно информации, чтобы верно оценить $f(X)$. Однако распределение 100 наблюдений в 20-мерном пространстве приводит к явлению, когда то или иное наблюдение не имеет *близлежащих соседей*, — это так называемое *проклятие размерности*. Иными словами, K наблюдений, являющихся ближайшими соседями контрольного наблюдения x_0 , при большом p могут находиться очень далеко от x_0 в p -мерном пространстве, что приводит к очень плохому предсказанию $f(x_0)$, а следовательно, и плохому качеству модели KNN. Как правило, параметрические методы превосходят непараметрические методы при небольшом числе наблюдений, приходящихся на один предиктор.

проклятие
размер-
ности




РИСУНОК 3.20. MSE на контрольной выборке у линейной регрессии (черные прерывистые линии) и KNN-регрессии (зеленые кривые) при возрастающем числе переменных p . Истинная функция нелинейна по первой переменной (как на рис. 3.19) и не зависит от дополнительных переменных. Качество линейной регрессии при наличии этих дополнительных шумовых переменных снижается медленно, тогда как качество KNN-регрессии при увеличении p падает намного быстрее

Даже в задачах малой размерности мы можем предпочесть линейную регрессию методу KNN из-за легкости интерпретации. Если MSE на контрольной выборке у KNN-регрессии лишь незначительно ниже ошибки линейной регрессии, то, возможно, имеет смысл пожертвовать точностью прогноза в пользу более простой модели, которую можно описать при помощи всего нескольких коэффициентов с низкими p -значениями.

3.6 Лабораторная работа: линейная регрессия

3.6.1 Библиотеки

Функция `library()` используется для загрузки библиотек, или групп функций и наборов данных, которые не включены в базовый дистрибутив R¹⁵. Обычные функции, выполняющие расчет регрессии по методу

`library()`

¹⁵ К сожалению, имя функции `library()` выбрано не совсем удачно и вводит в заблуждение. Она загружает *пакеты* (packages), а не *библиотеки* (libraries). Строго го-

наименьших квадратов и другие анализы, входят в состав стандартного дистрибутива R, однако более экзотические функции требуют дополнительных библиотек. Здесь мы загружаем пакет MASS, который представляет собой очень большую коллекцию наборов данных и функций. Кроме того, мы загружаем пакет ISLR, который содержит наборы данных для этой книги.

```
> library(MASS)
> library(ISLR)
```

Если вы получаете сообщение об ошибке при загрузке любой из этих библиотек, это, скорее всего, указывает на то, что соответствующая библиотека еще не установлена на вашей системе. Некоторые библиотеки, такие как MASS, поставляются вместе с R и не требуют отдельной установки на вашем компьютере. Однако другие пакеты, такие как ISLR, должны быть загружены перед их первым использованием. Это можно сделать непосредственно из R. Например, на компьютере с операционной системой Windows выберите опцию `Install package` из закладки `Packages`. После того как вы выберете тот или иной сайт-зеркало, появится список доступных пакетов. Просто выберите пакет, который вы хотите установить, и R автоматически загрузит его. В качестве альтернативы это можно сделать из командной строки R, выполнив `install.packages("ISLR")`. Такая установка должна быть выполнена только перед первым использованием пакета. Однако функцию `library()` необходимо вызывать каждый раз, когда вы хотите воспользоваться соответствующим пакетом.

3.6.2 Простая линейная регрессия

Библиотека MASS содержит набор данных `Boston`, который включает значения `medv` (медианная стоимость дома) для 506 окрестностей Бостона. Мы попытаемся предсказать `medv` на основе 13 предикторов, таких как `rm` (среднее количество комнат в доме), `age` (средний возраст дома) и `lstat` (процент домохозяйств с низким социально-экономическим статусом).

```
> fix(Boston )
> names(Boston )
[1] "crim" "zn" "indus" "chas" "nox" "rm" "age"
[8] "dis" "rad" "tax" "ptratio" "black" "lstat" "medv"
```

Для получения дополнительной информации по этому набору данных, мы можем набрать команду `?Boston`.

Мы начнем с использования функции `lm()` для подгонки простой линейной регрессионной модели, в которой `medv` будет откликом, а `lstat` — предиктором. Основной синтаксис выглядит как `lm(y ~ x, data)`, где `y` — это зависимая переменная, `x` — предиктор, а `data` — набор данных, в котором содержатся эти переменные.

```
> lm.fit = lm(medv ~ lstat)
Error in eval(expr, envir, enclos) : Object "medv" not found
```

воря, пакет — это «группа функций и наборов данных, которые не включены в базовый дистрибутив R». Под библиотекой же обычно понимают директорию, в которой установлены пакеты. В этой книге авторы используют термины «пакет» и «библиотека» в качестве синонимов. — *Прим. пер.*

Эта команда вызывает ошибку, поскольку R не знает, где найти переменные `medv` и `lstat`. Следующая строка говорит R о том, что эти переменные находятся в таблице `Boston`. Если мы прикрепим таблицу `Boston`¹⁶, то первая команда сработает правильно, поскольку теперь R распознает необходимые переменные.

```
> lm.fit = lm(medv ~ lstat, data = Boston)
> attach(Boston)
> lm.fit = lm(medv ~ lstat)
```

При вводе `lm.fit` будет выведена основная информация по модели. Для получения более детальной информации мы применяем `summary(lm.fit)`. Это даст нам *p*-значения и стандартные ошибки коэффициентов, а также коэффициент детерминации R^2 и F-критерий для модели.

```
> lm.fit
```

Call:

```
lm(formula = medv ~ lstat)
```

Coefficients:

```
(Intercept)      lstat
      34.55      -0.95
```

```
> summary (lm.fit)
```

Call:

```
lm(formula = medv ~ lstat)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-15.17   -3.99   -1.32    2.03   24.50
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   34.5538     0.5626    61.4   <2e-16 ***
lstat         -0.9500     0.0387   -24.5   <2e-16 ***
```

```
Signif. codes:  0 *** 0.001 ** 0.01 * 0.05 . 0.1 1
```

Residual standard error: 6.22 on 504 degrees of freedom

Multiple R-squared: 0.544 , Adjusted R-squared : 0.543

F-statistic: 602 on 1 and 504 DF, p-value: <2e-16

Мы можем воспользоваться функцией `names()`, чтобы выяснить, что еще хранится в объекте `lm.fit`. Хотя мы можем извлечь эти количественные показатели по их именам (например, `lm.fit$coefficients`), для получения доступа к ним надежнее будет использовать функции-экстракторы вроде `coef()`.

¹⁶ Имеется в виду операция, в результате которой содержимое объекта `Boston` будет добавлено в т. н. *поисковый путь* R (*search path*). — Прим. пер.

```
> names(lm.fit)
[1] "coefficients" "residuals" "effects"
[4] "rank" "fitted .values" "assign"
[7] "qr" "df.residual" "xlevels"
[10] "call" "terms" "model"

> coef(lm.fit)
(Intercept)      lstat
      34.55      -0.95
```

Для вычисления доверительных интервалов оценок коэффициентов мы можем применить команду `confint()`.

```
> confint(lm.fit)
                2.5 % 97.5 %
(Intercept)  33.45  35.659
lstat        -1.03 -0.874
```

Функцию `predict()` можно использовать для расчета доверительных интервалов и интервалов предсказаний при прогнозировании `medv` по заданному значению `lstat`.

```
> predict(lm.fit, data.frame(lstat = (c(5, 10, 15))),
          interval = "confidence")
      fit      lwr      upr
1  29.80  29.01  30.60
2  25.05  24.47  25.63
3  20.30  19.73  20.87

> predict(lm.fit, data.frame(lstat = (c(5, 10, 15))),
          interval = "prediction")
      fit      lwr      upr
1  29.80  17.566  42.04
2  25.05  12.828  37.28
3  20.30   8.078  32.53
```

Например, 95%-ный доверительный интервал, связанный со значением `lstat = 10`, составляет (24.47, 25.63), а 95%-ный интервал предсказания — (12.828, 37.28). Как и следовало ожидать, оба этих интервала центрированы относительно одной и той же точки (предсказанное значение `medv = 25.05` при `lstat = 10`), однако интервал предсказания является намного более широким.

Теперь мы изобразим `lstat` и `medv` вместе с регрессионной прямой, используя функции `plot()` и `abline()`.

```
> plot(lstat, medv)
> abline(lm.fit)
```

Имеется указание на некоторую нелинейность связи между `lstat` и `medv`. Мы исследуем данное обстоятельство позднее в этой лабораторной работе.

Функцию `abline()` можно использовать для изображения любой линии, не только линии наименьших квадратов. Чтобы нарисовать линию со свободным членом `a` и углом наклона `b` мы выполняем команду `abline(a,`

б). Ниже мы экспериментируем с некоторыми дополнительными настройками для изображения линий и точек. Команда `lwd = 3` увеличивает толщину регрессионной линии в 3 раза; это работает и в случае функций `plot()` и `lines()`. Мы можем также использовать опцию `pch`, чтобы выбрать различные символы для изображения точек.

```
> abline (lm.fit, lwd = 3)
> abline (lm.fit, lwd = 3, col = "red")
> plot(lstat, medv, col = "red")
> plot(lstat, medv, pch = 20)
> plot(lstat, medv , pch = "+")
> plot (1:20, 1:20, pch = 1:20)
```

Далее мы изучим некоторые диагностические графики, часть из которых обсуждалась в подразделе 3.3.3. Четыре таких графика автоматически создаются путем непосредственного применения функции `plot()` к результату работы функции `lm()`. Как правило, эта команда будет выводить только один график за раз, и при нажатии *Enter* будет выводиться следующий график. Однако часто удобнее бывает просмотреть все четыре графика одновременно. Мы можем сделать это при помощи функции `par()`, которая говорит R разделить графическое окно на отдельные панели так, чтобы можно было просмотреть несколько графиков одновременно. Например, `par(mfrow = c(2, 2))` разделяет графическое окно на сетку из 2×2 панелей.

`par()`

```
> par(mfrow = c(2, 2))
> plot(lm.fit)
```

В качестве альтернативы мы можем рассчитать остатки линейной регрессионной модели, используя функцию `residuals()`. Функция `rstudent()` выдаст студентизированные остатки, и мы сможем использовать ее для построения графика зависимости этих остатков от подогнанных значений.

`residuals()`
`rstudent()`

```
> plot(predict(lm.fit), residuals(lm.fit))
> plot(predict(lm.fit), rstudent(lm.fit))
```

Судя по графикам остатков, имеет место некоторая нелинейность. Значения показателя разбалансировки можно рассчитать для любого количества предикторов при помощи функции `hatvalues()`.

`rstudent()`

```
> plot(hatvalues(lm.fit ))
> which.max(hatvalues(lm.fit))
```

375

Функция `which.max()` определяет индексный номер наибольшего элемента некоторого вектора. В данном случае она говорит нам, какое наблюдение имеет максимальное значение показателя разбалансировки.

`which.max()`

3.6.3 Множественная линейная регрессия

Для подгонки множественной линейной регрессии по методу наименьших квадратов мы снова воспользуемся функцией `lm()`. Синтаксис `lm(y ~ x1 + x2 + x3)` применяется для подгонки модели с тремя предикторами —

x1, x2 и x3. Функция `summary()` теперь возвращает регрессионные коэффициенты для всех предикторов.

```
> lm.fit = lm(medv ~ lstat + age, data = Boston )
> summary(lm.fit)
```

Call:

```
lm(formula = medv ~ lstat + age, data = Boston )
```

Residuals :

Min	1Q	Median	3Q	Max
-15.98	-3.98	-1.28	1.97	23.16

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	33.2228	0.7308	45.46	<2e-16 ***
lstat	-1.0321	0.0482	-21.42	<2e-16 ***
age	0.0345	0.0122	2.83	0.0049 **

Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1 1

Residual standard error: 6.17 on 503 degrees of freedom

Multiple R-squared: 0.551, Adjusted R-squared : 0.549

F-statistic: 309 on 2 and 503 DF, p-value: <2e-16

Набор данных Boston содержит 13 переменных, и поэтому было бы утомительно набирать их названия для выполнения регрессионного анализа на основе всех предикторов. Вместо этого мы можем использовать следующий сокращенный вариант:

```
> lm.fit = lm(medv ~ ., data = Boston)
```

```
> summary(lm.fit)
```

Call:

```
lm(formula = medv ~ ., data = Boston)
```

Residuals :

Min	1Q	Median	3Q	Max
-15.594	-2.730	-0.518	1.777	26.199

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.646e+01	5.103e+00	7.144	3.28e-12 ***
crim	-1.080e-01	3.286e-02	-3.287	0.001087 **
zn	4.642e-02	1.373e-02	3.382	0.000778 ***
indus	2.056e-02	6.150e-02	0.334	0.738288
chas	2.687e+00	8.616e-01	3.118	0.001925 **
nox	-1.777e+01	3.820e+00	-4.651	4.25e-06 ***
rm	3.810e+00	4.179e-01	9.116	< 2e-16 ***
age	6.922e-04	1.321e-02	0.052	0.958229
dis	-1.476e+00	1.995e-01	-7.398	6.01e-13 ***

```
rad      3.060e-01  6.635e-02  4.613  5.07e-06 ***
tax      -1.233e-02  3.761e-03  -3.280  0.001112 **
ptratio  -9.527e-01  1.308e-01  -7.283  1.31e-12 ***
black     9.312e-03  2.686e-03   3.467  0.000573 ***
lstat     -5.248e-01  5.072e-02 -10.347  < 2e-16 ***
```

```
---
```

```
Signif. codes:  0 *** 0.001 ** 0.01 * 0.05 . 0.1 1
```

```
Residual standard error: 4.745 on 492 degrees of freedom
```

```
Multiple R-Squared: 0.7406, Adjusted R-squared: 0.7338
```

```
F-statistic: 108.1 on 13 and 492 DF, p-value: < 2.2e-16
```

Мы можем получить доступ к отдельным компонентам объекта с результатами анализа по их имени (наберите `?summary.lm` для получения списка доступных компонентов). Следовательно, `summary(lm.fit)$r.sq` даст нам R^2 , а `summary(lm.fit)$sigma` даст нам RSE. Функцию `vif()` из пакета `car` можно применить для вычисления значений фактора инфляции дисперсии. Для этого набора данных большинство VIF имеет низкие или умеренные значения. Пакет `car` не является частью базового дистрибутива R, и поэтому перед первым использованием его нужно установить при помощи функции `install.packages()`.

```
> library(car)
> vif(lm.fit)
      crim      zn      indus      chas      nox      rm      age
1.79    2.30    3.99    1.07    4.39    1.93    3.10
      dis      rad      tax      ptratio      black      lstat
3.96    7.48    9.01    1.80    1.35    2.94
```

Что, если мы захотели бы выполнить регрессионный анализ по всем переменным, за исключением одной? Например, в приведенных выше результатах `age` имеет высокое p -значение. Поэтому, возможно, мы хотим построить регрессию, исключив этот предиктор. Следующий синтаксис приводит к созданию регрессионной модели, включающей все переменные, кроме `age`.

```
> lm.fit1 = lm(medv ~ . -age, data = Boston)
> summary(lm.fit1)
...
```

В качестве альтернативы можно воспользоваться функцией `update()`. `update()`

```
> lm.fit1 = update(lm.fit, ~ . -age)
```

3.6.4 Эффекты взаимодействия

Включение эффектов взаимодействий в линейную модель при помощи функции `lm()` не составляет труда. Синтаксис `lstat:black` говорит R добавить эффект взаимодействия между `lstat` и `black`. Синтаксис `lstat*age` одновременно включает в качестве предикторов `lstat`, `age` и взаимодействие `lstat × age` — это сокращенная форма для `lstat + age + lstat:age`.

```
> summary(lm(medv ~ lstat*age, data = Boston))
```

Call:

```
lm(formula = medv ~ lstat * age, data = Boston)
```

Residuals :

Min	1Q	Median	3Q	Max
-15.81	-4.04	-1.33	2.08	27.55

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	36.088536	1.469835	24.55	< 2e-16 ***
lstat	-1.392117	0.167456	-8.31	8.8e-16 ***
age	-0.000721	0.019879	-0.04	0.971
lstat:age	0.004156	0.001852	2.24	0.025 *

Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1 1

Residual standard error: 6.15 on 502 degrees of freedom

Multiple R-squared: 0.556, Adjusted R-squared : 0.553

F-statistic: 209 on 3 and 502 DF, p-value: <2e-16

3.6.5 Нелинейные преобразования предикторов

Функция `lm()` может принимать также нелинейно преобразованные предикторы. Например, имея предиктор X , мы можем создать предиктор X^2 при помощи `I(X^2)`. Функция `I()` необходима, поскольку $\wedge$ имеет особое значение в формуле; изоляция при помощи `I()` позволяет использовать $\wedge$ в обычном значении, т.е. возведение X в квадрат. Теперь мы построим регрессию `medv` по `lstat` и `lstat2`.

```
> lm.fit2 = lm(medv ~ lstat + I(lstat^2))
```

```
> summary(lm.fit2)
```

Call:

```
lm(formula = medv ~ lstat + I(lstat^2))
```

Residuals :

Min	1Q	Median	3Q	Max
-15.28	-3.83	-0.53	2.31	25.41

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	42.86201	0.87208	49.1	<2e-16 ***
lstat	-2.33282	0.12380	-18.8	<2e-16 ***
I(lstat^2)	0.04355	0.00375	11.6	<2e-16 ***

Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1 1

Residual standard error: 5.52 on 503 degrees of freedom

Multiple R-squared: 0.641, Adjusted R-squared: 0.639
 F-statistic: 449 on 2 and 503 DF, p-value: <2e-16

Близкое к нулю р-значение квадратичного члена говорит о том, что его включение приводит к более качественной модели. Воспользуемся функцией `anova()` для дальнейшего количественного описания степени преимущества квадратичной модели над линейной.

`anova()`

```
> lm.fit = lm(medv ~ lstat)
> anova(lm.fit, lm.fit2)
Analysis of Variance Table

Model 1: medv ~ lstat
Model 2: medv ~ lstat + I(lstat^2)
  Res.Df    RSS Df Sum of Sq   F Pr(>F)
1     504 19472
2     503 15347  1      4125 135 <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Здесь Model 1 соответствует линейной модели, которая содержит только один предиктор (`lstat`), а Model 2 — большей квадратичной модели с двумя предикторами (`lstat` и `lstat2`). Функция `anova()` выполняет проверку определенной гипотезы для сравнения двух моделей. Эта нулевая гипотеза заключается в том, что обе модели описывают данные одинаково хорошо, а альтернативная гипотеза — в том, что полная модель¹⁷ описывает данные лучше. Здесь F-критерий составляет 135, а его р-значение практически равно нулю. Это является четким свидетельством в пользу того, что модель с предикторами `lstat` и `lstat2` существенно превосходит модель, в которую входит только предиктор `lstat`. Это неудивительно, поскольку ранее мы наблюдали признаки нелинейной зависимости между `medv` и `lstat`. Если мы выполним

```
> par(mfrow = c(2, 2))
> plot(lm.fit2)
```

то увидим, что при добавлении `lstat2` в модель какая-либо различимая закономерность в расположении остатков исчезает.

Для создания кубической модели мы можем добавить предиктор в форме `I(X3)`. Однако такой подход может стать трудоемким в случае полиномов более высокой степени. Более подходящим способом для создания полиномов при вызове `lm()` является использование функции `poly()`. Например, следующая команда даст полином пятой степени:

`poly()`

```
> lm.fit5 = lm(medv ~ poly(lstat, 5))
> summary(lm.fit5)
```

```
Call:
lm(formula = medv ~ poly(lstat, 5))
```

Residuals :

¹⁷ Под полной («full model») подразумевается модель, включающая все имеющиеся предикторы. — Прим. пер.

Min	1Q	Median	3Q	Max
-13.543	-3.104	-0.705	2.084	27.115

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	22.533	0.232	97.20	< 2e-16 ***
poly(lstat, 5)1	-152.460	5.215	-29.24	< 2e-16 ***
poly(lstat, 5)2	64.227	5.215	12.32	< 2e-16 ***
poly(lstat, 5)3	-27.051	5.215	-5.19	3.1e-07 ***
poly(lstat, 5)4	25.452	5.215	4.88	1.4e-06 ***
poly(lstat, 5)5	-19.252	5.215	-3.69	0.00025 ***

Signif. codes: 0 *** 0.001 ** 0.01 * 0.05 . 0.1 1

Residual standard error: 5.21 on 500 degrees of freedom

Multiple R-squared: 0.682, Adjusted R-squared: 0.679

F-statistic: 214 on 5 and 500 DF, p-value: <2e-16

Полученный результат свидетельствует о том, что включение дополнительных полиномиальных членов (вплоть до пятой степени) приводит к улучшению модели. Однако дальнейшее исследование данных показывает, что ни один из полиномиальных членов со степенью выше пяти не имеет достаточно низких p -значений при включении в модель.

Конечно, мы никоим образом не ограничены использованием только полиномиальных преобразований предикторов. Здесь мы пробуем логарифмирование:

```
> summary(lm(medv ~ log(rm), data = Boston))
...
```

3.6.6 Качественные предикторы

Теперь мы исследуем набор данных `Carseats` из библиотеки `ISLR`. Мы попробуем предсказать `Sales` (продажи детских автомобильных сидений) в 400 регионах на основе ряда предикторов.

```
> fix(Carseats)
> names(Carseats)
[1] "Sales"      "CompPrice"  "Income"     "Advertising"
[5] "Population" "Price"      "ShelveLoc"  "Age"
[9] "Education"  "Urban"     "US"
```

Данные `Carseats` включают категориальные предикторы, в частности `ShelveLoc` — индикатор качества расположения стеллажа, т.е. место в каждом магазине, где выставлено сидение. Предиктор `ShelveLoc` принимает три возможных значения: *Bad* (плохое), *Medium* (среднее) и *Good* (хорошее). Встречая качественную переменную вроде `ShelveLoc`, R автоматически создает индикаторные переменные. Ниже мы подгоняем множественную регрессионную модель, которая включает эффекты взаимодействия между некоторыми переменными.

```
> lm.fit = lm(Sales ~. + Income:Advertising + Price:Age,
              data = Carseats)
```

```
> summary(lm.fit)
```

Call:

```
lm(formula = Sales ~ . + Income:Advertising + Price:Age,
    data = Carseats )
```

Residuals:

Min	1Q	Median	3Q	Max
-2.921	-0.750	0.018	0.675	3.341

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	6.575565	1.008747	6.52	2.2e-10	***
CompPrice	0.092937	0.004118	22.57	< 2e-16	***
Income	0.010894	0.002604	4.18	3.6e-05	***
Advertising	0.070246	0.022609	3.11	0.00203	**
Population	0.000159	0.000368	0.43	0.66533	
Price	-0.100806	0.007440	-13.55	< 2e-16	***
ShelveLocGood	4.848676	0.152838	31.72	< 2e-16	***
ShelveLocMedium	1.953262	0.125768	15.53	< 2e-16	***
Age	-0.057947	0.015951	-3.63	0.00032	***
Education	-0.020852	0.019613	-1.06	0.28836	
UrbanYes	0.140160	0.112402	1.25	0.21317	
USYes	-0.157557	0.148923	-1.06	0.29073	
Income:Advertising	0.000751	0.000278	2.70	0.00729	**
Price:Age	0.000107	0.000133	0.80	0.42381	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.01 on 386 degrees of freedom

Multiple R-squared: 0.876, Adjusted R-squared: 0.872

F-statistic: 210 on 13 and 386 DF, p-value: <2e-16

Функция `contrasts()` возвращает матрицу, которая показывает, как именно R кодирует индикаторные переменные.

```
> attach(Carseats)
```

```
> contrasts(ShelveLoc)
```

	Good	Medium
Bad	0	0
Good	1	0
Medium	0	1

Для получения информации о других типах контрастов и о том, как их задать, воспользуйтесь командой `?contrasts`.

Программа R создала индикаторную переменную `ShelveLocGood`, которая принимает значение 1, если расположение стеллажа хорошее, и 0 в остальных случаях. Она также создала индикаторную переменную `ShelveLocMedium`, которая равна 1 при среднем качестве расположения стеллажа и 0 в остальных случаях. У каждой из этих двух индикаторных переменных плохое качество расположения соответствует нулю. Тот факт,

что коэффициент для `ShelveLocGood` в результатах расчета регрессионной модели является положительным, указывает на то, что хорошее расположение стеллажа связано с высокими продажами (по сравнению с плохим расположением). `ShelveLocMedium` имеет меньший положительный коэффициент, указывая на то, что среднее качество расположения сопровождается более высокими продажами, по сравнению с плохим расположением, но меньшими продажами, по сравнению с хорошим расположением.

3.6.7 Написание функций

Как мы уже видели, R поставляется с большим количеством полезных функций, и еще большее их количество доступно в составе библиотек для R. Однако часто нам будет интересно выполнить некоторую операцию, функции для которой нет. При таком сценарии мы можем написать свою собственную функцию. Например, ниже мы приводим пример простой функции `LoadLibraries()`, которая подключает библиотеки `ISLR` и `MASS`. При попытке вызова этой функции до того, как мы ее создали, R выдает ошибку.

```
> LoadLibraries
Error: object 'LoadLibraries' not found
> LoadLibraries()
Error: could not find function "LoadLibraries"
```

Теперь мы создадим эту функцию. Заметьте, что символы `+` выводятся на экран программой и их не нужно набирать. Символ `{` информирует R о том, что будет введено несколько команд. Нажатие *Enter* после `{` заставит R вывести знак `+`. После этого мы можем ввести столько команд, сколько захотим, нажимая *Enter* после каждой из них. Наконец, символ `}` информирует R о том, что больше команды вводиться не будут.

```
> LoadLibraries = function() {
+   library(ISLR)
+   library(MASS)
+   print("The libraries have been loaded.")
+ }
```

Если мы наберем `LoadLibraries` теперь, то R покажет нам содержимое этой функции.

```
> LoadLibraries
function(){
  library(ISLR)
  library(MASS)
  print("The libraries have been loaded.")
}
```

Вызов этой функции приведет к подключению библиотек и выводу на экран соответствующего уведомления.

```
> LoadLibraries()
[1] "The libraries have been loaded."
```


3.7 Упражнения

Теоретические

1. Опишите нулевые гипотезы, соответствующие p -значениям в табл. 3.4. Объясните, какие выводы вы можете сделать на основе этих p -значений. Ваше объяснение должно быть сформулировано в отношении связи между объемом продаж и затратами на телерекламу, радиорекламу и рекламу в газетах, а не в отношении коэффициентов линейной модели.
2. Приведите подробное объяснение различий в применении метода KNN для задач классификации и регрессии.
3. Предположим, что у нас есть набор данных с пятью предикторами: X_1 — средний балл за школьные предметы (GPA¹⁸), X_2 — коэффициент IQ, X_3 — пол (1 для женщин и 0 для мужчин), X_4 — взаимодействие между GPA и IQ, и X_5 — взаимодействие между GPA и полом. Независимой переменной является начальная заработная плата после окончания университета (тыс. долларов). Представьте, что мы используем метод наименьших квадратов для подгонки модели и получаем $\hat{\beta}_0 = 50$, $\hat{\beta}_1 = 20$, $\hat{\beta}_2 = 0.07$, $\hat{\beta}_3 = 35$, $\hat{\beta}_4 = 0.01$ и $\hat{\beta}_5 = -10$.
 - (a) Какой из приведенных ниже ответов правильный и почему?
 - i. При фиксированных значениях IQ и GPA мужчины в среднем зарабатывают больше женщин.
 - ii. При фиксированных значениях IQ и GPA женщины в среднем зарабатывают больше мужчин.
 - iii. При фиксированных значениях IQ и GPA мужчины в среднем зарабатывают больше женщин при условии, что GPA достаточно высок.
 - iv. При фиксированных значениях IQ и GPA женщины в среднем зарабатывают больше мужчин при условии, что GPA достаточно высок.
 - (b) Дайте прогнозную оценку заработной платы женщины с IQ = 111 и GPA = 4.0.
 - (c) Верно ли следующее утверждение: поскольку коэффициент для взаимодействия между GPA и IQ очень небольшой, то у нас есть мало оснований сделать вывод о наличии эффекта взаимодействия. Объясните свой ответ.
4. Я получил данные ($n = 100$ наблюдений), содержащие один предиктор и одну независимую количественную переменную. Затем я подогнал линейную регрессионную модель к этим данным, а также кубическую регрессию вида $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \epsilon$.

¹⁸ Эта аббревиатура происходит от «gross point average» — важного показателя, учитываемого при принятии абитуриентов в университеты США. — Прим. пер.

- (a) Представьте, что истинная зависимость между X и Y является линейной, т. е. $Y = \beta_0 + \beta_1 X + \epsilon$. Подумайте о сумме квадратов остатков (RSS) линейной регрессии на обучающей выборке, а также о RSS кубической регрессии на обучающей выборке. Стоит ли нам ожидать, что одна из этих величин будет ниже другой, обе величины будут равны, или имеющейся у нас информации недостаточно, чтобы сделать какое-либо заключение? Обоснуйте свой ответ.
- (b) Ответьте на вопрос (a) в отношении RSS для контрольной, а не обучающей выборки.
- (c) Представьте, что истинная зависимость между X и Y не является линейной, но мы не знаем, как сильно она отличается от линейной зависимости. Подумайте о RSS линейной регрессии на обучающей выборке и о RSS кубической регрессии на обучающей выборке. Стоит ли нам ожидать, что одна из этих величин будет ниже другой, обе величины будут равны, или имеющейся у нас информации недостаточно, чтобы сделать какое-либо заключение? Обоснуйте свой ответ.
- (d) Ответьте на вопрос (c) в отношении RSS для контрольной, а не обучающей выборки.
5. Предположим, что у нас имеются предсказанные значения, полученные на основе линейной регрессионной модели без свободного члена. При таком сценарии i -е предсказанное значение принимает форму

$$\hat{y}_i = x_i \hat{\beta},$$

где

$$\hat{\beta} = \left(\sum_{i=1}^n x_i y_i \right) / \left(\sum_{i=1}^n x_i^2 \right). \quad (3.38)$$

Покажите, что верно следующее выражение:

$$\hat{y}_i = \sum_{i'=1}^n a_{i'} y_{i'}.$$

Что представляет собой $a_{i'}$?

Обратите внимание: мы интерпретируем этот результат, исходя из того, что предсказанные на основе линейной регрессии значения являются линейными комбинациями значений отклика.

6. Используя (3.4), докажите, что в случае простой линейной регрессии линия наименьших квадратов всегда проходит через точку $(\bar{x}, \bar{y})$.
7. В тексте главы утверждается, что в случае простой линейной регрессии Y по X статистика R^2 из (3.17) равна квадрату коэффициента корреляции между X и Y (3.18). Докажите, что это так и есть. Для облегчения задачи вы можете допустить, что $\bar{x} = \bar{y} = 0$.



Практические

8. Этот вопрос касается применения простой линейной регрессии к данным `Auto`.
- (a) Воспользуйтесь функцией `lm()` для подгонки простой линейной регрессии с `mpg` в качестве отклика и `horsepower` в качестве предиктора. Примените функцию `summary()` для вывода результатов на экран. Прокомментируйте эту выведенную информацию. Например:
 - i. Есть ли линейная связь между предиктором и откликом?
 - ii. Насколько сильна связь между предиктором и откликом?
 - iii. Каково направление связи между предиктором и откликом?
 - iv. Чему равно модельное значение `mpg` при `horsepower = 98`? Каковы соответствующие 95%-ные доверительные интервалы для регрессионной прямой и для предсказанного значения?
 - (b) Постройте график зависимости отклика от предиктора. Используйте функцию `abline()` для добавления регрессионной линии, найденной по методу наименьших квадратов.
 - (c) Воспользуйтесь функцией `plot()` для построения диагностических графиков для модели, подогнанной по методу наименьших квадратов. Прокомментируйте любые обнаруженные вами проблемы с этой моделью.
9. Этот вопрос касается применения множественной линейной регрессии к данным `Auto`.
- (a) Постройте матрицу диаграмм рассеяния, которая включает все переменные из этой таблицы данных.
 - (b) Вычислите корреляционную матрицу для всех переменных, используя функцию `cor()`. Вам потребуется исключить из расчетов качественную переменную `name`. `cor()`
 - (c) Воспользуйтесь функцией `lm()` для подгонки множественной линейной регрессии с `mpg` в качестве отклика и всех других переменных, за исключением `name`, в качестве предикторов. Примените функцию `summary()` для вывода результатов на экран. Прокомментируйте эти результаты. Например:
 - i. Имеется ли связь между предикторами и откликом?
 - ii. Какие предикторы проявляют статистически значимую связь с откликом?
 - iii. О чем говорит коэффициент переменной `year`?
 - (d) Воспользуйтесь функцией `plot()` для построения диагностических графиков для этой линейной регрессионной модели. Прокомментируйте любые обнаруженные вами проблемы с этой моделью. Указывают ли остатки на наличие каких-либо необычно больших выбросов? Указывает ли график значений показателя разбалансировки на наличие наблюдений с необычно высокой разбалансировкой?

- (e) Используйте символы * и : для подгонки регрессионных моделей с эффектами взаимодействия. Являются ли какие-либо взаимодействия статистически значимыми?
 - (f) Попробуйте применить несколько разных преобразований к переменным, таких как $\log(X)$, $\sqrt{X}$, X^2 . Прокомментируйте свои находки.
10. Для ответа на следующий вопрос необходимо воспользоваться набором данных `Carseats`.
- (a) Постройте множественную регрессионную модель для предсказания `Sales` на основе `Price`, `Urban` и `US`¹⁹.
 - (b) Приведите интерпретацию каждого коэффициента в модели. Будьте осторожны — некоторые переменные являются качественными!
 - (c) Запишите модель в виде уравнения (помня о необходимости должным образом обходиться с качественными переменными).
 - (d) Для каких из предикторов вы можете отклонить нулевую гипотезу $H_0 : \beta_j = 0$?
 - (e) Учитывая свой ответ на предыдущий вопрос, постройте модель только с теми предикторами, для которых было обнаружено свидетельство в пользу их связи с откликом.
 - (f) Насколько хорошо модели из (a) и (e) описывают данные?
 - (g) Используя модель из (e), рассчитайте 95%-ные доверительные интервалы для каждого коэффициента.
 - (h) Имеются ли указания на наличие выбросов или наблюдений с высокой разбалансировкой в модели из (e)?
11. В этой задаче мы исследуем t -критерий для нулевой гипотезы $H_0 : \beta = 0$ в отношении простой линейной регрессии без свободного члена. Для начала мы сгенерируем значения предиктора x и отклика y :

```
> set.seed(1)
> x = rnorm(100)
> y = 2*x + rnorm(100)
```

- (a) Постройте простую линейную регрессию y по x без свободного члена. Приведите оценку коэффициента $\hat{\beta}$, стандартную ошибку оценки этого коэффициента, а также t -критерий и p -значение, связанные с нулевой гипотезой $H_0 : \beta = 0$. Прокомментируйте эти результаты. (Вы можете построить регрессию без свободного члена, используя команду `lm(y ~ x + 0)`.)

¹⁹ `Sales` — количество проданных единиц товара (тыс.); `Urban` — индикаторная переменная, кодирующая местоположение магазина — в городе (Yes) или за его пределами (No); `US` — индикатор того, находится ли магазин в США (Yes) или нет (No). — Прим. пер.

- (b) Теперь постройте простую линейную регрессию x по y без свободного члена, и приведите оценку регрессионного коэффициента, ее стандартную ошибку, а также t -критерий и p -значение, связанные с нулевой гипотезой $H_0 : \beta = 0$. Прокомментируйте эти результаты.
- (c) Какова связь между результатами, полученными в (a) и (b)?
- (d) В регрессии Y по X без свободного члена t -критерий для $H_0 : \beta = 0$ принимает форму $\hat{\beta}/SE(\hat{\beta})$, где определение оценки $\hat{\beta}$ дано в (3.38), а

$$SE(\hat{\beta}) = \sqrt{\frac{\sum_{i=1}^n (y_i - x_i \hat{\beta})^2}{(n-1) \sum_{i'=1}^n x_{i'}^2}}.$$

(Эти формулы несколько отличаются от тех, которые были приведены в подразделах 3.1.1 и 3.1.2, поскольку здесь мы строим регрессию без свободного члена.) Покажите, используя необходимые алгебраические преобразования, а также количественные вычисления в R, что t -критерий можно записать в виде

$$\frac{(\sqrt{n-1}) \sum_{i=1}^n x_i y_i}{\sqrt{(\sum_{i=1}^n x_i^2)(\sum_{i'=1}^n y_{i'}^2) - (\sum_{i'=1}^n x_{i'} y_{i'})^2}}.$$

- (e) Используя результаты из (d), докажите, что t -критерий в регрессии y по x не отличается от t -критерия в регрессии x по y .
 - (f) Выполнив вычисления в R, покажите, что при подгонке модели, включающей свободный член, t -критерий для $H_0 : \beta_1 = 0$ в регрессии y по x не отличается от такового в регрессии x по y .
12. Эта задача касается простой линейной регрессии без свободного члена.
- (a) Вспомните, что определение оценки коэффициента $\hat{\beta}$ для линейной регрессии Y по X без свободного члена дано в (3.38). При каком условии оценка коэффициента для регрессии X по Y не отличается от оценки коэффициента для регрессии Y по X ?
 - (b) Используя R, создайте набор данных с $n = 100$ наблюдениями, для которого оценка коэффициента регрессии X по Y *отличается* от оценки коэффициента регрессии Y по X .
 - (c) Используя R, создайте набор данных с $n = 100$ наблюдениями, для которого оценка коэффициента регрессии X по Y *не отличается* от оценки коэффициента регрессии Y по X .
13. В этом упражнении вы создадите несколько искусственных наборов данных и подгоните к ним простые линейные регрессионные модели. Убедитесь, что для получения одинаковых результатов вы применили команду `set.seed(1)` до выполнения задания (a).
- (a) Используя функцию `rmnorm()`, создайте вектор x со 100 наблюдениями, извлеченными из нормального распределения $N(0, 1)$. Он будет соответствовать некоторому признаку X .

- (b) Используя функцию `rmnorm()`, создайте вектор `eps` с 100 наблюдениями, извлеченными из распределения $N(0, 0.25)$, т. е. из нормального распределения со средним значением 0 и дисперсией 0.25.
- (c) Используя `x` и `eps`, создайте вектор `y` в соответствии с моделью

$$Y = -1 + 0.5X + \epsilon. \quad (3.39)$$

Какова длина вектора `y`? Чему равны значения β_0 и β_1 в этой линейной модели?

- (d) Постройте диаграмму рассеяния, изображающую зависимость между `x` и `y`. Прокомментируйте, что вы видите.
- (e) Постройте линейную модель по методу наименьших квадратов для предсказания `y` по `x`. Прокомментируйте полученный результат. Насколько $\hat{\beta}_0$ и $\hat{\beta}_1$ сравнимы с β_0 и β_1 ?
- (f) Добавьте линию наименьших квадратов к диаграмме рассеяния, полученной в (d). Изобразите истинную регрессионную линию на графике каким-либо другим цветом. Воспользуйтесь командой `legend()` для создания подходящей легенды.
- (g) Теперь постройте полиномиальную регрессионную модель, которая предсказывает `y` по `x` и `x`². Похоже ли, что квадратичный член улучшает модель? Объясните свой ответ.
- (h) Повторите (a) – (f), изменив процесс генерации данных таким образом, чтобы в них было *меньше* шума. Модель (3.39) должна оставаться неизменной. Вы можете сделать это путем уменьшения дисперсии нормального распределения, используемого для создания остатков ϵ в (b). Опишите свои результаты.
- (i) Повторите (a) – (f), изменив процесс генерации данных таким образом, чтобы в них было *больше* шума. Модель (3.39) должна оставаться неизменной. Вы можете сделать это путем увеличения дисперсии нормального распределения, из которого извлекаются остатки ϵ в (b). Опишите свои результаты.
- (j) Каковы доверительные интервалы для β_0 и β_1 , полученные на основе исходного набора данных, набора данных с большим шумом и набора данных с меньшим шумом? Прокомментируйте свои результаты.

14. Эта задача посвящена проблеме *коллинеарности*.

- (a) Выполните следующие команды в R:

```
> set.seed(1)
> x1 = runif(100)
> x2 = 0.5*x1 + rnorm(100)/10
> y = 2 + 2*x1 + 0.3*x2 + rnorm(100)
```

В последней строке создается линейная модель, в которой `y` является функцией от `x1` и `x2`. Запишите эту линейную модель в виде формулы. Чему равны регрессионные коэффициенты?

- (b) Какова корреляция между x_1 и x_2 ? Постройте диаграмму рассеяния, изображающую связь между этими переменными.
- (c) Используя эти данные, постройте регрессионную модель по методу наименьших квадратов для предсказания y по x_1 и x_2 . Опишите полученные результаты. Чему равны $\hat{\beta}_0$, $\hat{\beta}_1$ и $\hat{\beta}_2$? Как эти коэффициенты соотносятся с истинными значениями β_0 , β_1 и β_2 ? Можете ли вы отклонить нулевую гипотезу $H_0 : \beta_1 = 0$? Как на счет нулевой гипотезы $H_0 : \beta_2 = 0$?
- (d) Теперь подгоните регрессию по методу наименьших квадратов для предсказания y только по x_1 . Прокомментируйте свои результаты. Можете ли вы отклонить нулевую гипотезу $H_0 : \beta_1 = 0$?
- (e) Теперь подгоните регрессию по методу наименьших квадратов для предсказания y только по x_2 . Прокомментируйте свои результаты. Можете ли вы отклонить нулевую гипотезу $H_0 : \beta_1 = 0$?
- (f) Противоречат ли результаты, полученные в (c) – (e), друг другу? Объясните свой ответ.
- (g) Теперь допустим, что мы получили дополнительное наблюдение, которое, к сожалению, ранее было измерено неверно.

```
> x1 = c(x1, 0.1)
> x2 = c(x2, 0.8)
> y = c(y, 6)
```

Повторите подгонку моделей из (c) и (e), используя эти новые данные. Какой эффект оказывает это новое наблюдение на каждую из моделей? Является ли это наблюдение выбросом в каждой модели? Наблюдением с высокой разбалансировкой? И тем, и другим? Объясните свои ответы.

15. Эта задача касается набора данных Boston, который мы уже видели в лабораторной работе к этой главе. Теперь мы попытаемся предсказать уровень преступности на душу населения, используя другие переменные из этого набора данных. Другими словами, уровень преступности на душу населения является откликом, а все остальные переменные — предикторами.

- (a) Постройте простую регрессионную модель для предсказания отклика на основе каждого предиктора. Опишите свои результаты. В какой из моделей имеет место статистически значимая связь между предиктором и откликом? Постройте несколько графиков в подтверждение своих выводов.
- (b) Постройте множественную регрессионную модель для предсказания отклика на основе всех предикторов. Опишите свои результаты. Для каких предикторов мы можем отклонить нулевую гипотезу $H_0 : \beta_j = 0$?
- (c) Как соотносятся результаты, полученные вами в заданиях (a) и (b)? Постройте график, на котором по оси x показаны регрессионные коэффициенты из простых моделей, полученных в (a), а по

оси y — коэффициенты из множественной регрессии, полученной в (b). Иными словами, каждому предиктору соответствует отдельная точка на графике. Коэффициент каждого предиктора из простой регрессии отложен по оси x , а соответствующий коэффициент из множественной регрессии — по оси y .

- (d) Есть ли указания на нелинейную связь между каким-либо из предикторов и откликом? Для ответа на этот вопрос подгоните для каждого предиктора модель следующего вида:

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \epsilon.$$

Глава 4

Классификация

Линейная регрессионная модель, которая обсуждалась в главе 3, подразумевает, что независимая переменная Y является количественной. Однако часто независимая переменная является *качественной*. Например, цвет глаз — это качественная переменная, принимающая значения «голубой», «коричневый» или «зеленый». Часто качественные переменные называют *категориальными*; мы будем использовать эти термины попеременно. В этой главе мы изучаем методы, предназначенные для предсказания качественных откликов — процесса, известного как *классификация*. Предсказание качественного отклика для некоторого наблюдения можно назвать классификацией, поскольку это наблюдение относят к определенной категории, или классу. С другой стороны, часто методы классификации в качестве основы для выполнения классификации сначала предсказывают вероятность каждой из категорий качественной переменной. В этом смысле они ведут себя подобно методам регрессии.

качественная переменная

классификация

Существует множество методов классификации, или *классификаторов*, которые можно использовать для предсказания качественного отклика. Мы затронули некоторые из них в подразделах 2.1.5 и 2.2.3. В этой главе мы обсуждаем три наиболее широко распространенных классификатора: *логистическую регрессию*, *линейный дискриминантный анализ* и *метод K ближайших соседей*. В более поздних главах мы обсуждаем методы, требующие большего объема вычислений, такие как обобщенные аддитивные модели (глава 7), деревья классификации, случайные леса и бустинг (глава 8), а также машины опорных векторов (глава 9).

классификатор

логистическая регрессия

линейный дискриминантный анализ

метод K ближайших соседей

4.1 Общее представление о классификации

Проблемы классификации встречаются часто, возможно даже чаще, чем проблемы регрессии. Вот некоторые примеры:

1. Человек поступает в отделение экстренной медицинской помощи с набором симптомов, которые могут быть связаны с одним из трех заболеваний. Каким из трех заболеваний болен этот человек?
2. Сервис банковского обслуживания через Интернет должен иметь возможность определить, является ли та или иная онлайн-транзакция мошеннической, учитывая IP-адрес пользователя, историю его предыдущих транзакций и т. д.

3. На основе данных по структуре ДНК у ряда пациентов, имеющих определенное заболевание, и у пациентов, свободных от этого заболевания, биолог хотел бы выяснить, какие мутации ДНК вредны (т. е. вызывают заболевание), а какие — нет.

Подобно тому, как это было с регрессией, у нас имеется набор обучающих наблюдений $(x_1, y_1), \dots, (x_n, y_n)$, которые мы можем использовать для построения классификатора. Мы хотим, чтобы наш классификатор хорошо работал не только на обучающих данных, но и на контрольных наблюдениях, которые не были использованы для обучения классификатора.

В этой главе мы проиллюстрируем концепцию классификации на примере имитированных данных `Default`. Мы заинтересованы в предсказании того, погасит ли клиент свой долг по кредитной карте, учитывая размер годового дохода этого клиента и месячного баланса на его кредитной карте. Данные представлены на рис. 4.1. Мы изобразили годовой доход `income` и месячный баланс на кредитной карте `balance` для группы из 10 000 человек. Слева на рис. 4.1 клиенты, не выплатившие долг за текущий месяц, показаны оранжевым цветом, а выплатившие — голубым. (Общая доля неплательщиков составляет около 3%, и поэтому мы привели на графике только часть клиентов, погасивших долг). Похоже, что неплательщики в целом имеют более высокие значения долга по кредитной карте. На рис. 4.1 справа приведены две пары диаграмм размахов. Первая из них показывает распределение значений `balance`, разбитых в соответствии с уровнями бинарной переменной `default` (неплатеж), а вторая диаграмма показывает похожую информацию для `income`. В этой главе мы узнаем, как построить модель для предсказания `default` (Y) для любых заданных значений `balance` (X_1) и `income` (X_2). Поскольку Y не является количественной переменной, то простая линейная регрессионная модель из главы 3 здесь не подходит.

Следует отметить, что на рис. 4.1 хорошо видна тесная связь между предиктором `balance` и откликом `default`. В большинстве практических задач связь между предиктором и откликом будет далеко не такой выраженной. Однако в целях иллюстрации процедур классификации, обсуждаемых в этой главе, мы воспользуемся примером, в котором теснота связи между предиктором и откликом несколько преувеличена.

4.2 Почему не линейная регрессия?

Выше мы заявили, что метод линейной регрессии не подходит для работы с качественным откликом. Почему нет?

Представьте, что мы пытаемся предсказать состояние пациентки из отделения неотложной медицинской помощи по совокупности наблюдаемых у этой пациентки симптомов. В этом упрощенном примере возможны три диагноза: инсульт, передозировка наркотиками и эпилептический припадок. Мы могли бы закодировать эти значения в виде количественной переменной следующим образом:




РИСУНОК 4.1. Набор данных *Default*. Слева: значения годового дохода и уровня баланса на кредитной карте у нескольких клиентов банка. Клиенты, которые не погасили свой долг по кредитной карте, показаны оранжевым цветом, а те, которые погасили, — голубым. В центре: диаграмма размахов значений баланса на кредитной карте у клиентов с разным статусом дефолта. Справа: диаграмма размахов значений годового дохода у клиентов с разным статусом дефолта

$$Y = \begin{cases} 1, & \text{если инсульт} \\ 2, & \text{если передозировка} \\ 3, & \text{если припадок.} \end{cases}$$

Применив такое кодирование, можно было бы воспользоваться методом наименьших квадратов и подогнать линейную регрессионную модель, предсказывающую Y на основе совокупности предикторов $X_1, \dots, X_p$. К сожалению, такое кодирование подразумевает определенный порядок в расположении значений отклика: оно помещает передозировку наркотиками между инсультом и эпилептическим припадком и настаивает на том, что разница между инсультом и передозировкой наркотиками такая же, как и между передозировкой и эпилептическим припадком. На практике для этого нет никаких оснований. Например, одинаково приемлемым было бы следующее кодирование:

$$Y = \begin{cases} 1, & \text{если припадок} \\ 2, & \text{если инсульт} \\ 3, & \text{если передозировка,} \end{cases}$$

которое подразумевало бы совершенно другую связь между эти тремя медицинскими состояниями. Каждый из приведенных способов кодирования породил бы фундаментально разные линейные модели, которые в итоге привели бы к разным предсказаниям на контрольных данных.

Если бы значения зависимой переменной действительно можно было упорядочить естественным образом (например, *мягкий* > *умеренный* >

суровый), и у нас были основания считать, что разница между «мягким» и «умеренным» похожа на разницу между «умеренным» и «суровым», то кодирование в виде 1, 2 и 3 было бы уместным. В целом, к сожалению, не существует естественного способа конвертировать качественную зависимую переменную с числом уровней больше двух в количественный отклик, пригодный для линейной регрессии.

бинарный

Для бинарного качественного отклика (т. е. переменной с двумя уровнями) ситуация лучше. Например, может оказаться так, что есть только два варианта состояния пациента: инсульт и передозировка наркотиками. В таком случае мы потенциально могли бы использовать метод индикаторных переменных (см. подраздел 3.3.1), чтобы закодировать отклик следующим образом:

$$Y = \begin{cases} 0, & \text{если инсульт} \\ 1, & \text{если передозировка.} \end{cases}$$

Далее мы могли бы построить линейную регрессию для этого бинарного отклика и предсказывать передозировку наркотиками при $\hat{Y} > 0.5$ и инсульт в остальных случаях. Для бинарного отклика несложно показать, что даже если мы поменяем приведенные выше коды состояний местами, то линейная регрессия в итоге приведет к таким же предсказаниям.

Для бинарного отклика, закодированного при помощи 1 и 0, как в вышеприведенном примере, регрессия по методу наименьших квадратов действительно имеет смысл: можно показать, что в этом специальном случае величина $X\hat{\beta}$, полученная при помощи линейной регрессии, есть не что иное, как оценка $\text{Pr}(\text{передозировка наркотиками}|X)$. Однако при использовании линейной регрессии некоторые из наших оценок могут оказаться за пределами интервала $[0, 1]$ (см. рис. 4.2), что затруднит их интерпретацию в качестве вероятностей! Тем не менее такие предсказания можно упорядочить и рассматривать их как грубые оценки вероятности. Интересно, что результаты классификации, которые мы получаем для бинарного отклика при помощи линейной регрессии, будут идентичны результатам, которые дает линейный дискриминантный анализ (LDA) (раздел 4.4).

Однако метод индикаторных переменных нелегко приспособить для количественных откликов с числом уровней больше двух. По этим причинам предпочтительно использовать методы классификации (например, рассмотренные в этой книге), которые специально предназначены для количественных откликов.

4.3 Логистическая регрессия

Вернемся снова к набору данных `Default`, в котором зависимая переменная `default` представлена двумя категориями — `Yes` и `No`. Вместо того чтобы непосредственно моделировать отклик Y , логистическая регрессия моделирует *вероятность* принадлежности Y к той или иной категории.

Для набора данных `Default` логистическая регрессия моделирует вероятность неуплаты долга (дефолта). Например, вероятность дефолта для некоторого значения `balance` можно записать как




РИСУНОК 4.2. Классификация с использованием набора данных Default. Слева: вероятности дефолта, оцененные при помощи линейной регрессии. Некоторые вероятности оказались отрицательными! Оранжевые вертикальные отрезки показывают значения 0 и 1, кодирующие категории дефолта (No и Yes). Справа: вероятности дефолта, оцененные при помощи логистической регрессии. Все вероятности лежат в пределах интервала от 0 до 1

$$\Pr(\text{default} = \text{Yes}|\text{balance}).$$

Значения $\Pr(\text{default} = \text{Yes}|\text{balance})$, которые мы сокращенно обозначаем как $p(\text{balance})$, будут изменяться от 0 до 1. Далее для заданного значения balance можно предсказать вероятный статус дефолта. Например, для клиента с $p(\text{balance} > 0.5)$ можно было бы предсказать $\text{default} = \text{Yes}$. Если компания желает быть консервативной в предсказании того, какие клиенты не вернут свой долг, то в качестве альтернативы она может использовать более низкое пороговое значение вероятности, например $p(\text{balance} > 0.1)$.

4.3.1 Логистическая модель

Как же нам смоделировать связь между $p(X) = \Pr(Y = 1|X)$ и X ? (Для удобства мы применяем универсальное кодирование отклика в виде 0/1). В разделе 4.2 мы говорили о том, что для представления этих вероятностей можно воспользоваться линейной регрессионной моделью:

$$p(X) = \beta_0 + \beta_1 X. \tag{4.1}$$

Если мы применим этот подход для предсказания $\text{default} = \text{Yes}$ на основе balance , то получим модель, показанную слева на рис. 4.2. Хорошо видно проблема с этим подходом: для значений баланса на кредитной карте, близких к нулю, мы предсказываем отрицательную вероятность дефолта; если бы мы хотели выполнить предсказания для очень больших величин баланса, то получили бы значения, превышающие 1. Эти предсказания не имеют смысла, поскольку истинная вероятность дефолта, вне зависимости от баланса на кредитной карте, должна изменяться от 0 до 1. Эта проблема не является уникальной для данных по кредитным неплатежам.

Каждый раз, когда к бинарному отклику, закодированному при помощи 0 и 1, подгоняется прямая линия, мы практически всегда можем получить $p(X) < 0$ для одних значений X и $p(X) > 1$ — для других (если только размах значений X не ограничен).

Во избежание этой проблемы мы должны моделировать $p(X)$ на основе функции, которая возвращает значения из интервала от 0 до 1 для всех X . Таким свойством обладают многие функции. В логистической регрессии мы применяем логистическую функцию:

$$p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}}. \quad (4.2)$$

Для подгонки модели (4.1) мы применяем так называемый *метод максимального правдоподобия*, который обсуждается в следующем разделе. На рис. 4.2 справа показана логистическая регрессионная модель, подогнанная к данным из таблицы Default. Заметьте, что теперь для низких значений кредитного баланса мы предсказываем близкую к нулю, но всегда положительную вероятность дефолта. Аналогично для высоких значений баланса мы предсказываем вероятность дефолта, близкую к единице, но никогда не превышающую ее. Логистическая функция всегда порождает такую *S-образную* кривую, и поэтому вне зависимости от значений X мы будем получать разумный прогноз. Мы видим также, что логистическая модель отражает размах вероятностей лучше, чем линейная регрессионная модель, представленная на графике слева. Средняя расчетная вероятность в обоих случаях составляет 0.0333 (в среднем по обучающим данным) и равна общей доли неплательщиков в этом наборе данных.

После небольших преобразований (4.2) мы обнаружим, что

$$\frac{p(X)}{1 - p(X)} = e^{\beta_0 + \beta_1 X}. \quad (4.3)$$

Величина $p(X)/[1 - p(X)]$ называется *риском события*¹ и может принимать любое значение от 0 до ∞ . Значения риска, близкие к 0 и ∞ , указывают на очень низкие и очень высокие вероятности дефолта соответственно. Например, в среднем 1 из 5 человек с риском $1/4$ станет неплательщиком, поскольку $p(X) = 0.2$ предполагает отношение $\frac{0.2}{1-0.2} = 1/4$. Аналогично неплательщиками в среднем станут девять из десяти человек с риском, равным 9, поскольку $p(X) = 0.9$ предполагает отношение $\frac{0.9}{1-0.9} = 9$. Концепция «риска» традиционно использовалась вместо вероятностей в конных скачках, т. к. она более естественно подходит для описания стратегии заключения пари.

Если мы прологарифмируем обе части (4.3), то получим

$$\log\left(\frac{p(X)}{1 - p(X)}\right) = \beta_0 + \beta_1 X. \quad (4.4)$$

Левая часть в этом уравнении называется *логарифмом риска*, или *логитом*. Как видим, логит регрессионной модели (4.2) является линейным по X .

¹ В оригинале используется термин «odds». Иногда этот термин переводится также как «шанс». — Прим. пер.

логисти-
ческая
функция

макси-
мальное
правдопо-
добие

логит

Вспомните из главы 3, что в линейной регрессионной модели β_1 отражает среднее изменение Y , вызванное увеличением X на 1. В то же время в логистической регрессионной модели увеличение X на одну единицу изменяет на β_1 логарифм риска (см. уравнение 4.4), или, что то же самое, умножает риск на e^{β_1} (см. уравнение 4.3). Однако в связи с тем, что связь между $p(X)$ и X в (4.2) не выглядит как прямая линия, β_1 не отражает изменение $p(X)$, вызванное увеличением X на 1. Величина, на которую $p(X)$ изменяется при изменении X на одну единицу, будет зависеть от текущего значения X . Однако вне зависимости от значения X при положительном β_1 рост X будет сопровождаться увеличением $p(X)$, а при отрицательном β_1 рост X вызовет снижение $p(X)$. Факт нелинейной связи между $p(X)$ и X , а также тот факт, что скорость изменения $p(X)$ при изменении X на одну единицу зависит от текущего значения X , можно увидеть на графике, представленном справа на рис. 4.2.

4.3.2 Оценивание регрессионных коэффициентов

Коэффициенты β_0 и β_1 в (4.2) неизвестны и подлежат оцениванию по доступным обучающим данным. В главе 3 для нахождения неизвестных коэффициентов линейной регрессии мы использовали метод наименьших квадратов. Хотя мы могли бы применить (нелинейный) метод наименьших квадратов для подгонки модели (4.4), предпочтительным является более общий метод максимального правдоподобия. Суть использования максимального правдоподобия для подгонки логистической регрессии заключается в следующем: используя (4.2), мы ищем такие оценки β_0 и β_1 , чтобы предсказанная вероятность дефолта $\hat{p}(x_i)$ для каждого клиента максимально близко соответствовала его наблюдаемому статусу. Другими словами, мы пытаемся найти такие оценки $\hat{\beta}_0$ и $\hat{\beta}_1$, которые при подстановке в модель (4.2) для $p(X)$ давали бы число, близкое к единице для всех неплательщиков, и близкое к нулю для всех клиентов с высокой кредитоспособностью. Это простое объяснение можно формализовать в виде математического уравнения, известного как *функция правдоподобия*:

функция
правдопо-
добия

$$\ell(\beta_0, \beta_1) = \prod_{i: y_i=1} p(x_i) \prod_{i': y_{i'}=0} (1 - p(x_{i'})). \quad (4.5)$$

Оценки $\hat{\beta}_0$ и $\hat{\beta}_1$ выбирают таким образом, чтобы *максимизировать* функцию правдоподобия.

Метод максимального правдоподобия является очень общим и используется для подгонки многих нелинейных моделей, рассматриваемых в этой книге. Оказывается, что в линейной регрессии метод наименьших квадратов является частным случаем метода максимального правдоподобия. Математические детали максимального правдоподобия находятся за рамками данной книги. Однако в целом логистическую регрессию и другие модели можно легко подогнать при помощи такой статистической программы, как R, и поэтому нам нет необходимости углубляться в детали процедуры нахождения максимального правдоподобия.

В табл. 4.1 показаны оценки коэффициентов и сопутствующая им информация, полученные в результате подгонки логистической регрессионной модели по данным Default с целью предсказания вероятности default

ТАБЛИЦА 4.1. Коэффициенты логистической регрессионной модели для данных Default, которая предсказывает вероятность дефолта на основе размера долга по кредитной карте. Увеличение долга на одну единицу связано с увеличением логарифма риска дефолта на 0.0055 единицы

	Коэффициент	Ст. ошибка	Z- критерий	p
Свободный член	-10.6513	0.3612	-29.5	< 0.0001
balance	0.0055	0.0002	24.9	< 0.0001

= Yes по balance. Мы видим, что $\hat{\beta}_1 = 0.0055$, т.е. увеличение balance связано с ростом вероятности дефолта. Если быть точнее, то увеличение баланса на кредитной карте на одну единицу приводит к увеличению логарифма риска дефолта на 0.0055 единицы.

Многие аспекты результатов расчета логистической регрессии, показанных в табл. 4.1, похожи на результаты для линейной регрессии из главы 3. Например, мы можем выразить точность оценок коэффициентов путем вычисления их стандартных ошибок. z-критерий в табл. 4.1 играет ту же роль, что и t-критерий в результатах для линейной регрессии (см., например, табл. 3.1 на стр. 80). Так, z-критерий коэффициента β_1 равен $\hat{\beta}_1/SE(\hat{\beta}_1)$, и поэтому высокое (абсолютное) значение этого z-критерия является свидетельством против нулевой гипотезы $H_0 : \beta_1 = 0$. Эта нулевая гипотеза предполагает, что $p(X) = \frac{e^{\beta_0}}{1+e^{\beta_0}}$, т.е. вероятность дефолта не зависит от баланса на кредитной карте. Поскольку приведенное в табл. 4.1 p-значение для balance является очень небольшим, мы можем отклонить H_0 . Другими словами, мы заключаем, что между balance и default действительно имеется связь. Приведенная в табл. 4.1 оценка свободного члена уравнения обычно не представляет интереса; ее основное назначение заключается в коррекции предсказанных средних значений вероятности с учетом доли неплательщиков в данных.

4.3.3 Предсказания

Имея оценки коэффициентов, вычислить вероятность дефолта для любого значения баланса на кредитной карте очень просто. Например, используя оценки коэффициентов из табл. 4.1, мы предсказываем, что вероятность дефолта для клиента с долгом в 1000\$ составляет

$$\hat{p}(X) = \frac{e^{\hat{\beta}_0 + \hat{\beta}_1 X}}{1 + e^{\hat{\beta}_0 + \hat{\beta}_1 X}} = \frac{e^{-10.6513 + 0.0055 \times 1000}}{1 + e^{-10.6513 + 0.0055 \times 1000}} = 0.00576,$$

что меньше 1%. В то же время предсказанная вероятность дефолта для клиента с долгом в 2000\$ намного выше и составляет 0.586, или 58.6%.

В логистическую регрессию можно включать качественные предикторы, используя метод индикаторных переменных (см. подраздел 3.3.1). Например, набор данных Default содержит качественную переменную student. Для построения модели мы просто создаем индикаторную переменную, которая принимает значение 1 для студентов и 0 для не студентов. Логистическая модель для предсказания вероятности дефолта на основе

ТАБЛИЦА 4.2. Коэффициенты логистической регрессионной модели для данных Default, которая предсказывает вероятность дефолта на основе переменной student. Этот предиктор закодирован в виде индикаторной переменной (показана в таблице как student[Yes]) со значением 1 для студентов и значением 0 для не студентов

	Коэффициент	Ст. ошибка	Z- критерий	p
Свободный член	-3.5041	0.0707	-49.55	< 0.0001
student[Yes]	0.4049	0.1150	3.52	0.0004

переменной student описана в табл. 4.2. Коэффициент индикаторной переменной положителен, а соответствующее p-значение статистически значимо. Это указывает на то, что студенты в целом имеют более высокие риски неуплаты долга, чем не студенты:

$$\widehat{\Pr}(\text{default} = \text{Yes} \mid \text{student} = \text{Yes}) = \frac{e^{-3.5041+0.4049 \times 1}}{1 + e^{-3.5041+0.4049 \times 1}} = 0.0431,$$

$$\widehat{\Pr}(\text{default} = \text{Yes} \mid \text{student} = \text{No}) = \frac{e^{-3.5041+0.4049 \times 0}}{1 + e^{-3.5041+0.4049 \times 0}} = 0.0292.$$

4.3.4 Множественная логистическая модель

Теперь мы рассмотрим проблему предсказания бинарного отклика на основе нескольких предикторов. Подобно тому, как простая линейная регрессия в главе 3 была расширена до множественной регрессионной модели, мы можем обобщить (4.4) следующим образом:

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p, \quad (4.6)$$

где $X = (X_1, \dots, X_p)$ — это набор из p предикторов. Уравнение (4.6) можно переписать как

$$p(X) = \frac{e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}{1 + e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}. \quad (4.7)$$

Как и в подразделе 4.3.2, для нахождения оценок $\beta_0, \beta_1, \dots, \beta_p$ мы применяем метод максимального правдоподобия.

В табл. 4.3 показаны оценки коэффициентов для логистической регрессионной модели, которая предсказывает дефолт по переменным balance, income (тыс. долларов) и student. Какого-либо сюрприза в полученном результате нет. P-значения у переменных balance и student очень низкие, что указывает на их тесную связь с вероятностью дефолта. Однако коэффициент у индикаторной переменной student отрицательный, указывая на то, что студенты имеют меньшую вероятность не выплатить долг в сравнении с не студентами. В то же время коэффициент у этой

ТАБЛИЦА 4.3. Коэффициенты логистической регрессионной модели для данных Default, которая предсказывает вероятность дефолта на основе переменных balance, income и student. Предиктор student закодирован в виде индикаторной переменной student[Yes] со значением 1 для студентов и значением 0 для не студентов. При подгонке этой модели переменная income выражалась в тысячах долларов

	Коэффициент	Ст. ошибка	Z- критерий	p
Свободный член	-10.8690	0.4923	-22.08	< 0.0001
balance	0.0057	0.0002	24.74	< 0.0001
income	0.0030	0.0082	0.37	0.7115
student[Yes]	-0.6468	0.2362	-2.74	0.0062

индикаторной переменной в табл. 4.2 является положительным. Но как это возможно, чтобы эта переменная была связана с *увеличением* вероятности дефолта в табл. 4.2 и со *снижением* вероятности дефолта в табл. 4.3? График, приведенный слева на рис. 4.3, иллюстрирует этот кажущийся парадокс. Оранжевая и голубая сплошные линии показывают средние уровни встречаемости неплательщиков среди студентов и не-студентов соответственно в зависимости от долга по кредитной карте. Отрицательный коэффициент у student во множественной логистической регрессии показывает, что для некоторых фиксированных значений balance и income студенты имеют меньшую вероятность стать неплательщиками по сравнению с не студентами. И действительно — слева на рис. 4.3 мы видим, что встречаемость дефолта у студентов равна или ниже таковой у не студентов, вне зависимости от величины balance. Однако горизонтальные прерывистые линии в нижней части графика, которые показывают встречаемость неплательщиков среди студентов и не студентов в среднем по всем значениям balance и income, предполагают обратный эффект: в целом частота встречаемости неплательщиков у студентов выше, чем у не студентов. Как результат коэффициент для student в простой логистической регрессии имеет положительный знак (табл. 4.2).

График, приведенный на рис. 4.3 справа, объясняет это расхождение. Переменные student и balance коррелируют. Студенты в целом имеют более высокие долги, что, в свою очередь, связано с большей вероятностью дефолта. Другими словами, студенты чаще имеют высокие долги по кредитной карте, которые, как мы знаем по графику, показанному на рис. 4.3 слева, обычно сопровождаются большей частотой встречаемости дефолта. Поэтому даже если некоторый студент с определенным балансом на кредитной карте окажется неплательщиком с меньшей вероятностью, чем не студент с таким же балансом на кредитной карте, в целом студенты имеют более высокие долги, и поэтому становятся неплательщиками чаще, чем не студенты. Это важное различие для компании-эмитента кредитных карт, которая пытается определить, кому следует предложить свои услуги. Студент является более рискованным клиентом, чем не студент, при условии, что информация о долге по кредитной карте для этого студента недоступна. Однако студент является менее рискованным клиентом, чем не студент с *таким же балансом на кредитной карте!*




РИСУНОК 4.3. Смешивание эффектов предикторов в данных Default. Слева: показана встречаемость дефолта среди студентов (оранжевый цвет) и не студентов (голубой цвет). Сплошные линии соответствуют встречаемости дефолта в зависимости от balance, тогда как горизонтальные прерывистые линии показывают его общую встречаемость. Справа: диаграмма размахов для Default у студентов (оранжевый цвет) и не студентов (голубой цвет)

Этот простой пример иллюстрирует опасности и тонкости, связанные с построением регрессионных моделей с единственным предиктором в ситуациях, когда важными могут быть и другие предикторы. Как и в случае линейной регрессии, результаты, получаемые на основе одного предиктора, могут довольно сильно отличаться от результатов, полученных с использованием нескольких предикторов, особенно когда имеет место корреляция между предикторами. Обычно феномен, представленный на рис. 4.3, называют «смешиванием эффектов»².

Подставляя оценки регрессионных коэффициентов из табл. 4.3 в (4.7), мы можем делать предсказания. Например, оценка вероятности дефолта у студента с долгом по кредитной карте в 1500\$ и доходом в 40 000\$ составляет

$$\hat{p}(X) = \frac{e^{-10.869 + 0.00574 \times 1500 + 0.003 \times 40 - 0.6468 \times 1}}{1 + e^{-10.869 + 0.00574 \times 1500 + 0.003 \times 40 - 0.6468 \times 1}} = 0.058. \quad (4.8)$$

Оценка вероятности дефолта у не студента с такими же долгом и доходом составляет

$$\hat{p}(X) = \frac{e^{-10.869 + 0.00574 \times 1500 + 0.003 \times 40 - 0.6468 \times 0}}{1 + e^{-10.869 + 0.00574 \times 1500 + 0.003 \times 40 - 0.6468 \times 0}} = 0.105. \quad (4.9)$$

(Здесь мы умножаем оценку коэффициента для income на 40, а не 40 000, поскольку в описанной в табл. 4.3 модели эта переменная выражается в тысячах долларов.)

² В оригинале используется термин «confounding». — Прим. пер.

4.3.5 Логистическая регрессия для зависимых переменных с числом классов > 2

Иногда мы хотим выполнить классификацию для зависимой переменной, у которой имеется больше двух классов. Например, в разделе 4.2 в примере с отделением экстренной медицинской помощи у нас было три типа состояния пациентов: инсульт, передозировка наркотиками и эпилептический припадок. При таком сценарии мы хотим смоделировать как $\Pr(Y = \text{инсульт}|X)$, так и $\Pr(Y = \text{передозировка}|X)$, при том что $\Pr(Y = \text{эпилепсия}|X) = 1 - \Pr(Y = \text{инсульт}|X) - \Pr(Y = \text{передозировка}|X)$. Логистические модели с двумя классами, описанные в предыдущих разделах, имеют расширенные формы для случаев с несколькими классами, однако на практике они применяются довольно редко. Одна из причин заключается в том, что метод, который мы обсуждаем в следующем разделе (дискриминантный анализ), очень популярен для решения проблем классификации с несколькими классами. Поэтому здесь мы не углубляемся в детали логистической регрессии для нескольких классов — отметим просто, что такой подход возможен, что и программное обеспечение для него доступно в R.

4.4 Дискриминантный анализ

В логистической регрессии $\Pr(Y = k|X = x)$ моделируется непосредственно на основе логистической функции, представленной в (4.7) для случая с двумя классами. Пользуясь статистическим жаргоном, можно сказать, что мы моделируем условное распределение отклика Y с учетом предиктора(ов) X . Теперь мы рассмотрим альтернативный и прямой подход для оценивания этих вероятностей. В этом альтернативном подходе мы моделируем распределение предикторов X отдельно для каждого класса зависимой переменной (т.е. для конкретного уровня Y), а затем применяем теорему Байеса в обратном порядке для получения оценок $\Pr(Y = k|X = x)$. Если допустить, что эти распределения являются нормальными, то окажется, что эта модель очень похожа по форме на логистическую регрессию.

Зачем нам еще один метод, если у нас уже есть логистическая регрессия? На это есть несколько причин:

- Когда классы хорошо разделены, оценки параметров логистической регрессии на удивление очень нестабильны. Линейный дискриминантный анализ не страдает от этой проблемы.
- При малом n и примерно нормально распределенных предикторах во всех классах линейный дискриминантный анализ, опять-таки, более устойчив, чем логистическая регрессионная модель.
- Как было отмечено в подразделе 4.3.5, линейный дискриминантный анализ популярен в ситуациях, когда зависимая переменная имеет больше двух классов.

4.4.1 Использование теоремы Байеса для классификации

Предположим, что мы хотим отнести некоторое наблюдение к одному из K классов, где $K \geq 2$. Иными словами, качественная зависимая переменная Y может принимать K четко различающихся и неупорядоченных значений. Пусть π_k обозначает общую *априорную* вероятность того, что случайно выбранное наблюдение происходит из k -го класса, т.е. это вероятность того, что некоторое наблюдение ассоциировано с k -й категорией отклика Y . Пусть $f_k(X) \equiv Pr(X = x|Y = k)$ обозначает *функцию плотности вероятности* X для некоторого наблюдения, происходящего из k -го класса. Другими словами, $f_k(x)$ принимает относительно высокое значение, когда имеет место высокая вероятность пронаблюдать $X \approx x$ у некоторого наблюдения из класса k ; в свою очередь, $f_k(x)$ принимает низкое значение при низкой вероятности того, что у некоторого наблюдения из k -го класса $X \approx x$. Тогда *теорема Байеса* утверждает, что

априорная
вероят-
ность

функция
плотности
вероятно-
сти

теорема
Байеса

$$Pr(Y = k|X = x) = \frac{\pi_k f_k(x)}{\sum_{l=1}^K \pi_l f_l(x)}. \tag{4.10}$$

В соответствии с введенными ранее обозначениями мы будем использовать сокращение $p_k(X) = Pr(Y = k|X)$. Это предполагает, что вместо непосредственного вычисления величины $p_k(X)$, подобно тому, как это было сделано в подразделе 4.3.1, мы можем просто подставить оценки π_k и $f_k(X)$ в (4.10). Как правило, получение оценки π_k не составляет труда, если у нас есть случайная выборка значений Y из генеральной совокупности: мы просто вычисляем долю обучающих наблюдений, принадлежащих к классу k . Однако нахождение $f_k(X)$ обычно является более сложной задачей, если только мы не допустим, что эти функции плотности имеют определенные простые формы. Мы называем $p_k(x)$ *апостериорной* вероятностью принадлежности некоторого наблюдения $X = x$ к классу k . Другими словами, это вероятность принадлежности данного наблюдения к классу k , *исходя из значения предиктора* у этого наблюдения.

апостери-
орная
вероят-
ность

Как мы знаем из главы 2, среди всех классификаторов байесовский классификатор, который относит то или иное наблюдение к классу с наибольшей вероятностью $p_k(X)$, обладает минимальной возможной частотой ошибок. (Конечно, это справедливо только при условии, что параметры уравнения 4.10 заданы правильно.) Следовательно, если мы сумеем найти способ оценить $f_k(X)$, то сможем разработать классификатор, который аппроксимирует байесовский классификатор. Этому способу посвящены следующие разделы.

4.4.2 Линейный дискриминантный анализ для $p = 1$

Представим пока, что $p = 1$, т.е. у нас есть только один предиктор. Мы хотели бы получить оценку $f_k(x)$, которую можно подставить в (4.10) для нахождения $p_k(x)$. Далее мы будем относить то или иное наблюдение к классу, для которого вероятность $p_k(x)$ максимальна. Перед тем как оценить функцию $f_k(x)$, мы сделаем некоторые допущения в отношении ее формы.

Пусть $f_k(x)$ представлена *нормальным*, или *гауссовым*, *нормальное, гауссово распределение* распределением. В одномерном случае нормальная функция плотности принимает форму

$$f_k(x) = \frac{1}{\sqrt{2\pi\sigma_k}} \exp\left(-\frac{1}{2\sigma_k^2}(x - \mu_k)^2\right), \quad (4.11)$$

где μ_k и σ_k^2 — это среднее значение и дисперсия для k -го класса. Допустим пока, что $\sigma_1^2 = \dots = \sigma_K^2$, т. е. все классы имеют общую дисперсию, которую мы обозначим как σ^2 . Подставив (4.11) в (4.10), мы выясним, что

$$p_k(x) = \frac{\pi_k \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu_k)^2\right)}{\sum_{l=1}^K \pi_l \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu_l)^2\right)}. \quad (4.12)$$

(Заметьте, что π_k в (4.14) обозначает априорную вероятность принадлежности некоторого наблюдения к классу k — ее не следует путать с математической константой $\pi \approx 3.14159$.) Байесовский классификатор относит то или иное наблюдение $X = x$ к классу, у которого вероятность (4.12) максимальна. Прологарифмировав (4.12) и выполнив некоторые перестановки, нетрудно будет показать, что это аналогично отнесению данного наблюдения к классу, у которого максимальна величина

$$\delta_k(x) = x \cdot \frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log(\pi_k). \quad (4.13)$$

Например, если $K = 2$ и $\pi_1 = \pi_2$, то байесовский классификатор относит наблюдение к классу 1 при $2x(\mu_1 - \mu_2) > \mu_1^2 - \mu_2^2$ и к классу 2 в противном случае. Здесь байесовская решающая граница соответствует точке, где

$$x = \frac{\mu_1^2 - \mu_2^2}{2(\mu_1^2 - \mu_2^2)} = \frac{\mu_1 - \mu_2}{2}. \quad (4.14)$$

Слева на рис. 4.4 приведен пример. Показаны две нормальные функции плотности — $f_1(x)$ и $f_2(x)$, соответствующие двум отдельным классам. Средние значения и дисперсии этих двух функций составляют $\mu_1 = -1.25$, $\mu_2 = 1.25$ и $\sigma_1^2 = \sigma_2^2 = 1$. Функции перекрываются, и поэтому для заданного $X = x$ имеет место некоторая неопределенность относительно класса, к которому принадлежит это наблюдение. Если предположить, что некоторое наблюдение может с одинаковой вероятностью принадлежать к любому классу, т. е. $\pi_1 = \pi_2 = 0.5$, то из (4.14) мы увидим, что байесовский классификатор относит наблюдение к классу 1 при $x < 0$ и к классу 2 в противном случае. Заметьте, что в этом примере мы имеем возможность вычислить байесовский классификатор благодаря нашей осведомленности о гауссовом распределении X в пределах каждого класса, а также о всех соответствующих параметрах распределения. В реальной ситуации вычислить байесовский классификатор мы не можем.

На практике, даже если мы вполне уверены в нашем предположении о гауссовом распределении X в пределах каждого класса, нам все еще необходимо оценить параметры $\mu_1, \dots, \mu_K$, $\pi_1, \dots, \pi_K$ и σ^2 . Метод *линейного дискриминантного анализа* (LDA)³ аппроксимирует байесовский класси-

³ Аббревиатура от «linear disriminant analysis». — Прим. пер.




РИСУНОК 4.4. Слева: показаны две одномерные нормальные функции плотности вероятностей. Вертикальная прерывистая линия соответствует байесовской решающей границе. Справа: гистограмма 20 наблюдений, случайным образом извлеченных из каждого класса. Байесовская решающая граница снова показана в виде вертикальной прерывистой линии. Сплошная вертикальная линии соответствует решающей границе LDA, оцененной по обучающим данным

фикатор, подставляя оценки π_k , μ_k и σ^2 в (4.13). В частности, используются следующие оценки:

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i:y_i=k} x_i$$

$$\hat{\sigma}^2 = \frac{1}{n-K} \sum_{k=1}^K \sum_{i:y_i=k} (x_i - \hat{\mu}_k)^2, \quad (4.15)$$

где n — это общее число обучающих наблюдений, а n_k — число обучающих наблюдений в k -м классе. Оценка μ_k представляет собой просто среднее значение по всем обучающим наблюдениям из класса k , тогда как $\hat{\sigma}^2$ можно рассматривать как взвешенное среднее из выборочных дисперсий каждого из K классов. Иногда нам известны вероятности принадлежности к каждому классу $\pi_1, \dots, \pi_K$, которые можно сразу использовать в вычислениях. В отсутствие какой-либо дополнительной информации LDA оценивает π_k по доле обучающих наблюдений, принадлежащих к классу k . Другими словами,

$$\hat{\pi}_k = n_k/n. \quad (4.16)$$

LDA-классификатор подставляет оценки из (4.15) и (4.16) в (4.13) и относит наблюдение $X = x$ к классу, у которого величина

$$\hat{\delta}_k(x) = x \cdot \frac{\hat{\mu}_k}{\hat{\sigma}^2} - \frac{\hat{\mu}_k^2}{2\hat{\sigma}^2} + \log(\hat{\pi}_k) \quad (4.17)$$

максимальна. Прилагательное «линейный» в названии классификатора обусловлено тем фактом, что дискриминантная функция $\hat{\delta}_k(x)$ в (4.17)

дискри-
ми-
нантная
функция

является линейной функцией от x (в противоположность какой-либо более сложной функции от x).

На рис. 4.4 справа показана гистограмма для 20 наблюдений, случайно отобранных из каждого класса. Для выполнения LDA мы сначала нашли оценки π_k , μ_k и σ^2 , используя (4.15) и (4.16). Далее мы вычислили решающую границу (показана в виде черной сплошной линии) путем отнесения каждого наблюдения к классу с наибольшей величиной (4.17). Все точки слева от этой линии будут отнесены к «зеленому классу», а точки справа от этой линии — к «фиолетовому классу». Поскольку в данном случае $n_1 = n_2 = 20$, мы имеем $\hat{\pi}_1 = \hat{\pi}_2$. Как следствие решающая граница соответствует середине между выборочными средними двух классов: $(\hat{\mu}_1 + \hat{\mu}_2)/2$. На рисунке видно, что решающая граница LDA проходит несколько левее оптимальной байесовской решающей границы, равной $(\mu_1 + \mu_2)/2 = 0$. Каково качество этого LDA-классификатора в отношении рассматриваемых данных? Поскольку это имитированные данные, мы можем сгенерировать большой набор контрольных наблюдений для расчета байесовской частоты ошибок и частоты ошибок LDA на контрольной выборке. Эти ошибки составляют 10.6% и 11.1% соответственно. Другими словами, частота ошибок LDA-классификатора только на 0.5% выше минимально возможной ошибки! Таким образом, LDA очень хорошо работает на этом наборе данных.

Повторим еще раз: LDA-классификатор получают, делая допущение о том, что наблюдения в каждом классе имеют нормальное распределение со специфичным для конкретного класса вектором математического ожидания и общей дисперсией σ^2 , и подставляя оценки этих параметров в байесовский классификатор. В подразделе 4.4.4 мы рассмотрим набор менее строгих допущений, которые позволяют наблюдениям из класса k иметь свою собственную дисперсию σ_k^2 .

4.4.3 Линейный дискриминантный анализ для $p > 1$

Теперь мы расширим LDA-классификатор на случай с несколькими предикторами. Для этого мы предположим, что вектор $X = (X_1, X_2, \dots, X_p)$ извлечен из *многомерного гауссова*, или многомерного нормального, распределения со специфичным для каждого класса вектором математического ожидания и общей ковариационной матрицей. Начнем с краткого описания такого распределения.

Многомерное гауссово распределение подразумевает, что каждый из предикторов имеет свое одномерное нормальное распределение (как в (4.11)) и в определенной степени коррелирует с другими предикторами. Два примера многомерных гауссовых распределений с $p = 2$ приведены на рис. 4.5. Высота поверхности в любой заданной точке соответствует вероятности того, что X_1 и X_2 находятся в пределах некоторой малой области около этой точки. Если на любом из приведенных графиков рассеять поверхность вдоль оси X_1 или оси X_2 , то полученный поперечный разрез будет иметь форму одномерного нормального распределения. Слева на рис. 4.5 приведен пример, в котором $\text{Var}(X_1) = \text{Var}(X_2)$, а $\text{Cor}(X_1, X_2) = 0$; эта поверхность имеет характерную *колоколообразную форму*. Однако, как показано на том же рисунке справа, эта колоколообразная форма будет искажена, если предикторы коррелируют друг с другом или имеют неодн-

многомер-
ное
гауссово
распреде-
ление




РИСУНОК 4.5. Показаны две многомерные гауссовы функции плотности с $p = 2$. Слева: два предиктора не коррелируют друг с другом. Справа: корреляция между предикторами составляет 0.7

наковые дисперсии. В такой ситуации основа колокола будет иметь форму эллипса, а не круга. Чтобы показать, что p -мерная случайная переменная X имеет многомерное гауссово распределение, мы используем нотацию $X \sim N(\mu, \Sigma)$. Здесь $E(X) = \mu$ — это среднее значение X (вектора с p элементами), а $\text{Cov}(X) = \Sigma$ — ковариационная матрица вектора X размером $p \times p$. Формально плотность вероятности многомерного гауссова распределения выражается следующим образом:

$$f(x) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right). \quad (4.18)$$

При $p > 1$ LDA-классификатор предполагает, что наблюдения в k -м классе имеют многомерное гауссово распределение $N(\mu_k, \Sigma)$, где μ_k — это специфичный для данного класса вектор математического ожидания, а Σ — общая для всех K классов ковариационная матрица. Подстановка функции плотности вероятности для k -го класса $f_k(X = x)$ в (4.10) и выполнение некоторых алгебраических преобразований покажут, что байесовский классификатор относит наблюдение $X = x$ к классу, у которого величина

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k \quad (4.19)$$

максимальна. Это — векторно-матричная форма записи уравнения (4.13).

Слева на рис. 4.6 приведен пример. Изображены три нормально распределенных класса одинакового размера, каждый со своим специфичным вектором математического ожидания и общей ковариационной матрицей. Три эллипса охватывают области, соответствующие 95%-ной вероятности каждого из этих классов. Прерывистые линии представляют собой байесовские решающие границы. Иными словами — это совокупности значений x , для которых $\delta_k(x) = \delta_l(x)$, т. е.

$$x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k = x^T \Sigma^{-1} \mu_l - \frac{1}{2} \mu_l^T \Sigma^{-1} \mu_l \quad (4.20)$$




РИСУНОК 4.6. Показаны две многомерные гауссовы функции плотности с $p = 2$. Слева: два предиктора не коррелируют друг с другом. Справа: корреляция между предикторами составляет 0.7

для $k \neq l$. ($\log \pi_k$ из (4.19) исчез, поскольку все три класса имеют одинаковое число обучающих наблюдений, т. е. π_k одинаковы во всех классах.) Заметьте, что имеют место три линии, соответствующие байесовским решающим границам, поскольку имеются три пары классов. Другими словами, одна байесовская решающая граница отделяет класс 1 от класса 2, одна отделяет класс 1 от класса 3, и еще одна отделяет класс 2 от класса 3. Эти три байесовские решающие границы разделяют пространство предикторов на три области. Байесовский классификатор будет классифицировать то или иное наблюдение в соответствии с областью, в которой оно находится.

Напомним еще раз, что нам необходимо оценить неизвестные параметры $\mu_1, \dots, \mu_k$, $\pi_1, \dots, \pi_K$ и Σ ; формулы для них похожи на соответствующие формулы для одномерного случая, приведенные в (4.15). Для классификации нового наблюдения $X = x$ LDA подставляет эти оценки в (4.19) и относит это наблюдение к классу с наиболее высоким значением $\hat{\delta}_k(x)$. Заметьте, что $\delta_k(x)$ в (4.19) является линейной функцией от x , т. е. решающее правило LDA определяется только линейной комбинацией элементов x . Это также является причиной использования прилагательного «линейный» в названии LDA.

Справа на рис. 4.6 показаны 20 наблюдений, случайным образом извлеченных из каждого из трех классов, а также соответствующие решающие границы LDA (сплошные черные линии). В целом решающие границы LDA довольно близки к байесовским решающим границам, показанным в виде прерывистых линий. Частоты ошибок на контрольной выборке у байесовского и LDA-классификаторов составляют 0.0746 и 0.0770 соответственно. Таким образом, что LDA хорошо работает на этих данных.

Мы можем выполнить линейный дискриминантный анализ для данных Default для предсказания вероятности неуплаты долга по кредитной карте, исходя из размера этого долга, а также информации о том, является ли клиент банка студентом. Модель LDA, подогнанная по 10 000 обуча-

ющих наблюдений, приводит к частоте ошибок на обучающих данных в 2.27%. Это довольно низкая ошибка, однако следует сделать следующие два предостережения:

- Во-первых, частоты ошибок на обучающих данных обычно будут ниже частот ошибок на контрольных данных, которые в действительности интересуют нас больше всего. Другими словами, мы можем ожидать, что этот классификатор сработает хуже, когда мы применим его для выполнения предсказаний для новой группы клиентов. Это объясняется тем, что мы намеренно подгоняем параметры нашей модели таким образом, чтобы она хорошо работала на обучающих данных. Чем выше отношение числа параметров p к объему наблюдений n , тем важнее будет роль подобного *переобучения*. Для рассматриваемых данных это вряд ли будет проблемой, поскольку $p = 2$, а $n = 10\,000$. переобучение
- Во-вторых, поскольку 3.33% всех клиентов в обучающей выборке не уплатили свой долг, то простой, но при этом бесполезный классификатор, который всегда предсказывает, что каждый клиент выплатит свой долг вне зависимости от размера долга и социального статуса клиента (студент или нет), даст частоту ошибки в 3.33%. Иными словами, тривиальный *нулевой* классификатор обеспечит частоту ошибок, которая лишь незначительно выше частоты ошибок LDA. нулевой классификатор

На практике подобный бинарный классификатор может делать два типа ошибок: он может неверно отнести того или иного неплательщика к категории *плательщиков* или неверно отнести плательщика к категории *неплательщиков*. Часто интерес представляет выяснение того, к какому именно из этих двух типов относятся сделанные ошибки. *Матрица неточностей*⁴, приведенная для данных Default в табл. 4.4, является удобным способом представления такой информации. Как видно из этой табл., LDA-классификатор предсказал, что всего неплательщиками станут 104 человека. Среди них 81 клиент действительно стал неплательщиком, а 23 клиента — нет. Следовательно, неверно были классифицированы только 23 из 9667 человек, которые уплатили свой долг. Это выглядит как довольно низкая частота ошибок! Однако 252 из 333 (75.7%) неплательщиков были пропущены LDA-классификатором. Таким образом, несмотря на то что общая частота ошибок незначительна, частота ошибок среди неплательщиков является очень высокой. С точки зрения компании-эмитента кредитных карт, которая пытается определить рискованных клиентов, частота ошибки в $252/333 = 75.7\%$ среди неплательщиков может быть весьма неприемлемой.

матрица
неточностей

Качество модели в отношении конкретного класса является важным также в медицине и биологии, где употребляются термины *чувствительность* и *специфичность*. В рассматриваемом случае чувствительность — это доля истинных неплательщиков, обнаруженных классификатором (здесь она довольно низка — 24.3%). Специфичность — это доля правильно идентифицированных клиентов, уплативших свой долг (здесь она составляет $(1 - 23/9667) = 99.8\%$).

чувствительность
и специфичность

⁴ В оригинале используется термин «confusion matrix». — Прим. пер.

ТАБЛИЦА 4.4. Матрица неточностей сравнивает предсказания LDA-классификатора с истинным статусом дефолта для 10 000 обучающих наблюдений из набора данных Default. Числа, расположенные на диагонали этой матрицы, соответствуют клиентам с правильно предсказанным статусом дефолта, а числа вне этой диагонали соответствуют неправильно классифицированным клиентам. LDA сделал неверные предсказания для 23 клиентов, уплативших свой долг, а также для 252 клиентов-неплательщиков.

		Истинный статус дефолта		
		Нет	Да	Всего
Предсказанный статус дефолта	Нет	9644	252	9896
	Да	23	81	104
	Всего	9667	333	10 000

Почему LDA так плохо распознал неплательщиков? Иными словами, почему у него такая низкая чувствительность? Как мы уже видели, LDA пытается аппроксимировать байесовский классификатор, который имеет самую низкую *общую* частоту ошибок из всех возможных классификаторов (при условии, что гауссова модель верна). Другими словами, байесовский классификатор даст наименьшее возможное количество неправильно классифицированных наблюдений, вне зависимости от того, в каком классе допущены ошибки. Это значит, что некоторые неверно классифицированные наблюдения будут результатом ошибочного отнесения плательщика к неплательщикам, а другие такие наблюдения — результатом ошибочного отнесения неплательщика к категории плательщиков. Однако кредитная компания может быть особенно заинтересована в том, чтобы избегать ошибочной классификации неплательщиков, тогда как неверная классификация плательщиков, хотя и нежелательна, все же является менее проблематичной. Как мы сейчас увидим, LDA можно модифицировать таким образом, чтобы он лучше соответствовал нуждам кредитной компании.

Байесовский классификатор относит то или иное наблюдение к классу с наибольшей апостериорной вероятностью $p_k(X)$. В случае с двумя классами это равносильно отнесению клиента к группе неплательщиков, если

$$\Pr(\text{default} = \text{Yes} | X = x) > 0.5. \quad (4.21)$$

Таким образом, для отнесения того или иного клиента к классу *неплательщиков* байесовский классификатор и его расширенная версия — LDA — используют пороговое значение апостериорной вероятности дефолта, равное 50%. Однако если мы озабочены неверным предсказанием статуса дефолта для клиентов, которые действительно становятся неплательщиками, тогда мы должны понизить этот порог. Например, мы можем отнести к классу *неплательщиков* любого клиента, у которого апостериорная вероятность дефолта превышает 20%. Другими словами, вместо отнесения некоторого наблюдения к классу *неплательщиков* в случае выполнения условия (4.21) мы могли бы отнести его к этому классу в случае, если

$$\Pr(\text{default} = \text{Yes} | X = x) > 0.2. \quad (4.22)$$

Частоты ошибок, получаемые при использовании этого подхода, показаны в табл. 4.5. Теперь LDA-классификатор предсказывает, что неплательщиками станут 430 клиентов. Среди 333 клиентов, которые действительно стали неплательщиками, LDA делает неверное предсказание для 138 человек (41.4%). Это существенное улучшение, по сравнению с частотой ошибок 75.7%, которая имела место при использовании порогового значения в 50%. Однако это улучшение имеет свою цену: теперь 235 плательщиков классифицированы неверно. Как следствие общая частота ошибок несколько возросла — до 3.73%. Однако кредитная компания может рассматривать этот незначительный рост общей частоты ошибок как небольшую цену за более точное выявление неплательщиков.

ТАБЛИЦА 4.5. Матрица неточностей сравнивает предсказания LDA-классификатора с истинным статусом дефолта для 10 000 обучающих наблюдений из набора данных Default на основе модифицированного порогового значения, согласно которому к неплательщикам относятся все клиенты с предсказанной вероятностью дефолта $> 20\%$.

		Истинный статус дефолта		
		Нет	Да	Всего
Предсказанный статус дефолта	Нет	9432	138	9570
	Да	235	195	430
	Всего	9667	333	10 000

Рисунок 4.7 иллюстрирует компромисс, возникающий в результате изменения порогового значения апостериорной вероятности дефолта. Показаны разные уровни частоты ошибок в зависимости от этого порогового значения. Применение порогового значения, равного 0.5 (как в 4.21), минимизирует общую частоту ошибок (черная сплошная линия). Это ожидаемо, т. к. байесовский классификатор использует пороговое значение 0.5 и, как известно, обладает наименьшей общей частотой ошибок. Однако при использовании этого порога (0.5) частота ошибок среди неплательщиков довольно высока (голубая прерывистая линия). По мере уменьшения порогового значения частота ошибок среди неплательщиков постепенно снижается, но частота ошибок среди плательщиков возрастает. Как же нам выбрать оптимальное пороговое значение? Подобное решение должно основываться на знании предметной области — например, на основе детальной информации о финансовых потерях, связанных с невозможностью возврата долгов.

Популярным графическим способом одновременного описания двух типов ошибок для всех возможных пороговых значений вероятности является ROC-кривая. «ROC» — это исторический термин, возникший в теории связи. Данная аббревиатура обозначает «receiver operating characteristic»⁵. На рис. 4.8 показана ROC-кривая для LDA-классификатора на обучающей выборке. Общее качество классификатора, суммированное по всем возможным пороговым значениям вероятности,

ROC-
кривая

⁵ «Радиочастотная характеристика приемника». — Прим. пер.




РИСУНОК 4.7. На примере набора данных Default показана зависимость частоты ошибок от порогового значения апостериорной вероятности, используемой для классификации. Черная сплошная линия соответствует общей частоте ошибок. Голубая прерывистая показывает долю неверно классифицированных неплательщиков, а оранжевая прерывистая линия — долю неверно классифицированных плательщиков

площадь под ROC-кривой

выражают в виде *площади под ROC-кривой* — AUC⁶. Идеальная ROC-кривая будет касаться левого верхнего угла графика, и поэтому чем выше AUC, тем выше качество классификатора. Мы ожидаем, что у классификатора, чье качество не отличается от простого случайного угадывания, AUC составит 0.5 (при проверке на независимом контрольном наборе данных, которые не были использованы в обучении модели). ROC-кривые полезны для сравнения разных классификаторов, поскольку они принимают во внимание все возможные пороговые значения вероятности. Оказывается, что ROC-кривая логистической регрессионной модели из подраздела 4.3.4, подогнанной к этим же данным, практически неотличима от кривой LDA-модели, и поэтому мы ее здесь не приводим.

чувствительность
специфичность

Как мы видели выше, изменение порогового значения вероятности у классификатора изменяет частоту истинно положительных и истинно отрицательных случаев. Эти частоты известны также как *чувствительность* и $(1 - \text{специфичность})$ нашего классификатора. Поскольку разнообразие терминов, используемых в этом контексте, часто приводит к замешательству, мы приведем здесь их небольшой обзор. В табл. 4.6 показаны возможные результаты применения классификатора (или диагностического теста) к некоторой совокупности объектов. Чтобы провести параллель с эпидемиологической литературой, можно думать о «+» как о наличии «болезни», которую мы пытаемся обнаружить, а о «-» — как об отсутствии этой «болезни». Для сравнения с классической литературой по проверке статистических гипотез можно думать о «-» как о нулевой гипотезе, а о «+» — как об альтернативной гипотезе. Для набора данных Default «+» обозначает клиента-неплательщика, а «-» — клиента, который таковым не является.

⁶ Широко используемое сокращение «AUC» происходит от «area under the curve» («площадь под кривой»). — Прим. пер.




РИСУНОК 4.8. ROC-кривая LDA-классификатора для данных Default. Она изображает изменение двух типов ошибок по мере изменения порогового значения апостериорной вероятности дефолта. Сами эти значения не показаны. Частота истинно положительных случаев — это чувствительность, т. е. доля правильно классифицированных неплательщиков при заданном пороговом значении. Частота ложноположительных случаев — это (1 – специфичность), т. е. доля неверно классифицированных плательщиков при том же пороговом значении. Идеальная ROC-кривая касается верхнего левого угла, указывая на высокую частоту истинно положительных случаев и низкую частоту ложноположительных случаев. Прерывистая линия соответствует классификатору, «не несущему никакой информации», — это то, что мы ожидали бы в случае, когда социальный статус клиента и величина долга по кредитной карте не были связаны с вероятностью дефолта

ТАБЛИЦА 4.6. Возможные результаты применения классификатора или диагностического теста к некоторой совокупности объектов⁷

		Предсказанный класс		
		$-(H_0)$	$+(H_a)$	Всего
Истинный класс	$-(H_0)$	TN	FP	N
	$+(H_a)$	FN	TP	P
	Всего	N*	P*	

⁷Условные обозначения, использованные в этой таблице: H_0 и H_a — нулевая и альтернативная гипотезы соответственно; TN — истинно отрицательные случаи; FP — ложноположительные случаи; FN — ложноотрицательные случаи; TP — истинно положительные случаи; N и P — общее число наблюдаемых отрицательных и положительных случаев соответственно; N* и P* — общее число предсказанных отрицательных и положительных случаев соответственно. — Прим. пер.

В табл. 4.7 перечислены многие из популярных показателей качества, применяемых в этом контексте. Знаменатели частот ложноположительных и истинно положительных случаев — это общие количества случаев, действительно наблюдаемых в соответствующих классах. В то же время знаменатель в предсказательной ценности положительного и предсказательной ценности отрицательного тестов — это общее число наблюдений, предсказанных для соответствующего класса.

ТАБЛИЦА 4.7. *Важные параметры классификаторов и диагностических тестов, полученные из величин, представленных в табл. 4.6*

Название	Определение	Синонимы
Частота ложноположительных случаев	FP/N	Ошибка I типа; 1 – специфичность
Частота истинно положительных случаев	TP/P	1 – ошибка II типа; мощность; чувствительность; полнота
Предсказательная ценность положительного теста	TP/P*	Точность; 1 – доля ложных срабатываний
Предсказательная ценность отрицательного теста	TN/N*	

4.4.4 Квадратичный дискриминантный анализ

Как обсуждалось ранее, LDA предполагает, что наблюдения в каждом классе происходят из многомерного гауссова распределения со специфичными для каждого класса векторами математических ожиданий и общей для всех K классов ковариационной матрицей. Квадратичный дискриминантный анализ (QDA⁸) обеспечивает альтернативный подход. Подобно LDA, QDA-классификатор получают, делая предположение о том, что наблюдения в каждом классе имеют гауссово распределение, и подставляя оценки соответствующих параметров в уравнение теоремы Байеса для вычисления предсказаний. Однако, в отличие от LDA, QDA предполагает, что каждый класс имеет свою собственную ковариационную матрицу. Другими словами, этот метод предполагает, что наблюдение из k -го класса имеет форму $X \sim N(\mu_k, \Sigma_k)$, где Σ_k — это ковариационная матрица k -го класса. Исходя из этого предположения, байесовский классификатор относит наблюдение $X = x$ к классу, для которого величина

$$\begin{aligned} \delta_k(x) &= -\frac{1}{2}(x - \mu_k)^T \Sigma_k^{-1}(x - \mu_k) - \frac{1}{2} \log |\Sigma_k| + \log \pi_k = \\ &= -\frac{1}{2} x^T \Sigma_k^{-1} x + x^T \Sigma_k^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma_k^{-1} \mu_k - \frac{1}{2} \log |\Sigma_k| + \log \pi_k \end{aligned} \quad (4.23)$$

максимальна. Таким образом, QDA-классификатор подразумевает подстановку оценок Σ_k , μ_k и π_k в (4.23) и последующее отнесение наблюдения $X = x$ к классу, для которого полученная величина является наибольшей. В отличие от (4.19), в (4.23) член x представлен в виде *квадратичной функции*. Отсюда и происходит название QDA.

⁸ Аббревиатура от «quadratic discriminant analysis». — Прим. пер.




РИСУНОК 4.9. Слева: решающие границы байесовского классификатора (фиолетовая прерывистая линия), LDA (черная прерывистая линия) и QDA (зеленая прерывистая линия) для проблемы с двумя классами, где $\Sigma_1 = \Sigma_2$. Заштрихованные области соответствуют правилу принятия решений QDA. Поскольку байесовская решающая граница линейна, она лучше аппроксимируется при помощи LDA, нежели QDA. Справа: ситуация та же, что и на графике слева, но $\Sigma_1 \neq \Sigma_2$. Поскольку байесовская решающая граница нелинейна, она лучше аппроксимируется при помощи QDA, нежели LDA

Почему так важно предположение о том, что K классов имеют (или нет) общую ковариационную матрицу? Иными словами, почему предпочтительным мог бы быть метод QDA, а не LDA (и наоборот)? Ответ скрывается в компромиссе между смещением и дисперсией. При наличии p предикторов нахождение ковариационной матрицы требует оценивания $p(p+1)/2$ параметров. QDA оценивает отдельную ковариационную матрицу для каждого класса, что в целом дает $Kp(p+1)/2$ параметров. При наличии 50 предикторов результат будет кратным 1275, а это очень много параметров. Если же мы предположим, что K классов имеют общую ковариационную матрицу, то модель LDA становится линейной по x , а это означает, что нахождению подлежат Kp линейных коэффициентов. Следовательно, LDA является намного менее гибким классификатором, чем QDA, и поэтому обладает намного меньшей дисперсией. Потенциально это может привести к более высокому качеству предсказаний. Однако имеет место компромисс: если допущение LDA о том, что K классов обладают общей ковариационной матрицей, далеко от действительности, то LDA может демонстрировать очень высокое смещение. В целом LDA обычно будет более подходящим методом, чем QDA, если в наличии имеется относительно небольшое число наблюдений и, как следствие, критичным является снижение дисперсии. В то же время QDA рекомендуется применять, когда обучающая выборка велика и дисперсия классификатора не вызывает большого беспокойства, или когда допущение об общей ковариационной матрице у K классов явно несостоятельно.

Рисунок 4.9 иллюстрирует качество LDA- и QDA-классификаторов в двух сценариях. На диаграмме, приведенной слева, корреляция между X_1

и X_2 у двух нормально распределенных классов составляет 0.7. Как следствие байесовская решающая граница является линейной и точно аппроксимируется решающей границей LDA. Решающая граница QDA обладает более низким качеством, поскольку она страдает от высокой дисперсии, которая не компенсируется соответствующим снижением уровня смещения. В то же время справа на рис. 4.9 показан сценарий, в котором корреляция между переменными в «оранжевом» классе составляет 0.7, а в «голубом» классе -0.7 . Теперь байесовская решающая граница является квадратичной, и поэтому QDA аппроксимирует эту границу более точно, чем LDA.

4.5 Сравнение методов классификации

В этой главе мы рассмотрели три разных метода классификации: логистическую регрессию, LDA и QDA. В главе 2 мы также обсудили метод K ближайших соседей (KNN). Теперь мы рассмотрим ситуации, в которых один из этих методов мог бы сработать лучше других.

Несмотря на их разные предпосылки, логистическая регрессия и метод LDA тесно связаны. Пусть у нас есть два класса и $p = 1$ предиктор, и пусть $p_1(x)$ и $p_2(x) = 1 - p_1(x)$ обозначают вероятности того, что наблюдение $X = x$ принадлежит к классу 1 и классу 2 соответственно. Применив немного алгебры к (4.12) и (4.13), мы можем увидеть, что в рамках линейного дискриминантного анализа логарифм риска принимает следующий вид:

$$\log \left(\frac{p_1(x)}{1 - p_1(x)} \right) = \log \left(\frac{p_1(x)}{p_2(x)} \right) = c_0 + c_1 x, \quad (4.24)$$

где c_0 и c_1 являются функциями от μ_1 , μ_2 и σ^2 . Из (4.4) мы знаем, что в логистической регрессии

$$\log \left(\frac{p_1(x)}{1 - p_1(x)} \right) = \beta_0 + \beta_1 x. \quad (4.25)$$

Оба выражения — (4.24) и (4.25) — являются линейными функциями от x . Следовательно, как логистическая регрессия, так и LDA порождают линейные решающие границы. Единственное различие между этими двумя методами заключается в том, что β_0 и β_1 оцениваются при помощи метода максимального правдоподобия, а c_0 и c_1 вычисляются на основе оценок среднего значения и дисперсии нормального распределения. Аналогичная связь между LDA и логистической регрессией имеет место и в случае многомерных данных с $p > 1$.

Поскольку модели логистической регрессии и LDA различаются только способом подгонки, можно было бы ожидать, что эти два метода будут давать похожие результаты. Часто, но всегда, это действительно так. LDA подразумевает, что наблюдения происходят из гауссова распределения с общей для всех классов ковариационной матрицей, и поэтому может дать более качественные решения, по сравнению с логистической регрессией, когда это предположение примерно соответствует действительности. Однако логистическая регрессия может превзойти LDA, когда эти допущения в отношении гауссова распределения не выполняются.

Вспомните из главы 2, что KNN использует совершенно иной подход, по сравнению с классификаторами, рассмотренными в этой главе. Чтобы получить предсказание для некоторого наблюдения $X = x$ находят K ближайших к x обучающих наблюдений. После этого X относят к классу, к которому принадлежит большинство этих наблюдений. Следовательно, KNN является полностью непараметрическим методом: он не делает никаких предположений в отношении формы решающей границы. Поэтому мы можем ожидать, что этот метод будет превосходить LDA и логистическую регрессию в случаях, когда решающая граница в значительной мере нелинейна. С другой стороны, KNN не говорит нам, какие из предикторов являются важными, — мы не получаем таблицу с коэффициентами, подобную табл. 4.3.

Наконец, QDA служит своего рода компромиссом между непараметрическим методом KNN и линейными методами логистической регрессии и LDA. Поскольку QDA предполагает наличие квадратичной решающей границы, то в сравнении с линейными методами он способен точно моделировать более широкий круг проблем. Обладая меньшей гибкостью в сравнении с KNN, QDA все же может давать более точные предсказания при небольшом числе обучающих наблюдений, поскольку он делает определенные предположения в отношении формы решающей границы.

Для сравнения качества предсказаний этих четырех методов классификации мы искусственно создали данные для шести различных сценариев. В трех из этих сценариев байесовская решающая граница является линейной, а в остальных сценариях — нелинейной. Для каждого сценария мы создали 100 случайных обучающих выборок. Мы подогнали к этим обучающим данным модели каждого типа и рассчитали итоговые частоты ошибок на контрольной выборке большого объема. Результаты для линейных сценариев показаны на рис. 4.10, а результаты для нелинейных сценариев — на рис. 4.11. Метод KNN требует выбора значения K — числа ближайших соседей. Мы выполнили подгонку KNN-моделей для $K = 1$, а также для значения, выбранного автоматически с использованием т. н. метода *перекрестной проверки*, который мы будем обсуждать в главе 5.

В каждом из шести сценариев было $p = 2$ предиктора. Эти сценарии заключались в следующем:

Сценарий 1: В каждом из двух классов было по 20 обучающих наблюдений. В каждом классе наблюдения были представлены независимыми друг от друга случайными нормально распределенными переменными с разными средними значениями. Слева на рис. 4.10 видно, что LDA в этой ситуации сработал ожидаемо хорошо, поскольку это как раз та модель, которую предполагает данный метод. KNN сработал плохо из-за высокой дисперсии, которая не была компенсирована снижением уровня смещения. QDA также сработал хуже LDA, т. к. он породил более гибкий классификатор, чем требовалось. Поскольку логистическая регрессия предполагает линейную решающую границу, ее результаты лишь незначительно уступили результатам LDA.

Сценарий 2: Детали те же, что и в сценарии 1, однако предикторы в каждом классе коррелировали на уровне -0.5 . Центральная диаграмма на рис. 4.10 указывает на незначительные изменения отно-




РИСУНОК 4.10. Диаграммы размахов для частот ошибок на контрольных данных в каждом из линейных сценариев, описанных в тексте. Обозначения: *KNN-1* — *KNN* с $K = 1$; *KNN-CV* — *KNN* с автоматическим выбором K ; *LDA* — линейный дискриминантный анализ; *Logistic* — логистическая регрессия; *QDA* — квадратичный дискриминантный анализ

сительного качества предсказаний исследованных методов, по сравнению с предыдущим сценарием.

t-распределение

Сценарий 3: Мы создали X_1 и X_2 на основе *t*-распределения, с 50 наблюдениями в каждом классе. *t*-распределение по форме похоже на нормальное распределение, однако обычно оно генерирует более экстремальные наблюдения, т. е. большее количество точек, находящихся далеко от среднего значения. В этой ситуации решающая граница все еще была линейной и поэтому соответствовала ожиданиям логистической регрессии. Однако этот сценарий нарушил допущения метода *LDA*, поскольку наблюдения не были извлечены из нормального распределения. Диаграмма, приведенная на рис. 4.10 справа, показывает, что логистическая регрессия превзошла *LDA*, хотя в целом эти два метода сработали лучше других методов. В частности, результаты *QDA* значительно ухудшились из-за ненормального распределения наблюдений.

Сценарий 4: Данные были созданы на основе нормального распределения, причем корреляция между предикторами составила 0.5 в первом классе и -0.5 во втором классе. Эта ситуация соответствовала допущениям *QDA* и привела к квадратичной решающей границе. Диаграмма, представленная на рис. 4.11 слева, показывает, что *QDA* превзошел все другие методы.

Сценарий 5: В каждом классе наблюдения были сгенерированы на основе нормального распределения с независимыми предикторами. Однако значения отклика были созданы на основе логистической функции с использованием X_1^2 , X_2^2 и $X_1 \times X_2$ в качестве предикторов. Следовательно, имеет место квадратичная решающая граница. В центре на рис. 4.11 приведена диаграмма, из которой следует, что лучше всего снова сработал *QDA*, а на втором месте после него




РИСУНОК 4.11. Диаграммы размахов для частот ошибок на контрольных данных в каждом из нелинейных сценариев, описанных в тексте. Обозначения те же, что и на рис. 4.10

оказалась модель KNN с автоматически выбранным значением K . Качество предсказаний у линейных методов оказалось очень низким.

Сценарий 6: Основные условия те же, что в предыдущем сценарии, однако значения отклика были сгенерированы на основе более сложной нелинейной функции. В результате даже квадратичные решающие границы QDA не смогли адекватно смоделировать эти данные. Как следует из диаграммы, представленной на рис. 4.11 справа, QDA сработал немного лучше линейных методов, тогда существенно более гибкий метод KNN с автоматическим выбором значения K показал наиболее высокие результаты. В то же время KNN с $K = 1$ показал наиболее низкие результаты из всех методов. Это подчеркивает тот факт, что даже когда данные проявляют сложную нелинейную зависимость, непараметрический метод вроде KNN все же может показать очень плохие результаты, если уровень сглаживания подобран неправильно.

Эти шесть примеров показывают, что не существует метода, который будет превосходить другие методы в любой ситуации. Когда истинные решающие границы являются линейными, LDA и логистическая регрессия в целом будут работать хорошо. Когда эти границы умеренно нелинейны, QDA может дать более качественные решения. Наконец, для существенно более сложных границ наилучшим может оказаться такой непараметрический метод, как KNN. Однако следует очень тщательно выбирать уровень сглаживания для непараметрического метода. В следующей главе мы рассмотрим несколько подходов для выбора корректного уровня сглаживания, а также для выбора оптимального метода в целом.

В заключение вспомним из главы 3, что в ходе выполнения регрессионного анализа мы можем подогнать нелинейную зависимость между предикторами и откликом, используя преобразованные предикторы. Похожий подход можно было бы применить и для классификации. Например, мы могли бы создать более гибкую версию логистической регрессии, включив

в нее в качестве предикторов X^2 , X^3 и даже X^4 . Если увеличение дисперсии за счет добавленной гибкости компенсируется достаточно большим снижением уровня смещения, это может улучшить качество предсказаний логистической регрессии. Мы могли бы сделать то же самое и для LDA. Если бы мы добавили все возможные квадратичные члены и взаимодействия предикторов в LDA, то модель приобрела бы форму QDA-модели, хотя оценки параметров оказались бы другими. Такой подход позволяет нам построить нечто среднее между LDA- и QDA-моделями.

4.6 Лабораторная работа: логистическая регрессия, LDA, QDA и KNN

4.6.1 Данные по цене акций

Мы начнем с рассмотрения некоторых количественных и графических сводок по данным Smarket, которые входят в состав библиотеки ISLR. Этот набор данных включает процентные изменения доходности биржевого индекса S&P 500 для 1250 дней — с начала 2001 г. до конца 2005 г. Для каждой даты у нас есть значения процентного изменения доходности для каждого из пяти предыдущих дней — с Lag1 по Lag5. У нас есть также переменные Volume (количество акций (в миллиардах), проданных в предыдущий день), Today (процентное изменение доходности за конкретный день) и Direction (направление движения рынка — вверх (Up) или вниз (Down) — в этот день).

```
> library(ISLR)
> names(Smarket )
[1] "Year"      "Lag1"      "Lag2"      "Lag3"      "Lag4"
[6] "Lag5"      "Volume"    "Today"     "Direction"
```

```
> dim(Smarket )
[1] 1250 9
```

```
> summary(Smarket)
```

Year		Lag1		Lag2	
Min.	:2001	Min.	:-4.92200	Min.	:-4.92200
1st Qu.	:2002	1st Qu.	:-0.63950	1st Qu.	:-0.63950
Median	:2003	Median	: 0.03900	Median	: 0.03900
Mean	:2003	Mean	: 0.00383	Mean	: 0.00392
3rd Qu.	:2004	3rd Qu.	: 0.59675	3rd Qu.	: 0.59675
Max.	:2005	Max.	: 5.73300	Max.	: 5.73300

Lag3		Lag4		Lag5	
Min.	:-4.92200	Min.	:-4.92200	Min.	:-4.92200
1st Qu.	:-0.64000	1st Qu.	:-0.64000	1st Qu.	:-0.64000
Median	: 0.03850	Median	: 0.03850	Median	: 0.03850
Mean	: 0.00172	Mean	: 0.00164	Mean	: 0.00561
3rd Qu.	: 0.59675	3rd Qu.	: 0.59675	3rd Qu.	: 0.59700
Max.	: 5.73300	Max.	: 5.73300	Max.	: 5.73300

Volume	Today	Direction
Min. :0.356	Min. : -4.92200	Down :602
1st Qu. :1.257	1st Qu. : -0.63950	Up :648
Median :1.423	Median : 0.03850	
Mean :1.478	Mean : 0.00314	
3rd Qu. :1.642	3rd Qu. : 0.59675	
Max. :3.152	Max. : 5.73300	

```
> pairs(Smarket )
```

Функция `cor()` создает матрицу со значениями всех парных корреляций между предикторами из некоторого набора данных. Первая из приведенных ниже команд выдает сообщение об ошибке, поскольку переменная `Direction` является качественной.

```
> cor(Smarket)
Error in cor(Smarket ): 'x' must be numeric
> cor(Smarket[, -9])
```

	Year	Lag1	Lag2	Lag3	Lag4	Lag5
Year	1.0000	0.02970	0.03060	0.03319	0.03569	0.02979
Lag1	0.0297	1.00000	-0.02629	-0.01080	-0.00299	-0.00567
Lag2	0.0306	-0.02629	1.00000	-0.02590	-0.01085	-0.00356
Lag3	0.0332	-0.01080	-0.02590	1.00000	-0.02405	-0.01881
Lag4	0.0357	-0.00299	-0.01085	-0.02405	1.00000	-0.02708
Lag5	0.0298	-0.00567	-0.00356	-0.01881	-0.02708	1.00000
Volume	0.5390	0.04091	-0.04338	-0.04182	-0.04841	-0.02200
Today	0.0301	-0.02616	-0.01025	-0.00245	-0.00690	-0.03486

	Volume	Today
Year	0.5390	0.03010
Lag1	0.0409	-0.02616
Lag2	-0.0434	-0.01025
Lag3	-0.0418	-0.00245
Lag4	-0.0484	-0.00690
Lag5	-0.0220	-0.03486
Volume	1.0000	0.01459
Today	0.0146	1.00000

Коэффициенты корреляции между лаг-переменными и доходностью за «сегодня» вполне ожидаемо близки к нулю. Другими словами, похоже, что доходность «сегодня» очень слабо связана с доходностью в предыдущие дни. Единственная сильная корреляция имеется между `Year` и `Volume`. Изобразив данные графически, мы увидим, что `Volume` увеличивается во времени. Иными словами, в период с 2001 по 2005 г. среднее количество продаваемых ежедневно акций возросло.

```
> attach(Smarket)
> plot(Volume)
```

4.6.2 Логистическая регрессия

Далее мы построим логистическую модель с целью предсказания `Direction` на основе `Lag1` – `Lag5` и `Volume`. Функция `glm()` подгоняет `glm()`

обобщен-
ные
линейные
модели

обобщенные линейные модели — класс моделей, который включает и логистическую регрессию. Синтаксис функции `glm()` похож на синтаксис `lm()`, за тем исключением, что мы должны подать аргумент `family = binomial`, который скажет R построить логистическую, а не какую-либо другую обобщенную линейную модель.

```
> glm.fit = glm(Direction ~ Lag1 + Lag2 + Lag3 + Lag4 + Lag5 +
                Volume, data = Smarket, family = binomial)
```

```
> summary(glm.fit)
```

Call:

```
glm(formula = Direction ~ Lag1 + Lag2 + Lag3 + Lag4 + Lag5 +
     Volume, family = binomial, data = Smarket)
```

Deviance Residuals :

Min	1Q	Median	3Q	Max
-1.45	-1.20	1.07	1.15	1.33

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.12600	0.24074	-0.52	0.60
Lag1	-0.07307	0.05017	-1.46	0.15
Lag2	-0.04230	0.05009	-0.84	0.40
Lag3	0.01109	0.04994	0.22	0.82
Lag4	0.00936	0.04997	0.19	0.85
Lag5	0.01031	0.04951	0.21	0.83
Volume	0.13544	0.15836	0.86	0.39

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 1731.2 on 1249 degrees of freedom

Residual deviance: 1727.6 on 1243 degrees of freedom

AIC: 1742

Наименьшее *p*-значение здесь у переменной *Lag1*. Отрицательный коэффициент у этого предиктора предполагает, что если вчера наблюдалась положительная доходность, то сегодня она вряд ли пойдет вверх. Однако *p*-значение, равное 0.15, все-таки достаточно велико, и поэтому четкого свидетельства в пользу зависимости между *Lag1* и *Direction* нет.

Для получения доступа к коэффициентам этой подогнанной модели мы воспользуемся функцией `coef()`. Для доступа к детальному описанию свойств подогнанной модели, таких как *p*-значения коэффициентов, мы также можем применить функцию `summary()`.

```
> coef(glm.fit)
```

(Intercept)	Lag1	Lag2	Lag3	Lag4
-0.1260	-0.07307	-0.04230	0.01109	0.00936
Lag5	Volume			
0.01031	0.13544			

```
> summary(glm.fit)$coef
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.12600	0.2407	-0.523	0.601
Lag1	-0.07307	0.0502	-1.457	0.145


```

Lag2      -0.04230      0.0501      -0.845      0.398
Lag3       0.01109      0.0499       0.222      0.824
Lag4       0.00936      0.0500       0.187      0.851
Lag5       0.01031      0.0495       0.208      0.835
Volume     0.13544      0.1584       0.855      0.392

```

```
> summary(glm.fit)$coef[,4]
```

```

(Intercept)      Lag1      Lag2      Lag3      Lag4
      0.601      0.145      0.398      0.824      0.851
      Lag5      Volume
      0.835      0.392

```

Имея те или иные значения предикторов, можно воспользоваться функцией `predict()` и предсказать вероятность того, что доходность индекса пойдет вверх. Опция `type = "response"` сообщает R, что необходимо выводить вероятности в виде $P(Y = 1|X)$, а не какую-то другую информацию вроде логита. Если на функцию `predict()` не подан какой-то определенный набор данных, то вероятности рассчитываются для обучающих данных, которые были использованы для подгонки логистической модели. Ниже мы вывели только первые десять значений вероятности. Мы знаем, что эти значения соответствуют вероятности роста, а не падения доходности акций, поскольку функция `contrasts()` показывает, что программа создала индикаторную переменную, у которой 1 соответствует значению Up.

```

> glm.probs = predict(glm.fit, type = "response")
> glm.probs[1:10]
      1      2      3      4      5      6      7      8      9     10
0.507 0.481 0.481 0.515 0.511 0.507 0.493 0.509 0.518 0.489
> contrasts(Direction)
      Up
Down  0
Up    1

```

Чтобы предсказать направление роста доходности для конкретного дня, мы должны конвертировать эти вероятности в метки классов — Up или Down. Приведенные ниже команды создают вектор с метками классов, присвоенными в зависимости от того, превышает ли предсказанная вероятность роста доходности 0.5.

```

> glm.pred = rep("Down", 1250)
> glm.pred[glm.probs > .5] = "Up"

```

Первая команда создает вектор с 1250 значениями Down. Вторая команда превращает в Up все элементы вектора, у которых предсказанная вероятность роста доходности превышает 0.5. Имея эти предсказания, можно воспользоваться функцией `table()`, чтобы получить матрицу неточностей и определить, сколько наблюдений были классифицированы неверно. `table()`

```

> table(glm.pred, Direction)
      Direction
glm.pred Down  Up
Down    145  141
Up      457  507

```

```
> (507 + 145)/1250
[1] 0.5216
> mean(glm.pred == Direction )
[1] 0.5216
```

Диагональные элементы матрицы неточностей соответствуют верным предсказаниям, а элементы, расположенные вне диагонали, — ошибочным предсказаниям. Таким образом, наша модель для 507 дней правильно предсказала, что доходность возрастет, и для 145 дней, что доходность снизится, — в целом это $507 + 145 = 652$ правильно предсказанных случаев. Функцию `mean()` можно применить для вычисления доли правильно предсказанных случаев. В этом примере логистическая регрессия правильно предсказала направление движения рынка в 52.2% случаев.

На первый взгляд может показаться, что логистическая регрессионная модель работает немного лучше, чем случайное угадывание. Однако этот результат вводит в заблуждение, поскольку мы обучили и проверили модель на тех же 1250 наблюдениях. Другими словами, $100 - 52.2 = 47.8\%$ — это частота ошибок на *обучающих* данных. Как мы уже видели ранее, частоты ошибок на обучающих данных часто слишком оптимистична — она имеет тенденцию недооценивать частоту ошибок на контрольной выборке. Чтобы лучше оценить верность предсказаний логистической регрессионной модели при таком сценарии, мы можем подогнать модель на основе определенной части данных, а затем исследовать качество ее предсказаний на *неиспользованных* для обучения данных. Это даст более реалистичную частоту ошибок, в том смысле, что на практике нам будет интересно качество предсказаний нашей модели не для тех данных, которые мы использовали для ее подгонки, а для будущих дней, для которых направление движения рынка неизвестно.

Для реализации этой стратегии мы сначала создадим вектор, соответствующий наблюдениям за период с 2001 по 2004 г. Затем мы используем этот вектор для создания контрольной выборки, содержащей наблюдения за 2005 г.

```
> train = (Year < 2005)
> Smarket.2005 = Smarket[!train, ]
> dim(Smarket.2005)
[1] 252 9
> Direction.2005 = Direction [!train]
```

Объект `train` представляет собой вектор из 1250 элементов, соответствующих наблюдениям из нашего набора данных. Элементам вектора, которые соответствуют наблюдениям, полученным до 2004 г., присвоено значение `TRUE`, а элементам, которые соответствуют наблюдениям за 2005 г., присвоено значение `FALSE`. Объект `train` — это логический вектор, поскольку он содержит значения `TRUE` и `FALSE`. Логические векторы можно применять для получения определенных подмножеств строк или столбцов матрицы. Например, команда `Smarket[train, ]` отобрала бы ту часть матрицы с данными по доходности акций, которая соответствует только датам до 2005 г., поскольку это те данные, для которых элементы вектора `train` равны `TRUE`. Символ `!` позволяет обратить все элементы логического вектора. Другими словами, вектор `!train` похож на `train`, за исключением того, что элементы со значением `TRUE` в `train` заменяются на `FALSE`.

в `!train`, элементы со значением `FALSE` в `train` заменяются на `TRUE` в `!train`. Следовательно, `Smarket[!train, ]` возвращает часть матрицы с данными по доходности акций, содержащую только те наблюдения, для которых значения `train` равны `FALSE`, т. е. наблюдения с датами за 2005 г.

Теперь, применяя аргумент `subset`, мы подгоняем логистическую регрессионную модель на основе только тех наблюдений, которые соответствуют датам до 2005 г. Далее мы получаем предсказанные вероятности роста доходности для каждого дня из контрольной выборки, т. е. для дней 2005 г.

```
> glm.fit = glm(Direction ~ Lag1+Lag2+Lag3+Lag4+Lag5+Volume,
               data = Smarket, family = binomial, subset=train)
> glm.probs = predict(glm.fit, Smarket.2005, type = "response")
[1] 0.48
> mean(glm.pred != Direction.2005)
[1] 0.52
```

Заметьте, что мы обучили и проверили нашу модель на двух совершенно отдельных наборах данных: обучение было выполнено с использованием дат только до 2005 г., а контроль качества был выполнен лишь с использованием дат 2005 г. Наконец, мы вычисляем предсказания для 2005 г. и сравниваем их с направлениями движения рынка, действительно имевшими место в том году.

```
> glm.pred = rep("Down", 252)
> glm.pred[glm.probs > .5] = "Up"
> table(glm.pred, Direction.2005)
      Direction.2005
glm.pred  Down  Up
      Down    77  97
      Up     34  44
> mean(glm.pred == Direction.2005)
```

Выражение `!=` обозначает «не равно», и поэтому последняя команда вычисляет частоту ошибок на контрольных данных. Результаты довольно неутешительны: частота ошибок на контрольных данных составляет 52%, что хуже, чем случайное угадывание. Конечно, этот результат не является большим сюрпризом, поскольку обычно невозможно предсказать будущее развитие рынка на основе доходности за предыдущий день. (В конце концов, если бы такое было возможно, то авторы этой книги уже сколотили бы себе состояние, а не писали учебники по статистике.)

Напомним, что p -значения у всех предикторов в логистической регрессионной модели были совсем не впечатляющими, а самое низкое p -значение (хотя и не очень низкое) соответствовало переменной `Lag1`. Возможно, удалив переменные, выглядящие бесполезными для предсказания `Default`, мы сможем получить более эффективную модель. В конце концов, использование предикторов, не связанных с откликом, обычно увеличивает частоту ошибок на контрольной выборке (поскольку они вызывают рост дисперсии без соответствующего снижения смещения), и поэтому удаление таких предикторов может привести к определенному улучшению. Ниже мы повторно подогнали логистическую регрессию, используя только `Lag1` и `Lag2`, которые в исходной модели выглядели как переменные с самым высоким предсказательным потенциалом.

```

> glm.fit = glm(Direction ~ Lag1 + Lag2,
                 data = Smarket, family = binomial, subset = train)
> glm.probs = predict(glm.fit, Smarket.2005, type = "response")
> glm.pred = rep("Down", 252)
> glm.pred[glm.probs > .5] = "Up"
> table(glm.pred, Direction.2005)
      Direction.2005
glm.pred  Down  Up
      Down    35  35
      Up     76 106

> mean(glm.pred == Direction.2005)
[1] 0.56
> 106/(106 + 76)
[1] 0.582

```

Теперь результаты выглядят немного лучше: 56% дневных изменений были предсказаны верно. Стоит отметить, что в данном примере намного более простая стратегия предсказания ежедневного роста доходности также будет верна в 56% случаев! Следовательно, по общей частоте ошибок метод логистической регрессии ничем не лучше наивного подхода. Однако матрица неточностей показывает, что в случаях, когда логистическая регрессия предсказывает рост доходности, частота верных предсказаний составляет 58%. Это предполагает возможную компромиссную стратегию: покупку активов, когда модель предсказывает рост рынка, и избегание торгов в дни, для которых предсказывается снижение рынка. Конечно, нужно было бы изучить более тщательно, является ли это улучшение реальным или просто было вызвано случайными факторами.

Представьте, что мы хотим предсказать доходность, связанную с конкретными значениями Lag1 и Lag2. В частности, мы хотим предсказать Default для дня, когда Lag1 и Lag2 составляют 1.2 и 1.1 соответственно, а также когда они равны 1.5 и -0.8. Мы делаем это при помощи функции predict().

```

> predict(glm.fit, newdata = data.frame(Lag1 = c(1.2, 1.5),
                                         Lag2 = c(1.1, -0.8)), type = "response")
      1      2
0.4791  0.4961

```

4.6.3 Линейный дискриминантный анализ

Теперь мы выполним LDA на данных Smarket. В R мы подгоняем LDA-модель при помощи функции `lda()`, которая является частью библиотеки MASS. Заметьте, что синтаксис функции `lda()` идентичен синтаксису `lm()` и `glm()`, за тем исключением, что опция `family` отсутствует. Мы подгоняем модель на основе наблюдений, полученных ранее 2005 г.

```

> library(MASS)
> lda.fit = lda(Direction ~ Lag1 + Lag2,
                 data = Smarket, subset = train)
> lda.fit

```

Call:

```
lda (Direction ~ Lag1 + Lag2 , data = Smarket, subset = train)
```

Prior probabilities of groups :

Down	Up
0.492	0.508

Group means :

	Lag1	Lag2
Down	0.0428	0.0339
Up	-0.0395	-0.0313

Coefficients of linear discriminants:

	LD1
Lag1	-0.642
Lag2	-0.514

```
> plot(lda.fit)
```

Результаты LDA показывают, что $\hat{\pi}_1 = 0.492$, $\hat{\pi}_2 = 0.508$, т.е. 49.2% обучающих наблюдений соответствуют дням, когда рынок снижался. В результатах представлены также групповые средние — это средние значения каждого предиктора в каждом классе, которые используются LDA в качестве оценок μ_k . Эти значения указывают на то, что за два дня до роста рынка доходность акций обычно отрицательна, а за день до снижения рынка доходность обычно положительна. В части результатов, озаглавленной как «*Coefficients of linear discriminants*» (коэффициенты линейных дискриминантов), представлена линейная комбинация переменных Lag1 и Lag2, которая используется для формирования правила принятия решений LDA. Другими словами, это коэффициенты элементов $X = x$ в уравнении (4.19). Если величина $-0.642 \times \text{Lag1} - 0.514 \times \text{Lag2}$ велика, то LDA-классификатор предскажет рост доходности, а если она мала, то классификатор предскажет снижение доходности. Функция `plot()` строит графики *линейных дискриминантов*, полученных путем вычисления $-0.642 \times \text{Lag1} - 0.514 \times \text{Lag2}$ для каждого обучающего наблюдения.

Функция `predict()` возвращает список с тремя элементами. Первый элемент — `class` — содержит предсказания LDA касательно направления движения рынка. Второй элемент — `posterior` — представляет собой матрицу, в которой k -й столбец содержит вычисленную по (4.1) апостериорную вероятность принадлежности соответствующего наблюдения к классу k . Наконец, `x` содержит описанные ранее линейные дискриминанты.

```
> lda.pred = predict(lda.fit, Smarket.2005)
> names(lda.pred)
[1] "class" "posterior" "x"
```

Как было отмечено в разделе 4.5, предсказания логистической регрессии и LDA почти идентичны.

```
> lda.class = lda.pred$class
> table(lda.class, Direction.2005)
```



```

      Direction.2005
lda.pred Down Up
      Down   35 35
      Up    76 106
> mean(lda.class == Direction.2005)
[1] 0.56

```

Применение 50%-го порогового значения к апостериорным вероятностям позволяет нам восстановить предсказания, содержащиеся в `lda.pred$class`.

```

> sum(lda.pred$posterior[, 1] >= .5)
[1] 70
> sum(lda.pred$posterior[, 1] < .5)
[1] 182

```

Обратите внимание на то, что выданная моделью апостериорная вероятность соответствует вероятности снижения доходности:

```

> lda.pred$posterior[1:20,1]
> lda.class[1:20]

```

Если бы мы хотели при расчете предсказаний использовать пороговое значение апостериорной вероятности, отличное от 50%, то легко могли бы это сделать. Допустим, например, что мы хотим предсказывать снижение доходности только, если мы убеждены, что это действительно произойдет в соответствующий день (скажем, если апостериорная вероятность составляет не менее 90%).

```

> sum(lda.pred$posterior[, 1] > .9)
[1] 0

```

Ни один из дней 2005 г. не соответствует этому пороговому значению! Оказывается, что максимальная апостериорная вероятность снижения для всего 2005 г. составила 52.02%.

4.6.4 Квадратичный дискриминантный анализ

Теперь мы подгоним QDA-модель к данным `Smarket`. Метод QDA реализуется в R при помощи функции `qda()`. Синтаксис идентичен таковому у `lda()`.

```

> qda.fit = qda(Direction ~ Lag1 + Lag2,
                data = Smarket, subset = train)
> qda.fit

```

Call:

```
qda (Direction ~ Lag1 + Lag2 , data = Smarket, subset = train)
```

Prior probabilities of groups:

```

Down   Up
0.492  0.508

```

Group means :

	Lag1	Lag2
Down	0.0428	0.0339
Up	-0.0395	-0.0313

Результаты содержат групповые средние. Однако они не включают коэффициенты линейных дискриминантов, поскольку QDA основан на квадратичной, а не линейной функции предикторов. Функция `predict()` работает точно таким же образом, как и в случае с LDA.

```
> qda.class = predict(qda.fit, Smarket.2005)$class
> table(qda.class, Direction.2005)
Direction.2005
qda.class      Down Up
      Down      30 20
      Up       81 121
> mean(qda.class == Direction.2005)
[1] 0.599
```

Интересно, что предсказания QDA верны примерно в 60% случаев, хотя данные за 2005 г. не были использованы при подгонке модели. Подобный уровень точности довольно внушительен для данных по рынку акций, который, как известно, трудно поддается точному моделированию. Это указывает на то, что лежащая в основе QDA квадратичная форма может отражать истинную зависимость корректнее линейных форм, предполагаемых LDA и логистической регрессией. Однако прежде чем заключать пари на то, что этот метод обставит рынок, мы советуем оценить качество его предсказаний на большей контрольной выборке!

4.6.5 Метод K ближайших соседей

Теперь мы выполним построение KNN-модели при помощи функции `knn()` из библиотеки `class`. Эта функция довольно сильно отличается от других подгоняющих модели функций, с которыми мы уже познакомились. Вместо двухэтапного подхода, когда мы сначала подгоняем модель, а затем используем эту модель для получения предсказаний, `knn()` формирует предсказания при помощи одной команды. Эта функция требует четыре входных параметра:

1. Матрица с предикторами из обучающего набора данных, обозначаемая ниже как `train.X`.
2. Матрица с предикторами из набора данных, для которого мы хотим сделать предсказания (обозначена ниже как `test.X`).
3. Вектор с метками классов обучающих наблюдений (обозначен ниже как `train.Direction`).
4. Значение K — используемое классификатором число ближайших соседей.

Мы применяем функцию `cbind()`⁹ для объединения переменных `Lag1` и `Lag2` в две матрицы — для обучающего и контрольного наборов данных.

⁹ Сокращение от «column» (столбец) и «bind» (связывать). — Прим. пер.

```
> library(class)
> train.X = cbind(Lag1, Lag2)[train, ]
> test.X = cbind(Lag1, Lag2)[!train, ]
> train.Direction = Direction[train]
```

Теперь можно применить функцию `knn()` для предсказания направления движения рынка для дат 2005 г. Перед вызовом `knn()` мы задаем значение «зерна» генератора случайных чисел, поскольку в ситуациях, когда несколько ближайших соседей оказываются равноудаленными от интересующего нас наблюдения, R случайным образом выберет некоторые из них. Поэтому «зерно» необходимо задать для получения воспроизводимых результатов.

```
> set.seed(1)
> knn.pred = knn(train.X, test.X, train.Direction, k = 1)
> table(knn.pred, Direction.2005)
      Direction.2005
knn.pred  Down  Up
      Down    43 58
      Up     68 83
> (83 + 43)/252
[1] 0.5
```

Результаты, полученные с использованием $K = 1$, не очень хороши, поскольку только 50% наблюдений предсказаны верно. Конечно, может оказаться так, что $K = 1$ приводит к чрезмерно гибкой модели. Ниже мы повторяем анализ, используя $K = 3$.

```
> knn.pred = knn(train.X, test.X, train.Direction, k = 3)
> table(knn.pred, Direction.2005)
      Direction.2005
knn.pred  Down  Up
      Down    48 54
      Up     63 87
> mean(knn.pred == Direction.2005)
[1] 0.536
```

Качество модели несколько повысилось. Однако дальнейшее увеличение K не приводит к соответствующим улучшениям. Похоже, что из всех рассмотренных нами на данный момент методов QDA обеспечивает наилучшие результаты для этого набора данных.

4.6.6 Применение к данным по жилым прицепам

Наконец, мы применим метод KNN к данным `Caravan`, который является частью библиотеки ISLR. Этот набор данных включает 85 предикторов, описывающих демографические характеристики 5822 человек. Зависимой является переменная `Purchase`, которая показывает, покупает ли тот или иной человек страховой полис для своего жилого прицепа. В этом наборе данных страховку для своих прицепов купили только 6% людей.

```
> dim(Caravan)
[1] 5822 86
```

```
> attach(Caravan)
> summary(Purchase)
  No  Yes
5474 348
> 348/5822
[1] 0.0598
```

Поскольку классификатор KNN предсказывает класс некоторого контрольного наблюдения путем определения ближайших к нему наблюдений, имеет значение шкала измерения переменных. Любые переменные, которые выражаются большими числами, будут иметь гораздо больший эффект на *расстояние* между наблюдениями и, следовательно, на KNN-классификатор, чем переменные, которые выражаются при помощи малых чисел. Например, представьте себе набор данных с двумя переменными — «заработная плата» и «возраст», измеренными в долларах и в годах соответственно. С «точки зрения» KNN, разница в заработной плате, составляющая 1000\$, огромна, по сравнению с разницей в возрасте, составляющей 50 лет. Это противоречит нашему восприятию: разница в 1000\$ воспринимается нами как довольно небольшая, по сравнению с разницей в возрасте, составляющей 50 лет. Более того, важность шкалы измерения для KNN приводит к другой проблеме: если бы мы измерили заработную плату в японских иенах или выразили возраст в минутах, то результаты классификации довольно существенно отличались бы от того, что мы получаем при выражении этих переменных в долларах и в годах.

Хороший способ решения этой проблемы заключается в *стандартизации* данных таким образом, чтобы все переменные имели среднее значение, равное 0, и стандартное отклонение, равное 1. В таком случае все переменные будут представлены на одинаковой шкале. Функция `scale()` как раз и выполняет такую процедуру. При стандартизации данных мы исключаем столбец 86, поскольку он представляет собой качественную переменную `Purchase`.

стандарти-
зация

`scale()`

```
> standardized.X = scale(Caravan[, -86])
> var(Caravan[, 1])
[1] 165
> var(Caravan[, 2])
[1] 0.165
> var(standardized.X[, 1])
[1] 1
> var(standardized.X[, 2])
[1] 1
```

Теперь каждый столбец таблицы `standardized.X` имеет стандартное отклонение, равное 1, и среднее значение, равное 0.

Далее мы разбиваем данные на обучающую выборку, содержащую 1000 первых наблюдений, и контрольную выборку, содержащую все остальные наблюдения. Мы строим KNN-модель по обучающим данным с использованием $K = 1$ и оцениваем качество предсказаний на контрольных данных.

```
> test = 1:1000
> train.X = standardized.X[-test, ]
```

```

> test.X = standardized.X[test, ]
> train.Y = Purchase[-test]
> test.Y = Purchase[test]
> set.seed(1)
> knn.pred = knn(train.X, test.X, train.Y, k = 1)
> mean(test.Y != knn.pred)
[1] 0.118
> mean(test.Y != "No")
[1] 0.059

```

Вектор `test` является числовым и содержит числа от 1 до 1000. Команда `standardized.X[test, ]` возвращает часть данных с наблюдениями, чьи индексные номера изменяются от 1 до 1000, тогда как команда `standardized.X[-test, ]` возвращает часть данных с наблюдениями, чьи индексные номера *не* лежат в диапазоне от 1 до 1000. Частота ошибки KNN на 1000 контрольных наблюдений лишь немногим меньше 12%. На первый взгляд это значение может показаться довольно хорошим. Но поскольку страховку купили только 6% клиентов, мы всегда могли бы свести частоту ошибок до 6%, предсказывая `No` (страховка не куплена) вне зависимости от значений предикторов!

Предположим, что попытка продать страховку определенному клиенту связана с существенными издержками. Возможно, например, что продавец должен посетить каждого потенциального клиента. Если компания пытается продать страховку случайно выбранной группе клиентов, то успех будет достигнут только в 6% случаев, что может оказаться слишком низкой величиной, по сравнению с уровнем издержек. Вместо этого компания хотела бы продавать страховку только тем клиентам, которые купят ее с высокой вероятностью. В связи с этим общая частота ошибок не представляет интереса. Вместо этого интерес представляет доля клиентов, для которых покупка страховки предсказана верно.

Оказывается, что в случае с клиентами, для которых классификатор предсказывает покупку страховки, KNN с $K = 1$ работает гораздо лучше случайного угадывания. Среди 77 таких клиентов 9 (11.7%) действительно покупают страховку. Это в два раза лучше результата, который был бы получен при простом угадывании.

```

> table(knn.pred, test.Y)
      test.Y
knn.pred No  Yes
      No  873   50
      Yes  68    9
> 9/(68 + 9)
[1] 0.117

```

При использовании $K = 3$ частота правильных предсказаний повышается до 19%, а при $K = 5$ она составляет 26.7%. Это более чем в четыре раза превышает частоту правильных предсказаний при случайном угадывании. Похоже, что KNN находит какие-то реальные закономерности в довольно сложном наборе данных!

```

> knn.pred = knn(train.X, test.X, train.Y, k = 3)
> table(knn.pred, test.Y)

```



```

      test.Y
knn.pred No  Yes
      No  920   54
      Yes  21    5
> 5/26
[1] 0.192
> knn.pred = knn(train.X, test.X, train.Y, k = 5)
> table(knn.pred, test.Y)
      test.Y
knn.pred No  Yes
      No  930   55
      Yes  11    4
> 4/15
[1] 0.267

```

Для сравнения мы можем также подогнать к этим данным логистическую регрессионную модель. Если мы применим 0.5 в качестве порогового значения для предсказанной классификатором вероятности, то столкнемся с проблемой: покупка страховки будет предсказана только для семи контрольных наблюдений. Хуже того, мы ошибемся во всех этих случаях! Однако нам нет необходимости использовать пороговое значение 0.5. Если мы вместо этого будем предсказывать покупку страховки каждый раз, когда предсказанная вероятность превышает 0.25, то результаты окажутся намного лучше: мы предскажем покупку страховки для 33 человек и будем правы в 33% случаев. Это более чем в пять раз лучше случайного угадывания!

```

> glm.fit = glm(Purchase ~ ., data = Caravan,
                family = binomial, subset = -test)
Warning message:
glm .fit: fitted probabilities numerically 0 or 1 occurred

> glm.probs = predict(glm.fit, Caravan[test, ],
                    type = "response")
> glm.pred = rep("No", 1000)
> glm.pred[glm.probs > .5] = "Yes"

> table(glm.pred, test.Y)
      test.Y
glm.pred No  Yes
      No  934   59
      Yes   7    0
> glm.pred = rep("No", 1000)
> glm.pred[glm.probs > .25] = "Yes"
> table(glm.pred, test.Y)
      test.Y
glm.pred No  Yes
      No  919   48
      Yes  22   11
> 11/(22 + 11)
[1] 0.333

```

4.7 Упражнения

Теоретические

1. Применив немного алгебры, докажите, что выражение (4.2) эквивалентно (4.3). Другими словами, покажите, что представление логистической регрессионной модели в виде логистической функции эквивалентно логит-представлению.
2. В тексте было сделано утверждение о том, что отнесение некоторого наблюдения к классу с максимальной величиной (4.2) эквивалентно отнесению этого наблюдения к классу с максимальной величиной (4.13). Докажите, что это действительно так. Иными словами, покажите, что если некоторое наблюдение из класса k происходит из нормального распределения $N(\mu_k, \sigma^2)$, то байесовский классификатор относит это наблюдение к классу, у которого дискриминантная функция максимальна.
3. Эта задача касается QDA-модели, в которой наблюдения в каждом классе имеют нормальное распределение со специфичным для конкретного класса вектором математического ожидания и специфичной ковариационной матрицей. Мы рассмотрим простой случай с $p = 1$, т. е. только с одной независимой переменной. Предположим, что у нас есть K классов и что если некоторое наблюдение принадлежит к классу k , то X имеет одномерное нормальное распределение: $X \sim N(\mu_k, \sigma_k^2)$. Напомним, что функция плотности одномерного нормального распределения приведена в (4.11). Докажите, что в данном случае байесовский классификатор не является линейным. Покажите, что в действительности он является квадратичным.

Подсказка: для решения этой задачи вам следует воспользоваться аргументами, изложенными в подразделе 4.4.2, но не делать предположения о том, что $\sigma_1^2 = \dots = \sigma_K^2$.



4. При большом количестве предикторов p обычно наблюдается снижение качества KNN и других локальных методов, которые делают предсказания на основе только нескольких наблюдений, находящихся *вблизи* от интересующего нас контрольного наблюдения. Это явление известно как *проклятие размерности* и объясняет тот факт, что при большом p непараметрические методы часто работают неудовлетворительно. Сейчас мы познакомимся с этим проклятием подробнее.

- (а) Пусть у нас есть набор наблюдений, для каждого из которых измерен $p = 1$ признак X . Мы предполагаем, что признак X равномерно распределен на отрезке $[0, 1]$. С каждым наблюдением связано некоторое значение отклика. Предположим, что мы хотим предсказать отклик для некоторого контрольного наблюдения на основе только тех близлежащих точек, которые находятся в пределах 10% от значения X у этого наблюдения. Например, чтобы предсказать отклик для контрольного наблюдения с $X = 0.6$ мы будем использовать наблюдения из диапазона $[0.55, 0.65]$. Какую

долю имеющихся наблюдений (в среднем) мы будем использовать для получения предсказания?

- (b) Теперь допустим, что у нас есть некоторый набор наблюдений, для каждого из которых измерены $p = 2$ признака — X_1 и X_2 . Мы предполагаем, что наблюдения (X_1, X_2) равномерно распределены в диапазоне $[0, 1] \times [0, 1]$. Мы хотим предсказать отклик для некоторого контрольного наблюдения, используя только те близлежащие точки, которые находятся в пределах 10% от значения X_1 и в пределах 10% от значения X_2 у этого наблюдения. Например, чтобы предсказать отклик для контрольного наблюдения с $X_1 = 0.6$ и $X_2 = 0.35$ мы будем использовать наблюдения со значениями X_1 из диапазона $[0.55, 0.65]$ и значениями X_2 из диапазона $[0.3, 0.4]$. Какую долю имеющихся наблюдений (в среднем) мы будем использовать для получения предсказания?
- (c) Теперь представьте, что у нас есть набор наблюдений с $p = 100$ признаками. Как и раньше, наблюдения равномерно распределены по каждому признаку и каждый признак изменяется от 0 до 1. Мы хотим предсказать отклик для контрольного наблюдения, используя те ближайшие к нему точки, которые находятся в пределах 10% от значений каждого признака у этого наблюдения. Какую долю имеющихся наблюдений мы будем использовать для получения предсказания?
- (d) На основании своих ответов для (a)–(c) покажите, что недостаток KNN при большом p состоит в очень малом количестве обучающих наблюдений, находящихся «рядом» с любым контрольным наблюдением.
- (e) Теперь представьте, что мы хотим сделать предсказание для некоторого контрольного наблюдения путем создания p -мерного гиперкуба, центрированного по этому наблюдению и содержащего в среднем 10% обучающих наблюдений. Какова длина каждого ребра такого гиперкуба при $p = 1, 2$ и 100? Прокомментируйте свой ответ.

Примечание: гиперкуб — это обобщение куба на пространство произвольной размерности. При $p = 1$ гиперкуб является просто отрезком, при $p = 2$ — это квадрат, а при $p = 100$ — это p -мерный куб.

5. Теперь мы рассмотрим различия между LDA и QDA.

- (a) Если байесовская решающая граница является линейной, у какого метода мы ожидаем более высокое качество предсказаний на обучающих данных — LDA или QDA? А на контрольных данных?
- (b) Если байесовская решающая граница является нелинейной, у какого метода мы ожидаем более высокое качество предсказаний на обучающих данных — LDA или QDA? А на контрольных данных?
- (c) Ожидаем ли мы, что в целом по мере увеличения объема выборки точность предсказаний QDA в сравнении с LDA возрастет? А может, она снизится или останется неизменной? Почему?

- (d) Верно ли следующее утверждение: даже если байесовская решающая граница для некоторой задачи является линейной, при использовании QDA мы, возможно, получим более точные предсказания на контрольных данных, чем при использовании LDA, поскольку QDA является достаточно гибким методом для моделирования линейной решающей границы. Обоснуйте свой ответ.
6. Представьте, что мы собрали данные для группы студентов, посещающих курс по статистике, с переменными X_1 = количество часов, посвященных изучению предмета, X_2 = средний балл в школе и Y = индикатор получения самой высокой отметки за экзамен. Мы подогнали логистическую регрессию и получили оценки коэффициентов $\hat{\beta}_0 = -6$, $\hat{\beta}_1 = 0.05$, $\hat{\beta}_2 = 1$.
- (a) Рассчитайте вероятность того, что студент, затративший на обучение 40 часов и имеющий средний школьный балл 3.5, покажет наилучший результат на экзамене.
- (b) Сколько часов студенту из (a) необходимо затратить на обучение, чтобы с 50%-ной вероятностью получить наивысшую отметку за экзамен?
7. Представим, что мы хотим предсказать выплату дивидендов по некоторым акциям в этом году («да» или «нет») на основе X — прибыли, выраженной в процентах от объема продаж. Мы изучаем большое количество компаний и выясняем, что среднее значение X для компаний, выплативших дивиденды, составило $\bar{X} = 10$, тогда как для компаний, которые дивиденды не выплатили, оно составило $\bar{X} = 0$. Кроме того, дисперсия X у этих двух групп компаний составила $\hat{\sigma}^2 = 36$. Наконец, дивиденды были выплачены 80% компаний. Допустив, что X имеет нормальное распределение, рассчитайте вероятность выплаты дивидендов некоторой компанией в этом году при условии, что в прошлом году прибыль, выраженная в процентах от объема продаж, составила $X = 4$.
- Подсказка: вспомните, что функция плотности вероятности случайной нормально распределенной переменной выражается как $f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(x-\mu)^2/2\sigma^2}$. Вам придется воспользоваться теоремой Байеса.*
8. Представьте, что мы берем некоторый набор данных, разбиваем его на обучающую и контрольную выборки одинакового размера и затем проверяем две разные процедуры классификации. Сначала мы используем логистическую регрессию и получаем частоту ошибок 20% на обучающих данных и 30% на контрольных данных. Далее мы применяем метод K ближайших соседей с $K = 1$ и получаем среднюю частоту ошибок 18% (усредненную по обучающим и контрольным данным). Судя по этим результатам, какой метод нам следует предпочесть для классификации новых наблюдений? Почему?
9. Эта задача касается риска наступления события.

- (a) В среднем какая доля людей с риском неуплаты долга по кредитной карте, равным 0.37, в действительности станут неплательщиками?
- (b) Представьте, что у некоторого клиента вероятность неуплаты долга по кредитной карте составляет 16%. Чему у этого клиента равен риск неуплаты долга?

Практические

10. На этот вопрос необходимо ответить, используя набор данных *Weekly* из пакета *ISLR*. По своей сути этот набор данных похож на данные *Smarket* из лабораторной работы для предыдущей главы, за тем исключением, что он содержит 1089 значений недельной доходности акций за 21 год — с начала 1990 г. до конца 2010 г.
 - (a) Рассчитайте описательные статистики и постройте графики для переменных из таблицы *Weekly*. Видны ли какие-либо закономерности?
 - (b) Используйте весь набор данных для подгонки логистической регрессии с *Direction* в качестве отклика и пятью лаг-переменными и *Volume* в качестве предикторов. Примените функцию `summary()` для вывода результатов. Можно ли сделать заключение, что некоторые из предикторов являются статистически значимыми? Если да, то какие?
 - (c) Рассчитайте матрицу неточностей и общую долю правильно классифицированных случаев. Объясните, что говорит матрица неточностей о разных типах ошибок, сделанных логистической регрессией.
 - (d) Теперь постройте логистическую регрессию на основе обучающих данных, охватывающих период с 1990 по 2008 гг., с *Lag2* в качестве единственного предиктора. Рассчитайте матрицу неточностей и общую долю правильно классифицированных случаев для контрольной выборки (т.е. данных за 2009–2010 г.).
 - (e) Повторите (d) с использованием LDA.
 - (f) Повторите (d) с использованием QDA.
 - (g) Повторите (d) с использованием KNN с $K = 1$.
 - (h) Какой из методов обеспечивает наиболее точные предсказания для этих данных?
 - (i) Поэкспериментируйте с разными комбинациями предикторов (включая возможные трансформации и взаимодействия) для каждого метода. Составьте отчет с указанием предикторов, метода и матрицы неточностей, которые соответствуют наилучшим результатам на контрольной выборке. Обратите внимание, что вам также следует поэкспериментировать со значениями K для KNN-классификатора.
11. В этой задаче вы разработаете модель на основе данных *Auto* для предсказания того, является ли расход топлива у автомобиля высоким или низким.

- (a) Создайте бинарную переменную `mpg01`, которая равна 1, если переменная `mpg` превышает собственную медиану, и 0, если `mpg` меньше собственной медианы. Вы можете вычислить медиану при помощи функции `median()`. Обратите внимание: полезной может оказаться функция `data.frame()`, которая поможет создать одну таблицу данных, включающую как `mpg01`, так и другие переменные из таблицы `Auto`.
- (b) Исследуйте эти данные графически для установления связи между `mpg01` и другими переменными. Какие из этих переменных выглядят наиболее подходящими для предсказания `mpg01`? Для ответа на этот вопрос полезными могут оказаться диаграммы рассеяния и диаграммы размахов. Опишите свои находки.
- (c) Разбейте данные на обучающую и контрольные выборки.
- (d) Постройте LDA-модель по обучающим данным для предсказания `mpg01` на основе переменных, которые выглядели наиболее тесно связанными с `mpg01` в (b). Чему равна частота ошибок на контрольной выборке?
- (e) Постройте QDA-модель по обучающим данным для предсказания `mpg01` на основе переменных, которые выглядели наиболее тесно связанными с `mpg01` в (b). Чему равна частота ошибок на контрольной выборке?
- (f) Постройте логистическую регрессию по обучающим данным для предсказания `mpg01` на основе переменных, которые выглядели наиболее тесно связанными с `mpg01` в (b). Чему равна частота ошибок на контрольной выборке?
- (g) Постройте KNN-модель по обучающим данным для предсказания `mpg01` (с несколькими различающимися значениями K). Используйте только те переменные, которые выглядели наиболее тесно связанными с `mpg01` в (b). Чему равна частота ошибок на контрольной выборке? Какое значение K выглядит наиболее подходящим для этих данных?

12. Эта задача предполагает написание функций.

- (a) Напишите функцию `Power()`, которая выводит результат возведения 2 в 3-ю степень. Другими словами, ваша функция должна вычислять 2^3 и выводить результат на экран.

Подсказка: вспомните, что x^a возводит x в степень a . Для вывода результата используйте функцию `print()`.

- (b) Создайте новую функцию — `Power2()`, которая позволяет подать на нее *любые* два числа — x и a — и вывести значение x^a . Вы можете сделать это, начав свою функцию со строки

```
> Power2 = function(x, a){
```

Вы должны иметь возможность вызвать свою функцию путем набора в командной строке, например следующего:

```
> Power2(3, 8)
```

Эта команда должна вывести значение 3^8 , т.е. 6561.

- (с) Используя написанную вами только что функцию `Power2()`, вычислите 10^3 , 8^{17} и 131^3 .
- (d) Теперь создайте функцию `Power3()`, которая возвращает результат x^2 в виде объекта `R`, а не просто выводит результат вычислений на экран. Другими словами, если вы сохраните значение x^2 в объекте по названию `result`, то вы сможете получить этот объект при помощи функции `return()`, используя следующую строку:

```
> return(result)
```

Эта строка должна быть последней в вашей функции и располагаться перед символом `}`.

- (е) Теперь, используя функцию `Power3()`, создайте график $f(x) = x^2$. Ось x должна показывать диапазон целых чисел от 1 до 10, а ось y — x^2 . Дайте подходящие названия осям и выберите соответствующий заголовок для графика. Подумайте о том, чтобы представить ось x или ось y на логарифмической шкале. Вы можете сделать это при помощи аргументов `log = "x"`, `log = "y"` или `log = "xy"` функции `plot()`.
- (f) Создайте функцию `PlotPower()`, которая позволяет вам построить график зависимости x^a от x для некоторого фиксированного a и определенного диапазона значений x . Например, если вы выполните

```
> PlotPower(1:10, 3)
```

то должен появиться график, у которого по оси x представлены значения $1, 2, \dots, 10$, а по оси y — $1^3, 2^3, \dots, 10^3$.

13. Используя набор данных `Boston`, постройте классификаторы для предсказания того, превышает ли уровень преступности в некотором пригороде медианное значение этой переменной. Попробуйте модели логистической регрессии, LDA и KNN с разными наборами предикторов. Опишите свои результаты.

Глава 5

Методы создания повторных выборок

*Методы создания повторных выборок*¹ являются незаменимым инструментом в современной статистике. Они подразумевают многократное извлечение выборок из обучающих данных и подгонку некоторой интересующей нас модели по каждой из этих выборок для получения дополнительной информации об этой модели. Например, для оценивания дисперсии линейной модели мы можем извлечь несколько различных выборок из обучающих данных, подогнать линейную регрессию по каждой новой выборке, а затем исследовать степень различий получающихся моделей. Такой подход может дать нам информацию, которая была бы недоступной при подгонке только одной модели на основе исходной обучающей выборки.

Методы создания повторных выборок могут потребовать больших вычислительных ресурсов, поскольку они включают многократную подгонку одной и той же статистической модели к разным подмножествам обучающих данных. Однако благодаря недавним достижениям в области вычислительной техники ресурсоемкость этих методов обычно не является запретительной. В этой главе мы обсуждаем два наиболее часто используемых метода создания повторных выборок — *перекрестную проверку* и *бутстреп*. Оба метода являются важными инструментами в практическом применении многих методов статистического обучения. Например, перекрестную проверку можно использовать для оценивания ошибки на контрольной выборке, чтобы оценить качество того или иного метода статистического обучения или найти подходящий для этого метода уровень гибкости. Процесс определения качества предсказаний модели известен как *оценка модели*, тогда как процесс нахождения подходящего уровня гибкости известен как *отбор модели*². Бутстреп применяется в разных контекстах, но чаще всего — для получения меры точности оценки некоторого параметра или метода статистического обучения.

¹ В оригинале используется термин «resampling methods». — Прим. пер.

² В оригинале используются термины «model assessment» и «model selection» соответственно. — Прим. пер.

5.1 Перекрестная проверка

В главе 2 мы обсуждали различие между *частотой ошибок на контрольной выборке* и *частотой ошибок на обучающей выборке*. Частота ошибок на контрольной выборке представляет собой среднюю ошибку, которая возникает в результате применения некоторого метода статистического обучения для предсказания отклика по новому наблюдению, т.е. измерению, которое не было использовано при обучении модели. Применение того или иного метода статистического обучения для определенного набора данных является оправданным, если этот метод обеспечивает низкую ошибку на контрольной выборке. Ошибку на контрольной выборке можно легко вычислить при наличии предназначенного для этого контрольного набора данных. К сожалению, обычно такой набор данных отсутствует. В то же время ошибку на обучающей выборке можно легко рассчитать путем применения некоторой модели непосредственно к наблюдениям, по которым она была обучена. Однако, как мы видели в главе 2, частота ошибок на обучающей выборке часто значительно отличается от ошибки на контрольной выборке; в частности, частота ошибок на обучающих данных может существенно недооценивать частоту ошибок на контрольных данных.

В отсутствие очень большой и специально созданной контрольной выборки, непосредственно подходящей для оценивания частоты ошибок, можно применить ряд методов для нахождения подобной оценки по имеющимся обучающим данным. Некоторые из этих методов оценивают частоту ошибок на контрольной выборке за счет определенной математической поправки, применяемой к частоте ошибок на обучающей выборке. Такие подходы обсуждаются в главе 6. В этом же разделе мы рассматриваем класс методов, которые оценивают частоту ошибки на контрольной выборке путем *исключения* части обучающих наблюдений из процесса подгонки модели и последующего применения этой модели к исключенным наблюдениям.

В подразделах 5.1.1–5.1.4 мы для простоты предполагаем, что интерес представляет построение регрессионной модели с количественным откликом. В подразделе 5.1.5 мы рассматриваем случай классификации с качественным откликом. Как мы вскоре увидим, ключевая идея остается неизменной вне зависимости от того, является отклик количественными или качественным.

5.1.1 Метод проверочной выборки

Предположим, что мы хотели бы оценить ошибку на контрольной выборке для некоторой статистической модели, подогнанной по некоторому набору наблюдений. Показанный на рис. 5.1 *метод проверочной выборки*³ представляет собой очень простую стратегию для решения этой задачи. Он заключается в случайном разбиении имеющегося набора наблюдений на две части — *обучающую выборку* и *проверочную*, или *удержанную*, *выборку*. Модель строится по обучающей выборке, а затем применяется для предсказания отклика у наблюдений из проверочной выборки. Получаемая в итоге ошибка на проверочной выборке (обычно для количественного

метод проверочной выборки

проверочная выборка

³ В оригинале используется термин «the validation set approach». — Прим. пер.

отклика она выражается при помощи MSE) дает оценку ошибки на независимых данных.



РИСУНОК 5.1. Схематическая иллюстрация метода проверочной выборки. Набор из n наблюдений случайным образом разбивается на обучающую выборку (показана голубым цветом и содержит наблюдения 7, 22 и 13) и проверочную выборку (показана бежевым цветом и, помимо других наблюдений, содержит наблюдение 91). Статистическая модель подгоняется на обучающей выборке, а ее качество оценивается на проверочной выборке

Мы продемонстрируем метод проверочной выборки на примере набора данных Auto. Вспомните из главы 3, что mpg и horsepower связаны нелинейной зависимостью и что модель, предсказывающая mpg на основе horsepower и horsepower^2 , обладает более высоким качеством, чем модель, содержащая только линейный член. Естественным является вопрос о том, мог ли полином третьей или более высокой степени привести к дальнейшему улучшению качества модели. В главе 3 мы отвечаем на этот вопрос, исследуя p -значения, связанные в линейной регрессии с полиномиальными членами 3-й и более высокой степени. Однако мы могли бы ответить на этот вопрос и при помощи метода проверочной выборки. Для этого мы случайным образом разбиваем 392 наблюдения на две части — обучающую выборку, содержащую 196 наблюдений, и проверочную выборку, содержащую остальные 196 наблюдений. Среднеквадратичные ошибки (MSE), полученные в результате подгонки разных регрессионных моделей по обучающей выборке и последующего оценивания качества этих моделей на проверочной выборке, показаны слева на рис. 5.2. У квадратичной модели MSE на проверочной выборке значительно ниже, чем у линейной модели. Однако у кубической модели MSE на проверочной выборке несколько выше, чем у квадратичной модели. Таким образом, добавление кубического члена в регрессионную модель не приводит к улучшению качества предсказаний, по сравнению с использованием только квадратичного члена.

Вспомните, что для создания графика, приведенного на рис. 5.2 слева, мы случайным образом разбили исходный набор данных на две части — обучающую и проверочную. Если мы повторим процесс случайного разбиения данных на две части, то получим несколько отличающуюся оценку MSE на контрольной выборке. В качестве иллюстрации справа на рис. 5.2 для набора данных Auto показаны десять разных кривых MSE на проверочной выборке, полученных с использованием десяти различных разбиений на обучающую и проверочную выборки. Все десять кривых указывают на то, что модель с квадратичным членом имеет существенно меньшую MSE на проверочной выборке, чем модель, содержащая только линейный

член. Более того, все десять кривых указывают на то, что добавление в модель кубического члена или членов более высокой степени особой пользы не приносит. Однако стоит отметить, что каждая из этих десяти кривых дает свою оценку MSE на контрольной выборке для каждой из десяти рассмотренных регрессионных моделей. При этом между кривыми нет согласия в том, какая модель приводит к наименьшей MSE на проверочной выборке. Учитывая эти различия между кривыми, мы можем быть уверены лишь в том, что линейная модель для этих данных не подходит.

Метод проверочной выборки концептуально прост, и его несложно реализовать. Однако у него есть два потенциальных недостатка:

1. Как показано справа на рис. 5.2, оценка ошибки на проверочной выборке может оказаться очень вариабельной, что определяется тем, какие наблюдения попадают в обучающую выборку, а какие — в проверочную.
2. В ходе реализации метода проверочной выборки в подгонке модели участвует только часть наблюдений — те наблюдения, которые попадают в обучающую выборку. Поскольку при обучении на небольших выборках качество получаемых статистических моделей обычно невелико, это предполагает, что ошибка на проверочной выборке может *переоценивать* истинную ошибку модели, обученной по всему набору данных.

В следующих подразделах мы опишем *перекрестную проверку* — улучшенную версию метода проверочной выборки, которая решает эти две проблемы.




РИСУНОК 5.2. Метод проверочной выборки был применен к набору данных Auto для оценивания ошибки прогнозирования mpg на основе полиномиальных функций horsepower. Слева: ошибки на проверочной выборке при однократном разбиении на обучающую и проверочную выборки. Справа: метод проверочной выборки был применен десять раз, каждый раз с использованием нового разбиения наблюдений на обучающую и проверочную выборки. Этот график иллюстрирует вариабельность оценок MSE на контрольной выборке, полученных при помощи данного метода

5.1.2 Перекрестная проверка по отдельным наблюдениям

LOOCV

Перекрестная проверка по отдельным наблюдениям (LOOCV)⁴ тесно связана с описанным в подразделе 5.1.1 методом проверочной выборки, однако пытается преодолеть недостатки последнего.

Подобно методу проверочной выборки, в ходе LOOCV исходные наблюдения разбиваются на две части. Однако вместо создания двух подмножеств сравнимого размера одно наблюдение — (x_1, y_1) — используется в качестве контрольного, а остальные наблюдения — $\{(x_2, y_2), \dots, (x_n, y_n)\}$ — составляют обучающую выборку. Статистическая модель подгоняется по $n - 1$ обучающим наблюдениям, а предсказание $\hat{y}_1$ производится для исключенного наблюдения по его значению x_1 . Поскольку наблюдение (x_1, y_1) не было использовано в процессе обучения, то $MSE_1 = (y_1 - \hat{y}_1)^2$ обеспечивает приблизительно несмещенную оценку ошибки на контрольной выборке. Однако, несмотря на то что MSE_1 является несмещенной оценкой истинной ошибки на контрольной выборке, она служит плохой оценкой, поскольку, будучи рассчитанной по единственному наблюдению (x_1, y_1) , она обладает высокой дисперсией.

Мы можем продолжить эту процедуру, выбрав (x_2, y_2) в качестве контрольного наблюдения, обучив статистическую модель по $n - 1$ наблюдениям $\{(x_1, y_1), (x_3, y_3), \dots, (x_n, y_n)\}$ и рассчитав $MSE_2 = (y_2 - \hat{y}_2)^2$. Повторение этой процедуры n раз приводит к получению n квадратов остатков: $MSE_1, \dots, MSE_n$. LOOCV-оценка MSE есть среднее значение из этих n оценок ошибки:

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n MSE_i. \quad (5.1)$$

Схематичное изображение метода LOOCV приведено на рис. 5.3.

Метод LOOCV обладает двумя существенными преимуществами, по сравнению с методом проверочной выборки. Во-первых, он обладает меньшим смещением. При реализации LOOCV мы многократно подгоняем статистическую модель с использованием $n - 1$ обучающих наблюдений — это почти столько же, сколько содержится в составе всего набора данных. В этом состоит отличие от метода проверочной выборки, где размер обучающей выборки обычно составляет примерно половину от размера исходного набора данных. Следовательно, метод LOOCV обычно не переоценивает частоту ошибок на контрольной выборке в той мере, как это делает метод проверочной выборки. Во-вторых, в отличие от многократного применения метода проверочной выборки, которое дает разные результаты из-за случайного разбиения на обучающую и проверочную выборки, многократное выполнение LOOCV всегда даст одинаковые результаты: случайность при разбиении на обучающую и проверочную выборки попросту отсутствует.

Мы применили LOOCV к данным Autos целью нахождения MSE на контрольной выборке для линейной регрессионной модели, которая пред-

⁴ Аббревиатура от «leave-one-out cross-validation». В русскоязычных источниках используется также термин «контроль по отдельным объектам». — Прим. пер.




РИСУНОК 5.3. Схематичное изображение метода LOOCV. Набор из n наблюдений многократно разбивается на обучающую выборку (показана голубым цветом), содержащую все наблюдения, кроме одного, и проверочную выборку, которая содержит только одно это наблюдение (показана бежевым цветом). Ошибка на контрольном множестве затем оценивается путем усреднения n получающихся MSE. Первое обучающее подмножество содержит все наблюдения, за исключением первого, второе обучающее подмножество содержит все наблюдения, за исключением второго, и т. д.

сказывает `mpg` на основе полиномиальных функций `horsepower`. Результаты этого анализа показаны слева на рис. 5.4.

Реализация LOOCV потенциально может оказаться ресурсоемкой, поскольку модель необходимо подогнать n раз. При большом n , а также при длительной подгонке каждой отдельной модели это может занять очень много времени. Для линейной или полиномиальной регрессии, рассчитываемой по методу наименьших квадратов, имеется удивительный экономный способ, который позволяет сравнивать затраты ресурсов на реализацию LOOCV с затратами на подгонку единственной модели. Применяется следующая формула:

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - h_i} \right)^2, \quad (5.2)$$

где $\hat{y}_i$ — это i -е модельное значение отклика, а h_i — показатель разбалансировки, определение которого дано в (3.37) на стр. 112. Эта формула похожа на обычную формулу MSE, за тем исключением, что i -й остаток делится на $1 - h_i$. Показатель разбалансировки изменяется от $1/n$ до 1 и отражает степень влияния того или иного наблюдения на его модельное значение. Следовательно, для соблюдения приведенного равенства остатки наблюдений с высоким показателем разбалансировки увеличиваются пропорционально степени влияния этих наблюдений.

LOOCV — это очень общий метод, применимый для любых предсказательных моделей. Например, мы могли бы применить его для логистической регрессии или дискриминантного анализа, или любых других методов, описанных в предыдущих главах. Волшебная формула (5.2) не является универсальной — в случаях, когда она не работает, модель должна подгоняться повторно n раз.

5.1.3 k -кратная перекрестная проверка

k -кратная
перекрест-
ная
проверка

Альтернативой LOOCV является k -кратная перекрестная проверка⁵. Этот метод подразумевает случайное разбиение совокупности наблюдений на k групп, или *блоков*, примерно одинакового размера. Первый блок служит в качестве проверочной выборки, а модель подгоняется по остальным $k - 1$ блокам. Среднеквадратичная ошибка MSE_1 рассчитывается далее по наблюдениям из удержанного блока. Эта процедура повторяется k раз: каждый раз в качестве проверочной выборки используется другой блок. В результате этого процесса получают k оценок ошибки на контрольном множестве — $MSE_1, MSE_2, \dots, MSE_k$. Итоговая оценка рассчитывается путем усреднения этих значений:

$$CV_{(k)} = \frac{1}{k} \sum_{i=1}^k MSE_i. \quad (5.3)$$

Иллюстрация метода k -кратной проверки приведена на рис. 5.5.

Нетрудно увидеть, что LOOCV является частным случаем k -кратной перекрестной проверки, где k равно n . На практике k -кратная перекрестная проверка обычно выполняется с использованием $k = 5$ или $k = 10$. Почему $k = 5$ или $k = 10$ лучше, чем $k = n$? Наиболее очевидное преимущество заключается в экономии вычислительных ресурсов. LOOCV требует подгонки статистической модели n раз. Это потенциально может оказаться очень ресурсоемким процессом (за исключением линейных моделей, подгоняемых по методу наименьших квадратов, для которых можно применить формулу (5.2)). Однако перекрестная проверка — очень общий подход, применимый почти для любого метода статистического обучения. Процедуры подгонки некоторых статистических моделей требуют больших объемов вычислений, в связи с чем LOOCV может вызвать вычислительные проблемы, особенно при очень больших n . В то же время для выполнения 10-кратной перекрестной проверки подгонку статистической модели необходимо выполнить только десять раз, что может оказаться намного более выполнимым. Как мы увидим в подразделе 5.1.4, могут быть и другие, не имеющие отношения к ресурсоемкости, преимущества использования 5- или 10-кратной перекрестной проверки — они имеют отношение к компромиссу между смещением и дисперсией.

Справа на рис. 5.4 показаны девять различных оценок среднеквадратичной ошибки для набора данных Auto, каждая из которых была получена в результате случайного разбиения исходных наблюдений на 10 частей. Как видно по этому рисунку, из-за случайного разбиения наблюдений на десять блоков имеет место некоторая вариабельность оценок. Однако эта вариабельность обычно намного ниже вариабельности оценок ошибки на контрольной выборке, получаемых при помощи метода проверочной выборки (см. график, представленный справа на рис. 5.2).

При работе с реальными данными истинная ошибка предсказаний нам не известна, что затрудняет определение точности оценки, получаемой при помощи перекрестной проверки. Однако, используя имитированные данные, мы можем вычислить истинную ошибку и таким образом оценить верность результатов перекрестной проверки. На рис. 5.6 мы изобразили

⁵ В оригинале используется термин « k -fold cross-validation». — Прим. пер.




РИСУНОК 5.4. Перекрестная проверка была применена к набору данных Auto для нахождения ошибки предсказания mpg на основе полиномиальных функций horsepower. Слева: кривая ошибок LOOCV. Справа: 10-кратная перекрестная проверка была повторена девять раз, каждый раз с использованием нового разбиения наблюдений на десять частей. График показывает девять слабо различающихся кривых ошибок, полученных с помощью перекрестной проверки




РИСУНОК 5.5. Схематичное изображение 5-кратной перекрестной проверки. Набор из n наблюдений случайным образом разбивается на пять неперекрывающихся групп. Каждая из этих пяти групп последовательно выступает в качестве проверочной выборки (обозначены бежевым цветом), а остальные группы — в качестве обучающей выборки (показаны голубым цветом). Ошибка предсказаний оценивается путем усреднения пяти итоговых оценок MSE




РИСУНОК 5.6. Истинная и оцененные среднеквадратичные ошибки предсказаний для имитированных данных, показанных на рис. 2.9 (слева), 2.10 (в центре) и 2.11 (справа). Истинная MSE показана голубым цветом, LOOCV-оценки — в виде черной прерывистой линии, а оценки 10-кратной перекрестной проверки — в виде сплошной оранжевой линии. Крестиками показаны минимумы каждой кривой

оценки MSE на контрольной выборке, полученные при помощи перекрестной проверки, и истинные ошибки, получаемые в результате применения сглаживающих сплайнов к имитированным данным из рис. 2.9–2.11 (глава 2). Истинная MSE на контрольной выборке показана голубым цветом. Черные прерывистые и сплошные оранжевые линии показывают оценки, полученные при помощи LOOCV и 10-кратной перекрестной проверки соответственно. На всех трех графиках оценки, полученные при помощи этих двух методов перекрестной проверки, очень похожи. Справа на рис. 5.6 истинная MSE и кривые, соответствующие этим двум методам перекрестной проверки, почти идентичны. В центре на рис. 5.6 все кривые очень похожи в области низких значений гибкости, однако при высоких уровнях гибкости методы перекрестной проверки переоценивают истинную ошибку предсказаний. Слева на рис. 5.6 форма кривых, соответствующих методам перекрестной проверки, в целом имеет правильную форму, однако оба метода недооценивают истинную ошибку на контрольной выборке.

Выполняя перекрестную проверку, мы стремимся определить качество предсказаний той или иной статистической модели на независимых данных; в этом случае нам интересна сама оценка MSE на контрольной выборке. Однако в других случаях нам будет интересно только *положение минимума на кривой ошибок*. Дело в том, что мы можем выполнять перекрестную проверку для нескольких методов статистического обучения или для одного метода с использованием разных уровней его гибкости с целью найти метод, обеспечивающий наименьшую ошибку на контрольной выборке. Здесь важно положение минимума на кривой оцененных ошибок, а не конкретное значение оценки MSE. Как видно на рис. 5.6, несмотря на то что методы перекрестной проверки иногда занижают истинную MSE на контрольных данных, их кривые довольно хорошо определяют правильный уровень гибкости, т. е. уровень, соответствующий наименьшей ошибке предсказаний.

5.1.4 Компромисс между смещением и дисперсией в контексте k -кратной перекрестной проверки

В подразделе 5.1.3 мы отметили, что k -кратная перекрестная проверка с $k < n$ имеет вычислительные преимущества, по сравнению с LOOCV. Однако помимо вычислительных аспектов, менее очевидным, но потенциально более важным преимуществом k -кратной перекрестной проверки является то, что она дает более точную оценку ошибки на контрольной выборке, по сравнению с LOOCV. Это обусловлено компромиссом между смещением и дисперсией.

Как было отмечено в подразделе 5.1.1, метод проверочной выборки может приводить к завышенным оценкам ошибки на контрольной выборке, поскольку при реализации этого метода обучающее множество, по которому подгоняется статистическая модель, содержит только половину всех наблюдений. Используя ту же логику, не составляет труда увидеть, что LOOCV будет давать примерно несмещенные оценки ошибки на контрольной выборке, поскольку каждое обучающее множество содержит $n - 1$ наблюдений, т. е. почти столько же, сколько есть наблюдений в исходном наборе данных. В свою очередь, выполнение k -кратной перекрестной проверки со значением k , равным, например, 5 или 10, будет давать промежуточный уровень смещения, поскольку каждое обучающее множество содержит $(k - 1)n/k$ наблюдений — меньше, чем в случае с LOOCV, но намного больше, чем в случае с методом проверочной выборки. Следовательно, с точки зрения снижения уровня смещения, LOOCV обладает явным преимуществом в сравнении с k -кратной перекрестной проверкой.

Тем не менее мы знаем, что смещение не является единственным источником беспокойства в отношении той или иной статистической процедуры — мы должны также учесть дисперсию этой процедуры. Оказывается, что LOOCV обладает более высокой дисперсией, чем k -кратная перекрестная проверка с $k < n$. Почему это так? Когда мы выполняем LOOCV, мы, по сути, усредняем результаты подгонки n моделей, каждая из которых обучена на почти одинаковом наборе наблюдений; как следствие эти результаты очень сильно (положительно) коррелируют друг с другом. В то же время при выполнении k -кратной перекрестной проверки с $k < n$ мы усредняем результаты подгонки k моделей, которые коррелируют друг с другом в меньшей степени из-за меньшего сходства между их обучающими выборками. Поскольку среднее значение большого числа коррелирующих величин имеет более высокую дисперсию, чем среднее значение большого числа слабо коррелирующих величин, то LOOCV-оценка ошибки предсказаний обычно обладает большей дисперсией, чем оценка ошибки, полученная при помощи k -кратной перекрестной проверки.

В качестве заключения отметим, что компромисс между смещением и дисперсией имеет место и при выборе k для k -кратной перекрестной проверки. Исходя из приведенных выше рассуждений, обычно выполняют 5- или 10-кратную перекрестную проверку, поскольку было установлено, что эти значения обеспечивают оценки ошибки предсказаний с умеренными уровнями смещения и дисперсии.

5.1.5 Перекрестная проверка при решении задач классификации

До сих пор в этой главе мы обсуждали перекрестную проверку в контексте регрессионных моделей, в которых отклик Y является количественным, и поэтому для количественного описания ошибки на контрольном множестве мы использовали MSE. Однако перекрестная проверка может быть также очень полезной для решения задач классификации, когда Y является качественной переменной. При таком сценарии механизм перекрестной проверки не отличается от описанного ранее в этой главе, за тем исключением, что вместо MSE мы выражаем ошибку на контрольной выборке в виде числа неверно классифицированных объектов. Например, для задач классификации частота ошибок при использовании LOOCV принимает форму

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n \text{Err}_i, \quad (5.4)$$

где $\text{Err}_i = I(y_i \neq \hat{y}_i)$. Формулы частот ошибок для k -кратной перекрестной проверки и метода проверочной выборки имеют аналогичную форму.

В качестве примера мы построим несколько моделей логистической регрессии по двумерным данным, изображенным на рис. 2.13. Слева вверху на рис. 5.7 черная сплошная линия соответствует решающей границе, оцененной в результате подгонки к этим данным стандартной логистической регрессии. Поскольку это имитированные данные, мы можем вычислить истинную частоту ошибок на контрольной выборке — она равна 0.201 и существенно превышает байесовскую частоту ошибок, равную 0.133. Очевидно, что в этом случае логистическая регрессия не имеет достаточной гибкости для моделирования байесовской решающей границы. Подобно тому, как мы сделали это в подразделе 3.3.2 при рассмотрении линейных регрессионных моделей, для получения нелинейной решающей границы мы можем легко расширить логистическую регрессию при помощи полиномиальных функций предикторов. Например, мы можем подогнать следующую *квадратичную* логистическую модель:

$$\log \left(\frac{p}{1-p} \right) = \beta_0 + \beta_1 X_1 + \beta_2 X_1^2 + \beta_3 X_2 + \beta_4 X_2^2. \quad (5.5)$$

Справа вверху на рис. 5.7 показана решающая граница, которая теперь принимает изогнутую форму. Однако частота ошибок улучшилась незначительно — до 0.197. Несколько более выраженное улучшение видно на графике, представленном на рис. 5.7 слева внизу, где мы подогнали логистическую регрессию с кубическими полиномами предикторов. Теперь частота ошибок снизилась до 0.160. Использование полиномов четвертой степени (справа внизу) несколько увеличивает частоту ошибок.

На практике при работе с реальными данными байесовская решающая граница и истинная частота ошибочных предсказаний неизвестны. Какую же из четырех изображенных на рис. 5.7 логистических регрессионных моделей нам выбрать? Для принятия решения можем применить перекрестную проверку. Слева на рис. 5.8 черным цветом показаны частоты




РИСУНОК 5.7. Логистические регрессионные модели, подогнанные к данным из рис. 2.13. Байесовская решающая граница показана в виде фиолетовой прерывистой линии. Решающие границы, оцененные на основе полиномиальных функций первой, второй, третьей и четвертой степеней, показаны в виде черных линий. Частоты ошибок для этих четырех регрессионных моделей составляют 0.201, 0.197, 0.160 и 0.162 соответственно, тогда как байесовская частота ошибок равна 0.133




РИСУНОК 5.8. Ошибка классификации объектов на контрольной выборке (коричневая кривая), на обучающей выборке (голубая кривая) и ошибка, полученная при помощи 10-кратной перекрестной проверки (черная кривая) для двумерных данных рис. 5.7. Слева: логистическая регрессия на основе полиномиальных функций предикторов. Степень использованных полиномов указана на оси X . Справа: KNN-классификатор с разными значениями K (числом ближайших соседей)

ошибок, полученные при помощи 10-кратной перекрестной проверки логистических регрессионных моделей с полиномиальными функциями предикторов вплоть до 10-й степени. Истинные частоты ошибок показаны коричневым цветом, а частоты ошибок на обучающих выборках — голубым. Как мы уже видели ранее, при увеличении гибкости модели частота ошибок на обучающей выборке обычно снижается. (На рисунке видно, что хотя частота ошибок на обучающих данных и не снижается монотонно, в целом при увеличении сложности модели она все же имеет тенденцию на снижение.) В то же время частота ошибок на контрольной выборке демонстрирует характерную U-образную форму. Десятикратная перекрестная проверка обеспечивает довольно хорошую аппроксимацию истинной частоты ошибок на контрольной выборке. Несмотря на некоторое занижение частоты ошибок, кривая перекрестной проверки достигает минимума при использовании полиномов четвертой степени, что очень близко к минимуму кривой истинной частоты ошибок на контрольной выборке, который наблюдается при использовании полиномов третьей степени. Более того, применение полиномов четвертой степени могло бы привести к хорошему качеству предсказаний, поскольку истинная частота ошибок на контрольном множестве для полиномов третьей, четвертой, пятой и шестой степеней примерно одинакова.

Справа на рис. 5.8 показаны такие же три кривые для KNN-классификатора с разными значениями K (здесь K означает используемое классификатором количество ближайших соседей, а не количество блоков для перекрестной проверки). Частота ошибок на обучающей выборке снова снижается по мере возрастания гибкости метода, из чего следует, что мы не можем использовать эту частоту ошибок для выбора оптимального значения K . Хотя кривая перекрестной проверки несколько занижает частоту ошибок на контрольной выборке, ее минимум близок к оптимальному значению K .

5.2 Бутстреп

Бутстреп⁶ — это широко применимый и чрезвычайно мощный статистический инструмент, который можно использовать для количественного описания неопределенности в отношении оценки некоторого параметра или метода статистического обучения. В качестве простого примера можно привести использование бутстрепа для оценивания стандартных ошибок коэффициентов некоторой линейной модели. В случае с линейной регрессией этот подход не очень полезен, поскольку мы видели в главе 3, что стандартные статистические программы (например, R) выдают такие стандартные ошибки автоматически. Однако сила бутстрепа заключается в том, что его можно легко применить для широкого круга методов статистического обучения, включая такие методы, для которых меру дисперсии сложно вычислить или получить автоматически при помощи статистических программ.

бутстреп

В этом разделе мы описываем бутстреп на гипотетическом примере, в котором мы хотим определить оптимальное размещение инвестиций на основе простой модели. В разделе 5.3 мы рассмотрим применение бутстрепа для описания вариабельности регрессионных коэффициентов линейной модели.

Представьте, что мы хотим инвестировать некоторую фиксированную сумму денег в два финансовых актива, которые обеспечивают доходность в размере X и Y соответственно, где X и Y — это случайные величины. Мы вложим некоторую долю наших денег α в X , а оставшуюся часть $(1 - \alpha)$ — в Y . Поскольку имеет место вариабельность доходности по этим двум активам, мы хотим выбрать такую долю α , которая минимизирует общий риск, или вариабельность, нашей инвестиции. Иными словами, мы хотим минимизировать $\text{Var}(\alpha X + (1 - \alpha)Y)$. Можно показать, что минимизирующее этот риск значение α вычисляется как

$$\alpha = \frac{\sigma_Y^2 - \sigma_{XY}}{\sigma_X^2 + \sigma_Y^2 - 2\sigma_{XY}}, \quad (5.6)$$

где $\sigma_X^2 = \text{Var}(X)$, $\sigma_Y^2 = \text{Var}(Y)$, а $\sigma_{XY} = \text{Cov}(X, Y)$.

В действительности величины σ_X^2 , σ_Y^2 и σ_{XY} неизвестны. Мы можем вычислить оценки этих величин $\hat{\sigma}_X^2$, $\hat{\sigma}_Y^2$ и $\hat{\sigma}_{XY}$ по данным, которые содержат прошлые измерения X и Y . Затем мы можем оценить значение α , которое минимизирует дисперсию нашей инвестиции, следующим образом:

$$\hat{\alpha} = \frac{\hat{\sigma}_Y^2 - \hat{\sigma}_{XY}}{\hat{\sigma}_X^2 + \hat{\sigma}_Y^2 - 2\hat{\sigma}_{XY}}. \quad (5.7)$$

Рисунок 5.9 иллюстрирует этот подход для нахождения α на основе имитированных данных. На каждом графике мы сгенерировали 100 пар значений доходности для инвестиций X и Y . Эти значения доходности были использованы для оценивания σ_X^2 , σ_Y^2 и σ_{XY} , которые мы подставили в (5.7) для нахождения α . Итоговое значение $\hat{\alpha}$, полученное на основе каждого имитированного набора данных, изменяется от 0.532 до 0.657.

⁶ Устоявшегося перевода «bootstrap» на русский язык не существует. Здесь используется прямая транслитерация этого термина («бутстреп»), чаще всего встречающаяся




РИСУНОК 5.9. На каждом графике изображены 100 имитированных значений доходности инвестиционных активов X и Y . Слева направо и сверху вниз: полученные оценки α составляют 0.576, 0.532, 0.657 и 0.651

Естественным является желание дать количественную характеристику точности нашей оценки α . Для нахождения оценки стандартного отклонения $\hat{\alpha}$ мы повторили процесс имитации 100 пар наблюдений X и Y и расчета α по формуле (5.7) 1000 раз. Тем самым мы получили 1000 оценок α , которые можно обозначить как $\hat{\alpha}_1, \hat{\alpha}_2, \dots, \hat{\alpha}_{1000}$. На рис. 5.10 слева показана гистограмма полученных оценок. Для этих имитаций были использованы параметры $\sigma_X^2 = 1$, $\sigma_Y^2 = 1.25$ и $\sigma_{XY} = 0.5$, и поэтому мы знаем, что $\alpha = 0.6$. Мы отметили это значение при помощи сплошной вертикальной линии на гистограмме. Среднее значение из 1000 оценок α составляет

$$\bar{\alpha} = \frac{1}{1000} \sum_{r=1}^{1000} \hat{\alpha}_r = 0.5996,$$

что очень близко к $\alpha = 0.6$, а стандартное отклонение этой ошибки составляет

$$\sqrt{\frac{1}{1000 - 1} \sum_{r=1}^{1000} (\hat{\alpha}_r - \bar{\alpha})^2} = 0.083.$$

Это дает нам очень хорошее представление о точности $\hat{\alpha}$: $SE(\hat{\alpha}) \approx 0.083$. Таким образом, для случайной выборки из генеральной совокупности мы могли бы ожидать отклонение $\hat{\alpha}$ от α в среднем примерно на 0.08.

Однако на практике описанная выше процедура нахождения $SE(\hat{\alpha})$ неприменима, поскольку в реальности мы не можем взять новые выборки из исходной генеральной совокупности. Тем не менее метод бутстрепа позволяет нам использовать компьютер для подражания процессу создания новых выборок, что дает нам возможность оценить вариабельность $\hat{\alpha}$ без создания настоящих дополнительных выборок. Вместо многократного получения независимых наборов данных из генеральной совокупности мы получаем различные наборы данных путем многократного извлечения наблюдений из уже имеющегося набора данных.




РИСУНОК 5.10. Слева: гистограмма оценок α , полученных путем создания 1000 имитированных выборок из генеральной совокупности. В центре: гистограмма оценок α , полученных на основе 1000 бутстреп-выборок из одного набора данных. Справа: оценки α , приведенные на графиках слева и в центре, показаны в виде диаграммы размахов. На каждом графике розовая линия показывает истинное значение α

Этот подход проиллюстрирован на рис. 5.11 на примере простого набора данных Z , который содержит только 3 наблюдения. Мы случайным образом отбираем n наблюдений из этого набора данных для создания бутстреп-выборки Z^{*1} . Отбор выполняется с *возвращением*⁷ — это означает, что одно и то же наблюдение может встречаться в бутстреп-выборке более одного раза. В этом примере третье наблюдение встречается в Z^{*1} два раза, первое — один раз, а второе — ни одного раза. Заметьте, что если Z^{*1} содержит то или иное наблюдение, то включены как X -, так и Y -значения этого наблюдения. Мы можем использовать Z^{*1} для нахождения оценки α , которую мы обозначим как $\hat{\alpha}^{*1}$. Эта процедура повторяется определенное большое число раз B с целью получения B различных бутстреп-выборок $Z^{*1}, Z^{*2}, \dots, Z^{*B}$ и B соответствующих оценок α — $\hat{\alpha}^{*1}, \hat{\alpha}^{*2}, \dots, \hat{\alpha}^{*B}$. Используя следующую формулу, мы можем вычислить стандартную ошибку этих бутстреп-оценок:

возвраще-
ние

⁷ В оригинале для обозначения этой процедуры используется термин «sampling with replacement». — Прим. пер.

$$SE_B(\hat{\alpha}) = \sqrt{\frac{1}{B-1} \sum_{r=1}^B \left(\hat{\alpha}^{*r} - \frac{1}{B} \sum_{r'=1}^B \hat{\alpha}^{*r'} \right)^2}. \tag{5.8}$$

Эта величина служит оценкой стандартной ошибки $\hat{\alpha}$, полученной на основе исходного набора данных.




РИСУНОК 5.11. Схематическое изображение принципа работы бутстрепа на примере небольшого набора данных с $n = 3$ наблюдениями. Каждая бутстреп-выборка содержит 3 наблюдения, отобранных с возвращением из исходного набора данных. Каждая из этих бутстреп-выборок используется для нахождения оценки α .

Метод бутстрепа проиллюстрирован на рис. 5.10, в центре которого приведена гистограмма 1000 оценок α , каждая из которых была вычислена по отдельной бутстреп-выборке. Эта гистограмма была построена на основе единственного набора данных, из чего следует, что ее можно было бы создать и с использованием реальных данных. Заметьте, что эта гистограмма очень похожа на показанную слева идеализированную гистограмму оценок α , полученных путем создания 1000 имитированных выборок из генеральной совокупности. В частности, бутстреп-оценка $SE(\hat{\alpha})$, рассчитанная по формуле (5.8), составляет 0.087, что очень близко к 0.083 — оценке, полученной на основе 1000 имитированных выборок. Справа показана та же информация, что и на первых двух графиках, но другим

образом — в виде диаграммы размахов оценок α , полученных путем создания 1000 имитированных выборок из генеральной совокупности и на основе бутстреп-выборок. Как и раньше, наблюдается близкое сходство этих двух множеств оценок, что указывает на возможность эффективно применения бутстрепа для нахождения оценки вариабельности $\hat{\alpha}$.

5.3 Лабораторная работа: перекрестная проверка и бутстреп

В этой лабораторной работе мы рассмотрим методы создания повторных выборок, описанные в данной главе. Выполнение некоторых команд из этой лабораторной работы на вашем компьютере может занять определенное время.

5.3.1 Метод проверочной выборки

Мы рассмотрим применение метода проверочной выборки для оценивания ошибок предсказаний разных моделей, построенных по данным из таблицы `Auto`.

Сначала мы воспользуемся функцией `set.seed()` для установления «зерна» генератора случайных чисел R, что позволит читателю этой книги получить результаты, идентичные приведенным ниже. Обычно при выполнении анализа, включающего элемент случайности (как, например, в случае с перекрестной проверкой), установление такого «зерна» является хорошей идеей, поскольку в будущем это позволит с точностью воспроизвести полученные результаты.

зерно

Мы начнем с вызова функции `sample()`, позволяющей разбить данные на две половины путем случайного извлечения 196 наблюдений из исходных 392 наблюдений. Мы будем называть эти наблюдения обучающей выборкой.

sample()

```
> library(ISLR)
> set.seed(1)
> train = sample(392, 196)
```

(Здесь мы используем сокращенную форму записи команды `sample()`; подробнее см. `?sample`.) Далее мы воспользуемся аргументом `subset` функции `lm()` для подгонки линейной модели на основе только тех наблюдений, которые входят в состав обучающей выборки.

```
> lm.fit = lm(mpg ~ horsepower, data = Auto, subset = train)
```

Теперь мы применим функцию `predict()`, чтобы предсказать отклик для всех 392 наблюдений, а затем — функцию `mean()` для вычисления MSE по 196 наблюдениям из проверочной выборки. Обратите внимание, что индекс `-train` в приведенной ниже команде выбирает только те наблюдения, которые не являются частью обучающей выборки.

```
> attach(Auto)
> mean((mpg - predict(lm.fit, Auto))[-train]^2)
[1] 26.14
```


Таким образом, оценка среднеквадратичной ошибки на контрольной выборке для этой линейной регрессионной модели составляет 26.14. Мы можем воспользоваться функцией `poly()` для оценивания ошибки на контрольной выборке для квадратичной и кубической регрессионных моделей.

```
> lm.fit2 = lm(mpg ~ poly(horsepower, 2), data = Auto,
               subset = train)
> mean((mpg - predict(lm.fit2, Auto))[-train]^2)
[1] 19.82
> lm.fit3 = lm(mpg ~ poly(horsepower, 3), data = Auto,
               subset = train)
> mean((mpg - predict(lm.fit3, Auto))[-train]^2)
[1] 19.78
```

Эти ошибки составляют 19.82 и 19.78 соответственно. Если мы выберем несколько отличающуюся обучающую выборку, то получим немного другие ошибки на проверочной выборке.

```
> set.seed(2)
> train = sample(392, 196)
> lm.fit = lm(mpg ~ horsepower, subset = train)
> mean((mpg - predict(lm.fit, Auto))[-train]^2)
[1] 23.30
> lm.fit2 = lm(mpg ~ poly(horsepower, 2), data = Auto,
               subset = train)
> mean((mpg - predict(lm.fit2, Auto))[-train]^2)
[1] 18.90
> lm.fit3 = lm(mpg ~ poly(horsepower, 3), data = Auto,
               subset = train)
> mean((mpg - predict(lm.fit3, Auto))[-train]^2)
[1] 19.26
```

Разбивая наблюдения на обучающую и проверочную выборки, мы обнаружим, что ошибки на проверочной выборке для линейной, квадратичной и кубической моделей составляют 23.30, 18.90 и 19.26 соответственно.

Эти результаты согласуются с нашими предыдущими выводами: модель, которая предсказывает `mpg` на основе квадратичной функции `horsepower`, обладает более высоким качеством, чем модель, включающая только линейную функцию `horsepower`, и есть мало оснований предпочесть модель, основанную на кубической функции `horsepower`.

5.3.2 Перекрестная проверка по отдельным наблюдениям

LOOCV—оценку ошибки можно вычислить автоматически для любой обобщенной линейной модели при помощи функций `glm()` и `cv.glm()`. В лабораторной работе к главе 4 для построения логистической регрессии мы применили функцию `glm()` в сочетании с аргументом `family = "binomial"`. Но если мы вызовем `glm()` без указания аргумента `family`, то она рассчитает линейную регрессию, в точности как функция `lm()`. Например, команды

`cv.glm()`

```
> glm.fit = glm(mpg ~ horsepower, data = Auto)
> coef(glm.fit)
(Intercept)  horsepower
      39.936      -0.158
```

и

```
> lm.fit = lm(mpg ~ horsepower, data = Auto)
> coef(lm.fit)
(Intercept)  horsepower
      39.936      -0.158
```

дают идентичные линейные регрессионные модели. В этой лабораторной работе мы будем строить линейные регрессионные модели при помощи функции `glm()`, а не `lm()`, поскольку первую из этих функций можно использовать совместно с `cv.glm()`. Функция `cv.glm()` является частью библиотеки `boot`.

```
> library(boot)
> glm.fit = glm(mpg ~ horsepower, data = Auto)
> cv.err = cv.glm(Auto, glm.fit)
> cv.err$delta
      1      1
24.23 24.23
```

Функция `cv.glm()` возвращает список с несколькими компонентами. Два числа, хранящихся в векторе `delta`, представляют собой результаты перекрестной проверки. В данном случае эти числа одинаковы (с точностью до второго знака) и соответствуют LOOCV-оценке, определение которой дано в (5.1). Ниже мы обсуждаем ситуацию, в которой эти два числа различаются. Наша LOOCV-оценка ошибки на контрольном множестве примерно равна 24.23.

Мы можем повторить эту процедуру для полиномиальных моделей с возрастающей сложностью структуры. Чтобы автоматизировать данный процесс, мы применяем функцию `for()` для инициализации цикла, который последовательно подгоняет полиномиальные регрессионные модели со степенью от $i = 1$ до $i = 5$, вычисляет соответствующую ошибку при помощи перекрестной проверки и сохраняет результат в i -м элементе вектора `cv.error`. Мы начинаем с инициализации этого вектора. Скорее всего, на выполнение цикла потребуется пара минут.

```
> cv.error = rep(0, 5)
> for(i in 1:5){
+   glm.fit = glm(mpg ~ poly(horsepower, i), data = Auto)
+   cv.error[i] = cv.glm(Auto, glm.fit)$delta[1]
+ }
> cv.error
[1] 24.23 19.25 19.33 19.42 19.03
```

Как и на рис. 5.4, мы наблюдаем резкое снижение оценки MSE на контрольной выборке при переходе от линейной к квадратичной модели и отсутствие какого-либо выраженного улучшения при дальнейшем увеличении степени полиномов.

5.3.3 k -кратная перекрестная проверка

Функцию `cv.glm()` можно применять также для выполнения k -кратной перекрестной проверки. Ниже для набора данных `Auto` мы используем $k = 10$ — часто применяемое значение k . Как и ранее, мы устанавливаем значение зерна генератора случайных чисел и инициализируем вектор, в котором мы будем сохранять оценки ошибок, соответствующие полиномиальным моделям со степенью от 1 до 10.

```
> set.seed(17)
> cv.error.10 = rep(0, 10)
> for (i in 1:10) {
+   glm.fit = glm(mpg ~ poly(horsepower, i), data = Auto)
+   cv.error.10[i] = cv.glm(Auto, glm.fit, K = 10)$delta[1] }
> cv.error.10
[1] 24.21 19.19 19.31 19.34 18.88 19.02 18.90 19.71 18.95 19.50
```

Заметьте, что длительность вычислений намного короче, чем в случае с LOOCV. (В принципе, благодаря формуле (5.2) длительность вычислений у LOOCV для линейной модели, подгоняемой по методу наименьших квадратов, должна быть короче времени, уходящего на реализацию k -кратной перекрестной проверки, но, к сожалению, функция `cv.glm()` не использует преимущество этой формулы.) Мы по-прежнему не наблюдаем убедительного свидетельства в пользу того, полиномы третьей или более высокой степени приводят к более низкой ошибке на контрольном множестве, по сравнению с квадратичной моделью.

В подразделе 5.3.2 мы видели, что при выполнении LOOCV два числа из вектора `delta` оказались практически одинаковыми. Однако при использовании k -кратной перекрестной проверки они несколько различаются. Первое из этих чисел — это стандартная оценка, полученная при помощи k -кратной перекрестной проверки, согласно (5.3). Второе число — это та же оценка, но с поправкой на смещение. Для этого набора данных эти две оценки очень похожи.

5.3.4 Бутстреп

Мы продемонстрируем использование бутстрепа на примере простого примера из раздела 5.2, а также на примере оценивания точности предсказаний линейной регрессионной модели, построенной по данным `Auto`.

Оценивание точности статистического параметра

Одним из больших преимуществ метода бутстрепа является то, что его можно применять почти во всех ситуациях. Не требуется никаких сложных математических вычислений. Выполнение бутстрепа в R состоит из двух шагов. На первом шаге мы должны создать функцию, которая вычисляет интересующий нас параметр. На втором шаге мы применяем функцию `boot()` из библиотеки `boot` для реализации бутстрепа путем многократного извлечения выборок из данных с возвращением.

Набор данных `Portfolio` из пакета `ISLR` описан в разделе 5.2. Чтобы применить бутстреп к этим данным, вы сначала должны создать функцию

`alpha.fn()`, которая принимает данные (X, Y) и вектор с индексными номерами наблюдений, используемых для вычисления α . Затем эта функция возвращает оценку α , рассчитанную на основе соответствующих наблюдений.

```
> alpha.fn = function(data, index){
+ X = data$X[index]
+ Y = data$Y[index]
+ return((var(Y) - cov(X,Y)) / (var(X) + var(Y) - 2*cov(X, Y)))
+ }
```

Эта функция возвращает оценку α , полученную в результате применения формулы (5.7) к наблюдениям с индексными номерами `index`. Например, следующая команда говорит R рассчитать α по всем 100 наблюдениям:

```
> alpha.fn(Portfolio, 1:100)
[1] 0.576
```

Следующая команда использует функцию `sample()` для случайного извлечения с возвращением 100 наблюдений из диапазона от 1 до 100. Это аналогично созданию новой бутстреп-выборки и повторному вычислению $\hat{\alpha}$ на основе этих новых данных.

```
> set.seed(1)
> alpha.fn(Portfolio, sample(100, 100, replace = TRUE))
[1] 0.596
```

Мы можем реализовать бутстреп-анализ путем многократного повторения этой команды и сохранения соответствующих оценок α для дальнейшего вычисления их стандартного отклонения. Однако функция `boot()` автоматизирует этот процесс. Ниже мы создаем $R = 1000$ бутстреп-оценок α .

```
> boot(Portfolio, alpha.fn, R = 1000)
```

ORDINARY NONPARAMETRIC BOOTSTRAP

Call:

```
boot(data = Portfolio, statistic = alpha.fn, R = 1000)
```

Bootstrap Statistics :

	original	bias	std . error
t1*	0.5758	-7.315e -05	0.0886

Эти результаты показывают, что оценка α , рассчитанная на основе исходных данных, составляет 0.5758, а бутстреп-оценка $SE(\hat{\alpha}) = 0.0886$.

Оценивание точности линейной регрессионной модели

Метод бутстреп можно применить для оценивания вариабельности коэффициентов, а также точности предсказаний той или иной статистической модели. Здесь мы применим бутстреп для оценивания вариабельности оценок коэффициентов β_0 и β_1 — свободного члена и углового коэффициента

линейной регрессионной модели, построенной по данным Auto для предсказания mpg по horsepower. Мы сравним бутстреп-оценки с оценками, вычисленными по формулам для $SE(\hat{\beta}_0)$ и $SE(\hat{\beta}_1)$ из подраздела 3.1.2.

Сначала мы создаем простую функцию `boot.fn()`, которая принимает данные Auto и набор индексных номеров наблюдений и возвращает оценки свободного члена и углового коэффициента линейной регрессионной модели. Затем мы применяем эту функцию ко всей совокупности из 392 наблюдений для вычисления оценок β_0 и β_1 по обычным формулам для коэффициентов линейной регрессионной модели (глава 3). Заметьте, что нам не нужны фигурные скобки в начале и в конце тела функции, поскольку оно состоит только из одной строки.

```
> boot.fn = function(data, index)
+ return(coef(lm(mpg ~ horsepower, data = data, subset = index)))
> boot.fn(Auto, 1:392)
(Intercept)  horsepower
   39.936      -0.158
```

Функцию `boot.fn()` можно использовать также для создания бутстреп-оценок свободного члена и углового коэффициента путем случайного извлечения наблюдений с возвращением. Ниже мы приводим два примера.

```
> set.seed(1)
> boot.fn(Auto, sample(392, 392, replace = TRUE))
(Intercept)  horsepower
   38.739      -0.148
> boot.fn(Auto, sample(392, 392, replace = TRUE))
(Intercept)  horsepower
   40.038      -0.160
```

Далее мы применяем функцию `boot()` для вычисления стандартных ошибок 1000 бутстреп-оценок свободного члена и углового коэффициента.

```
> boot(Auto, boot.fn, 1000)
```

ORDINARY NONPARAMETRIC BOOTSTRAP

Call:

```
boot(data = Auto, statistic = boot.fn, R = 1000)
```

Bootstrap Statistics :

	original	bias	std. error
t1*	39.936	0.0297	0.8600
t2*	-0.158	-0.0003	0.0074

Из этих результатов следует, что бутстреп-оценка $SE(\hat{\beta}_0)$ составляет 0.86, а бутстреп-оценка $SE(\hat{\beta}_1)$ — 0.0074. К обсуждалось в подразделе 3.2.1, для вычисления стандартных ошибок коэффициентов линейной регрессионной модели можно применять готовые формулы. Такие оценки можно получить при помощи функции `summary()`.

Стандартные ошибки оценок $\hat{\beta}_0$ и $\hat{\beta}_1$, вычисленные по формулам из подраздела 3.1.2, составляют 0.717 для свободного члена и 0.0064 для углового коэффициента. Интересно, что эти значения несколько отличаются

от оценок, полученных с применением бутстрепа. Указывает ли это на проблему с бутстрепом? В действительности дело обстоит иначе. Вспомните, что стандартные формулы, приведенные в уравнении на стр. 78, основаны на определенных допущениях. Например, они зависят от неизвестного параметра σ^2 — остаточной дисперсии. В связи с этим мы оцениваем σ^2 по RSS. Хотя формулы для стандартных ошибок коэффициентов не зависят от правильности линейной спецификации модели, формула для оценки σ^2 — зависит. На рис. 3.8 (стр. 104) мы видим, что в данных имеет место нелинейная зависимость, в связи с чем остатки линейной модели, а следовательно и $\hat{\sigma}^2$, будут завышенными. Во-вторых, стандартные формулы предполагают (отчасти нереалистично), что x_i являются фиксированными значениями и вся вариабельность обусловлена разбросом остатков ϵ_i . Метод бутстрепа не полагается ни на одно из этих допущений и поэтому с большой вероятностью дает более точные оценки стандартных ошибок $\hat{\beta}_0$ и $\hat{\beta}_1$, чем функция `summary()`.

Ниже мы вычисляем бутстреп-оценки и обычные оценки стандартных ошибок коэффициентов квадратичной модели, подогнанной к тем же данным. Поскольку квадратичная модель хорошо описывает эти данные (рис. 3.8), здесь мы наблюдаем более тесное соответствие между бутстреп-оценками и обычными оценками $SE(\hat{\beta}_0)$, $SE(\hat{\beta}_1)$ и $SE(\hat{\beta}_2)$.

```
> boot.fn = function(data, index)
+ coefficients(lm(mpg ~ horsepower + I(horsepower^2),
+               data = data, subset = index))
> set.seed(1)
> boot(Auto, boot.fn, 1000)
```

ORDINARY NONPARAMETRIC BOOTSTRAP

Call:

```
boot(data = Auto, statistic = boot.fn, R = 1000)
```

Bootstrap Statistics :

	original	bias	std. error
t1*	56.900	6.098e-03	2.0945
t2*	-0.466	-1.777e-04	0.0334
t3*	0.001	1.324e-06	0.0001

```
> summary(lm(mpg ~ horsepower + I(horsepower^2),
+           data = Auto))$coef
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	56.9001	1.80043	32	1.7e-109
horsepower	-0.4662	0.03112	-15	2.3e-40
I(horsepower^2)	0.0012	0.00012	10	2.2e-21

5.4 Упражнения

Теоретические

1. Используя основные статистические свойства дисперсии, а также приемы интегрального исчисления для одной переменной, выведите

формулу (5.6). Другими словами, докажите, что α из (5.6) действительно минимизирует $\text{Var}(\alpha X + (1 - \alpha)Y)$.

2. Теперь мы определим вероятность попадания того или иного наблюдения в бутстреп-выборку. Предположим, что мы делаем бутстреп-выборку из совокупности, содержащей n наблюдений.
 - (a) Какова вероятность того, что первое наблюдение в бутстреп-выборке *не является* j -м наблюдением в исходной совокупности?
 - (b) Какова вероятность того, что второе наблюдение *не является* j -м наблюдением в исходной совокупности?
 - (c) Покажите, что вероятность *невхождения* j -го наблюдения в бутстреп-выборку составляет $(1 - 1/n)^n$.
 - (d) Чему равна вероятность того, что j -е наблюдение входит в бутстреп-выборку при $n = 5$?
 - (e) Чему равна вероятность того, что j -е наблюдение входит в бутстреп-выборку при $n = 100$?
 - (f) Чему равна вероятность того, что j -е наблюдение входит в бутстреп-выборку при $n = 10\,000$?
 - (g) Постройте график, который показывает вероятность вхождения j -го наблюдения в бутстреп-выборку для целых чисел n от 1 до 100 000. Прокомментируйте, что вы видите.
 - (h) Теперь мы количественно исследуем вероятность того, что бутстреп-выборка объемом $n = 100$ содержит j -е наблюдение. Здесь $j = 4$. Мы многократно создаем бутстреп-выборки и каждый раз отмечаем факт вхождения четвертого наблюдения в конкретную бутстреп-выборку.

```
> store = rep(NA, 10000)
> for (i in 1:10000) {
  store[i] = sum(sample(1:100, rep = TRUE) == 4) > 0
}
> mean(store)
```

Прокомментируйте полученные результаты.

3. Теперь мы повторим пройденный материал по k -кратной перекрестной проверке.
 - (a) Объясните, как работает k -кратная перекрестная проверка.
 - (b) Каковы преимущества и недостатки k -кратной перекрестной проверки, по сравнению с
 - i. методом проверочной выборки;
 - ii. LOOCV?
4. Предположим, что мы применяем тот или иной метод статистического обучения для предсказания отклика Y по некоторому значению предиктора X . Опишите подробно, как мы могли бы оценить стандартное отклонение этого предсказываемого значения.

Практические

5. В главе 4 мы воспользовались логистической регрессией для предсказания вероятности неуплаты долга по кредитной карте (`default`) на основе дохода клиента (`income`) и величины долга (`balance`) (данные из таблицы `Default`). Теперь мы применим метод проверочной выборки для оценивания частоты ошибок, совершаемых этой логистической регрессионной моделью. Не забудьте перед началом анализа установить зерно генератора случайных чисел.
- (a) Постройте логистическую регрессионную модель, которая использует `income` и `balance` для предсказания `default`.
 - (b) Применив метод проверочной выборки, оцените частоту ошибок, совершаемых этой моделью. Для этого вы должны выполнить следующие шаги:
 - i. Разбейте исходные данные на обучающую и проверочную выборки.
 - ii. Подгоните множественную логистическую регрессионную модель, используя только обучающие данные.
 - iii. Получите предсказания неуплаты долга для каждого клиента из проверочной выборки, вычислив апостериорную вероятность дефолта для соответствующего клиента и отнеся его к категории неплательщиков в случае, если эта апостериорная вероятность превышает 0.5.
 - iv. Вычислите частоту ошибок на проверочной выборке, которая представляет собой долю неверно классифицированных наблюдений в проверочной выборке.
 - (c) Повторите процесс из (b) три раза, используя разные разбиения наблюдений на обучающую и проверочную выборки. Прокомментируйте полученные результаты.
 - (d) Теперь мы рассмотрим логистическую регрессионную модель, которая предсказывает вероятность дефолта на основе `income`, `balance` и индикаторной переменной `student`. Оцените частоту ошибок, совершаемых этой моделью на новых данных, используя метод проверочной выборки. Дайте комментарий относительно того, приводит ли включение переменной `student` к снижению частоты ошибок на проверочной выборке.
6. Мы продолжаем рассмотрение логистической регрессионной модели, предсказывающей вероятность `default` на основе `income` и `balance` по данным из таблицы `Default`. В частности, теперь мы вычислим оценки стандартных ошибок коэффициентов `income` и `balance` в этой модели, применив два разных способа: (1) бутстреп и (2) использование готовых формул, реализованных в функции `glm()`. Не забудьте перед началом анализа установить зерно генератора случайных чисел.
- (a) Воспользовавшись функциями `summary()` и `glm()`, определите стандартные ошибки коэффициентов переменных `income` и `balance` из множественной логистической регрессионной модели, которая включает оба предиктора.

- (b) Напишите функцию `boot.fn()`, которая принимает таблицу данных `Default` и вектор с индексными номерами наблюдений и возвращает оценки коэффициентов `income` и `balance` из множественной логистической регрессионной модели.
 - (c) Примените функцию `boot` вместе с вашей функцией `boot.fn()` для нахождения оценок стандартных ошибок регрессионных коэффициентов `income` и `balance`.
 - (d) Прокомментируйте величины стандартных ошибок, полученных при помощи функции `glm()` и вашей бутстреп-функции.
7. В подразделах 5.3.2 и 5.3.3 мы видели, что для вычисления LOOCV-оценок ошибки на контрольной выборке можно использовать функцию `cv.glm()`. В качестве альтернативы эти вычисления можно было бы проделать просто с помощью функций `glm()` и `predict.glm()`, организовав `for`-цикл. Сейчас вы реализуете этот подход для вычисления LOOCV-ошибки для простой логистической регрессионной модели на примере данных `Weekly`. Напомним, что определение LOOCV-ошибки для задач классификации дано в формуле (5.4).
- (a) Постройте логистическую регрессионную модель, которая предсказывает `Direction` по `Lag1` и `Lag2`.
 - (b) Постройте логистическую регрессионную модель, которая предсказывает `Direction` на основе `Lag1` и `Lag2` по всем наблюдениям, за исключением первого.
 - (c) Примените модель из (b), чтобы предсказать направление движения рынка для первого наблюдения. Вы можете сделать это, предсказав рост рынка при $P(\text{Direction} = \text{"Up"} \mid \text{Lag1}, \text{Lag2}) > 0.5$. Правильным ли оказалось предсказание для этого наблюдения?
 - (d) Напишите `for`-цикл для i от 1 до n , где n — это число наблюдений в таблице данных, который выполняет следующие шаги:
 - i. Подгонка логистической регрессионной модели для предсказания `Direction` по `Lag1` и `Lag2` с использованием всех наблюдений, за исключением i -го.
 - ii. Вычисление апостериорной вероятности роста рынка для i -го наблюдения.
 - iii. Предсказание роста рынка на основе апостериорной вероятности для i -го наблюдения.
 - iv. Определение того, была ли допущена ошибка в отношении направления движения рынка для i -го наблюдения. Если ошибка была допущена, покажите это при помощи 1, а если нет — при помощи 0.
 - (e) Вычислите среднее значение из n чисел, полученных в (d)iv, для нахождения LOOCV-оценки ошибки на контрольной выборке. Прокомментируйте свои результаты.
8. Теперь мы выполним перекрестную проверку на имитированном наборе данных.

- (a) Создайте набор имитированных данных следующим образом:

```
> set.seed(1)
> y = rnorm(100)
> x = rnorm(100)
> y = x - 2*x^2 + rnorm(100)
```

Что в этом наборе данных n , а что — p ? Запишите модель, породившую эти данные, в виде уравнения.

- (b) Постройте график зависимости Y от X . Прокомментируйте, что вы видите.
- (c) Задайте зерно генератора случайных чисел и вычислите LOOCV-ошибки предсказаний, возникающие в результате подгонки следующих четырех моделей по методу наименьших квадратов:

- i. $Y = \beta_0 + \beta_1 X + \epsilon$
- ii. $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \epsilon$
- iii. $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \epsilon$
- iv. $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \beta_4 X^4 + \epsilon$.

Обратите внимание: для создания единой таблицы данных, содержащей X и Y , полезной может оказаться функция `data.frame()`.

- (d) Повторите (c), применив другое зерно генератора случайных чисел, и опишите свои результаты. Похожи ли эти результаты на то, что вы получили в (c)? Почему?
- (e) Какая из четырех моделей в (c) обладала наиболее низкой LOOCV-ошибкой? Ожидали ли вы такой результат? Объясните свой ответ.
- (f) Дайте комментарии в отношении статистической значимости оценок коэффициентов, полученных для каждой модели в (c) методом наименьших квадратов. Согласуются ли эти результаты с выводами, сделанными на основе результатов перекрестной проверки?

9. Теперь мы рассмотрим набор данных `Boston` из библиотеки `MASS`.

- (a) Используя этот набор данных, вычислите оценку среднего значения `medv` в генеральной совокупности. Обозначьте эту оценку как $\hat{\mu}$.
- (b) Вычислите оценку стандартной ошибки $\hat{\mu}$. Интерпретируйте этот результат.

Подсказка: мы можем вычислить стандартную ошибку выборочной средней, разделив выборочное стандартное отклонение на квадратный корень из объема выборки.

- (c) Теперь оцените стандартную ошибку $\hat{\mu}$, применив бутстреп. Насколько она отличается от величины, полученной вам в (b)?

- (d) Используя свою бутстреп-оценку из (c), вычислите 95%-ный доверительный интервал для среднего значения `medv`. Сравните его с результатами, полученными при помощи `t.test(Boston$medv)`.

Подсказка: вы можете вычислить приблизительный 95%-ный доверительный интервал по формуле $[\hat{\mu} - 2SE(\hat{\mu}), \hat{\mu} + 2SE(\hat{\mu})]$.

- (e) Используя этот набор данных, вычислите оценку медианы ($\hat{\mu}_{med}$) переменной `medv` в генеральной совокупности.
- (f) Теперь мы хотели бы оценить стандартную ошибку $\hat{\mu}_{med}$. К сожалению, простой формулы для вычисления стандартной ошибки медианы не существует. Поэтому для получения такой оценки примените бутстреп. Прокомментируйте свои результаты.
- (g) Используя этот набор данных, вычислите десятый процентиль ($\hat{\mu}_{0.1}$) стоимости домов в пригородах Бостона. (Вы можете использовать для этого функцию `quantile()`.)
- (h) Воспользуйтесь бутстрепом для нахождения стандартной ошибки $\hat{\mu}_{0.1}$. Прокомментируйте свои результаты.

Глава 6

Отбор и регуляризация линейных моделей

В регрессионных задачах для описания связи между откликом Y и набором переменных $X_1, X_2, \dots, X_p$ часто используется стандартная линейная модель вида

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p + \epsilon. \quad (6.1)$$

В главе 3 мы видели, что обычно эту модель подгоняют по методу наименьших квадратов.

В следующих главах мы рассмотрим некоторые подходы, расширяющие методологию линейных моделей. В главе 7 мы обобщим (6.1) на случай нелинейных, но все же аддитивных зависимостей, а в главе 8 мы рассмотрим еще более общие нелинейные модели. Однако линейная модель имеет выраженное преимущество с точки зрения возможности сделать статистические выводы, и при решении практических проблем она оказывается удивительно хорошим конкурентом нелинейных методов. Поэтому, прежде чем погрузиться в «нелинейный мир», в этой главе мы обсудим некоторые способы, позволяющие усовершенствовать простую линейную модель с помощью процедур оценки параметров, альтернативных обычному методу наименьших квадратов.

Зачем нам использовать какую-то другую процедуру вместо метода наименьших квадратов? Как мы вскоре увидим, альтернативные процедуры могут привести к более высокой *точности предсказаний* и *интерпретируемости модели*.

- *Точность предсказаний*: при условии, что истинная зависимость между откликом и предикторами является примерно линейной, метод наименьших квадратов будет обладать низким смещением. При $n \gg p$, т. е. когда количество наблюдений n намного превышает количество переменных p , метод наименьших квадратов обычно обладает также низкой дисперсией и, следовательно, обеспечивает хорошее качество предсказаний на контрольных наблюдениях. Однако если n превышает p незначительно, то модель, подогнанная по методу наименьших квадратов, может проявлять заметную дисперсию, что сопровождается переобучением и, как следствие, низким качеством

предсказаний на новых наблюдениях, которые не были задействованы в обучении модели. В случае же, когда $p > n$, метод наименьших квадратов не способен дать уникальные оценки параметров модели: дисперсия *бесконечна*, и этот метод вообще неприменим. *Накладывая ограничения* на оцененные коэффициенты, или «сжимаемая» их, мы можем существенно снизить дисперсию за счет незначительного увеличения смещения. Это может привести к существенным улучшениям точности предсказаний отклика на наблюдениях, которые не были использованы в обучении модели.

- *Интерпретируемость модели*: часто случается так, что некоторые или даже многие переменные, включенные в регрессионную модель, в действительности не связаны с откликом. Включение таких *несущественных* переменных приводит к ненужной сложности итоговой модели. Удалив такие переменные, т. е. приравняв их коэффициенты к нулю, мы можем получить легко интерпретируемую модель. При использовании метода наименьших квадратов получение каких-либо коэффициентов, в точности равных нулю, крайне маловероятно. В этой главе мы рассмотрим некоторые подходы для автоматического *отбора признаков*, или *отбора переменных*, т. е. исключения несущественных переменных из множественной регрессионной модели.

Существует много альтернатив (как классических, так и современных) использованию метода наименьших квадратов для подгонки модели (6.1). В этой главе мы обсуждаем три важных класса таких методов.

- *Отбор подмножества переменных*: этот подход включает определение некоторого набора переменных, которые, как мы думаем, связаны с откликом. Далее мы подгоняем модель по методу наименьших квадратов с использованием этого уменьшенного набора переменных.
- *Сжатие*: Этот подход включает подгонку модели, содержащей все p предикторов. Однако, в отличие от коэффициентов, получаемых по методу наименьших квадратов, здесь оцененные коэффициенты «сжимаются» в направлении к нулю. Эффектом такого сжатия (также известно как «регуляризация») является снижение дисперсии. В зависимости от типа выполняемого сжатия оценки некоторых коэффициентов могут оказаться в точности равными нулю. Следовательно, методы сжатия могут выполнять отбор переменных.
- *Снижение размерности*: этот подход включает проецирование p предикторов на M -мерное подпространство, где $M < p$. Это достигается путем вычисления M различных *линейных комбинаций*, или *проекций*, переменных. Далее эти проекции используются в качестве предикторов для подгонки линейной регрессионной модели по методу наименьших квадратов.

В следующих разделах мы описываем каждый из этих подходов более детально, а также обсуждаем их преимущества и недостатки. Хотя в этой главе описываются дополнения и модификации линейной регрессионной модели из главы 3, те же концепции применимы и к другим методам, таким как методы классификации из главы 4.

6.1 Отбор подмножества переменных

В этом разделе мы рассматриваем некоторые методы отбора подмножества предикторов. Они включают процедуры нахождения оптимального подмножества предикторов и пошагового отбора моделей.

6.1.1 Отбор оптимального подмножества

Чтобы выполнить *отбор оптимального подмножества*¹, мы подгоняем отдельную регрессию по методу наименьших квадратов для всех возможных комбинаций из p предикторов. Другими словами, мы подгоняем все p моделей, содержащих только один предиктор, все $\binom{p}{2} = p(p-1)/2$ моделей, содержащих в точности два предиктора, и т. д. Далее мы проверяем все получившиеся модели с целью определить наиболее *оптимальную* из них.

отбор
оптималь-
ного под-
множества

Проблема нахождения *оптимальной* модели среди 2^p возможных вариантов путем отбора оптимального подмножества нетривиальна. Обычно эта процедура разбивается на две стадии, описанные в алгоритме 6.1.

Алгоритм 6.1 Отбор оптимального подмножества переменных

1. Пусть M_0 обозначает *нулевую модель*, которая не содержит предикторов. Для каждого наблюдения эта модель предсказывает просто выборочное среднее значение.
 2. Для $k = 1, 2, \dots, p$:
 - (a) Постройте все $\binom{p}{k}$ моделей, которые содержат в точности k предикторов.
 - (b) Выберите *наиболее оптимальную* среди этих $\binom{p}{k}$ моделей и назовите ее M_k . Здесь под оптимальной понимается модель, имеющая наименьшую сумму квадратов остатков (RSS), или, что эквивалентно, максимальное значение R^2 .
 3. Выберите единственную оптимальную модель среди $M_0, \dots, M_p$, используя такие полученные при помощи перекрестной проверки показатели, как ошибка на контрольной выборке, C_p (AIC), BIC или скорректированный коэффициент детерминации R^2 .
-

На втором шаге алгоритма 6.1 для каждого подмножества предикторов определяется оптимальная модель (по обучающим данным) с целью снижения размерности задачи с 2^p до $p+1$ возможных моделей. На рис. 6.1 эти модели образуют нижнюю границу, обозначенную красным цветом.

Далее для нахождения единственной оптимальной модели мы просто должны выбрать среди $p+1$ вариантов. Эту задачу следует выполнять с большой осторожностью, поскольку по мере увеличения количества предикторов RSS этих $p+1$ моделей монотонно снижается, а R^2 монотонно

¹ В оригинале используется термин «best subset selection». — Прим. пер.

возрастает. Следовательно, если для выбора оптимальной модели мы применяем эти критерии, то в итоге мы всегда выберем модель, содержащую весь набор переменных. Проблема заключается в том, что низкая RSS или высокий коэффициент детерминации R^2 указывают на модель с низкой ошибкой на обучающей выборке, тогда как мы хотим выбрать модель с низкой ошибкой на контрольной выборке. (Как было показано в главе 2 на рис. 2.9–2.11, ошибка на обучающей выборке обычно существенно ниже ошибки на контрольной выборке, но при этом низкая ошибка на обучающей выборке никоим образом не гарантирует низкой ошибки на контрольной выборке.) Поэтому на шаге 3 для выбора среди $M_0, M_1, \dots, M_p$ мы применяем такие полученные при помощи перекрестной проверки показатели, как ошибка на контрольной выборке, C_p , ВИС или скорректированный коэффициент детерминации R^2 . Эти подходы обсуждаются в подразделе 6.1.3.




РИСУНОК 6.1. Показаны RSS и R^2 для всех возможных моделей, содержащих определенное подмножество из десяти предикторов из набора данных Credit. Граница, показанная красным цветом, проходит через точки, которые соответствуют оптимальным (по RSS и R^2) моделям соответствующего размера. Хотя набор данных содержит десять предикторов, значения по оси X изменяются от 1 до 11, поскольку одна из переменных является категориальной и принимает три значения, что сопровождается созданием двух индикаторных переменных

Пример применения отбора оптимального подмножества предикторов показан на рис. 6.1. Каждая точка на этом рисунке соответствует регрессионной модели, которая была подождена по методу наименьших квадратов на основе определенного подмножества из 11 исходных предикторов, входящих в таблицу Credit (см. главу 3). Переменная *ethnicity* является качественной переменной с тремя уровнями, и поэтому она представлена двумя индикаторными переменными, которые в данном случае рассматриваются в качестве отдельных предикторов. Мы изобразили RSS и R^2 для каждой модели в зависимости от количества предикторов. Красная кривая соединяет точки, соответствующие оптимальным моделям каждого размера (согласно RSS и R^2). Как и следовало ожидать, рисунок показывает, что эти критерии качества улучшаются по мере увеличения

числа переменных; однако, начиная с модели с тремя переменными, добавление дополнительных предикторов сопровождается весьма незначительным улучшением RSS и R^2 .

Хотя мы описали отбор оптимального подмножества переменных для регрессии, рассчитываемой по методу наименьших квадратов, та же идея применима и к другим типам моделей, таким как логистическая регрессия. В случае с логистической регрессией на втором шаге алгоритма 6.1 для упорядочивания моделей мы используем не RSS , а *аномальность*² — показатель, который играет роль RSS для более широкого класса моделей. Аномальность равна минус двум максимизированным значениям логарифма правдоподобия; чем меньше аномальность, тем лучше модель описывает данные.

аномальность

Несмотря на то что отбор оптимального подмножества предикторов является простым и концептуально привлекательным методом, он страдает ограничениями вычислительного характера. Число подлежащих рассмотрению возможных моделей быстро возрастает при увеличении p . В целом существует 2^p моделей, включающих подмножества p предикторов. Так, при $p = 10$ рассмотрению подлежит примерно 1000 возможных моделей, а при $p = 20$ число таких моделей превышает миллион! Поэтому при $p > 40$ отбор оптимального подмножества предикторов становится невозможным из-за громадного объема вычислений, даже если используются быстрые современные компьютеры. Существуют более экономные способы вычислений (так называемые методы «ветвей и границ»)³, позволяющие исключать из рассмотрения некоторые модели, однако эти способы имеют свои ограничения при больших p . Кроме того, они работают только с линейной регрессией по методу наименьших квадратов. Далее мы рассмотрим более эффективные альтернативы отбору оптимального подмножества предикторов.

6.1.2 Пошаговый отбор

По причинам вычислительного характера, при очень большом p отбор оптимального подмножества предикторов неприменим. При большом p этот метод может также страдать от проблем статистического характера. Чем больше область поиска, тем выше вероятность нахождения моделей, которые хорошо предсказывают обучающие данные, несмотря на то что на будущих данных они могут не иметь никакой предсказательной силы. Поэтому огромная область поиска может приводить к переобучению и высокой дисперсии оценок коэффициентов.

По обеим этим причинам *пошаговые* методы, которые выполняют поиск среди намного меньшего числа моделей, являются привлекательными альтернативами отбору оптимального подмножества предикторов.

² В оригинале используется термин «deviance». Устойчивого перевода этого термина на русский язык не существует (помимо «аномальности», встречаются, например, «отклонение», «девианс», «девианса», «девиация»). В соответствии со словарем терминов, представленным на сайте Международного статистического института (ISI; <http://isi.cbs.nl/glossary/term933.htm>), здесь «deviance» переводится как «аномальность». — Прим. пер.

³ В оригинале используется термин «branch-and-bound techniques». — Прим. пер.